

Aprendizado de Máquina

Planejamento das Notas de Aula

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Estatística, Ciências Atuariais, Matemática Aplicada e Engenharia Matemática

September 14, 2026

Resumo

Este documento organiza todo o planejamento das notas de aula do curso. Ele mapeia as **aulas oficiais** (acompanhando a sequência consolidada dos slides do curso, numerados de 01 a 11) e as **aulas extras** (tópicos complementares de aprendizado não supervisionado e aplicações), associando cada aula aos respectivos capítulos dos dois livros-texto adotados. Para cada aula há um arquivo `.tex` próprio nesta pasta, contendo o roteiro detalhado do que deve ser dito em sala.

1 Livros-texto adotados

- [AME] Rafael Izbicki & Tiago Mendonça dos Santos. *Aprendizado de Máquina: Uma Abordagem Estatística*. Disponível on-line: <https://rafaelizbicki.com/ame/>.
- [ISLP] Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani & Jonathan Taylor. *An Introduction to Statistical Learning, with Applications in Python*. Disponível on-line: <https://www.statlearning.com/>.

Filosofia de uso dos dois livros. O [AME] é a espinha dorsal teórica: apresenta o aprendizado de máquina sob a ótica estatística (função de risco, viés-variância, garantias teóricas), com notação enxuta e tratamento unificado de regressão e classificação. O [ISLP] é a fonte de intuição, exemplos e implementação em Python (`scikit-learn`), além de fornecer figuras e conjuntos de dados clássicos. Nas notas, o esqueleto conceitual segue o [AME] e os exemplos/laboratórios seguem o [ISLP].

2 Estrutura geral do curso

O curso está organizado em três blocos:

- I. Fundamentos e Regressão** (Aulas 01–06): formalização do problema de aprendizado, regressão linear e regularização, seleção de modelos por validação cruzada, métodos não paramétricos (KNN, árvores, *ensembles*) e boas práticas de implementação (*pipelines*).
- II. Classificação** (Aulas 07–10): formulação do problema de classificação, classificadores gaussianos e logístico, métricas, SVM, KNN e árvores de classificação.
- III. Aprendizado não supervisionado e aplicações** (Aulas Extras): agrupamento (*k*-médias), redução de dimensionalidade (PCA, t-SNE) e uma aplicação de processamento de linguagem natural (NLP) à classificação.

Ao todo: **10 aulas oficiais + 3 aulas extras = 13 conjuntos de notas de aula**, mais este documento de planejamento.

3 Mapa das aulas

#	Aula	Tópicos principais	Leitura
Bloco I — Fundamentos e Regressão			
01	Introdução ao Aprendizado de Máquina	Notação e suposições; predição vs. inferência; as duas culturas; função de risco; super e subajuste; balanço viés–variância; <i>tuning parameters</i>	AME cap. 1; ISLP cap. 1–2
02	Regressão Linear e Regularização	Mínimos quadrados; além da linearidade; alta dimensão; seleção de subconjuntos e <i>step-wise</i> ; Lasso e Ridge; esparsidade; interpretação bayesiana	AME cap. 2–3; ISLP cap. 3, 6
03	Seleção de Modelos e Validação Cruzada	Estimação do risco; <i>data splitting</i> ; validação cruzada com k dobras; escolha de k ; <i>bootstrap</i>	AME §1.4–1.5; ISLP cap. 5
04	Métodos Não Paramétricos (KNN)	Séries ortogonais e <i>splines</i> (panorama); k vizinhos mais próximos; suavizadores lineares	AME §4.1–4.3; ISLP §3.5, 7.1–7.5
05	Árvores de Regressão e <i>Ensembles</i>	Árvores de regressão (construção e poda); agregação e redução de variância; <i>bagging</i> ; florestas aleatórias	AME §4.8–4.10; ISLP cap. 8
06	Pré-processamento e <i>Pipelines</i>	Padronização (<i>StandardScaler</i>); vazamento de dados (<i>data leakage</i>); construção de <i>pipelines</i> ; integração com validação cruzada	ISLP labs cap. 5–6; AME §2.1.2
Bloco II — Classificação			
07	Classificação e Classificadores Gaussianos	Formulação e função de risco 0–1; classificadores <i>plug-in</i> ; regressão logística; Bayes ingênuo; LDA e QDA	AME cap. 7, §8.1; ISLP cap. 4
08	Métricas para Classificação	Matriz de confusão; acurácia, precisão, <i>recall</i> , F_1 ; curva ROC e AUC; perdas assimétricas; dados desbalanceados; calibração	AME §7.4, cap. 9; ISLP §4.4–4.5

#	Aula	Tópicos principais	Leitura
09	Máquinas de Vetores de Suporte (SVM)	Classificador de margem máxima; <i>soft margin</i> ; o truque do <i>kernel</i> ; SVM com kernels; relação com regressão logística; multiclasse	AME §8.2, §4.6; ISLP cap. 9
10	KNN e Árvores de Classificação	KNN para classificação; árvores de classificação (índice de Gini, entropia); <i>ensembles</i> para classificação; comparação entre classificadores	AME §8.3–8.6; ISLP §4.7.6, cap. 8
Bloco III — Aulas Extras (Não supervisionado e Aplicações)			
E1	Análise de Agrupamento: <i>k</i> -Médias	Aprendizado não supervisionado; <i>k</i> -médias (algoritmo de Lloyd); inicialização e escolha de <i>k</i> ; agrupamento hierárquico (panorama)	AME cap. 11; ISLP §12.4
E2	Redução de Dimensionalidade (PCA e t-SNE)	Componentes principais (PCA); interpretação geométrica; proporção de variância explicada; aplicações (compressão); t-SNE para visualização	AME cap. 10; ISLP §12.2
E3	NLP + Classificação (Aplicação)	Limpeza e exploração de texto; <i>bag-of-words</i> / TF-IDF; classificação de <i>spam</i> ; avaliação das métricas no contexto de texto	Aplicação (notebook); AME §8.1.3

4 Aulas práticas e avaliações (contexto)

As notas de aula são teóricas; o curso conta ainda com material de apoio ao qual as notas fazem referência. Os **notebooks** ficam na pasta da própria aula, em **aulas/**, e os materiais transversais em **recursos/**:

- **Aulas práticas** (notebooks): uma por aula, **Aula prática NN.ipynb**, na pasta da própria aula. São laboratórios guiados, para acompanhar em sala: texto e código alternados, uma ideia por célula, mostrando o resultado em vez de deixá-lo em aberto — quem propõe exercício é a lista da mesma aula. Cada uma reproduz as simulações das figuras da nota correspondente, com os mesmos parâmetros e a mesma semente.
- **Listas de exercícios**, também uma por aula e na pasta da própria aula, para depois da aula:
 - **Lista teorica NN.tex/.pdf** — 2 a 4 exercícios de nível fácil a mediano, todos tratados igual. O gabarito sai do *mesmo* arquivo-fonte (**Lista teorica NN - gabarito.pdf**), o que impede que enunciado e solução divirjam;
 - **Lista prática NN.ipynb** — notebook com lacunas marcadas por ... para o aluno completar, acompanhado de **Lista prática NN - gabarito.ipynb**.

- **Exemplos** em Python, na pasta da aula correspondente: comparação de classificadores paramétricos (aula 07), SVM (09), KNN e árvores (10), k -médias (E1) e PCA (E2).
- As **avaliações do curso**, em `avaliacoes/`, na raiz: a **Lista de revisao 01-06** — treze exercícios inéditos de nível intermediário, cobrindo o Bloco I — e a **Avaliacao teorica 01**, cujas três questões foram *sorteadas* dessa lista, uma por aula. Como nas listas, o gabarito sai do mesmo arquivo-fonte do enunciado.
- As duas **avaliações presenciais** de 2025-02 (AP1 e AP2) com gabarito, herdadas, em `recursos/avaliacoes`.

5 Convenções das notas de aula

- Cada aula tem um arquivo `NN Título.tex` próprio, compilável a partir da pasta da própria aula. O preâmbulo é compartilhado: cada `.tex` carrega o estilo comum com `\usepackage{../../recursos/latex/estilo-notas}`, de modo que notação, ambientes de teorema e caixas pedagógicas ficam definidos em um único lugar.
- Estrutura padrão de cada nota: *objetivos da aula* $\rightarrow$ *motivação* $\rightarrow$ *desenvolvimento teórico* (definições, resultados, demonstrações quando cabível) $\rightarrow$ *intuições e exemplos* $\rightarrow$ *prática em Python* (referência ao notebook) $\rightarrow$ *resumo* e *leitura recomendada*.
- Notação unificada seguindo o [AME]: (X, Y) par aleatório, $r(x) = \mathbb{E}[Y \mid X = x]$ função de regressão, $g(x)$ classificador, $\mathcal{D} = \{(X_i, Y_i)\}_{i=1}^n$ amostra de treino, $R(\cdot)$ função de risco.
- Caixas de “*o que dizer em sala*” destacam o fio condutor do discurso e as perguntas a fazer aos alunos.