

# Aprendizado de Máquina

Planejamento das Notas de Aula

Curso de Aprendizado de Máquina — UFRJ  
Estatística, Ciências Atuariais, Matemática Aplicada e Engenharia Matemática

August 3, 2026

## Resumo

Este documento organiza todo o planejamento das notas de aula do curso. Ele mapeia as **aulas oficiais** (acompanhando a sequência consolidada dos slides do curso, numerados de 01 a 11) e as **aulas extras** (tópicos complementares de aprendizado não supervisionado e aplicações), associando cada aula aos respectivos capítulos dos dois livros-texto adotados. Para cada aula há um arquivo `.tex` próprio nesta pasta, contendo o roteiro detalhado do que deve ser dito em sala.

## 1 Livros-texto adotados

- [AME] Rafael Izbicki & Tiago Mendonça dos Santos. *Aprendizado de Máquina: Uma Abordagem Estatística*. Disponível on-line: <https://rafaelizbicki.com/ame/>.
- [ISLP] Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani & Jonathan Taylor. *An Introduction to Statistical Learning, with Applications in Python*. Disponível on-line: <https://www.statlearning.com/>.

**Filosofia de uso dos dois livros.** O [AME] é a espinha dorsal teórica: apresenta o aprendizado de máquina sob a ótica estatística (função de risco, viés-variância, garantias teóricas), com notação enxuta e tratamento unificado de regressão e classificação. O [ISLP] é a fonte de intuição, exemplos e implementação em Python (`scikit-learn`), além de fornecer figuras e conjuntos de dados clássicos. Nas notas, o esqueleto conceitual segue o [AME] e os exemplos/laboratórios seguem o [ISLP].

## 2 Estrutura geral do curso

O curso está organizado em três blocos:

- I. Fundamentos e Regressão** (Aulas 01–07): formalização do problema de aprendizado, regressão linear e regularização, seleção de modelos por validação cruzada, métodos não paramétricos (KNN, árvores, *ensembles*) e boas práticas de implementação (*pipelines*).
- II. Classificação** (Aulas 08–11): formulação do problema de classificação, classificadores gaussianos e logístico, métricas, SVM, KNN e árvores de classificação.
- III. Aprendizado não supervisionado e aplicações** (Aulas Extras): agrupamento (*k*-médias), redução de dimensionalidade (PCA, t-SNE) e uma aplicação de processamento de linguagem natural (NLP) à classificação.

Ao todo: **11 aulas oficiais + 3 aulas extras = 14 conjuntos de notas de aula**, mais este documento de planejamento.

### 3 Mapa das aulas

| #                                        | Aula                                        | Tópicos principais                                                                                                                                          | Leitura                          |
|------------------------------------------|---------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------|
| <b>Bloco I — Fundamentos e Regressão</b> |                                             |                                                                                                                                                             |                                  |
| 01                                       | Introdução ao Aprendizado de Máquina        | Notação e suposições; predição vs. inferência; as duas culturas; função de risco; super e subajuste; balanço viés–variância; <i>tuning parameters</i>       | AME cap. 1; ISLP cap. 1–2        |
| 02                                       | Regressão Linear e Regularização            | Mínimos quadrados; além da linearidade; alta dimensão; seleção de subconjuntos e <i>step-wise</i> ; Lasso e Ridge; esparsidade; interpretação bayesiana     | AME cap. 2–3; ISLP cap. 3, 6     |
| 03                                       | Seleção de Modelos e Validação Cruzada      | Estimação do risco; <i>data splitting</i> ; validação cruzada com $k$ dobras; escolha de $k$ ; <i>bootstrap</i>                                             | AME §1.5; ISLP cap. 5            |
| 04                                       | Métodos Não Paramétricos (KNN)              | Séries ortogonais e <i>splines</i> (panorama); $k$ vizinhos mais próximos; Nadaraya–Watson; regressão polinomial local                                      | AME §4.1–4.5; ISLP §3.5, 7.1–7.6 |
| 05                                       | Métodos Não Paramétricos: Aspectos Teóricos | Maldição da dimensionalidade; taxas de convergência; esparsidade e redundância; um pouco de teoria do KNN e séries ortogonais                               | AME §4.13, cap. 5                |
| 06                                       | Árvores de Regressão e <i>Ensembles</i>     | Árvores de regressão (construção e poda); <i>bagging</i> ; florestas aleatórias; importância de atributos; <i>boosting</i>                                  | AME §4.8–4.10; ISLP cap. 8       |
| 07                                       | Pré-processamento e <i>Pipelines</i>        | Padronização ( <code>StandardScaler</code> ); vazamento de dados ( <i>data leakage</i> ); construção de <i>pipelines</i> ; integração com validação cruzada | ISLP labs cap. 5–6; AME §2.1.2   |
| <b>Bloco II — Classificação</b>          |                                             |                                                                                                                                                             |                                  |
| 08                                       | Classificação e Classificadores Gaussianos  | Formulação e função de risco 0–1; classificadores <i>plug-in</i> ; regressão logística; Bayes ingênuo; LDA e QDA                                            | AME cap. 7, §8.1; ISLP cap. 4    |

| #                                                                 | Aula                                      | Tópicos principais                                                                                                                                 | Leitura                             |
|-------------------------------------------------------------------|-------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------|
| 09                                                                | Métricas para Classificação               | Matriz de confusão; acurácia, precisão, <i>recall</i> , $F_1$ ; curva ROC e AUC; perdas assimétricas; dados desbalanceados; calibração             | AME §7.4, cap. 9; ISLP §4.4–4.5     |
| 10                                                                | Máquinas de Vetores de Suporte (SVM)      | Classificador de margem máxima; <i>soft margin</i> ; o truque do <i>kernel</i> ; SVM com kernels; relação com regressão logística; multiclasse     | AME §8.2, §4.6; ISLP cap. 9         |
| 11                                                                | KNN e Árvores de Classificação            | KNN para classificação; árvores de classificação (índice de Gini, entropia); <i>ensembles</i> para classificação; comparação entre classificadores | AME §8.3, §8.6; ISLP §4.7.6, cap. 8 |
| <b>Bloco III — Aulas Extras (Não supervisionado e Aplicações)</b> |                                           |                                                                                                                                                    |                                     |
| E1                                                                | Análise de Agrupamento: $k$ -Médias       | Aprendizado não supervisionado; $k$ -médias (algoritmo de Lloyd); inicialização e escolha de $k$ ; agrupamento hierárquico (panorama)              | AME cap. 11; ISLP §12.4             |
| E2                                                                | Redução de Dimensionalidade (PCA e t-SNE) | Componentes principais (PCA); interpretação geométrica; proporção de variância explicada; aplicações (compressão); t-SNE para visualização         | AME cap. 10; ISLP §12.2             |
| E3                                                                | NLP + Classificação (Aplicação)           | Limpeza e exploração de texto; <i>bag-of-words</i> / TF-IDF; classificação de <i>spam</i> ; avaliação das métricas no contexto de texto            | Aplicação (notebook); AME §8.1.3    |

## 4 Aulas práticas e avaliações (contexto)

As notas de aula são teóricas; o curso conta ainda com material de apoio ao qual as notas fazem referência. Os **notebooks** ficam na pasta da própria aula, em **aulas/**, e os materiais transversais em **recursos/**:

- **Aulas práticas** (notebooks): 01, 02, 03–05, 06–07 e 08, alinhadas às aulas teóricas correspondentes e guardadas na pasta da primeira aula que cada uma cobre (01-introducao, 02-regressao-linear, 03-validacao-cruzada, 06-arvores-ensembles e 08-classificadores-gau). As práticas 01 e 02 seguem a conduta dos laboratórios do [ISLP]: texto e código alternados, uma ideia por célula, com blocos “Sua vez” para exercício em sala.
- **Exemplos** em Python, na pasta da aula correspondente: comparação de classificadores paramétricos (aula 08), SVM (10), KNN e árvores (11),  $k$ -médias (E1), PCA (E2) e NLP (E3).

- **Listas de exercícios** 01–08, em `recursos/listas`, e duas **avaliações presenciais** (AP1 e AP2) com gabarito, em `recursos/avaliacoes`.

## 5 Convenções das notas de aula

- Cada aula tem um arquivo `NN Título.tex` próprio, compilável a partir da pasta da própria aula. O preâmbulo é compartilhado: cada `.tex` carrega o estilo comum com `\usepackage{../../recursos/latex/estilo-notas}`, de modo que notação, ambientes de teorema e caixas pedagógicas ficam definidos em um único lugar.
- Estrutura padrão de cada nota: *objetivos da aula*  $\rightarrow$  *motivação*  $\rightarrow$  *desenvolvimento teórico* (definições, resultados, demonstrações quando cabível)  $\rightarrow$  *intuições e exemplos*  $\rightarrow$  *prática em Python* (referência ao notebook)  $\rightarrow$  *resumo* e *leitura recomendada*.
- Notação unificada seguindo o [AME]:  $(X, Y)$  par aleatório,  $r(x) = \mathbb{E}[Y \mid X = x]$  função de regressão,  $g(x)$  classificador,  $\mathcal{D} = \{(X_i, Y_i)\}_{i=1}^n$  amostra de treino,  $R(\cdot)$  função de risco.
- Caixas de “*o que dizer em sala*” destacam o fio condutor do discurso e as perguntas a fazer aos alunos.