

Aula 01 — Introdução ao Aprendizado de Máquina

Curso de Aprendizado de Máquina — UFRJ

Leitura recomendada: AME cap. 1; ISLP cap. 1–2

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- enunciar o problema de aprendizado supervisionado e distinguir *regressão* de *classificação*;
- escrever a função de regressão $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ e justificá-la como solução do problema de predição sob perda quadrática;
- diferenciar os objetivos de *predição* e de *inferência* e relacionar isso às “duas culturas” da modelagem estatística;
- definir *risco* e *risco empírico* e explicar por que minimizar o risco empírico no treino não basta;
- explicar *super* e *subajuste* e a decomposição *viés-variância*;
- identificar o papel dos *tuning parameters* no controle da complexidade.

Esta é a aula que fixa a **linguagem** de todo o curso, então vale ir devagar na notação: tudo o que vier depois — regressão linear, KNN, árvores, SVM, classificação — é caso particular do arcabouço montado aqui. Comece pela pergunta que a aula inteira responde:

o que significa, exatamente, dizer que um modelo “aprendeu”?

Guarde o seu palpite. Na Seção 4 teremos uma definição precisa, e ela provavelmente não vai coincidir com a intuição de “acertar os dados que eu já tenho”.

1 O que é aprendizado de máquina?

Aprendizado de máquina (AM) nasceu nos anos 1960 como ramo da inteligência artificial voltado a *aprender padrões a partir de dados*. A partir do final dos anos 1990 a área se consolidou e passou a ter forte interseção com a estatística. Neste curso adotamos a **ótica estatística** do [AME]: tratamos os dados como realizações de variáveis aleatórias e usamos probabilidade e inferência para entender *quando* e *por que* um método funciona.

Trabalhamos em três grandes cenários:

Supervisionado

observamos pares $(\mathbf{x}, y)$ (covariáveis e rótulo) e queremos prever y a partir de $\mathbf{x}$. Subdivide-se em *regressão* (Y quantitativo) e *classificação* (Y qualitativo).

Não supervisionado

observamos apenas $\mathbf{x}$ (sem rótulos) e buscamos estrutura: agrupamento, redução de dimensionalidade, associação.

Por reforço um agente aprende por tentativa e erro interagindo com um ambiente (fora do escopo deste curso).

A maior parte do curso é sobre aprendizado supervisionado; o aprendizado não supervisionado aparece nas aulas extras (k -médias, PCA).

Atenção: um erro de tradução que confunde muita gente

Y *quantitativa* $\Rightarrow$ problema de **regressão**. Y *qualitativa* $\Rightarrow$ problema de **classificação**. Na dúvida, pergunte se faz sentido calcular a *média* da resposta: faz sentido falar em “temperatura média” (regressão), não faz sentido em “e-mail médio entre spam e não-spam” (classificação).

2 Notação e suposições

Seja $Y \in \mathbb{R}$ a **variável resposta** (também: variável dependente, rótulo, *label*) e $\mathbf{x} = (x_1, \dots, x_d) \in \mathbb{R}^d$ o vetor de **covariáveis** (também: atributos, preditores, *features*, variáveis explicativas). O objetivo central da Parte I do [AME] é estimar a **função de regressão**

$$r(\mathbf{x}) := \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]. \quad (1)$$

Quando Y é quantitativo, temos um problema de **regressão**; quando Y é qualitativo, um problema de **classificação**.

Definição 2.1 (Amostra de treino). Salvo menção em contrário, supomos uma amostra i.i.d. $\mathcal{D} = \{(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)\}$, com $(\mathbf{X}_i, Y_i) \sim (\mathbf{X}, Y)$, de uma distribuição conjunta P desconhecida. Denotamos por $x_{i,j}$ o valor da j -ésima covariável na i -ésima observação, $\mathbf{X}_i = (x_{i,1}, \dots, x_{i,d})$.

Vale a pena visualizar os dados como uma tabela, que é literalmente o formato em que eles chegam num arquivo `.csv`: cada *linha* é uma observação, cada *coluna* é uma covariável, e a última coluna é a resposta.

Resposta	Covariáveis			
Y_1	$x_{1,1}$	$x_{1,2}$	$\cdots$	$x_{1,d}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$
Y_n	$x_{n,1}$	$x_{n,2}$	$\cdots$	$x_{n,d}$

Aqui n é o *número de observações* e d o *número de covariáveis*. Boa parte das dificuldades do curso aparece quando d cresce em relação a n — uma tabela mais larga do que alta. Voltaremos a isso já na Aula 02.

Atenção

A suposição i.i.d. é forte e nem sempre razoável (séries temporais, dados espaciais, vies de seleção, *dataset shift*). Voltaremos a isso na Aula 09; por ora ela é o nosso “mundo ideal”. A distribuição P é *fixa* mas *desconhecida*: é a fonte de toda a incerteza.

3 Por que estimar a função de regressão? Predição versus inferência

Há duas razões distintas para estimar r :

- **Predição.** Queremos um bom palpite $\hat{r}(\mathbf{x})$ para o Y de uma nova observação com covariáveis $\mathbf{x}$. Aqui $\hat{r}$ pode ser uma “caixa-preta”: interessa o *acerto*, não a forma.
- **Inferência.** Queremos *entender* a relação entre $\mathbf{X}$ e Y : quais covariáveis importam, qual o sinal e a magnitude do efeito, há interações? Aqui interessa a *interpretabilidade* do modelo.

Quatro exemplos do [AME] deixam a diferença concreta:

Exemplo 3.1 (Expectativa de vida e PIB per capita). Para 211 países, Y é a expectativa de vida e x o PIB per capita. Estimar $\mathbb{E}[Y \mid x]$ serve tanto para *prever* a expectativa de vida de um país cujo PIB conhecemos quanto para *testar* se existe relação entre as duas variáveis. Objetivo misto.

Exemplo 3.2 (Distância de uma galáxia até a Terra). O *redshift* de uma galáxia mede sua distância. A espectroscopia o determina com precisão, mas é cara e lenta. A alternativa é estimar $r(\mathbf{x})$ tomando $\mathbf{X}_i$ como a *imagem* da i -ésima galáxia. Aqui a relação entre cada pixel e a resposta não interessa a ninguém: objetivo puramente **preditivo**.

Exemplo 3.3 (Direção do olhar a partir de uma foto). No *Isomap face data*, Y é a direção para a qual a pessoa olha e $\mathbf{x}$ é a imagem do rosto. De novo, puramente preditivo.

Exemplo 3.4 (Ano de lançamento de músicas). No *YearPredictionMSD*, $\mathbf{x}$ traz timbre, “energia”, “dançabilidade” etc. e Y é o ano de lançamento. Queremos (i) prever o ano e (ii) entender como o perfil das músicas mudou — por exemplo, os anos 70 eram mais dançáveis? Objetivo misto.

Ideia central

Por que $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ é o alvo “certo” para predição? Porque, sob a perda quadrática, a função que minimiza o erro esperado de predição é exatamente a esperança condicional.

Proposição 3.5 (r minimiza o erro quadrático esperado). *Entre todas as funções $g : \mathbb{R}^d \rightarrow \mathbb{R}$, a função de regressão $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ minimiza o erro quadrático esperado $\mathbb{E}[(Y - g(\mathbf{X}))^2]$.*

Demonstração. Fixe $\mathbf{x}$ e escreva $\mathbb{E}[(Y - g(\mathbf{X}))^2 \mid \mathbf{X} = \mathbf{x}]$. Somando e subtraindo $r(\mathbf{x})$,

$$\mathbb{E}[(Y - g(\mathbf{x}))^2 \mid \mathbf{X} = \mathbf{x}] = \mathbb{E}[(Y - r(\mathbf{x}))^2 \mid \mathbf{X} = \mathbf{x}] + (r(\mathbf{x}) - g(\mathbf{x}))^2,$$

pois o termo cruzado se anula: $\mathbb{E}[(Y - r(\mathbf{x}))(r(\mathbf{x}) - g(\mathbf{x})) \mid \mathbf{X} = \mathbf{x}] = (r(\mathbf{x}) - g(\mathbf{x})) \mathbb{E}[Y - r(\mathbf{x}) \mid \mathbf{X} = \mathbf{x}] = 0$. O primeiro termo não depende de g e o segundo é minimizado (zerado) por $g(\mathbf{x}) = r(\mathbf{x})$. Tomando esperança sobre $\mathbf{X}$, segue o resultado. $\square$

Vale destrinchar o passo que faz a conta funcionar, porque ele reaparece o curso inteiro. O termo cruzado se anula porque, *dado* $\mathbf{X} = \mathbf{x}$, a quantidade $r(\mathbf{x}) - g(\mathbf{x})$ é uma **constante** — ela sai da esperança — e o que sobra é $\mathbb{E}[Y - r(\mathbf{x}) \mid \mathbf{X} = \mathbf{x}] = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}] - r(\mathbf{x}) = 0$, pela própria definição (1) de r . Em palavras: *o erro que resta depois de acertar a média condicional não tem correlação com nada que dependa só de $\mathbf{x}$* . É a mesma ideia de uma projeção ortogonal.

Observação 3.6. A decomposição acima já contém a semente do *erro irreduzível*: mesmo conhecendo r perfeitamente, resta $\mathbb{E}[(Y - r(\mathbf{X}))^2] = \mathbb{E}[\text{Var}(Y \mid \mathbf{X})] > 0$ em geral, pois Y não é função determinística de $\mathbf{X}$.

3.1 As duas culturas

Leo Breiman (2001) descreveu duas posturas de modelagem:

- **Cultura dos modelos de dados:** supõe-se um modelo estocástico (por exemplo, linear gaussiano) e o foco é estimar e interpretar seus parâmetros. Testar as suposições (normalidade, linearidade, homocedasticidade) é parte central do trabalho. Tradição estatística clássica.

- **Cultura dos modelos algorítmicos:** trata-se o mecanismo gerador como desconhecido e busca-se uma função preditora com bom desempenho (florestas, *boosting*, redes). Muitas vezes não há modelo probabilístico explícito por trás. Tradição de AM.

O [AME] — e este curso — fica majoritariamente na segunda: buscamos estimar $r(\mathbf{x})$ *sem supor* que nossos modelos contêm a verdadeira função de regressão. Mas usamos a teoria estatística da primeira para *avaliar* os métodos da segunda.

Um exemplo ajuda a sentir a diferença de objetivo. Comparar a previsão de demanda de energia (predição pura: ninguém precisa entender o modelo, só acertar o número) com a avaliação do efeito de um medicamento (inferência: o número sozinho não serve, é preciso saber *o quanto* e *por quê*). Pergunte-se: em qual desses um modelo caixa-preta altamente preciso seria *inaceitável*? A resposta explica por que interpretabilidade é um requisito, e não um capricho, em várias áreas.

4 A função de risco

Para comparar candidatos a preditor precisamos de um critério de qualidade. Dado uma **função de perda** $L(y, \hat{y}) \geq 0$, definimos o risco.

Definição 4.1 (Risco). O **risco** (ou erro de generalização) de uma função g é

$$R(g) = \mathbb{E}[L(Y, g(\mathbf{X}))], \quad (2)$$

a perda esperada sobre uma observação *nova* $(\mathbf{X}, Y) \sim P$.

Em regressão usamos tipicamente a perda quadrática $L(y, \hat{y}) = (y - \hat{y})^2$, e então $R(g) = \mathbb{E}[(Y - g(\mathbf{X}))^2]$. Pela Proposição 3.5, r é o *minimizador* do risco. A decomposição fundamental do risco de g é

$$R(g) = \underbrace{\mathbb{E}[(g(\mathbf{X}) - r(\mathbf{X}))^2]}_{\text{excesso de risco}} + \underbrace{\mathbb{E}[\text{Var}(Y | \mathbf{X})]}_{\text{erro irreduzível}}, \quad (3)$$

que é exatamente a conta da Proposição 3.5 escrita de outro jeito (Teorema 1 do [AME]). A leitura é: *o risco de g se parte na distância entre g e o alvo r , que depende de você, mais um piso que não depende de ninguém.*

Atenção

Aqui está a resposta à pergunta da abertura. Um modelo **não** “aprendeu” quando acerta os dados que já viu — ele aprendeu quando tem **risco baixo**, e risco é uma esperança sobre observações *que ele nunca viu*. Toda a dificuldade do curso vem daí: P é desconhecida, então $R(g)$ é uma quantidade *teórica* que precisamos *estimar*. É o tema da Aula 03.

4.1 Risco empírico

O estimador natural do risco, dado um conjunto de dados $\{(\mathbf{X}_i, Y_i)\}$, é a média das perdas:

$$\hat{R}(g) = \frac{1}{n} \sum_{i=1}^n L(Y_i, g(\mathbf{X}_i)). \quad (4)$$

Se calculado *nos mesmos dados usados para treinar* g , ele subestima sistematicamente o risco — daí a necessidade de dados de teste/validação. A razão é simples quando dita em voz alta: g foi *escolhida* para ir bem justamente naqueles pontos. Medir o desempenho ali é como corrigir a prova com o gabarito que o próprio aluno escreveu.

Se, em vez disso, $\hat{R}$ for calculado num conjunto de **teste** de tamanho m que não participou de nada, ele é uma média de m variáveis i.i.d. e o Teorema Central do Limite dá até uma barra de erro:

$$\hat{R}(g) \pm 2\sqrt{\hat{\sigma}^2/m}, \quad \hat{\sigma}^2 = \frac{1}{m} \sum_{k=1}^m (W_k - \bar{W})^2, \quad W_k = (Y_k - g(\mathbf{X}_k))^2, \quad (5)$$

um intervalo de confiança aproximado de 95% para $R(g)$. Isso é mais útil do que parece: dois modelos cujos intervalos se sobrepõem largamente *não* foram distinguidos pelo seu conjunto de teste, por mais que um deles tenha ficado com o número menor. E note a consequência de projeto: como o erro do intervalo cai com $\sqrt{m}$, estimar o risco é uma tarefa muito mais barata do que construir um bom preditor — com n grande, dá para reservar bem menos que 30% para teste.

Observação 4.2 (Risco condicional e risco esperado). Há uma sutileza na Equação (2). Se g é tratada como *fixa*, a esperança é só sobre a nova observação $(\mathbf{X}, Y)$ e temos o **risco condicional**: uma garantia sobre *aquela* função. Se tratamos $g = \hat{g}$ como aleatória (ela é função dos dados de treino), a esperança também percorre todas as amostras possíveis e temos o **risco esperado**: uma garantia sobre o *procedimento* que gerou $\hat{g}$, não sobre o resultado de uma rodada específica. Usaremos os dois conforme o contexto; a decomposição viés-variância da Seção 5.2, por exemplo, é sobre o risco esperado.

5 Seleção de modelos: super e subajuste

Um método de AM em geral define uma **classe de funções** $\mathcal{H}$ (a “flexibilidade” do modelo) e escolhe dentro dela aquela que melhor ajusta os dados. Há uma tensão:

- **Subajuste (*underfitting*):** $\mathcal{H}$ é simples demais para capturar r . Erro de treino *e* de teste altos. Modelo “enviesado”.
- **Superajuste (*overfitting*):** $\mathcal{H}$ é flexível demais e ajusta o ruído da amostra. Erro de treino baixo, erro de teste alto. Modelo “variável”.

Para ver isso acontecer, vamos fabricar um problema em que a resposta é conhecida. Tome $X \sim \text{Unif}(-3, 3)$ e

$$Y = \underbrace{\text{sen}(1,5X) + 0,3X}_{r(x)} + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2), \quad \sigma = 0,7. \quad (6)$$

Como *nós* inventamos a população, sabemos que r é aquela e que o erro irreduzível vale $\sigma^2 = 0,49$. Sorteamos $n = 50$ pontos de treino e ajustamos polinômios de graus crescentes. A Figura 1 mostra três deles.

Repetindo isso para cada grau e medindo os dois erros, obtemos o comportamento típico: o erro de treino cai monotonicamente, mas o risco tem forma de “U” — existe um ponto de complexidade ótima (Figura 2).

Duas leituras que valem mais do que parecem à primeira vista:

- **O erro de treino fura o σ^2 .** A partir do grau 3 ele fica abaixo de 0,49, que é o menor risco alcançável por *qualquer* função. Nenhum preditor pode ser tão bom assim; o que ele está fazendo é ajustar o ruído daquela amostra específica.
- **O risco nunca desce abaixo de σ^2 .** A linha tracejada é um piso intransponível. Se o seu erro de teste chegar perto dele, você está no limite do problema, não do método — procurar um modelo melhor é perda de tempo.




Figura 1: Três ajustes sobre *a mesma* amostra de $n = 50$ pontos. O grau 1 é rígido demais para acompanhar a curvatura de r (subajuste). O grau 15 passa perto de quase todos os pontos, inclusive perseguindo o ruído, e oscila onde r é suave (superajuste). O grau 5 acerta o essencial.




Figura 2: Erro de treino e risco em função do grau, médias sobre 400 amostras de treino da população (6). O erro de treino cai sempre e chega a *furar* o piso σ^2 — sinal inequívoco de que está medindo ruído, não sinal. O risco desce, atinge o mínimo no grau 5 e volta a subir; no grau 12 já vale 79, mais de 160 vezes o mínimo.

Atenção: o que “superajuste” quer dizer, exatamente

O [ISLP] é preciso aqui, e a precisão importa: superajuste é o caso em que **um modelo menos flexível teria dado um risco menor**. Não é sinônimo de “erro de treino menor que o de teste” — isso acontece quase sempre, com ou sem superajuste, porque quase todo método minimiza direta ou indiretamente o erro de treino.

O quanto o “U” é profundo depende de quão longe r está da classe de modelos que você usa. Se r for quase linear, o mínimo aparece cedo e o lado direito sobe rápido; se r for muito não linear, o erro despenca bastante antes de voltar a subir. A forma geral, porém, é sempre a mesma.

5.1 Um exemplo que contraria a intuição

Poderia parecer que, sabendo a forma correta do modelo, o melhor a fazer é ajustá-la. Não é bem assim, e o [AME] traz um exemplo simulado que convém guardar. Gere dados com

$$Y | \mathbf{x} \sim N(\beta^\top \mathbf{x}, 1), \quad \beta = (0, 3, 2, 0,2, 0,1, 0,1), \quad \mathbf{x} = (1, x, x^2, \dots, x^5),$$

ou seja, a regressão verdadeira é um polinômio de grau 5. Ajuste dois modelos: um polinômio de grau 5 (especificação correta) e um de grau 2 (incorreta). Repetindo o experimento para 1000 conjuntos de treino, o modelo de **grau 2** teve risco esperado menor — e ganhou do modelo correto em **97,8%** das amostras.

Ideia central

Especificar o modelo corretamente **não** garante melhor poder preditivo. Os três últimos coeficientes de β são minúsculos (0,2, 0,1, 0,1): o ganho de viés ao incluí-los é desprezível perto do custo de *estimá-los*. O modelo errado, porém mais simples, tem variância bem menor e sai na frente.

Essa é a diferença de mentalidade entre a estatística inferencial clássica — em que se busca um estimador não viesado — e a inferência preditiva, em que se aceita viés de bom grado desde que a variância caia mais do que o viés sobe.

Observação 5.1. Uma ressalva honesta: interpolar os dados não implica necessariamente superajustar. Redes neurais muito grandes frequentemente interpolam o treino e ainda assim generalizam bem, um fenômeno conhecido como *descida dupla* (Belkin et al., 2019). A curva em “U” é a regra para os métodos deste curso, não uma lei da natureza.

5.2 O balanço entre viés e variância

Considere um estimador $\hat{r}$ construído a partir da amostra aleatória $\mathcal{D}$. Em um ponto fixo $\mathbf{x}_0$, sob perda quadrática, vale a decomposição clássica:

$$\mathbb{E}_{\mathcal{D}}[(Y_0 - \hat{r}(\mathbf{x}_0))^2] = \underbrace{(\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0)] - r(\mathbf{x}_0))^2}_{\text{viés}^2} + \underbrace{\text{Var}_{\mathcal{D}}(\hat{r}(\mathbf{x}_0))}_{\text{variância}} + \underbrace{\sigma^2(\mathbf{x}_0)}_{\text{irreduzível}}, \quad (7)$$

onde Y_0 é uma resposta nova em $\mathbf{x}_0$ e $\sigma^2(\mathbf{x}_0) = \text{Var}(Y | \mathbf{X} = \mathbf{x}_0)$.

Teorema 5.2 (Decomposição viés-variância). *Vale a identidade (7).*

Demonstração. Escreva $Y_0 - \hat{r}(\mathbf{x}_0) = (Y_0 - r(\mathbf{x}_0)) + (r(\mathbf{x}_0) - \hat{r}(\mathbf{x}_0))$. O primeiro parêntese tem média zero e variância $\sigma^2(\mathbf{x}_0)$ e é independente de $\mathcal{D}$. Para o segundo, some e subtraia $\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0)]$ e expanda o quadrado; o termo cruzado se anula porque $\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0) - \mathbb{E}_{\mathcal{D}}\hat{r}(\mathbf{x}_0)] = 0$. Reagrupando os três quadrados obtém-se (7). $\square$

Cada termo tem um significado que vale nomear:

Viés o erro que você comete por aproximar um problema complicado com um modelo mais simples. Uma reta ajustada a uma senoide erra *em média*, por mais dados que você colete.

Variância o quanto $\hat{r}$ mudaria se você tivesse sorteado *outra* amostra de treino do mesmo tamanho. Um polinômio de grau 15 sobre 50 pontos muda radicalmente de uma amostra para a outra; uma reta quase não muda.

Irreduzível o ruído de Y em torno de r . Não depende do que você faça.

A Figura 3 mede os três termos na população (6) e confirma a identidade numericamente.




Figura 3: Os três termos de (7) em função do grau, sobre 500 amostras de treino. O viés² desaba (do grau 5 em diante o polinômio já reproduz r); a variância sobe sem parar; σ^2 é constante. A faixa cinza é a soma dos três, e os triângulos pretos são o risco medido *à parte*, sem usar a decomposição: eles caem exatamente sobre a faixa. A identidade fecha com folga máxima de 2×10^{-16} , ou seja, na precisão da máquina.

Ideia central

Modelos *flexíveis* têm baixo viés e alta variância; modelos *rígidos* têm alto viés e baixa variância. Selecionar um modelo é, em essência, **escolher o ponto do balanço viés–variância** que minimiza o risco. Não dá para zerar os dois ao mesmo tempo com n finito.

E por que o mínimo existe? Porque as duas curvas não mudam no mesmo ritmo: no começo, aumentar a flexibilidade derruba o viés *mais rápido* do que levanta a variância, e o risco cai. A partir de certo ponto o viés já está perto de zero e não há mais nada a ganhar, mas a variância continua subindo — e o risco volta a crescer. O “U” da Figura 2 é a soma dessas duas corridas em ritmos diferentes.

Atenção

Na Figura 3 pudemos calcular viés e variância porque *inventamos* a população e conhecemos r . Num problema real isso é impossível: r é justamente o que não sabemos. A decomposição

é uma ferramenta de *raciocínio* — serve para você prever em que direção mexer — e não um diagnóstico que se roda nos dados.

6 Tuning parameters

A flexibilidade de um método costuma ser controlada por um ou mais **hiperparâmetros** (*tuning parameters*), que *não* são estimados junto com o ajuste, mas escolhidos “por fora”. No exemplo desta aula, o hiperparâmetro é o grau do polinômio, e a Figura 2 é literalmente o gráfico do risco em função dele. Exemplos que veremos:

Método	Hiperparâmetro	Efeito de aumentá-lo
Regressão polinomial	grau do polinômio	mais flexível ($\uparrow$ variância)
Lasso / Ridge	λ (penalização)	mais rígido ($\uparrow$ viés)
k vizinhos (KNN)	k	mais rígido ($\uparrow$ viés)
Árvore	profundidade / α de poda	(depende do parâmetro)

A escolha desses parâmetros é um problema de *seleção de modelos*, resolvido estimando o risco para vários valores e tomando o melhor — tema central da Aula 03.

Atenção

Hiperparâmetros devem ser escolhidos *sem olhar o conjunto de teste*. Usar o teste para escolher λ ou k e depois reportar o erro nesse mesmo teste é uma forma de vazamento de dados (*data leakage*) que infla o desempenho. A divisão em *três* partes — treino, validação e teste — existe exatamente para isso: o treino ajusta, a validação escolhe o hiperparâmetro, e o teste, tocado uma única vez no fim, estima o risco do vencedor.

Uma alternativa: penalização

Nem sempre é preciso separar dados para estimar o risco. Como o erro de treino subestima o risco tanto mais quanto mais parâmetros o modelo tem, pode-se *corrigi-lo* somando uma medida de complexidade:

$$R(g) \approx \text{EQM}(g) + P(g), \quad P(g) = \frac{2p\hat{\sigma}^2}{n} \text{ (AIC)}, \quad P(g) = \frac{\log(n)p\hat{\sigma}^2}{n} \text{ (BIC)},$$

com p o número de parâmetros de g . A lógica é a de uma gangorra: com muitos parâmetros o EQM é baixo mas $P(g)$ é alto; com poucos, o contrário. Nas notas do [AME] os modelos escolhidos por AIC e por validação cruzada acabam bem próximos. Neste curso privilegiamos a validação cruzada, que não depende de contar parâmetros — uma vantagem e tanto quando o método nem tem parâmetros para contar, como o KNN.

7 Prática em Python

O notebook Aula prática 01 refaz, célula a célula, tudo o que esta aula descreve: constrói a população (6), verifica que r minimiza o risco, mostra o otimismo do erro de treino, levanta a curva em “U” e fecha a decomposição viés-variância. Ele também cobre o ambiente de trabalho (`numpy`, `pandas`, `matplotlib`) para quem está chegando agora.

O esqueleto de uma análise supervisionada, que repetiremos o curso inteiro:

```

1 from sklearn.model_selection import train_test_split
2 from sklearn.metrics import mean_squared_error
3
4 # 1. separar treino e teste (NUNCA tocar no teste durante o ajuste)
5 X_tr, X_te, y_tr, y_te = train_test_split(X, y, test_size=0.3, random_state=0)
6
7 # 2. ajustar o modelo no treino
8 modelo.fit(X_tr, y_tr)
9
10 # 3. avaliar o RISCO estimado no teste
11 y_hat = modelo.predict(X_te)
12 print(mean_squared_error(y_te, y_hat)) # estimativa de  $R(g)$ 

```

As três linhas correspondem exatamente aos três conceitos desta aula: a classe $\mathcal{H}$ (escolhida ao instanciar `modelo`), o risco empírico (4) minimizado por `fit`, e o risco (2) estimado no teste. Se essa correspondência estiver clara, a aula cumpriu seu papel.

Resumo

- O alvo da regressão é $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$, minimizador do risco quadrático (Prop. 3.5).
- *Predição* (acerto) e *inferência* (entendimento) são objetivos distintos — as “duas culturas”.
- *Risco* é perda esperada sob P (desconhecida); o *risco empírico* no treino é otimista. “Aprender” é ter risco baixo, não erro de treino baixo.
- Flexibilidade demais $\Rightarrow$ superajuste; de menos $\Rightarrow$ subajuste. O erro de teste tem forma de “U” (Fig. 2), com piso em σ^2 .
- *Viés–variância* (Teo. 5.2) formaliza esse balanço (Fig. 3). Acertar a especificação do modelo não garante predizer melhor.
- *Tuning parameters* controlam a complexidade e são escolhidos por seleção de modelos (Aula 03), *nunca* olhando o teste.

Leitura recomendada. [AME] Capítulo 1 inteiro — em especial §1.2 (os quatro exemplos), o Teorema 1 em §1.4, o Exemplo 1.7 em §1.5 (o modelo correto que prediz pior) e §1.5.2 (viés–variância). [ISLP] Capítulos 1 e 2, em particular §2.1 (*What is statistical learning*) e §2.2 (*Assessing model accuracy*, com as Figuras 2.9–2.12, que são a versão deles das nossas Figuras 2 e 3).