

Aula 01 — Introdução ao Aprendizado de Máquina

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME cap. 1; ISLP cap. 1–2

Objetivos da aula

Ao final desta aula o aluno deve ser capaz de:

- enunciar o problema de aprendizado supervisionado e distinguir *regressão* de *classificação*;
- escrever a função de regressão $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ e justificá-la como solução do problema de predição sob perda quadrática;
- diferenciar os objetivos de *predição* e de *inferência* e relacionar isso às “duas culturas” da modelagem estatística;
- definir *risco* e *risco empírico* e explicar por que minimizar o risco empírico no treino não basta;
- explicar *super* e *subajuste* e a decomposição *viés-variância*;
- identificar o papel dos *tuning parameters* no controle da complexidade.

Em sala

Esta é a aula que fixa a **linguagem** de todo o curso. Vale ir devagar na notação: tudo o que vier depois (regressão linear, KNN, árvores, SVM, classificação) é um caso particular do arcabouço montado aqui. Pergunta de abertura para a turma: “*o que significa, exatamente, dizer que um modelo ‘aprendeu’?*”

1 O que é aprendizado de máquina?

Aprendizado de máquina (AM) nasceu nos anos 1960 como ramo da inteligência artificial voltado a *aprender padrões a partir de dados*. A partir do final dos anos 1990 a área se consolidou e passou a ter forte interseção com a estatística. Neste curso adotamos a **ótica estatística** do [AME]: tratamos os dados como realizações de variáveis aleatórias e usamos probabilidade e inferência para entender *quando* e *por que* um método funciona.

Trabalhamos em três grandes cenários:

Supervisionado

observamos pares $(\mathbf{x}, y)$ (covariáveis e rótulo) e queremos prever y a partir de $\mathbf{x}$. Subdivide-se em *regressão* (Y quantitativo) e *classificação* (Y qualitativo).

Não supervisionado

observamos apenas $\mathbf{x}$ (sem rótulos) e buscamos estrutura: agrupamento, redução de dimensionalidade, associação.

Por reforço um agente aprende por tentativa e erro interagindo com um ambiente (fora do escopo deste curso).

A maior parte do curso é sobre aprendizado supervisionado; o aprendizado não supervisionado aparece nas aulas extras (k -médias, PCA).

2 Notação e suposições

Seja $Y \in \mathbb{R}$ a **variável resposta** (também: variável dependente, rótulo, *label*) e $\mathbf{x} = (x_1, \dots, x_p) \in \mathbb{R}^p$ o vetor de **covariáveis** (também: atributos, preditores, *features*, variáveis explicativas). O objetivo central da Parte I do [AME] é estimar a **função de regressão**

$$r(\mathbf{x}) := \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]. \quad (1)$$

Quando Y é quantitativo, temos um problema de **regressão**; quando Y é qualitativo, um problema de **classificação**.

Definição 2.1 (Amostra de treino). Salvo menção em contrário, supomos uma amostra i.i.d. $\mathcal{D} = \{(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)\}$, com $(\mathbf{X}_i, Y_i) \sim (\mathbf{X}, Y)$, de uma distribuição conjunta P desconhecida. Denotamos por $x_{i,j}$ o valor da j -ésima covariável na i -ésima observação, $\mathbf{X}_i = (x_{i,1}, \dots, x_{i,p})$.

Atenção

A suposição i.i.d. é forte e nem sempre razoável (séries temporais, dados espaciais, viés de seleção, *dataset shift*). A Aula 06 volta a ela, quando observações dependentes entre si aparecem como fonte de vazamento; por ora ela é o nosso “mundo ideal”. A distribuição P é *fixa* mas *desconhecida*: é a fonte de toda a incerteza.

3 Por que estimar a função de regressão? Predição versus inferência

Há duas razões distintas para estimar r :

- **Predição.** Queremos um bom palpite $\hat{r}(\mathbf{x})$ para o Y de uma nova observação com covariáveis $\mathbf{x}$. Aqui $\hat{r}$ pode ser uma “caixa-preta”: interessa o *acerto*, não a forma.
- **Inferência.** Queremos *entender* a relação entre $\mathbf{X}$ e Y : quais covariáveis importam, qual o sinal e a magnitude do efeito, há interações? Aqui interessa a *interpretabilidade* do modelo.

Ideia central

Por que $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ é o alvo “certo” para predição? Porque, sob a perda quadrática, a função que minimiza o erro esperado de predição é exatamente a esperança condicional.

Proposição 3.1 (r minimiza o erro quadrático esperado). *Entre todas as funções $g : \mathbb{R}^p \rightarrow \mathbb{R}$, a função de regressão $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ minimiza o erro quadrático esperado $\mathbb{E}[(Y - g(\mathbf{X}))^2]$.*

Demonstração. Fixe $\mathbf{x}$ e escreva $\mathbb{E}[(Y - g(\mathbf{X}))^2 \mid \mathbf{X} = \mathbf{x}]$. Somando e subtraindo $r(\mathbf{x})$,

$$\mathbb{E}[(Y - g(\mathbf{x}))^2 \mid \mathbf{X} = \mathbf{x}] = \mathbb{E}[(Y - r(\mathbf{x}))^2 \mid \mathbf{X} = \mathbf{x}] + (r(\mathbf{x}) - g(\mathbf{x}))^2,$$

pois o termo cruzado se anula: $\mathbb{E}[(Y - r(\mathbf{x}))(r(\mathbf{x}) - g(\mathbf{x})) \mid \mathbf{X} = \mathbf{x}] = (r(\mathbf{x}) - g(\mathbf{x})) \mathbb{E}[Y - r(\mathbf{x}) \mid \mathbf{X} = \mathbf{x}] = 0$. O primeiro termo não depende de g e o segundo é minimizado (zerado) por $g(\mathbf{x}) = r(\mathbf{x})$. Tomando esperança sobre $\mathbf{X}$, segue o resultado. $\square$

Observação 3.2. A decomposição acima já contém a semente do *erro irreduzível*: mesmo conhecendo r perfeitamente, resta $\mathbb{E}[(Y - r(\mathbf{X}))^2] = \mathbb{E}[\text{Var}(Y \mid \mathbf{X})] > 0$ em geral, pois Y não é função determinística de $\mathbf{X}$.

3.1 As duas culturas

Leo Breiman (2001) descreveu duas posturas de modelagem:

- **Cultura dos modelos de dados:** supõe-se um modelo estocástico (por exemplo, linear gaussiano) e o foco é estimar e interpretar seus parâmetros. Tradição estatística clássica.
- **Cultura dos modelos algorítmicos:** trata-se o mecanismo gerador como desconhecido e busca-se uma função preditora com bom desempenho (florestas, *boosting*, redes). Tradição de AM.

Este curso transita entre as duas: usamos a teoria estatística para *avaliar* métodos algorítmicos.

Em sala

Bom exemplo para contrastar predição $\times$ inferência: previsão de demanda de energia (predição pura) *versus* avaliar o efeito de um medicamento (inferência). Pergunte: “em qual desses um modelo ‘caixa-preta’ altamente preciso pode ser inaceitável?”

4 A função de risco

Para comparar candidatos a preditor precisamos de um critério de qualidade. Dado uma **função de perda** $L(y, \hat{y}) \geq 0$, definimos o risco.

Definição 4.1 (Risco). O **risco** (ou erro de generalização) de uma função g é

$$R(g) = \mathbb{E}[L(Y, g(\mathbf{X}))], \quad (2)$$

a perda esperada sobre uma observação *nova* $(\mathbf{X}, Y) \sim P$.

Em regressão usamos tipicamente a perda quadrática $L(y, \hat{y}) = (y - \hat{y})^2$, e então $R(g) = \mathbb{E}[(Y - g(\mathbf{X}))^2]$. Pela Proposição 3.1, r é o *minimizador* do risco. A decomposição fundamental do risco de g é

$$R(g) = \underbrace{\mathbb{E}[(g(\mathbf{X}) - r(\mathbf{X}))^2]}_{\text{excesso de risco}} + \underbrace{\mathbb{E}[\text{Var}(Y | \mathbf{X})]}_{\text{erro irreduzível}}. \quad (3)$$

Atenção

O risco (2) é uma esperança sob P , que *não conhecemos*. Logo o risco é uma quantidade *teórica*: o desafio prático é *estimá-lo*. É o que faremos na Aula 03 (validação cruzada). O erro de treino é um estimador **otimista** do risco — nunca o use como medida final de desempenho.

4.1 Risco empírico

O estimador natural do risco, dado um conjunto de dados $\{(\mathbf{X}_i, Y_i)\}$, é a média das perdas:

$$\hat{R}(g) = \frac{1}{n} \sum_{i=1}^n L(Y_i, g(\mathbf{X}_i)). \quad (4)$$

Se calculado *nos mesmos dados usados para treinar* g , ele subestima sistematicamente o risco — daí a necessidade de dados de teste/validação.

5 Seleção de modelos: super e subajuste

Um método de AM em geral define uma **classe de funções** $\mathcal{H}$ (a “flexibilidade” do modelo) e escolhe dentro dela aquela que melhor ajusta os dados. Há uma tensão:

- **Subajuste (*underfitting*):** $\mathcal{H}$ é simples demais para capturar r . Erro de treino e de teste altos. Modelo “enviesado”.
- **Superajuste (*overfitting*):** $\mathcal{H}$ é flexível demais e ajusta o ruído da amostra. Erro de treino baixo, erro de teste alto. Modelo “variável”.

O comportamento típico: à medida que aumentamos a flexibilidade, o erro de treino cai monotonamente, mas o erro de teste tem forma de “U” — existe um ponto de complexidade ótima.

Em sala

Use o exemplo do [AME]/aula prática: gerar dados de um modelo polinomial com ruído e ajustar polinômios de graus crescentes $(1, 2, \dots, 15)$. Mostre graficamente o “U” do erro de teste. Pergunte: “qual grau vocês escolheriam só olhando o erro de treino? E se olhassem o de teste?”

5.1 O balanço entre viés e variância

Considere um estimador $\hat{r}$ construído a partir da amostra aleatória $\mathcal{D}$. Em um ponto fixo $\mathbf{x}_0$, sob perda quadrática, vale a decomposição clássica:

$$\mathbb{E}_{\mathcal{D}}[(Y_0 - \hat{r}(\mathbf{x}_0))^2] = \underbrace{(\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0)] - r(\mathbf{x}_0))^2}_{\text{viés}^2} + \underbrace{\text{Var}_{\mathcal{D}}(\hat{r}(\mathbf{x}_0))}_{\text{variância}} + \underbrace{\sigma^2(\mathbf{x}_0)}_{\text{irreduzível}}, \quad (5)$$

onde Y_0 é uma resposta nova em $\mathbf{x}_0$ e $\sigma^2(\mathbf{x}_0) = \text{Var}(Y \mid \mathbf{X} = \mathbf{x}_0)$.

Teorema 5.1 (Decomposição viés–variância). *Vale a identidade (5).*

Demonstração. Escreva $Y_0 - \hat{r}(\mathbf{x}_0) = (Y_0 - r(\mathbf{x}_0)) + (r(\mathbf{x}_0) - \hat{r}(\mathbf{x}_0))$. O primeiro parêntese tem média zero e variância $\sigma^2(\mathbf{x}_0)$ e é independente de $\mathcal{D}$. Para o segundo, some e subtraia $\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0)]$ e expanda o quadrado; o termo cruzado se anula porque $\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0) - \mathbb{E}_{\mathcal{D}}\hat{r}(\mathbf{x}_0)] = 0$. Reagrupando os três quadrados obtém-se (5). $\square$

Ideia central

Modelos *flexíveis* têm baixo viés e alta variância; modelos *rígidos* têm alto viés e baixa variância. Selecionar um modelo é, em essência, **escolher o ponto do balanço viés–variância** que minimiza o risco. Não dá para zerar os dois ao mesmo tempo com n finito.

6 Tuning parameters

A flexibilidade de um método costuma ser controlada por um ou mais **hiperparâmetros** (*tuning parameters*), que *não* são estimados junto com o ajuste, mas escolhidos “por fora”. Exemplos que veremos:

Método	Hiperparâmetro	Efeito de aumentá-lo
Regressão polinomial	grau do polinômio	mais flexível ($\uparrow$ variância)
Lasso / Ridge	λ (penalização)	mais rígido ($\uparrow$ viés)
k vizinhos (KNN)	k	mais rígido ($\uparrow$ viés)
Árvore	profundidade / α de poda	(depende do parâmetro)

A escolha desses parâmetros é um problema de *seleção de modelos*, resolvido estimando o risco para vários valores e tomando o melhor — tema central da Aula 03.

Atenção

Hiperparâmetros devem ser escolhidos *sem olhar o conjunto de teste*. Usar o teste para escolher λ ou k e depois reportar o erro nesse mesmo teste é uma forma de vazamento de dados (*data leakage*) que infla o desempenho.

7 Prática em Python

Esta aula é majoritariamente conceitual; a primeira prática (notebook Aula prática 01) cobre o ambiente de trabalho (`numpy`, `pandas`, `matplotlib`) e um primeiro ajuste com `scikit-learn`. O esqueleto de uma análise supervisionada que repetiremos o curso inteiro:

```

1 from sklearn.model_selection import train_test_split
2 from sklearn.metrics import mean_squared_error
3
4 # 1. separar treino e teste (NUNCA tocar no teste durante o ajuste)
5 X_tr, X_te, y_tr, y_te = train_test_split(X, y, test_size=0.3, random_state=0)
6
7 # 2. ajustar o modelo no treino
8 modelo.fit(X_tr, y_tr)
9
10 # 3. avaliar o RISCO estimado no teste
11 y_hat = modelo.predict(X_te)
12 print(mean_squared_error(y_te, y_hat)) # estimativa de  $R(g)$ 

```

Resumo

- O alvo da regressão é $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$, minimizador do risco quadrático (Prop. 3.1).
- *Predição* (acerto) e *inferência* (entendimento) são objetivos distintos — as “duas culturas”.
- *Risco* é perda esperada sob P (desconhecida); o *risco empírico* no treino é otimista.
- Flexibilidade demais $\Rightarrow$ superajuste; de menos $\Rightarrow$ subajuste. O erro de teste tem forma de “U”.
- *Viés-variância* (Teo. 5.1) formaliza esse balanço.
- *Tuning parameters* controlam a complexidade e são escolhidos por seleção de modelos (Aula 03).

Leitura recomendada. [AME] Capítulo 1 (especialmente §1.1–1.6); [ISLP] Capítulos 1 e 2 (em particular §2.1–2.2, sobre *What is statistical learning* e *bias-variance trade-off*).