

Lista Teórica 01 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 01 — Introdução ao Aprendizado de Máquina

Exercício 1 — o tipo de problema e o tipo de objetivo. Para cada situação abaixo, diga (i) se é um problema de *regressão* ou de *classificação* e (ii) se o interesse é de *predição* ou de *inferência*. Justifique cada resposta em uma linha.

- (a) Uma seguradora quer estimar quanto um segurado vai gastar em sinistros no próximo ano, para calcular o prêmio.
- (b) Um epidemiologista quer saber *quais* hábitos de vida estão associados a maior pressão arterial, e com que magnitude.
- (c) Um aplicativo de e-mail precisa decidir se cada mensagem que chega vai para a caixa de entrada ou para a pasta de spam.
- (d) Um banco precisa saber qual das variáveis do cadastro mais pesa na recusa de crédito, porque a lei o obriga a explicar a recusa ao cliente.

Solução

- (a) **Regressão** (Y é um valor em reais, quantitativo) e **predição**: o prêmio depende do número previsto, não de entender o mecanismo. Faz sentido falar em “gasto médio”.
- (b) **Regressão** (pressão arterial é quantitativa) e **inferência**: a pergunta é sobre *quais* covariáveis importam e com que sinal e magnitude — uma caixa-preta muito precisa não responderia a isso.
- (c) **Classificação** ($Y \in \{\text{spam}, \text{não-spam}\}$, qualitativa; não faz sentido falar em “e-mail médio”) e **predição**: só interessa acertar o destino da mensagem.
- (d) **Classificação** (recusar ou não é qualitativa) e **inferência**: a exigência legal é de *interpretabilidade*, o que restringe as famílias de modelo que podem ser usadas.

Repare que (a) e (b) são os dois de regressão e (c) e (d) os dois de classificação, mas os objetivos se cruzam: o tipo de Y e o tipo de objetivo são escolhas independentes.

Exercício 2 — o melhor preditor constante e o piso do risco. Considere a perda quadrática $L(y, \hat{y}) = (y - \hat{y})^2$ e suponha $\mathbb{E}[Y^2] < \infty$.

- (a) Entre todos os preditores **constantes** $g(\mathbf{x}) \equiv c$, mostre que o risco $R(c) = \mathbb{E}[(Y - c)^2]$ é minimizado em $c^* = \mathbb{E}[Y]$ e que $R(c^*) = \text{Var}(Y)$.
- (b) A Proposição da Aula 01 diz que $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ minimiza o risco entre *todas* as funções. Conclua que $R(r) \leq \text{Var}(Y)$ e diga em que situação vale a igualdade. Interprete essa situação em uma frase.
- (c) Na população sintética da Aula 01 o erro irreduzível é $\sigma^2 = 0,49$. Um colega mede o erro do seu modelo e obtém 0,42; ele conclui que conseguiu um risco abaixo do piso teórico. Dê **duas** explicações possíveis para o número que ele viu.

Solução

(a) Some e subtraia $\mathbb{E}[Y]$ dentro do quadrado:

$$\mathbb{E}[(Y-c)^2] = \mathbb{E}[(Y-\mathbb{E}[Y]) + (\mathbb{E}[Y]-c)]^2 = \text{Var}(Y) + 2(\mathbb{E}[Y]-c) \underbrace{\mathbb{E}[Y-\mathbb{E}[Y]]}_{=0} + (\mathbb{E}[Y]-c)^2,$$

ou seja $R(c) = \text{Var}(Y) + (\mathbb{E}[Y] - c)^2$. O primeiro termo não depende de c e o segundo é um quadrado, logo o mínimo está em $c^* = \mathbb{E}[Y]$ e vale $R(c^*) = \text{Var}(Y)$.

(b) O preditor constante c^* é uma função como qualquer outra, e r minimiza o risco sobre todas elas; logo $R(r) \leq R(c^*) = \text{Var}(Y)$. A igualdade vale quando r é constante, isto é, quando $\mathbb{E}[Y | \mathbf{X} = \mathbf{x}] = \mathbb{E}[Y]$ para (quase) todo $\mathbf{x}$. Em palavras: **as covariáveis não carregam informação nenhuma sobre a média de Y** , e o melhor que se pode fazer é chutar a média geral. É o caso de referência contra o qual todo modelo deveria ser comparado.

(c) Duas explicações:

- (i) ele mediu o **erro de treino**, não o risco. O risco empírico calculado nos próprios dados de ajuste subestima sistematicamente o risco, e pode perfeitamente ficar abaixo de σ^2 — o modelo foi escolhido para ir bem justamente naqueles pontos;
- (ii) ele mediu num conjunto de teste **pequeno**, e 0,42 é uma estimativa ruidosa de um risco que de fato é $\geq 0,49$. A barra de erro $\hat{R} \pm 2\sqrt{\hat{\sigma}^2/m}$ da Aula 01 existe exatamente para isso: com m pequeno ela é larga o bastante para conter 0,49.

O que *não* é possível é o risco verdadeiro ficar abaixo de σ^2 : pela decomposição do risco, ele é um excesso de risco não-negativo somado ao piso.

Exercício 3 — lendo a curva em U. A tabela abaixo traz o erro de treino e o risco de polinômios de vários graus, ajustados à população sintética da Aula 01 ($n = 50$, $\sigma^2 = 0,49$). Cada número é a média sobre 400 amostras de treino independentes.

grau	1	2	3	5	8	10	12
erro de treino	0,9417	0,9192	0,5152	0,4348	0,4037	0,3840	0,3642
risco $R(\hat{r})$	1,0079	1,0392	0,6129	0,5699	0,8915	4,8503	79,2438

O risco aqui é o *erro de teste esperado*: a média sobre as 400 amostras de treino, com o piso σ^2 entrando exatamente, e **não** a medida num conjunto de teste finito. A diferença é o que separa este exercício do Exercício 2(c), e é ela que sustenta o item (c).

- (a) Que grau você escolheria, e por quê?
- (b) O [ISLP] define *superajuste* como o caso em que *um modelo menos flexível teria dado um risco menor*. Segundo essa definição, em quais graus da tabela há superajuste? (Cuidado: são mais do que os óbvios.) Um dos graus que você vai encontrar tem erro de treino *alto* e variância baixíssima — a tabela do Exercício 4 traz as duas parcelas dele. Explique por que, ainda assim, ele perde para o grau 1. *Dica*: tanto $r(x) = \sin(1,5x) + 0,3x$ quanto o intervalo $[-3, 3]$ são simétricos em relação à origem.
- (c) No grau 12 o erro de treino vale 0,3642, abaixo de $\sigma^2 = 0,49$. Isso contradiz a afirmação de que nenhum método consegue risco abaixo de σ^2 ? Explique.
- (d) O erro de treino cai de forma monótona em toda a tabela. Isso é uma coincidência desta simulação ou era de se esperar? Justifique.

Solução

(a) O grau **5**: é o menor risco da tabela (0,5699), e é o risco que mais se aproxima do piso $\sigma^2 = 0,49$. Note que *não* é o menor erro de treino — este está no grau 12, o pior modelo da tabela.

(b) Nos graus **2, 8, 10 e 12**. Os graus 8, 10 e 12 são os óbvios: todos têm risco maior que o do grau 5. O grau **2** é o que costuma passar despercebido — seu risco (1,0392) é *maior* que o do grau 1 (1,0079), embora seu erro de treino seja menor. Ou seja: já existe superajuste no segundo ponto da tabela, muito antes da explosão. Superajuste não é sinônimo de “curva maluca”; é uma comparação de riscos.

E o grau 2 merece um segundo olhar, porque ele mostra o que essa definição *não* diz. Pela tabela do Exercício 4, ali o viés² vale 0,4794 contra uma variância de 0,0698: **87% do excesso de risco é viés**. E o erro de treino, 0,9192, é o segundo mais alto da tabela. Esse é um modelo *rígido demais* — o retrato do subajuste — e ainda assim satisfaz o critério de superajuste. Os dois rótulos não são exclusivos.

A razão de ele perder para o grau 1 é a **paridade**. Como $r(x) = \sin(1,5x) + 0,3x$ é uma função *ímpar* e $[-3, 3]$ é simétrico em torno da origem, um termo par como x^2 não tem nada a aproximar: o viés² nem cai — sobe de leve, de 0,4786 para 0,4794 — e em troca a variância quase dobra, de 0,0394 para 0,0698. É um parâmetro pago e não usado. O mesmo acontece em *todo* grau par: fora da tabela, o grau 4 tem risco 0,6452 contra 0,6129 do grau 3, e o grau 6 tem 0,6156 contra 0,5699 do grau 5. A curva em “U” de fato ziguezagueia; a tabela parece lisa porque pula os graus 4, 6, 7, 9 e 11.

A lição é dupla. O critério do [ISLP] é **relativo** — ele diz “você está do lado errado da curva”, não “o seu modelo tem variância alta”. E ele não diagnostica a *causa*: para saber se o culpado é o viés ou a variância, só a decomposição do Exercício 4 responde.

(c) Não contradiz. A afirmação é sobre o **risco**, uma esperança sobre observações novas; 0,3642 é o **erro de treino**, medido nos mesmos pontos que ajustaram o polinômio. O erro de treino é um estimador otimista do risco, e no grau 12 o otimismo é enorme: o risco correspondente é 79,2438, mais de 200 vezes o erro de treino. Aliás, é o par (treino baixo, risco alto) que caracteriza a situação.

(d) Era de se esperar. Os polinômios de grau p formam uma família **encaixada**: todo polinômio de grau p também é um polinômio de grau $p + 1$ (com o coeficiente líder igual a zero). Como o ajuste por mínimos quadrados escolhe o membro da família que minimiza o erro de treino, ampliar a família só pode manter ou reduzir esse mínimo. O risco, que não é o critério otimizado, não tem nenhuma obrigação de cair — e não cai.

Exercício 4 — a decomposição viés–variância. Fixe um ponto $\mathbf{x}_0$ e trate $\hat{r}(\mathbf{x}_0)$ como aleatório, porque depende da amostra de treino $\mathcal{D}$.

(a) Mostre que

$$\mathbb{E}_{\mathcal{D}}[(\hat{r}(\mathbf{x}_0) - r(\mathbf{x}_0))^2] = \underbrace{(\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0)] - r(\mathbf{x}_0))^2}_{\text{viés}^2} + \underbrace{\text{Var}_{\mathcal{D}}(\hat{r}(\mathbf{x}_0))}_{\text{variância}}.$$

Dica: some e subtraia $\mu := \mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0)]$ dentro do quadrado — é a mesma manipulação do Exercício 2(a).

(b) Somando o erro irreduzível, o risco no ponto $\mathbf{x}_0$ fica $\text{viés}^2 + \text{variância} + \sigma^2$. A tabela abaixo traz as três parcelas para a mesma simulação do Exercício 3 (médias sobre a grade de $\mathbf{x}_0$). Confira a identidade em **todas** as colunas da tabela, e descreva em uma frase o que acontece com cada parcela quando o grau cresce.

grau	1	2	5	10	12
viés ²	0,4786	0,4794	0,0018	0,0034	0,5410
variância	0,0394	0,0698	0,0781	4,3570	78,2128
risco	1,0079	1,0392	0,5699	4,8503	79,2438

Solução

(a) Escreva $\mu := \mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0)]$ e insira $-\mu + \mu$:

$$\mathbb{E}_{\mathcal{D}}[(\hat{r}(\mathbf{x}_0) - r(\mathbf{x}_0))^2] = \mathbb{E}_{\mathcal{D}}[(\hat{r}(\mathbf{x}_0) - \mu) + (\mu - r(\mathbf{x}_0))]^2.$$

Expandindo o quadrado saem três termos. O primeiro é $\mathbb{E}_{\mathcal{D}}[(\hat{r}(\mathbf{x}_0) - \mu)^2] = \text{Var}_{\mathcal{D}}(\hat{r}(\mathbf{x}_0))$. O terceiro, $(\mu - r(\mathbf{x}_0))^2$, é constante em relação a $\mathcal{D}$ e é o viés ao quadrado. O termo cruzado se anula porque $\mu - r(\mathbf{x}_0)$ é constante e $\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0) - \mu] = \mu - \mu = 0$:

$$2(\mu - r(\mathbf{x}_0)) \mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0) - \mu] = 0.$$

Como a dica antecipa, é a mesma conta do item (a) do Exercício 2, com $\hat{r}(\mathbf{x}_0)$ no lugar de Y e $r(\mathbf{x}_0)$ no lugar de c — o que não é coincidência: nos dois casos estamos decompondo um erro quadrático médio em torno da média do objeto aleatório.

(b) Com $\sigma^2 = 0,49$:

$$\begin{array}{llll} \text{grau 1 :} & 0,4786 + 0,0394 + 0,49 & = & 1,0080 \quad (\approx 1,0079) \\ \text{grau 2 :} & 0,4794 + 0,0698 + 0,49 & = & 1,0392 \\ \text{grau 5 :} & 0,0018 + 0,0781 + 0,49 & = & 0,5699 \\ \text{grau 10 :} & 0,0034 + 4,3570 + 0,49 & = & 4,8504 \quad (\approx 4,8503) \\ \text{grau 12 :} & 0,5410 + 78,2128 + 0,49 & = & 79,2438 \end{array}$$

As diferenças na quarta casa são só arredondamento da tabela.

Comportamento das parcelas: o **viés**² fica *parado* do grau 1 para o grau 2 — o termo par não aproxima nada, que é a discussão do Exercício 3(b) — e só então desaba: do grau 5 em diante o polinômio já consegue reproduzir r , e o viés vira ruído numérico. A **variância** cresce sem parar, e a partir do grau 8 cresce de forma explosiva: é ela, sozinha, que produz o lado direito da curva em U. O σ^2 é constante por definição — não depende do modelo. O grau 12 é um caso à parte: ali o viés² *volta a subir*, porque o ajuste está tão instável que a média das curvas ajustadas já não se parece com r .