

Lista Teórica 01

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 01 — Introdução ao Aprendizado de Máquina

Exercício 1 — o tipo de problema e o tipo de objetivo. Para cada situação abaixo, diga (i) se é um problema de *regressão* ou de *classificação* e (ii) se o interesse é de *predição* ou de *inferência*. Justifique cada resposta em uma linha.

- (a) Uma seguradora quer estimar quanto um segurado vai gastar em sinistros no próximo ano, para calcular o prêmio.
- (b) Um epidemiologista quer saber *quais* hábitos de vida estão associados a maior pressão arterial, e com que magnitude.
- (c) Um aplicativo de e-mail precisa decidir se cada mensagem que chega vai para a caixa de entrada ou para a pasta de spam.
- (d) Um banco precisa saber qual das variáveis do cadastro mais pesa na recusa de crédito, porque a lei o obriga a explicar a recusa ao cliente.

Exercício 2 — o melhor preditor constante e o piso do risco. Considere a perda quadrática $L(y, \hat{y}) = (y - \hat{y})^2$ e suponha $\mathbb{E}[Y^2] < \infty$.

- (a) Entre todos os preditores **constantes** $g(\mathbf{x}) \equiv c$, mostre que o risco $R(c) = \mathbb{E}[(Y - c)^2]$ é minimizado em $c^* = \mathbb{E}[Y]$ e que $R(c^*) = \text{Var}(Y)$.
- (b) A Proposição da Aula 01 diz que $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ minimiza o risco entre *todas* as funções. Conclua que $R(r) \leq \text{Var}(Y)$ e diga em que situação vale a igualdade. Interprete essa situação em uma frase.
- (c) Na população sintética da Aula 01 o erro irreduzível é $\sigma^2 = 0,49$. Um colega mede o erro do seu modelo e obtém 0,42; ele conclui que conseguiu um risco abaixo do piso teórico. Dê **duas** explicações possíveis para o número que ele viu.

Exercício 3 — lendo a curva em U. A tabela abaixo traz o erro de treino e o risco de polinômios de vários graus, ajustados à população sintética da Aula 01 ($n = 50$, $\sigma^2 = 0,49$). Cada número é a média sobre 400 amostras de treino independentes.

grau	1	2	3	5	8	10	12
erro de treino	0,9417	0,9192	0,5152	0,4348	0,4037	0,3840	0,3642
risco $R(\hat{r})$	1,0079	1,0392	0,6129	0,5699	0,8915	4,8503	79,2438

O risco aqui é o *erro de teste esperado*: a média sobre as 400 amostras de treino, com o piso σ^2 entrando exatamente, e **não** a medida num conjunto de teste finito. A diferença é o que separa este exercício do Exercício 2(c), e é ela que sustenta o item (c).

- (a) Que grau você escolheria, e por quê?
- (b) O [ISLP] define *superajuste* como o caso em que *um modelo menos flexível teria dado um risco menor*. Segundo essa definição, em quais graus da tabela há superajuste? (Cuidado: são mais do que os óbvios.) Um dos graus que você vai encontrar tem erro de treino *alto* e variância baixíssima — a tabela do Exercício 4 traz as duas parcelas dele. Explique por que, ainda assim, ele perde para o grau 1. *Dica*: tanto $r(x) = \sin(1,5x) + 0,3x$ quanto o intervalo $[-3, 3]$ são simétricos em relação à origem.

- (c) No grau 12 o erro de treino vale 0,3642, abaixo de $\sigma^2 = 0,49$. Isso contradiz a afirmação de que nenhum método consegue risco abaixo de σ^2 ? Explique.
- (d) O erro de treino cai de forma monótona em toda a tabela. Isso é uma coincidência desta simulação ou era de se esperar? Justifique.

Exercício 4 — a decomposição viés–variância. Fixe um ponto $\mathbf{x}_0$ e trate $\hat{r}(\mathbf{x}_0)$ como aleatório, porque depende da amostra de treino $\mathcal{D}$.

- (a) Mostre que

$$\mathbb{E}_{\mathcal{D}}[(\hat{r}(\mathbf{x}_0) - r(\mathbf{x}_0))^2] = \underbrace{(\mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0)] - r(\mathbf{x}_0))^2}_{\text{viés}^2} + \underbrace{\text{Var}_{\mathcal{D}}(\hat{r}(\mathbf{x}_0))}_{\text{variância}}.$$

Dica: some e subtraia $\mu := \mathbb{E}_{\mathcal{D}}[\hat{r}(\mathbf{x}_0)]$ dentro do quadrado — é a mesma manipulação do Exercício 2(a).

- (b) Somando o erro irreduzível, o risco no ponto $\mathbf{x}_0$ fica $\text{viés}^2 + \text{variância} + \sigma^2$. A tabela abaixo traz as três parcelas para a mesma simulação do Exercício 3 (médias sobre a grade de $\mathbf{x}_0$). Confira a identidade em **todas** as colunas da tabela, e descreva em uma frase o que acontece com cada parcela quando o grau cresce.

grau	1	2	5	10	12
viés ²	0,4786	0,4794	0,0018	0,0034	0,5410
variância	0,0394	0,0698	0,0781	4,3570	78,2128
risco	1,0079	1,0392	0,5699	4,8503	79,2438