

Aula 02 — Regressão Linear e Regularização

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME cap. 2–3; ISLP cap. 3 e 6

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- escrever o modelo de regressão linear em forma matricial e deduzir o estimador de mínimos quadrados (MQO);
- explicar por que MQO falha (ou nem existe) em *altas dimensões* (p grande, ou $p > n$);
- descrever seleção de subconjuntos e regressão *stepwise*;
- definir as penalizações **Ridge** (ℓ_2) e **Lasso** (ℓ_1) e interpretá-las como controle do balanço viés–variância;
- explicar *por que o Lasso zera coeficientes* (esparsidade) e o Ridge não, com a intuição geométrica;
- reconhecer a interpretação bayesiana das duas penalizações.

Esta aula é a Aula 01 em ação. Lá vimos que existe um balanço viés–variância e que escolher um modelo é escolher um ponto nesse balanço. Aqui aprendemos a *mover esse ponto de propósito*, sem trocar de família de modelos: a regularização introduz viés deliberadamente para comprar uma redução maior de variância. Vamos começar pela pergunta que motiva tudo:

se eu tenho 50 covariáveis e 30 observações, o que acontece com os mínimos quadrados?

A resposta curta é “algo pior do que dar errado: ele dá *infinitas* respostas, todas com erro de treino zero”. A Seção 2 explica por quê.

1 O modelo de regressão linear

Métodos **paramétricos** supõem que a função de predição é descrita por um número finito de parâmetros. A regressão linear usa

$$g(\mathbf{x}) = \boldsymbol{\beta}^\top \mathbf{x} = \beta_0 x_0 + \beta_1 x_1 + \cdots + \beta_p x_p, \quad x_0 \equiv 1, \quad (1)$$

com $\boldsymbol{\beta} = (\beta_0, \dots, \beta_p)$. É essencial notar que x_j *não* precisa ser uma covariável original: podemos criar atributos derivados (x_j^2 , $x_j x_k$, $\log x_j$, etc.). Assim, “linear” refere-se à linearidade **nos parâmetros** $\boldsymbol{\beta}$, não nas variáveis — o modelo é muito mais flexível do que parece à primeira vista.

Ideia central

Você já usou isso na Aula 01 sem perceber. Ajustar um polinômio de grau 15 é ajustar uma *regressão linear* nas covariáveis $x, x^2, \dots, x^{15}$. Tudo o que dissermos aqui sobre “muitas covariáveis” vale, portanto, também para “polinômio de grau alto”.

1.1 Mínimos quadrados ordinários (MQO)

Estimamos β minimizando a soma dos quadrados dos resíduos (RSS):

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n (y_i - \beta^\top \mathbf{x}_i)^2 = \arg \min_{\beta} \|\mathbf{y} - \mathbb{X}\beta\|^2, \quad (2)$$

onde $\mathbb{X} \in \mathbb{R}^{n \times (p+1)}$ é a matriz de delineamento (linha i igual a $\mathbf{x}_i^\top$, com a coluna de 1s) e $\mathbf{y} = (y_1, \dots, y_n)^\top$.

Proposição 1.1 (Equações normais). *Se $\mathbb{X}^\top \mathbb{X}$ é invertível, o minimizador de (2) é*

$$\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{y}. \quad (3)$$

Demonstração. Seja $S(\beta) = \|\mathbf{y} - \mathbb{X}\beta\|^2 = \mathbf{y}^\top \mathbf{y} - 2\beta^\top \mathbb{X}^\top \mathbf{y} + \beta^\top \mathbb{X}^\top \mathbb{X} \beta$. O gradiente é $\nabla S(\beta) = -2\mathbb{X}^\top \mathbf{y} + 2\mathbb{X}^\top \mathbb{X} \beta$. Igualando a zero obtêm-se as *equações normais* $\mathbb{X}^\top \mathbb{X} \beta = \mathbb{X}^\top \mathbf{y}$; como a Hessiana $2\mathbb{X}^\top \mathbb{X}$ é semidefinida positiva, o ponto crítico é mínimo. Se $\mathbb{X}^\top \mathbb{X}$ é invertível, vale (3). $\square$

Observação 1.2. $\hat{\beta}$ é o estimador de máxima verossimilhança sob o modelo $y_i = \beta^\top \mathbf{x}_i + \varepsilon_i$, com $\varepsilon_i \sim N(0, \sigma^2)$ i.i.d. A predição é $\hat{r}(\mathbf{x}) = \hat{\beta}^\top \mathbf{x}$. Sob o modelo linear correto, MQO é o melhor estimador linear não-viesado (Gauss–Markov).

1.2 E quando a linearidade é falsa?

Quase sempre é. Vale então perguntar o que o MQO estima quando $r(\mathbf{x})$ não é linear — e a resposta é tranquilizadora.

Teorema 1.3 (MQO converge para o melhor preditor linear). *Seja $\beta^* = \arg \min_{\beta} \mathbb{E}[(y - \beta^\top \mathbf{x})^2]$ o melhor preditor linear (o “oráculo”), e suponha $\Sigma = \mathbb{E}[\mathbf{x}\mathbf{x}^\top]$ bem definida. Então, quando $n \rightarrow \infty$,*

$$\hat{\beta} \xrightarrow{P} \beta^* \quad e \quad R(g_{\hat{\beta}}) \xrightarrow{P} R(g_{\beta^*}).$$

Esboço. Minimizando $\mathbb{E}[(y - \beta^\top \mathbf{x})^2]$ obtém-se $\beta^* = \Sigma^{-1} \alpha$, com $\alpha_j = \mathbb{E}[yX_j]$. O estimador se escreve na mesma forma, $\hat{\beta} = \hat{\Sigma}^{-1} \hat{\alpha}$, com $\hat{\Sigma} = n^{-1} \sum_i \mathbf{x}_i \mathbf{x}_i^\top$ e $\hat{\alpha}_j = n^{-1} \sum_i y_i X_{i,j}$. Pela lei dos grandes números $\hat{\Sigma} \rightarrow \Sigma$ e $\hat{\alpha} \rightarrow \alpha$; o teorema de Mann–Wald transporta a convergência através da função contínua $(\Sigma, \alpha) \mapsto \Sigma^{-1} \alpha$, e de novo através de $\beta \mapsto R(g_\beta)$. $\square$

Ideia central

Traduzindo: mesmo com o modelo “errado”, o MQO acerta a *melhor aproximação linear possível* de r — a projeção de Y no espaço gerado pelas covariáveis. O viés que sobra não é culpa do estimador, é culpa da classe de modelos escolhida. Por isso ampliar o conjunto de atributos (incluir x^2 , interações) reduz esse viés de especificação — ao custo de aumentar p , que é exatamente o problema da próxima seção.

2 O problema das altas dimensões

Quando p é grande relativamente a n , o MQO esbarra em três limitações:

1. **Variância alta.** Quanto mais parâmetros, maior $\text{Var}(\hat{\beta})$ — o modelo superajusta (Aula 01). A matriz $\text{Var}(\hat{\beta}) = \sigma^2 (\mathbb{X}^\top \mathbb{X})^{-1}$ “explode” quando as colunas de $\mathbb{X}$ são quase colineares.

2. **Não unicidade.** Se $p > n$, então $\mathbb{X}^\top \mathbb{X}$ é singular e (3) *não tem solução única*: há infinitos β com RSS nulo (superajuste perfeito).

3. **Interpretabilidade.** Muitas covariáveis irrelevantes dificultam a leitura do modelo.

Vale ver a primeira delas acontecer. Fixe $n = 60$ observações e vá aumentando p , com apenas 5 covariáveis de fato relevantes e o resto puro ruído (Figura 1).




Figura 1: Com $n = 60$ fixo e p crescendo. À esquerda, o número de condição de $\mathbb{X}^\top \mathbb{X}$ — a razão entre seu maior e seu menor autovalor — sai de 1,4 e chega a 3×10^4 : inverter essa matriz vira uma operação numericamente delicada. À direita, a consequência: o risco do MQO sai de 1,0 (o próprio σ^2 , ou seja, praticamente perfeito) e passa de 10^4 . O modelo não ficou “um pouco pior”; ele ficou inútil.

Atenção: o caso $p > n$ é qualitativamente diferente

Repare que os problemas 1 e 2 não são o mesmo. Se $p < n$ mas as colunas são quase colineares, a solução *existe e é única*, só que instável. Se $p > n$, ela nem é única: o núcleo de $\mathbb{X}$ tem dimensão $\geq p - n$, e somar a $\hat{\beta}$ qualquer vetor desse núcleo dá *outra* solução com exatamente o mesmo RSS nulo. O erro de treino não distingue entre elas, e não há nada nos dados que justifique preferir uma. A regularização, entre outras coisas, serve para desempatar.

A resposta é **reduzir a complexidade efetiva**: ou selecionando um subconjunto de covariáveis, ou *encolhendo* os coeficientes (regularização).

2.1 Seleção de subconjuntos e *stepwise*

Melhor subconjunto

ajusta-se o modelo para *todos* os 2^p subconjuntos de covariáveis e escolhe-se o melhor segundo um critério que penaliza complexidade (AIC, BIC) ou via validação cruzada. Inviável para p moderado (2^p explode).

Forward stepwise

começa com o modelo vazio e adiciona, a cada passo, a covariável que mais reduz o RSS, até um critério de parada.

Backward stepwise

começa com o modelo completo e remove, a cada passo, a covariável menos útil (exige $n > p$).

A economia do *stepwise* é enorme: ele examina $1 + p(p+1)/2$ modelos em vez de 2^p . Para $p = 20$ isso é 211 contra 1 048 576; para $p = 40$, 821 contra mais de 10^{12} .

Exemplo 2.1 (Quanto isso custa, na prática). O [AME] simula $n = 500$ observações de $Y = 3X_1 - 2X_2 + X_3 - 3X_4 + X_5 + \sum_{i=6}^{20} 0 \cdot X_i + \varepsilon$, com $\varepsilon \sim N(0; 0,5^2)$: apenas 5 das 20 covariáveis importam. Os resultados:

Método	Variáveis selecionadas	Tempo	Risco estimado
Mín. quadrados	todas	0,002 s	14,63
Melhor subconj. (AIC)	$x_1..x_5, x_{10}, x_{12}, x_{13}, x_{19}, x_{20}$	1 h 20 min	0,30
<i>Forward stepwise</i>	$x_1..x_5, x_{10}, x_{12}, x_{13}, x_{19}, x_{20}$	0,46 s	0,30
Ridge	todas	0,16 s	0,33
Lasso	$x_1, \dots, x_5$	0,08 s	0,25

Três leituras. Primeira: o MQO com todas as variáveis tem risco *cinquenta vezes* maior que o Lasso — as 15 covariáveis nulas destroem o modelo. Segunda: o *forward stepwise* encontrou exatamente o mesmo modelo do melhor subconjunto em 0,46 segundos em vez de 1h20; a heurística gananciosa saiu de graça aqui. Terceira: o Lasso foi o mais rápido e o único a recuperar precisamente $\{x_1, \dots, x_5\}$.

Atenção

Crerios como AIC/BIC ($\hat{R} \approx \text{EQM} + P(g)$, com $P(g) \propto p/\hat{\sigma}^2$) estimam o risco *corrigindo* o otimismo do erro de treino. Mas seleção *stepwise* é gananciosa (não examina todos os modelos) e a inferência clássica “pós-seleção” fica inválida: os p -valores reportados ignoram que o modelo foi escolhido olhando os dados. Um p -valor de 0,01 numa variável que sobreviveu a uma triagem entre 20 candidatas não significa o que a tabela diz que significa.

3 Regularização: encolhendo coeficientes

A ideia da regularização (ou *penalização*, ou *shrinkage*) é adicionar ao RSS um termo que penaliza coeficientes grandes, desencorajando o superajuste:

$$\hat{\beta}_{\text{pen}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \text{Pen}(\beta) \right\}.$$

O hiperparâmetro $\lambda \geq 0$ controla a intensidade: $\lambda = 0$ recupera MQO; $\lambda \rightarrow \infty$ força $\beta \rightarrow 0$. λ é escolhido por **validação cruzada** (Aula 03).

Ideia central

Regularizar = introduzir *viés* de propósito para reduzir *variância*. Sob p grande, o ganho na variância supera a perda no viés e o risco total cai. É a Aula 01 em ação.

3.1 Qual medida de complexidade?

Antes das fórmulas, vale escolher *como medir* o tamanho de β . Há três candidatas naturais, e a comparação entre elas explica por que o Lasso é o que é:

β (com $p = 10$)	$\sum_j \mathbf{1}\{\beta_j \neq 0\}$ (ℓ_0)	$\sum_j \beta_j $ (ℓ_1)	$\sum_j \beta_j^2$ (ℓ_2)
$(0, 0, \dots, 0)$	0	0,0	0
$(0, 1; 0, 1; \dots; 0, 1)$	10	1,0	0,1
$(1, 1, \dots, 1)$	10	10,0	10

Compare as linhas 1 e 2: os dois modelos fazem previsões quase idênticas, mas a norma ℓ_0 salta de 0 para 10 — ela é *descontínua*, uma mudança infinitesimal nos coeficientes muda a penalização ao máximo. Compare agora as linhas 2 e 3: as previsões são *muito* diferentes, e ainda assim a ℓ_0 dá o mesmo valor 10 para as duas. A norma ℓ_0 é, ao mesmo tempo, sensível demais e insensível demais.

Ideia central

A norma ℓ_1 é o melhor dos dois mundos: como a ℓ_0 , ela é pequena para vetores com muitos zeros — e por isso induz esparsidade; ao contrário da ℓ_0 , ela varia *continuamente* com β , o que torna o problema convexo e resolúvel em milissegundos. Não é exagero dizer que o Lasso existe porque a ℓ_1 é a relaxação convexa da ℓ_0 .

3.2 Regressão Ridge (ℓ_2)

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}. \quad (4)$$

A grande vantagem é a solução fechada:

$$\hat{\beta}^{\text{ridge}} = (\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I}_0)^{-1} \mathbb{X}^\top \mathbf{y}, \quad (5)$$

onde $\mathbb{I}_0$ é a identidade $(p+1) \times (p+1)$ com o primeiro elemento trocado por zero — é assim que se deixa o intercepto β_0 fora da penalização. (Faz sentido: penalizar β_0 tornaria a solução dependente de onde você pôs a origem de Y .)

Proposição 3.1 (Ridge sempre tem solução única). *Para todo $\lambda > 0$, a matriz $\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I}$ é definida positiva (logo invertível), mesmo quando $p > n$.*

Demonstração. Para qualquer $\mathbf{v} \neq 0$, $\mathbf{v}^\top (\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I}) \mathbf{v} = \|\mathbb{X}\mathbf{v}\|^2 + \lambda \|\mathbf{v}\|^2 \geq \lambda \|\mathbf{v}\|^2 > 0$. $\square$

Eis a primeira virtude do Ridge: *estabiliza* o problema mal-condicionado das altas dimensões. Note que a demonstração é exatamente o antídoto para a Figura 1: somar λ à diagonal levanta o menor autovalor de $\mathbb{X}^\top \mathbb{X}$ de perto de zero para pelo menos λ , e o número de condição desaba. Os coeficientes são encolhidos suavemente em direção a zero, mas em geral **nenhum é exatamente zero**.

3.3 O Lasso (ℓ_1)

$$\hat{\beta}^{\text{lasso}} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbb{X}\beta\|^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}. \quad (6)$$

Trocamos a norma ℓ_2 pela ℓ_1 . Não há solução fechada (o termo $|\beta_j|$ não é diferenciável em 0), mas o problema é convexo e resolvido eficientemente (*coordinate descent*, LARS). A propriedade marcante:

Ideia central

O Lasso faz **seleção de variáveis**: para λ grande o suficiente, vários $\hat{\beta}_j$ são *exatamente* zero. Obtemos um modelo *esparso* e interpretável de graça — ao contrário do Ridge.

Observação 3.2 (Por que o Lasso aguenta p enorme). Greenshtein e Ritov (2004) mostram que, sob condições de limitação, o Lasso com restrição $\|\beta\|_1 \leq L$ satisfaz, com probabilidade $\geq 1 - \delta$,

$$R(g_{\hat{\beta}_L}) - R(g_{\beta_L^*}) \leq \sqrt{\frac{16(L+1)^4 B^2}{n} \log\left(\frac{2p}{\delta}\right)}.$$

O detalhe que importa é onde o p aparece: dentro de um **logaritmo**. Dobrar o número de covariáveis quase não muda a garantia — é por isso que o Lasso funciona com milhares de covariáveis e n modesto, situação em que o MQO nem está definido.

Por que o Lasso zera coeficientes e o Ridge não?

Ambos têm a formulação equivalente *com restrição*: para cada λ existe um orçamento t tal que resolver (6) é o mesmo que resolver

$$\min_{\beta} \|\mathbf{y} - \mathbb{X}\beta\|^2 \quad \text{sujeito a} \quad \underbrace{\sum_j |\beta_j| \leq t}_{\text{Lasso}} \quad \text{ou} \quad \underbrace{\sum_j \beta_j^2 \leq t^2}_{\text{Ridge}}.$$

Nessa forma a geometria fica visível. As curvas de nível do RSS são *elipses* concêntricas centradas em $\hat{\beta}^{\text{MQO}}$ — e são elipses *alongadas* quando as covariáveis são correlacionadas, porque nessa direção dá para aumentar um coeficiente e diminuir o outro quase sem alterar o ajuste. A solução penalizada é o ponto onde a menor elipse possível *toca* a região permitida. E aí a forma da região decide tudo: a bola do Ridge é lisa, então o contato se dá num ponto genérico; o losango do Lasso tem *quinas sobre os eixos*, e é muito fácil que o toque aconteça justamente numa quina — onde algum β_j é exatamente zero.




Figura 2: A geometria da esparsidade, com números de um ajuste real ($n = 60$, duas covariáveis padronizadas com correlação $-0,50$). Em verde, curvas de nível do RSS, centradas em $\hat{\beta}^{\text{MQO}} = (1,573; 0,808)$ e alongadas porque as covariáveis são correlacionadas. Em cor, a região permitida. A solução é o ponto onde a menor elipse *toca* a região. À esquerda, o toque cai na **quina** do losango e β_2 sai exatamente zero; à direita, o círculo não tem quina, o toque acontece num ponto qualquer da borda e os dois coeficientes sobrevivem — apenas encolhidos. Os orçamentos t dos dois painéis são diferentes (cada método com o seu); o que se compara aqui é a *forma* da região, não o seu tamanho.

Atenção

Perceba que a esparsidade do Lasso é um acidente *feliz* da geometria, e não uma regra infalível. Se a elipse estivesse orientada de outro jeito — por exemplo, se $\hat{\beta}^{\text{MQO}}$ estivesse perto da diagonal —, o toque cairia numa aresta e nenhum coeficiente seria zerado. Em dimensão p , porém, o losango tem $2p$ quinas e 2^p faces de dimensão baixa, e a chance de acertar alguma cresce depressa. É por isso que “o Lasso zera coeficientes” é uma afirmação sobre o comportamento *típico*, não um teorema.

Exemplo 3.3 (Caso ortonormal: fórmulas explícitas). Quando $\mathbb{X}^\top \mathbb{X} = \mathbb{I}$, os estimadores têm forma fechada em função do MQO $\hat{\beta}_j$:

$$\hat{\beta}_j^{\text{ridge}} = \frac{\hat{\beta}_j}{1 + \lambda}, \quad \hat{\beta}_j^{\text{lasso}} = \text{sin}(\hat{\beta}_j) \left(|\hat{\beta}_j| - \frac{\lambda}{2} \right)_+.$$

O Ridge *multiplica* por um fator < 1 (encolhe proporcionalmente, nunca zera); o Lasso *subtrai* uma constante e trunca em zero (*soft thresholding*) — por isso anula os pequenos.




Figura 3: As duas fórmulas do caso ortonormal, com $\lambda = 1$. O Ridge é uma reta pela origem de inclinação $1/(1 + \lambda)$: encolhe *proporcionalmente*, e quanto maior o coeficiente, maior o encolhimento em valor absoluto. O Lasso é paralelo à identidade, deslocado de $\lambda/2$: encolhe todo mundo pela *mesma quantidade* — e quem era menor que $\lambda/2$ em módulo (a faixa sombreada) não sobrevive ao deslocamento e vira exatamente zero.

3.4 Interpretação bayesiana

Ambas as penalizações são o *logaritmo de uma priori* sobre β . Suponha $Y_i | \mathbf{x}_i, \beta \sim N(\beta^\top \mathbf{x}_i, \sigma^2)$ independentes, com σ^2 conhecido. Então:

- se $\beta \sim N(0, \sigma_\beta^2 \mathbb{I})$, a **moda a posteriori** de β é exatamente a solução Ridge (4) com $\lambda = \sigma^2 / \sigma_\beta^2$;

- se $\beta_1, \dots, \beta_p \stackrel{\text{i.i.p.}}{\sim} \text{Laplace}(0, \tau_\beta)$, a moda a posteriori é exatamente a solução Lasso (6) com $\lambda = \sigma^2 \tau_\beta$.

A priori de Laplace é mais “pontuda” em zero e tem caudas mais pesadas: ela favorece soluções com muitos coeficientes *nulos* e alguns grandes — exatamente a esparsidade observada.

Ideia central: uma leitura filosófica

Sob essa ótica, λ é a priori: quanto menor a dispersão que você atribui a β a priori, maior o λ e mais encolhidas as estimativas. Escolher λ por validação cruzada equivale, então, a **escolher a distribuição a priori que prediz melhor** — usar a maquinaria bayesiana como motivação para estimadores melhores, sem necessariamente comprar a interpretação subjetiva.

Atenção

Uma sutileza que o [ISLP] faz questão de registrar: no caso Ridge a solução é a moda e a média a posteriori. No caso Lasso ela é só a **moda** — a média a posteriori do Lasso *não* é esparsa. A esparsidade é uma propriedade daquele ponto específico da distribuição, não da distribuição inteira.

Atenção

Como as penalizações somam β_j^2 ou $|\beta_j|$, elas **dependem da escala** das covariáveis. *Sempre padronize* (média 0, variância 1) antes de aplicar Ridge/Lasso, caso contrário variáveis em unidades grandes são penalizadas de menos. Repare que o MQO *não* tem esse problema: trocar metros por centímetros só divide o coeficiente por 100 e a predição fica igual. Com penalização isso deixa de valer, porque o termo $\lambda \sum \beta_j^2$ enxerga a mudança. Isso conecta diretamente com a Aula 06 (*pipelines* e **StandardScaler**).

4 Caminhos de regularização

Como λ varre $[0, \infty)$, cada $\hat{\beta}_j$ traça uma curva. Pôr todas num gráfico — o **caminho de regularização** — é a melhor forma de ver a diferença entre os dois métodos de uma vez só (Figura 4).

Atenção: o λ que melhor prediz não é o que melhor seleciona

Uma armadilha que aparece assim que você roda **LassoCV** num problema real: a validação cruzada escolhe λ para *predizer* bem, e o λ ótimo para predição costuma ser *menor* do que o ótimo para seleção. O resultado é um modelo que prediz muito bem mas mantém coeficientes minúsculos e não nulos em várias covariáveis irrelevantes — falsos positivos. Se o seu objetivo é *descobrir quais* variáveis importam, e não só predizer, olhe o caminho inteiro e compare as *magnitudes*: as relevantes costumam estar ordens de grandeza acima do resto.

5 Prática em Python

Em **scikit-learn**, as três variantes seguem a mesma interface; o **alpha** é o nosso λ . Note a padronização *dentro* do *pipeline* (Aula 06) para evitar vazamento.




Figura 4: Coeficientes em função da penalização, num problema com $n = 80$, $p = 30$ e apenas 5 covariáveis relevantes. À esquerda o Ridge: todos os 30 coeficientes saem de zero *juntos* e crescem suavemente — em nenhum momento algum deles é exatamente nulo. À direita o Lasso: os coeficientes ficam *grudados no zero* e vão sendo “ligados” um a um conforme a penalização afrouxa; as 5 covariáveis relevantes (em vinho) entram primeiro, muito antes das 25 irrelevantes (em cinza). É esse comportamento de liga-desliga que chamamos de seleção de variáveis.

```

1 from sklearn.linear_model import LinearRegression, Ridge, Lasso, LassoCV
2 from sklearn.preprocessing import StandardScaler
3 from sklearn.pipeline import make_pipeline
4
5 # Lasso com lambda escolhido por validacao cruzada
6 modelo = make_pipeline(StandardScaler(),
7                         LassoCV(cv=5, random_state=0))
8 modelo.fit(X_tr, y_tr)
9
10 lasso = modelo.named_steps["lassocv"]
11 print("lambda escolhido:", lasso.alpha_)
12 print("coeficientes nao-nulos:", (lasso.coef_ != 0).sum(), "de", X.shape[1])

```

Atenção: um detalhe de escala que já custou caro a muita gente

As classes do `scikit-learn` **não** usam a mesma normalização. Ridge minimiza $\|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \alpha \|\boldsymbol{\beta}\|^2$, enquanto Lasso e ElasticNet minimizam $\frac{1}{2n} \|\mathbf{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \alpha \|\boldsymbol{\beta}\|_1$. Há um fator $2n$ de diferença: um α que é forte num é desprezível no outro. Ao comparar as duas famílias na mesma grade, converta.

O notebook **Aula prática 02** percorre tudo isso com dados de verdade (`superconductivity.csv`, $p = 81$): mede o número de condição, exibe duas soluções distintas de MQO com o mesmo RSS quando $p > n$, levanta os caminhos de regularização e compara MQO, Ridge e Lasso.

Observação 5.1 (quando a regularização *não* ajuda). Vale saber de antemão o que você vai encontrar lá: com $n = 14884$ e $p = 81$, o MQO vai bem e o Lasso *não* melhora a predição — as amostras sobram para estimar 81 parâmetros com precisão. O ganho aparece em outro lugar: o Lasso entrega quase o mesmo desempenho (EQM de teste 318,8 contra 307,8) com 66 covariáveis em vez de 81. Já num recorte com $n = 40$, os papéis se invertem e a regularização ganha com folga. Regularizar não é sempre melhor; é melhor quando p é grande *em relação a* n .

Resumo

- Regressão linear: $g(\mathbf{x}) = \boldsymbol{\beta}^\top \mathbf{x}$, linear *nos parâmetros*; MQO $\hat{\boldsymbol{\beta}} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{y}$. Mesmo com o modelo errado, o MQO acerta o melhor preditor linear (Teo. 1.3).
- Em altas dimensões MQO tem variância alta (Fig. 1) e nem existe de forma única se $p > n$.
- Entre as medidas de complexidade, a ℓ_1 é a única que induz esparsidade e mantém o problema convexo.
- **Ridge** (ℓ_2): solução fechada, sempre única, encolhe sem zerar.
- **Lasso** (ℓ_1): faz seleção de variáveis pela geometria das quinas (Fig. 2) / *soft thresholding* (Fig. 3); a garantia teórica depende de p apenas como $\log p$.
- Ridge $\equiv$ priori gaussiana ($\lambda = \sigma^2 / \sigma_\beta^2$); Lasso $\equiv$ priori de Laplace ($\lambda = \sigma^2 \tau_\beta$).
- λ é *tuning parameter* (validação cruzada, Aula 03); sempre *padronize* as covariáveis.

Leitura recomendada. [AME] Capítulo 2 (§2.1 mínimos quadrados e o Teorema 2) e Capítulo 3 inteiro — em especial a Tabela 3.1 (as três normas), §3.3 (Lasso e a garantia do Teorema 3), §3.4 (Ridge), §3.5 (formulação com restrição), §3.6 (interpretação bayesiana) e §3.8 (o Exemplo 2.1 desta aula). [ISLP] Capítulo 3 (regressão linear) e Capítulo 6, §6.1 (seleção de subconjuntos) e §6.2 (*shrinkage*); a Figura 6.7 deles é a versão da nossa Figura 2, e a 6.10 é a nossa Figura 3.

Para praticar. Lista teorica 02.pdf e Lista prática 02.ipynb