Aula 02 — Regressão Linear e Regularização

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME cap. 2–3; ISLP cap. 3 e 6

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- escrever o modelo de regressão linear em forma matricial e deduzir o estimador de mínimos quadrados (MQO);
- explicar por que MQO falha (ou nem existe) em *altas dimensões* (p grande, ou $p > n$);
- descrever seleção de subconjuntos e regressão *stepwise*;
- definir as penalizações **Ridge** (ℓ_2) e **Lasso** (ℓ_1) e interpretá-las como controle do balanço viés–variância;
- explicar *por que o Lasso zera coeficientes* (esparsidade) e o Ridge não, com a intuição geométrica;
- reconhecer a interpretação bayesiana das duas penalizações.

Esta aula é a Aula 01 em ação. Lá vimos que existe um balanço viés–variância e que escolher um modelo é escolher um ponto nesse balanço. Aqui aprendemos a *mover esse ponto de propósito*, sem trocar de família de modelos: a regularização introduz viés deliberadamente para comprar uma redução maior de variância. Vamos começar pela pergunta que motiva tudo:

se eu tenho 50 covariáveis e 30 observações, o que acontece com os mínimos quadrados?

A resposta curta é "algo pior do que dar errado: ele dá *infinitas* respostas, todas com erro de treino zero". A Seção 2 explica por quê.

1 O modelo de regressão linear

Métodos **paramétricos** supõem que a função de predição é descrita por um número finito de parâmetros. A regressão linear usa

$$g(\boldsymbol{x}) = \boldsymbol{\beta}^\top \boldsymbol{x} = \beta_0 x_0 + \beta_1 x_1 + \cdots + \beta_p x_p, \qquad x_0 \equiv 1, \tag{1}$$

com $\boldsymbol{\beta} = (\beta_0, \ldots, \beta_p)$. É essencial notar que x_j *não* precisa ser uma covariável original: podemos criar atributos derivados (x_j^2, $x_j x_k$, $\log x_j$, etc.). Assim, "linear" refere-se à linearidade **nos parâmetros** $\boldsymbol{\beta}$, não nas variáveis — o modelo é muito mais flexível do que parece à primeira vista.

Ideia central

Você já usou isso na Aula 01 sem perceber. Ajustar um polinômio de grau 15 é ajustar uma *regressão linear* nas covariáveis $x, x^2, \ldots, x^{15}$. Tudo o que dissermos aqui sobre "muitas covariáveis" vale, portanto, também para "polinômio de grau alto".

1.1 Mínimos quadrados ordinários (MQO)

Estimamos $\boldsymbol{\beta}$ minimizando a soma dos quadrados dos resíduos (RSS):

$$\widehat{\boldsymbol{\beta}} = \arg\min_{\boldsymbol{\beta}} \sum_{i=1}^{n} \left(y_i - \boldsymbol{\beta}^\top \boldsymbol{x}_i\right)^2 = \arg\min_{\boldsymbol{\beta}} \|\boldsymbol{y} - \mathbb{X}\boldsymbol{\beta}\|^2 , \tag{2}$$

onde $\mathbb{X} \in \mathbb{R}^{n\times(p+1)}$ é a matriz de delineamento (linha i igual a $\boldsymbol{x}_i^\top$, com a coluna de 1s) e $\boldsymbol{y} = (y_1, \ldots, y_n)^\top$.

Proposição 1.1 (Equações normais)**.** *Se $\mathbb{X}^\top\mathbb{X}$ é invertível, o minimizador de (2) é*

$$\widehat{\boldsymbol{\beta}} = (\mathbb{X}^\top\mathbb{X})^{-1}\mathbb{X}^\top\boldsymbol{y}. \tag{3}$$

Demonstração. Seja $S(\boldsymbol{\beta}) = \|\boldsymbol{y} - \mathbb{X}\boldsymbol{\beta}\|^2 = \boldsymbol{y}^\top\boldsymbol{y} - 2\boldsymbol{\beta}^\top\mathbb{X}^\top\boldsymbol{y} + \boldsymbol{\beta}^\top\mathbb{X}^\top\mathbb{X}\boldsymbol{\beta}$. O gradiente é $\nabla S(\boldsymbol{\beta}) = -2\mathbb{X}^\top\boldsymbol{y} + 2\mathbb{X}^\top\mathbb{X}\boldsymbol{\beta}$. Igualando a zero obtêm-se as *equações normais* $\mathbb{X}^\top\mathbb{X}\boldsymbol{\beta} = \mathbb{X}^\top\boldsymbol{y}$; como a Hessiana $2\mathbb{X}^\top\mathbb{X}$ é semidefinida positiva, o ponto crítico é mínimo. Se $\mathbb{X}^\top\mathbb{X}$ é invertível, vale (3). □

Observação 1.2. $\widehat{\boldsymbol{\beta}}$ é o estimador de máxima verossimilhança sob o modelo $y_i = \boldsymbol{\beta}^\top\boldsymbol{x}_i + \varepsilon_i$, com $\varepsilon_i \sim N(0, \sigma^2)$ i.i.d. A predição é $\widehat{r}(\boldsymbol{x}) = \widehat{\boldsymbol{\beta}}^\top\boldsymbol{x}$. Sob o modelo linear correto, MQO é o melhor estimador linear não-viesado (Gauss–Markov).

1.2 E quando a linearidade é falsa?

Quase sempre é. Vale então perguntar o que o MQO estima quando $r(\boldsymbol{x})$ *não* é linear — e a resposta é tranquilizadora.

Teorema 1.3 (MQO converge para o melhor preditor linear)**.** *Seja $\boldsymbol{\beta}^* = \arg\min_{\boldsymbol{\beta}} \mathbb{E}[(y - \boldsymbol{\beta}^\top\boldsymbol{x})^2]$ o **melhor preditor linear** (o "oráculo"), e suponha $\Sigma = \mathbb{E}[\boldsymbol{x}\boldsymbol{x}^\top]$ bem definida. Então, quando $n \to \infty$,*

$$\widehat{\boldsymbol{\beta}} \xrightarrow{P} \boldsymbol{\beta}^* \qquad e \qquad R(g_{\widehat{\boldsymbol{\beta}}}) \xrightarrow{P} R(g_{\boldsymbol{\beta}^*}).$$

Esboço. Minimizando $\mathbb{E}[(y - \boldsymbol{\beta}^\top\boldsymbol{x})^2]$ obtém-se $\boldsymbol{\beta}^* = \Sigma^{-1}\boldsymbol{\alpha}$, com $\alpha_j = \mathbb{E}[yX_j]$. O estimador se escreve na mesma forma, $\widehat{\boldsymbol{\beta}} = \widehat{\Sigma}^{-1}\widehat{\boldsymbol{\alpha}}$, com $\widehat{\Sigma} = n^{-1}\sum_i \boldsymbol{x}_i\boldsymbol{x}_i^\top$ e $\widehat{\alpha}_j = n^{-1}\sum_i y_i X_{i,j}$. Pela lei dos grandes números $\widehat{\Sigma} \to \Sigma$ e $\widehat{\boldsymbol{\alpha}} \to \boldsymbol{\alpha}$; o teorema de Mann–Wald transporta a convergência através da função contínua $(\Sigma, \boldsymbol{\alpha}) \mapsto \Sigma^{-1}\boldsymbol{\alpha}$, e de novo através de $\boldsymbol{\beta} \mapsto R(g_\beta)$. □

Ideia central

Traduzindo: mesmo com o modelo "errado", o MQO acerta *a melhor aproximação linear possível* de r — a projeção de Y no espaço gerado pelas covariáveis. O viés que sobra não é culpa do estimador, é culpa da classe de modelos escolhida. Por isso ampliar o conjunto de atributos (incluir x^2, interações) reduz esse viés de especificação — ao custo de aumentar p, que é exatamente o problema da próxima seção.

2 O problema das altas dimensões

Quando p é grande relativamente a n, o MQO esbarra em três limitações:

1. **Variância alta.** Quanto mais parâmetros, maior $\mathrm{Var}(\widehat{\boldsymbol{\beta}})$ — o modelo superajusta (Aula 01). A matriz $\mathrm{Var}(\widehat{\boldsymbol{\beta}}) = \sigma^2(\mathbb{X}^\top\mathbb{X})^{-1}$ "explode" quando as colunas de $\mathbb{X}$ são quase colineares.

2. **Não unicidade.** Se $p > n$, então $\mathbb{X}^\top\mathbb{X}$ é singular e (3) *não tem solução única*: há infinitos $\boldsymbol{\beta}$ com RSS nulo (superajuste perfeito).

3. **Interpretabilidade.** Muitas covariáveis irrelevantes dificultam a leitura do modelo.

Vale ver a primeira delas acontecer. Fixe $n = 60$ observações e vá aumentando p, com apenas 5 covariáveis de fato relevantes e o resto puro ruído (Figura 1).

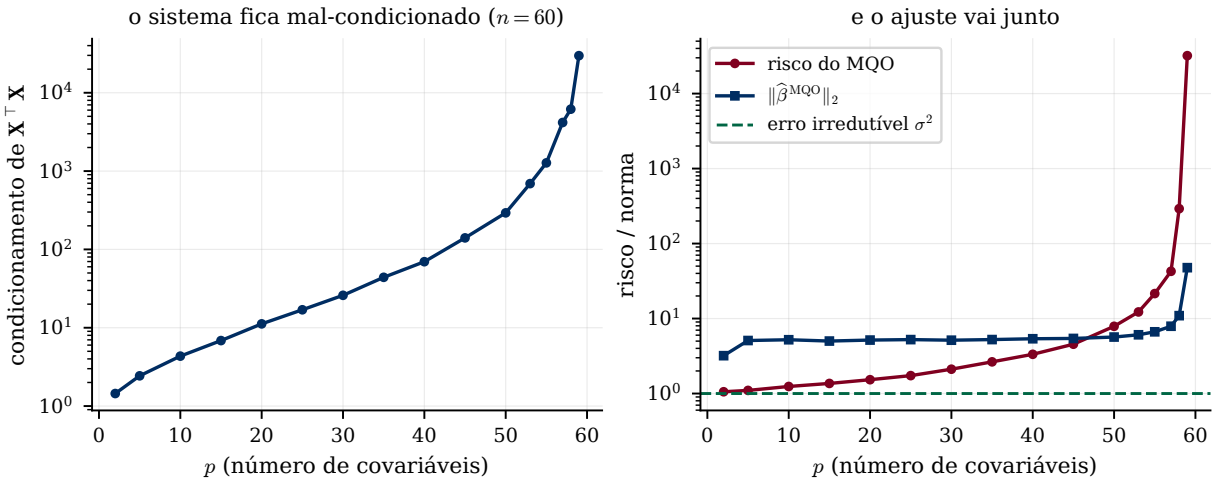


Figura 1: Com $n = 60$ fixo e p crescendo. À esquerda, o número de condição de $\mathbb{X}^\top\mathbb{X}$ — a razão entre seu maior e seu menor autovalor — sai de 1,4 e chega a 3×10^4: inverter essa matriz vira uma operação numericamente delicada. À direita, a consequência: o risco do MQO sai de 1,0 (o próprio σ^2, ou seja, praticamente perfeito) e passa de 10^4. O modelo não ficou "um pouco pior"; ele ficou inútil.

Atenção: o caso $p > n$ é qualitativamente diferente

Repare que os problemas 1 e 2 não são o mesmo. Se $p < n$ mas as colunas são quase colineares, a solução *existe e é única*, só que instável. Se $p > n$, ela nem é única: o núcleo de $\mathbb{X}$ tem dimensão $\geq p - n$, e somar a $\widehat{\boldsymbol{\beta}}$ qualquer vetor desse núcleo dá *outra* solução com exatamente o mesmo RSS nulo. O erro de treino não distingue entre elas, e não há nada nos dados que justifique preferir uma. A regularização, entre outras coisas, serve para desempatar.

A resposta é **reduzir a complexidade efetiva**: ou selecionando um subconjunto de covariáveis, ou *encolhendo* os coeficientes (regularização).

2.1 Seleção de subconjuntos e *stepwise*

Melhor subconjunto
: ajusta-se o modelo para *todos* os 2^p subconjuntos de covariáveis e escolhe-se o melhor segundo um critério que penaliza complexidade (AIC, BIC) ou via validação cruzada. Inviável para p moderado (2^p explode).

Forward stepwise
: começa com o modelo vazio e adiciona, a cada passo, a covariável que mais reduz o RSS, até um critério de parada.

Backward stepwise
: começa com o modelo completo e remove, a cada passo, a covariável menos útil (exige $n > p$).

A economia do *stepwise* é enorme: ele examina $1 + p(p+1)/2$ modelos em vez de 2^p. Para $p = 20$ isso é 211 contra 1 048 576; para $p = 40$, 821 contra mais de 10^{12}.

Exemplo 2.1 (Quanto isso custa, na prática)**.** O [AME] simula $n = 500$ observações de $Y = 3X_1 - 2X_2 + X_3 - 3X_4 + X_5 + \sum_{i=6}^{20} 0 \cdot X_i + \varepsilon$, com $\varepsilon \sim N(0; 0{,}5^2)$: apenas 5 das 20 covariáveis importam. Os resultados:

Método	**Variáveis selecionadas**	**Tempo**	**Risco estimado**
Mín. quadrados	todas	0,002 s	14,63
Melhor subconj. (AIC)	$x_1..x_5, x_{10}, x_{12}, x_{13}, x_{19}, x_{20}$	1 h 20 min	0,30
Forward stepwise	$x_1..x_5, x_{10}, x_{12}, x_{13}, x_{19}, x_{20}$	0,46 s	0,30
Ridge	todas	0,16 s	0,33
Lasso	$x_1, \ldots, x_5$	0,08 s	**0,25**

Três leituras. Primeira: o MQO com todas as variáveis tem risco *cinquenta vezes* maior que o Lasso — as 15 covariáveis nulas destroem o modelo. Segunda: o *forward stepwise* encontrou exatamente o mesmo modelo do melhor subconjunto em 0,46 segundos em vez de 1h20; a heurística gananciosa saiu de graça aqui. Terceira: o Lasso foi o mais rápido *e* o único a recuperar precisamente $\{x_1, \ldots, x_5\}$.

Atenção

Critérios como AIC/BIC ($\widehat{R} \approx \text{EQM} + P(g)$, com $P(g) = 2p\,\widehat{\sigma}^2/n$ no AIC) estimam o risco *corrigindo* o otimismo do erro de treino. Mas seleção *stepwise* é gananciosa (não examina todos os modelos) e a inferência clássica "pós-seleção" fica inválida: os p-valores reportados ignoram que o modelo foi escolhido olhando os dados. Um p-valor de 0,01 numa variável que sobreviveu a uma triagem entre 20 candidatas não significa o que a tabela diz que significa.

3 Regularização: encolhendo coeficientes

A ideia da regularização (ou *penalização*, ou *shrinkage*) é adicionar ao RSS um termo que penaliza coeficientes grandes, desencorajando o superajuste:

$$\widehat{\boldsymbol{\beta}}_{\text{pen}} = \arg\min_{\boldsymbol{\beta}} \Big\{ \|\boldsymbol{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \lambda\, \text{Pen}(\boldsymbol{\beta}) \Big\}.$$

O hiperparâmetro $\lambda \geq 0$ controla a intensidade: $\lambda = 0$ recupera MQO; $\lambda \to \infty$ força $\boldsymbol{\beta} \to 0$. **λ é escolhido por validação cruzada** (Aula 03).

Ideia central

Regularizar = introduzir *viés* de propósito para reduzir *variância*. Sob p grande, o ganho na variância supera a perda no viés e o risco total cai. É a Aula 01 em ação.

3.1 Qual medida de complexidade?

Antes das fórmulas, vale escolher *como medir* o tamanho de $\boldsymbol{\beta}$. Há três candidatas naturais, e a comparação entre elas explica por que o Lasso é o que é:

$\boldsymbol{\beta}$ (com $p = 10$)	$\sum_j \mathbf{1}\{\beta_j \neq 0\}$ (ℓ_0)	$\sum_j \lvert\beta_j\rvert$ (ℓ_1)	$\sum_j \beta_j^2$ (ℓ_2)
$(0, 0, \ldots, 0)$	0	0,0	0
$(0{,}1; 0{,}1; \ldots; 0{,}1)$	10	1,0	0,1
$(1, 1, \ldots, 1)$	10	10,0	10

Compare as linhas 1 e 2: os dois modelos fazem predições quase idênticas, mas a norma ℓ_0 salta de 0 para 10 — ela é *descontínua*, uma mudança infinitesimal nos coeficientes muda a penalização ao máximo. Compare agora as linhas 2 e 3: as predições são *muito* diferentes, e ainda assim a ℓ_0 dá o mesmo valor 10 para as duas. A norma ℓ_0 é, ao mesmo tempo, sensível demais e insensível demais.

Ideia central

A norma ℓ_1 é o melhor dos dois mundos: como a ℓ_0, ela é pequena para vetores com muitos zeros — e por isso induz esparsidade; ao contrário da ℓ_0, ela varia *continuamente* com $\boldsymbol{\beta}$, o que torna o problema convexo e resolúvel em milissegundos. Não é exagero dizer que o Lasso existe porque a ℓ_1 é a relaxação convexa da ℓ_0.

3.2 Regressão Ridge (ℓ_2)

$$\widehat{\boldsymbol{\beta}}^{\,\text{ridge}} = \arg\min_{\boldsymbol{\beta}} \Big\{ \|\boldsymbol{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \lambda \sum_{j=1}^{p} \beta_j^2 \Big\}. \tag{4}$$

A grande vantagem é a solução fechada:

$$\widehat{\boldsymbol{\beta}}^{\,\text{ridge}} = (\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I}_0)^{-1} \mathbb{X}^\top \boldsymbol{y}, \tag{5}$$

onde $\mathbb{I}_0$ é a identidade $(p+1) \times (p+1)$ *com o primeiro elemento trocado por zero* — é assim que se deixa o intercepto β_0 fora da penalização. (Faz sentido: penalizar β_0 tornaria a solução dependente de onde você pôs a origem de Y.)

Proposição 3.1 (Ridge sempre tem solução única)**.** *Para todo $\lambda > 0$, a matriz $\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I}$ é definida positiva (logo invertível), mesmo quando $p > n$.*

Demonstração. Para qualquer $\boldsymbol{v} \neq 0$, $\boldsymbol{v}^\top (\mathbb{X}^\top \mathbb{X} + \lambda \mathbb{I}) \boldsymbol{v} = \|\mathbb{X}\boldsymbol{v}\|^2 + \lambda \|\boldsymbol{v}\|^2 \geq \lambda \|\boldsymbol{v}\|^2 > 0.$ □

Eis a primeira virtude do Ridge: *estabiliza* o problema mal-condicionado das altas dimensões. Note que a demonstração é exatamente o antídoto para a Figura 1: somar λ à diagonal levanta o menor autovalor de $\mathbb{X}^\top \mathbb{X}$ de perto de zero para pelo menos λ, e o número de condição desaba. Os coeficientes são encolhidos suavemente em direção a zero, mas em geral **nenhum é exatamente zero**.

3.3 O Lasso (ℓ_1)

$$\widehat{\boldsymbol{\beta}}^{\,\text{lasso}} = \arg\min_{\boldsymbol{\beta}} \Big\{ \|\boldsymbol{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \lambda \sum_{j=1}^{p} |\beta_j| \Big\}. \tag{6}$$

Trocamos a norma ℓ_2 pela ℓ_1. Não há solução fechada (o termo $|\beta_j|$ não é diferenciável em 0), mas o problema é convexo e resolvido eficientemente (*coordinate descent*, LARS). A propriedade marcante:

Ideia central

O Lasso faz **seleção de variáveis**: para λ grande o suficiente, vários $\widehat{\beta}_j$ são *exatamente* zero. Obtemos um modelo *esparso* e interpretável de graça — ao contrário do Ridge.

Observação 3.2 (Por que o Lasso aguenta p enorme)**.** Greenshtein e Ritov (2004) mostram que, sob condições de limitação, o Lasso com restrição $\|\boldsymbol{\beta}\|_1 \le L$ satisfaz, com probabilidade $\ge 1-\delta$,

$$R(g_{\widehat{\beta}_L}) - R(g_{\beta_L^*}) \;\le\; \sqrt{\frac{16(L+1)^4 B^2}{n}\,\log\!\Big(\frac{2p}{\delta}\Big)}.$$

O detalhe que importa é onde o p aparece: dentro de um **logaritmo**. Dobrar o número de covariáveis quase não muda a garantia — é por isso que o Lasso funciona com milhares de covariáveis e n modesto, situação em que o MQO nem está definido.

Por que o Lasso zera coeficientes e o Ridge não?

Ambos têm a formulação equivalente *com restrição*: para cada λ existe um orçamento t tal que resolver (6) é o mesmo que resolver

$$\min_{\boldsymbol{\beta}} \|\boldsymbol{y}-\mathbb{X}\boldsymbol{\beta}\|^2 \quad \text{sujeito a} \quad \underbrace{\textstyle\sum_j |\beta_j| \le t}_{\text{Lasso}} \quad \text{ou} \quad \underbrace{\textstyle\sum_j \beta_j^2 \le t^2}_{\text{Ridge}}.$$

Nessa forma a geometria fica visível. As curvas de nível do RSS são *elipses* concêntricas centradas em $\widehat{\boldsymbol{\beta}}^{\text{MQO}}$ — e são elipses *alongadas* quando as covariáveis são correlacionadas, porque nessa direção dá para aumentar um coeficiente e diminuir o outro quase sem alterar o ajuste. A solução penalizada é o ponto onde a menor elipse possível *toca* a região permitida. E aí a forma da região decide tudo: a bola do Ridge é lisa, então o contato se dá num ponto genérico; o losango do Lasso tem *quinas sobre os eixos*, e é muito fácil que o toque aconteça justamente numa quina — onde algum β_j é exatamente zero.

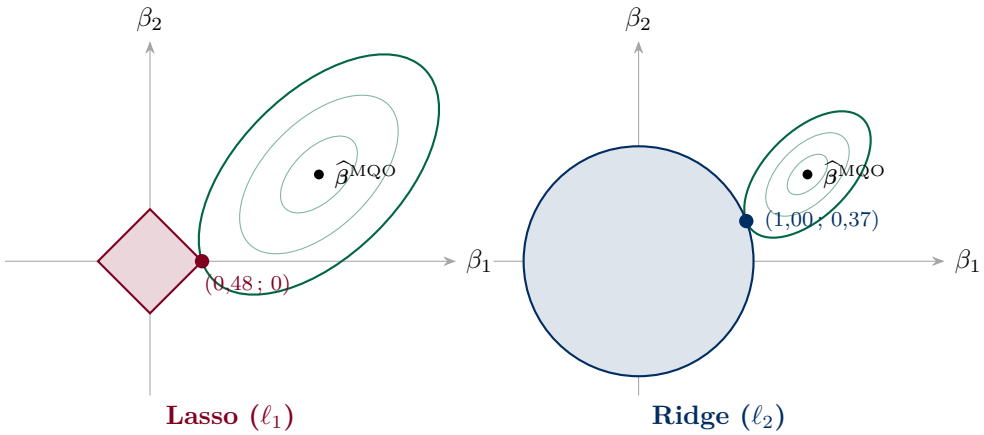


Figura 2: A geometria da esparsidade, com números de um ajuste real ($n = 60$, duas covariáveis padronizadas com correlação $-0{,}50$). Em verde, curvas de nível do RSS, centradas em $\widehat{\boldsymbol{\beta}}^{\text{MQO}} = (1{,}573\,;\,0{,}808)$ e alongadas porque as covariáveis são correlacionadas. Em cor, a região permitida. A solução é o ponto onde a menor elipse *toca* a região. À esquerda, o toque cai na **quina** do losango e β_2 sai exatamente zero; à direita, o círculo não tem quina, o toque acontece num ponto qualquer da borda e os dois coeficientes sobrevivem — apenas encolhidos. Os orçamentos t dos dois painéis são diferentes (cada método com o seu); o que se compara aqui é a *forma* da região, não o seu tamanho.

Atenção

Perceba que a esparsidade do Lasso é um acidente *feliz* da geometria, e não uma regra infalível. Se a elipse estivesse orientada de outro jeito — por exemplo, se $\widehat{\boldsymbol{\beta}}^{\text{MQO}}$ estivesse perto da diagonal —, o toque cairia numa aresta e nenhum coeficiente seria zerado. Em dimensão p, porém, o losango tem $2p$ quinas e 2^p faces de dimensão baixa, e a chance de acertar alguma cresce depressa. É por isso que "o Lasso zera coeficientes" é uma afirmação sobre o comportamento *típico*, não um teorema.

Exemplo 3.3 (Caso ortonormal: fórmulas explícitas)**.** Quando $\mathbb{X}^\top\mathbb{X} = \mathbb{I}$, os estimadores têm forma fechada em função do MQO $\widehat{\beta}_j$:

$$\widehat{\beta}_j^{\text{ridge}} = \frac{\widehat{\beta}_j}{1+\lambda}, \qquad \widehat{\beta}_j^{\text{lasso}} = \operatorname{sinal}(\widehat{\beta}_j)\,\big(\,\big|\widehat{\beta}_j\big| - \tfrac{\lambda}{2}\big)_+.$$

O Ridge *multiplica* por um fator < 1 (encolhe proporcionalmente, nunca zera); o Lasso *subtrai* uma constante e trunca em zero (*soft thresholding*) — por isso anula os pequenos.

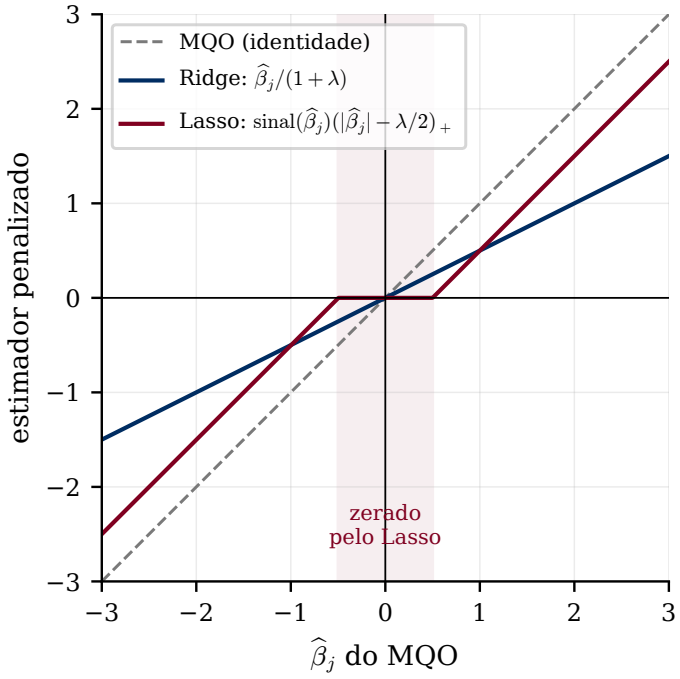


Figura 3: As duas fórmulas do caso ortonormal, com $\lambda = 1$. O Ridge é uma reta pela origem de inclinação $1/(1+\lambda)$: encolhe *proporcionalmente*, e quanto maior o coeficiente, maior o encolhimento em valor absoluto. O Lasso é paralelo à identidade, deslocado de $\lambda/2$: encolhe todo mundo pela *mesma quantidade* — e quem era menor que $\lambda/2$ em módulo (a faixa sombreada) não sobrevive ao deslocamento e vira exatamente zero.

3.4 Interpretação bayesiana

Ambas as penalizações são o *logaritmo de uma priori* sobre $\boldsymbol{\beta}$. Suponha $Y_i \mid \boldsymbol{x}_i, \boldsymbol{\beta} \sim N(\boldsymbol{\beta}^\top \boldsymbol{x}_i, \sigma^2)$ independentes, com σ^2 conhecido. Então:

- se $\boldsymbol{\beta} \sim N(0, \sigma_\beta^2 \mathbb{I})$, a **moda a posteriori** de $\boldsymbol{\beta}$ é exatamente a solução Ridge (4) com $\lambda = \sigma^2/\sigma_\beta^2$;

- se $\beta_1, \ldots, \beta_p \overset{\text{i.i.d.}}{\sim} \text{Laplace}(0, \tau_\beta)$, a moda a posteriori é exatamente a solução Lasso (6) com $\lambda = \sigma^2 \tau_\beta$.

A priori de Laplace é mais "pontuda" em zero e tem caudas mais pesadas: ela favorece soluções com muitos coeficientes *nulos* e alguns grandes — exatamente a esparsidade observada.

Ideia central: uma leitura filosófica

Sob essa ótica, λ *é* a priori: quanto menor a dispersão que você atribui a $\boldsymbol{\beta}$ a priori, maior o λ e mais encolhidas as estimativas. Escolher λ por validação cruzada equivale, então, a **escolher a distribuição a priori que prediz melhor** — usar a maquinaria bayesiana como motivação para estimadores melhores, sem necessariamente comprar a interpretação subjetiva.

Atenção

Uma sutileza que o [ISLP] faz questão de registrar: no caso Ridge a solução é a moda *e* a média a posteriori. No caso Lasso ela é só a **moda** — a média a posteriori do Lasso *não* é esparsa. A esparsidade é uma propriedade daquele ponto específico da distribuição, não da distribuição inteira.

Atenção

Como as penalizações somam β_j^2 ou $|\beta_j|$, elas **dependem da escala** das covariáveis. *Sempre padronize* (média 0, variância 1) antes de aplicar Ridge/Lasso, caso contrário variáveis em unidades grandes são penalizadas de menos. Repare que o MQO *não* tem esse problema: trocar metros por centímetros só divide o coeficiente por 100 e a predição fica igual. Com penalização isso deixa de valer, porque o termo $\lambda \sum \beta_j^2$ enxerga a mudança. Isso conecta diretamente com a Aula 06 (*pipelines* e `StandardScaler`).

4 Caminhos de regularização

Como λ varre $[0, \infty)$, cada $\widehat{\beta}_j$ traça uma curva. Pôr todas num gráfico — o **caminho de regularização** — é a melhor forma de ver a diferença entre os dois métodos de uma vez só (Figura 4).

Atenção: o λ que melhor prediz não é o que melhor seleciona

Uma armadilha que aparece assim que você roda `LassoCV` num problema real: a validação cruzada escolhe λ para *predizer* bem, e o λ ótimo para predição costuma ser *menor* do que o ótimo para seleção. O resultado é um modelo que prediz muito bem mas mantém coeficientes minúsculos e não nulos em várias covariáveis irrelevantes — falsos positivos. Se o seu objetivo é *descobrir quais* variáveis importam, e não só predizer, olhe o caminho inteiro e compare as *magnitudes*: as relevantes costumam estar ordens de grandeza acima do resto.

5 Prática em Python

Em `scikit-learn`, as três variantes seguem a mesma interface; o `alpha` é o nosso λ. Note a padronização *dentro* do *pipeline* (Aula 06) para evitar vazamento.

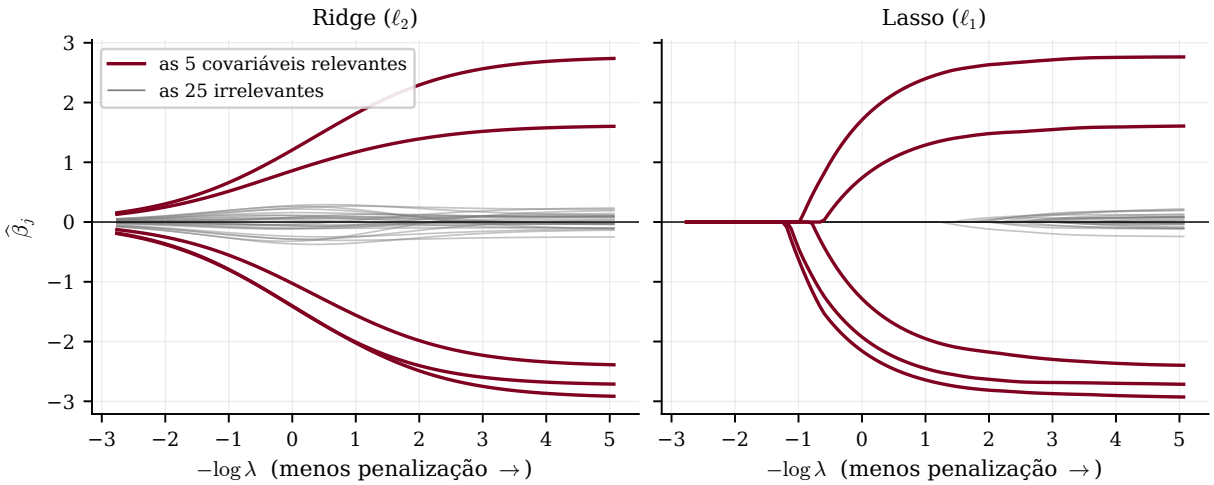


Figura 4: Coeficientes em função da penalização, num problema com $n = 80$, $p = 30$ e apenas 5 covariáveis relevantes. À esquerda o Ridge: todos os 30 coeficientes saem de zero *juntos* e crescem suavemente — em nenhum momento algum deles é exatamente nulo. À direita o Lasso: os coeficientes ficam *grudados no zero* e vão sendo "ligados" um a um conforme a penalização afrouxa; as 5 covariáveis relevantes (em vinho) entram primeiro, muito antes das 25 irrelevantes (em cinza). É esse comportamento de liga-desliga que chamamos de seleção de variáveis.

```python
from sklearn.linear_model import LinearRegression, Ridge, Lasso, LassoCV
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import make_pipeline

# Lasso com lambda escolhido por validacao cruzada
modelo = make_pipeline(StandardScaler(),
                       LassoCV(cv=5, random_state=0))
modelo.fit(X_tr, y_tr)

lasso = modelo.named_steps["lassocv"]
print("lambda escolhido:", lasso.alpha_)
print("coeficientes nao-nulos:", (lasso.coef_ != 0).sum(), "de", X.shape[1])
```

Atenção: um detalhe de escala que já custou caro a muita gente

As classes do `scikit-learn` **não** usam a mesma normalização. `Ridge` minimiza $\|\boldsymbol{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \alpha\,\|\boldsymbol{\beta}\|^2$, enquanto `Lasso` e `ElasticNet` minimizam $\frac{1}{2n}\,\|\boldsymbol{y} - \mathbb{X}\boldsymbol{\beta}\|^2 + \alpha\,\|\boldsymbol{\beta}\|_1$. Há um fator $2n$ de diferença: um α que é forte num é desprezível no outro. Ao comparar as duas famílias na mesma grade, converta.

O notebook `Aula prática 02` percorre tudo isso com dados de verdade (`superconductivity.csv`, $p = 81$): mede o número de condição, exibe duas soluções distintas de MQO com o mesmo RSS quando $p > n$, levanta os caminhos de regularização e compara MQO, Ridge e Lasso.

Observação 5.1 (quando a regularização *não* ajuda)**.** Vale saber de antemão o que você vai encontrar lá: com $n = 14\,884$ e $p = 81$, o MQO vai bem e o Lasso *não* melhora a predição — as amostras sobram para estimar 81 parâmetros com precisão. O ganho aparece em outro lugar: o Lasso entrega quase o mesmo desempenho (EQM de teste 318,8 contra 307,8) com 66 covariáveis em vez de 81. Já num recorte com $n = 40$, os papéis se invertem e a regularização ganha com folga. Regularizar não é sempre melhor; é melhor quando p é grande *em relação a* n.

Resumo

- Regressão linear: $g(\boldsymbol{x}) = \boldsymbol{\beta}^\top \boldsymbol{x}$, linear *nos parâmetros*; MQO $\widehat{\boldsymbol{\beta}} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \boldsymbol{y}$. Mesmo com o modelo errado, o MQO acerta o melhor preditor linear (Teo. 1.3).
- Em altas dimensões MQO tem variância alta (Fig. 1) e nem existe de forma única se $p > n$.
- Entre as medidas de complexidade, a ℓ_1 é a única que induz esparsidade *e* mantém o problema convexo.
- **Ridge** (ℓ_2): solução fechada, sempre única, encolhe sem zerar.
- **Lasso** (ℓ_1): faz seleção de variáveis pela geometria das quinas (Fig. 2) / *soft thresholding* (Fig. 3); a garantia teórica depende de p apenas como $\log p$.
- Ridge $\equiv$ priori gaussiana ($\lambda = \sigma^2/\sigma_\beta^2$); Lasso $\equiv$ priori de Laplace ($\lambda = \sigma^2 \tau_\beta$).
- λ é *tuning parameter* (validação cruzada, Aula 03); sempre *padronize* as covariáveis.

Leitura recomendada. [AME] Capítulo 2 (§2.1 mínimos quadrados e o Teorema 2) e Capítulo 3 inteiro — em especial a Tabela 3.1 (as três normas), §3.3 (Lasso e a garantia do Teorema 3), §3.4 (Ridge), §3.5 (formulação com restrição), §3.6 (interpretação bayesiana) e §3.8 (o Exemplo 2.1 desta aula). [ISLP] Capítulo 3 (regressão linear) e Capítulo 6, §6.1 (seleção de subconjuntos) e §6.2 (*shrinkage*); a Figura 6.7 deles é a versão da nossa Figura 2, e a 6.10 é a nossa Figura 3.