

Aula 02 — Regressão Linear e Regularização

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME cap. 2–3; ISLP cap. 3 e 6

Objetivos da aula

Ao final desta aula o aluno deve ser capaz de:

- escrever o modelo de regressão linear em forma matricial e deduzir o estimador de mínimos quadrados (MQO);
- explicar por que MQO falha (ou nem existe) em *altas dimensões* (d grande, ou $d > n$);
- descrever seleção de subconjuntos e regressão *stepwise*;
- definir as penalizações **Ridge** (ℓ_2) e **Lasso** (ℓ_1) e interpretá-las como controle do balanço viés–variância;
- explicar *por que o Lasso zera coeficientes* (esparsidade) e o Ridge não, com a intuição geométrica;
- reconhecer a interpretação bayesiana das duas penalizações.

Em sala

Conexão com a Aula 01: regressão linear é o método *paramétrico* mais simples — baixa variância, possivelmente alto viés. Regularização é a ferramenta para *mover o ponto* no balanço viés–variância sem trocar de família de modelos. Pergunta de abertura: “se eu tenho 50 covariáveis e 30 observações, o que acontece com os mínimos quadrados?”

1 O modelo de regressão linear

Métodos **paramétricos** supõem que a função de predição é descrita por um número finito de parâmetros. A regressão linear usa

$$g(\mathbf{x}) = \boldsymbol{\beta}^\top \mathbf{x} = \beta_0 x_0 + \beta_1 x_1 + \cdots + \beta_d x_d, \quad x_0 \equiv 1, \quad (1)$$

com $\boldsymbol{\beta} = (\beta_0, \dots, \beta_d)$. É essencial notar que x_j *não* precisa ser uma covariável original: podemos criar atributos derivados (x_j^2 , $x_j x_k$, $\log x_j$, etc.). Assim, “linear” refere-se à linearidade **nos parâmetros** $\boldsymbol{\beta}$, não nas variáveis — o modelo é muito mais flexível do que parece à primeira vista.

1.1 Mínimos quadrados ordinários (MQO)

Estimamos $\boldsymbol{\beta}$ minimizando a soma dos quadrados dos resíduos (RSS):

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta}} \sum_{i=1}^n (Y_i - \boldsymbol{\beta}^\top \mathbf{X}_i)^2 = \arg \min_{\boldsymbol{\beta}} \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2, \quad (2)$$

onde $\mathbf{X} \in \mathbb{R}^{n \times (d+1)}$ é a matriz de delineamento (linha i igual a $\mathbf{X}_i^\top$, com a coluna de 1s) e $\mathbf{Y} = (Y_1, \dots, Y_n)^\top$.

Proposição 1.1 (Equações normais). Se $\mathbf{X}^\top \mathbf{X}$ é invertível, o minimizador de (2) é

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}. \quad (3)$$

Demonstração. Seja $S(\beta) = \|\mathbf{Y} - \mathbf{X}\beta\|^2 = \mathbf{Y}^\top \mathbf{Y} - 2\beta^\top \mathbf{X}^\top \mathbf{Y} + \beta^\top \mathbf{X}^\top \mathbf{X} \beta$. O gradiente é $\nabla S(\beta) = -2\mathbf{X}^\top \mathbf{Y} + 2\mathbf{X}^\top \mathbf{X} \beta$. Igualando a zero obtêm-se as *equações normais* $\mathbf{X}^\top \mathbf{X} \beta = \mathbf{X}^\top \mathbf{Y}$; como a Hessiana $2\mathbf{X}^\top \mathbf{X}$ é semidefinida positiva, o ponto crítico é mínimo. Se $\mathbf{X}^\top \mathbf{X}$ é invertível, vale (3). $\square$

Observação 1.2. $\hat{\beta}$ é o estimador de máxima verossimilhança sob o modelo $Y_i = \beta^\top \mathbf{X}_i + \varepsilon_i$, com $\varepsilon_i \sim N(0, \sigma^2)$ i.i.d. A predição é $\hat{r}(\mathbf{x}) = \hat{\beta}^\top \mathbf{x}$. Sob o modelo linear correto, MQO é o melhor estimador linear não-viesado (Gauss–Markov).

Observação 1.3 (Quando a linearidade falha). Mesmo quando $r(\mathbf{x})$ não é linear, MQO estima a *melhor aproximação linear* de r (a projeção de Y no espaço gerado pelas covariáveis). Por isso, ampliar o conjunto de atributos (§4.1, bases) é uma forma de reduzir esse viés de especificação.

2 O problema das altas dimensões

Quando d é grande relativamente a n , o MQO sofre de três males:

1. **Variância alta.** Quanto mais parâmetros, maior $\text{Var}(\hat{\beta})$ — o modelo superajusta (Aula 01). A matriz $\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$ “explode” quando as colunas de $\mathbf{X}$ são quase colineares.
2. **Não unicidade.** Se $d > n$, então $\mathbf{X}^\top \mathbf{X}$ é singular e (3) *não tem solução única*: há infinitos β com RSS nulo (superajuste perfeito).
3. **Interpretabilidade.** Muitas covariáveis irrelevantes dificultam a leitura do modelo.

A resposta é **reduzir a complexidade efetiva**: ou selecionando um subconjunto de covariáveis, ou *encolhendo* os coeficientes (regularização).

2.1 Seleção de subconjuntos e *stepwise*

Melhor subconjunto

ajusta-se o modelo para *todos* os 2^d subconjuntos de covariáveis e escolhe-se o melhor segundo um critério que penaliza complexidade (AIC, BIC) ou via validação cruzada. Inviável para d moderado (2^d explode).

Forward stepwise

começa com o modelo vazio e adiciona, a cada passo, a covariável que mais reduz o RSS, até um critério de parada.

Backward stepwise

começa com o modelo completo e remove, a cada passo, a covariável menos útil (exige $n > d$).

Atenção

Critérios como AIC/BIC ($\hat{R} \approx \text{EQM} + P(g)$, com $P(g) \propto p/\hat{\sigma}^2$) estimam o risco *corrigindo* o otimismo do erro de treino. Mas seleção *stepwise* é gananciosa (não examina todos os modelos) e a inferência clássica “pós-seleção” fica inválida: os p -valores reportados ignoram que o modelo foi escolhido olhando os dados.

3 Regularização: encolhendo coeficientes

A ideia da regularização (ou *penalização*, ou *shrinkage*) é adicionar ao RSS um termo que penaliza coeficientes grandes, desencorajando o superajuste:

$$\hat{\beta}_{\text{pen}} = \arg \min_{\beta} \left\{ \|\mathbf{Y} - \mathbf{X}\beta\|^2 + \lambda \text{Pen}(\beta) \right\}.$$

O hiperparâmetro $\lambda \geq 0$ controla a intensidade: $\lambda = 0$ recupera MQO; $\lambda \rightarrow \infty$ força $\beta \rightarrow 0$. λ é escolhido por validação cruzada (Aula 03).

Ideia central

Regularizar = introduzir *viés* de propósito para reduzir *variância*. Sob d grande, o ganho na variância supera a perda no viés e o risco total cai. É a Aula 01 em ação.

3.1 Regressão Ridge (ℓ_2)

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \|\mathbf{Y} - \mathbf{X}\beta\|^2 + \lambda \sum_{j=1}^d \beta_j^2 \right\}. \quad (4)$$

(O intercepto β_0 em geral não é penalizado.) A grande vantagem é a solução fechada:

$$\hat{\beta}^{\text{ridge}} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{Y}. \quad (5)$$

Proposição 3.1 (Ridge sempre tem solução única). *Para todo $\lambda > 0$, a matriz $\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}$ é definida positiva (logo invertível), mesmo quando $d > n$.*

Demonstração. Para qualquer $\mathbf{v} \neq 0$, $\mathbf{v}^\top (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}) \mathbf{v} = \|\mathbf{X}\mathbf{v}\|^2 + \lambda \|\mathbf{v}\|^2 \geq \lambda \|\mathbf{v}\|^2 > 0$. $\square$

Eis a primeira virtude do Ridge: *estabiliza* o problema mal-condicionado das altas dimensões. Os coeficientes são encolhidos suavemente em direção a zero, mas em geral **nenhum é exatamente zero**.

3.2 O Lasso (ℓ_1)

$$\hat{\beta}^{\text{lasso}} = \arg \min_{\beta} \left\{ \|\mathbf{Y} - \mathbf{X}\beta\|^2 + \lambda \sum_{j=1}^d |\beta_j| \right\}. \quad (6)$$

Trocamos a norma ℓ_2 pela ℓ_1 . Não há solução fechada (o termo $|\beta_j|$ não é diferenciável em 0), mas o problema é convexo e resolvido eficientemente (*coordinate descent*, LARS). A propriedade marcante:

Ideia central

O Lasso faz **seleção de variáveis**: para λ grande o suficiente, vários $\hat{\beta}_j$ são *exatamente* zero. Obtemos um modelo *esparso* e interpretável de graça — ao contrário do Ridge.

Por que o Lasso zera coeficientes e o Ridge não?

Ambos têm a formulação equivalente *com restrição*:

$$\min_{\beta} \|\mathbf{Y} - \mathbf{X}\beta\|^2 \quad \text{sujeito a} \quad \underbrace{\sum_j |\beta_j| \leq t}_{\text{Lasso}} \quad \text{ou} \quad \underbrace{\sum_j \beta_j^2 \leq t}_{\text{Ridge}}.$$

Geometricamente, minimizamos uma forma quadrática (elipses de RSS centradas em $\hat{\beta}^{\text{MQO}}$) restrita a uma região. A região do Ridge é uma *bola* (suave: a solução quase nunca toca um eixo); a do Lasso é um *losango* com *quinas sobre os eixos* — e as elipses tendem a tocar a restrição exatamente numa quina, onde algum $\beta_j = 0$. Daí a esparsidade.

Exemplo 3.2 (Caso ortonormal: fórmulas explícitas). Quando $\mathbf{X}^\top \mathbf{X} = \mathbf{I}$, os estimadores têm forma fechada em função do MQO $\hat{\beta}_j$:

$$\hat{\beta}_j^{\text{ridge}} = \frac{\hat{\beta}_j}{1 + \lambda}, \quad \hat{\beta}_j^{\text{lasso}} = \text{sign}(\hat{\beta}_j) \left(|\hat{\beta}_j| - \frac{\lambda}{2} \right)_+.$$

O Ridge *multiplica* por um fator < 1 (encolhe proporcionalmente, nunca zero); o Lasso *subtrai* uma constante e trunca em zero (*soft thresholding*) — por isso anula os pequenos.

3.3 Interpretação bayesiana

Ambas as penalizações são o *logaritmo de uma priori* sobre β :

- Ridge $\equiv$ MAP com priori **gaussiana** $\beta_j \sim N(0, \tau^2)$: $-\log p(\beta) \propto \sum_j \beta_j^2$.
- Lasso $\equiv$ MAP com priori **de Laplace** (dupla exponencial) $p(\beta_j) \propto e^{-|\beta_j|/b}$: $-\log p(\beta) \propto \sum_j |\beta_j|$.

A priori de Laplace é mais “pontuda” em zero e tem caudas mais pesadas: ela favorece soluções com muitos coeficientes *nulos* e alguns grandes — exatamente a esparsidade observada.

Atenção

Como as penalizações somam β_j^2 ou $|\beta_j|$, elas **dependem da escala** das covariáveis. *Sempre padronize* (média 0, variância 1) antes de aplicar Ridge/Lasso, caso contrário variáveis em unidades grandes são penalizadas de menos. Isso conecta diretamente com a Aula 07 (*pipelines* e *StandardScaler*).

4 Prática em Python

Em *scikit-learn*, as três variantes seguem a mesma interface; o *alpha* é o nosso λ . Note a padronização *dentro* do *pipeline* (Aula 07) para evitar vazamento.

```
1 from sklearn.linear_model import LinearRegression, Ridge, Lasso, LassoCV
2 from sklearn.preprocessing import StandardScaler
3 from sklearn.pipeline import make_pipeline
4
5 # Lasso com lambda escolhido por validacao cruzada
6 modelo = make_pipeline(StandardScaler(),
7                         LassoCV(cv=5, random_state=0))
8 modelo.fit(X_tr, y_tr)
9
10 lasso = modelo.named_steps["lassocv"]
11 print("lambda escolhido:", lasso.alpha_)
12 print("coeficientes nao-nulos:", (lasso.coef_ != 0).sum(), "de", X.shape[1])
```

O exemplo clássico (dados de câncer de próstata, ou as resenhas da Amazon no [AME]) mostra o padrão típico: o Lasso seleciona poucas covariáveis com desempenho comparável ou superior ao MQO, especialmente quando d é grande.

O notebook Aula prática 02 percorre tudo isso no *superconductivity.csv* ($d = 81$), inclusive a pegadinha de escala entre Ridge e Lasso.

Resumo

- Regressão linear: $g(\mathbf{x}) = \boldsymbol{\beta}^\top \mathbf{x}$, linear *nos parâmetros*; MQO $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$.
- Em altas dimensões MQO tem variância alta e nem existe se $d > n$.
- **Ridge** (ℓ_2): solução fechada, sempre única, encolhe sem zerar.
- **Lasso** (ℓ_1): faz seleção de variáveis (esparsidade) pela geometria das quinas / *soft thresholding*.
- Ridge $\equiv$ priori gaussiana; Lasso $\equiv$ priori de Laplace.
- λ é *tuning parameter* (validação cruzada, Aula 03); sempre *padronize* as covariáveis.

Leitura recomendada. [AME] Capítulos 2 e 3 (§3.3 Lasso, §3.4 Ridge, §3.6 interpretação bayesiana); [ISLP] Capítulo 3 (regressão linear) e Capítulo 6 (§6.1 seleção de subconjuntos, §6.2 *shrinkage*).