

Lista Teórica 02 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 02 — Regressão Linear e Regularização

Exercício 1 — a reta passa pela média. Considere a regressão linear simples $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, com $i = 1, \dots, n$, ajustada por mínimos quadrados.

- Escreva a primeira equação normal (a que vem de derivar a soma de quadrados em relação a β_0) e conclua que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$. Interprete: por onde passa a reta ajustada?
- Mostre que os resíduos $e_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$ somam zero.
- As duas propriedades acima valem se você ajustar o modelo *sem* intercepto, isto é, $y_i = \beta_1 x_i + \varepsilon_i$? Explique.

Solução

(a) Com $S(\beta_0, \beta_1) = \sum_i (y_i - \beta_0 - \beta_1 x_i)^2$,

$$\frac{\partial S}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0 \implies \sum_i y_i = n\beta_0 + \beta_1 \sum_i x_i.$$

Dividindo por n : $\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$, ou seja $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$. Lida ao contrário, a igualdade $\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$ diz que o ponto $(\bar{x}, \bar{y})$ **satisfaz a equação da reta ajustada**: a reta de mínimos quadrados sempre passa pelo centro de massa da nuvem, qualquer que seja o conjunto de dados.

(b) É a mesma equação. A primeira equação normal é literalmente $\sum_i e_i = 0$, pois $e_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$ é exatamente o que está dentro da soma que igualamos a zero.

(c) **Não.** As duas propriedades são consequência de haver um parâmetro β_0 para derivar — sem intercepto, essa equação normal simplesmente não existe. Sobra apenas $\sum_i x_i (y_i - \hat{\beta}_1 x_i) = 0$, que força os resíduos a serem ortogonais a $\mathbf{x}$, e não a somar zero. Na prática: uma regressão sem intercepto pode ter resíduos com média bem diferente de zero, e a reta não precisa passar por $(\bar{x}, \bar{y})$.

Exercício 2 — o que λ faz, e por que padronizar.

- Para a Ridge, use a solução fechada $\hat{\beta}^{\text{ridge}} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{Y}$ para descrever o que acontece com as estimativas quando $\lambda \rightarrow 0$ e quando $\lambda \rightarrow \infty$. Em qual dos dois extremos o viés é maior? E a variância?
- O intercepto β_0 não entra na penalização. Dê um argumento concreto para essa escolha. *Sugestão:* pense no que aconteceria se você somasse 1000 a todos os y_i .
- Suponha que a covariável x_1 esteja medida em metros e que você resolva passá-la para centímetros, sem mexer em mais nada. O que acontece com $\hat{\beta}_1$ do MQO? E com a solução da Ridge, para um mesmo λ ? Que conclusão prática se tira daí?

Solução

(a) Quando $\lambda \rightarrow 0$, $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \rightarrow (\mathbf{X}^\top \mathbf{X})^{-1}$ (se esta existir) e a Ridge tende ao MQO: viés zero sob o modelo linear correto, e variância máxima. Quando $\lambda \rightarrow \infty$, a matriz $\lambda \mathbf{I}$ domina, o inverso vai a zero e $\hat{\beta}^{\text{ridge}} \rightarrow \mathbf{0}$: o modelo vira o preditor constante $\hat{\beta}_0$. Aí o **viés é máximo** e a **variância é zero**. É o balanço viés-variância da Aula 01 parametrizado por λ , e é por isso que existe um λ intermediário melhor que os dois extremos.

(b) Some 1000 a todos os y_i . A relação entre $\mathbf{x}$ e y não mudou em nada — só a origem da escala de y — e o que *deveria* acontecer é $\hat{\beta}_0$ subir 1000 e os demais coeficientes ficarem iguais. É exatamente o que ocorre quando β_0 não é penalizado. Se ele fosse penalizado, um β_0 de valor 1000 pagaria um preço enorme, e o ajuste preferiria distorcer os outros coeficientes para compensar: a solução passaria a depender de onde você pôs o zero da régua, o que não faz sentido nenhum.

(c) No **MQO**, nada de importante: se x_1 é multiplicada por 100, então $\hat{\beta}_1$ é dividida por 100, o produto $\hat{\beta}_1 x_1$ não muda e as predições são idênticas. O MQO é *equivariante* a mudanças de escala.

Na **Ridge** (e no Lasso) não. O ajuste continua querendo dividir $\hat{\beta}_1$ por 100, mas agora esse coeficiente cem vezes menor paga uma penalização praticamente nula: na prática, a covariável em centímetros passa a ser quase *isenta* do encolhimento, e as predições mudam. Ou seja: com escalas diferentes, λ significa coisas diferentes para cada covariável.

Conclusão prática: **padronize as covariáveis antes de qualquer método penalizado**. E, como a padronização estima média e desvio-padrão a partir dos dados, ela precisa acontecer *dentro* do procedimento de ajuste — é o assunto da Aula 07 e o motivo de existir o Pipeline.

Exercício 3 — Ridge e Lasso com números. No caso ortonormal ($\mathbf{X}^\top \mathbf{X} = \mathbf{I}$) as duas soluções têm forma fechada em função do MQO:

$$\hat{\beta}_j^{\text{ridge}} = \frac{\hat{\beta}_j}{1 + \lambda}, \quad \hat{\beta}_j^{\text{lasso}} = \text{sin}(\hat{\beta}_j) \left(|\hat{\beta}_j| - \frac{\lambda}{2} \right)_+,$$

onde $(u)_+ = \max(u, 0)$. Tome $\lambda = 1$ e $\hat{\beta}^{\text{MQO}} = (2,00; 0,30; -0,80)$.

- Calcule $\hat{\beta}^{\text{ridge}}$ e $\hat{\beta}^{\text{lasso}}$.
- Alguns coeficientes foram zerados? Por qual dos dois métodos, e qual é a condição exata para que isso aconteça com o coeficiente j ?
- Compare o quanto *cada método* encolheu o maior coeficiente (2,00) e o menor em módulo (0,30), em valor absoluto. Descreva em uma frase a diferença de comportamento.
- A partir de qual valor de λ o Lasso zeraria *todos* os três coeficientes?

Solução

(a) Ridge: divide-se tudo por $1 + \lambda = 2$,

$$\hat{\beta}^{\text{ridge}} = (1,00; 0,15; -0,40).$$

Lasso: subtrai-se $\lambda/2 = 0,5$ do módulo, truncando em zero,

$$\hat{\beta}^{\text{lasso}} = (2,00 - 0,5; 0; -(0,80 - 0,5)) = (1,50; 0; -0,30).$$

(b) Sim: o segundo coeficiente, e só pelo **Lasso**, porque $|0,30| < \lambda/2 = 0,5$. A condição

geral é $|\hat{\beta}_j| \leq \lambda/2$. A Ridge nunca zera: ela multiplica por $1/(1 + \lambda)$, que é positivo para todo λ finito.

(c) Encolhimento em valor absoluto:

	coeficiente 2,00	coeficiente 0,30
Ridge	2,00 $\rightarrow$ 1,00: encolheu 1,00	0,30 $\rightarrow$ 0,15: encolheu 0,15
Lasso	2,00 $\rightarrow$ 1,50: encolheu 0,50	0,30 $\rightarrow$ 0,00: encolheu 0,30

A Ridge encolhe **proporcionalmente**: quem é grande perde muito em valor absoluto, quem é pequeno perde pouco — e sobrevive. O Lasso encolhe **todo mundo pela mesma quantidade** $\lambda/2$: quem é grande mal sente, e quem é menor que o corte é aniquilado. É por isso que só o Lasso faz seleção de variáveis.

(d) Todos zeram quando $\lambda/2 \geq \max_j |\hat{\beta}_j| = 2,00$, isto é, $\lambda \geq 4$.

Exercício 4 — a solução fechada da Ridge.

- (a) Minimizando $S_\lambda(\beta) = \|\mathbf{Y} - \mathbf{X}\beta\|^2 + \lambda\|\beta\|^2$, obtenha $\hat{\beta}^{\text{ridge}} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{Y}$. *Sugestão:* o gradiente de $\|\mathbf{Y} - \mathbf{X}\beta\|^2$ está na demonstração das equações normais, na nota de aula.
- (b) Mostre que, para todo $\lambda > 0$, a matriz $\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}$ é invertível — **mesmo quando** $d > n$, caso em que o MQO nem está definido.
- (c) Explique, em duas ou três linhas, por que o item (b) é uma das razões de o Ridge ser útil em alta dimensão.

Solução

(a) Expandindo,

$$S_\lambda(\beta) = \mathbf{Y}^\top \mathbf{Y} - 2\beta^\top \mathbf{X}^\top \mathbf{Y} + \beta^\top \mathbf{X}^\top \mathbf{X} \beta + \lambda \beta^\top \beta,$$

cujo gradiente é $\nabla S_\lambda(\beta) = -2\mathbf{X}^\top \mathbf{Y} + 2\mathbf{X}^\top \mathbf{X} \beta + 2\lambda \beta$. Igualando a zero:

$$(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}) \beta = \mathbf{X}^\top \mathbf{Y}.$$

Pelo item (b) a matriz é invertível, então a solução é única e vale $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{Y}$. A Hessiana $2(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})$ é definida positiva, logo é mínimo.

(b) Basta mostrar que a forma quadrática é positiva. Para $\mathbf{v} \neq \mathbf{0}$,

$$\mathbf{v}^\top (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}) \mathbf{v} = \|\mathbf{X}\mathbf{v}\|^2 + \lambda \|\mathbf{v}\|^2 \geq \lambda \|\mathbf{v}\|^2 > 0,$$

pois $\lambda > 0$ e $\|\mathbf{v}\| > 0$. Uma matriz simétrica definida positiva é invertível. Note onde a hipótese $d > n$ não foi usada: a conta não depende de $\mathbf{X}$ ter posto cheio. Se $d > n$, existe $\mathbf{v} \neq \mathbf{0}$ com $\mathbf{X}\mathbf{v} = \mathbf{0}$ — e é justamente aí que a primeira parcela morre e a segunda salva a conta.

(c) Quando $d > n$ o MQO não tem solução única: a matriz $\mathbf{X}^\top \mathbf{X}$ é singular e existem infinitos β com o mesmo erro de treino. Somar λ à diagonal levanta o menor autovalor de perto de zero (ou de exatamente zero) para pelo menos λ , o que torna o problema bem-posto e derruba o número de condição. Em outras palavras, a penalização não é só um freio contra o superajuste: ela é o que faz o problema *ter* resposta.