

Lista Teórica 02

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 02 — Regressão Linear e Regularização

Exercício 1 — a reta passa pela média. Considere a regressão linear simples $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, com $i = 1, \dots, n$, ajustada por mínimos quadrados.

- Escreva a primeira equação normal (a que vem de derivar a soma de quadrados em relação a β_0) e conclua que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$. Interprete: por onde passa a reta ajustada?
- Mostre que os resíduos $e_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$ somam zero.
- As duas propriedades acima valem se você ajustar o modelo *sem* intercepto, isto é, $y_i = \beta_1 x_i + \varepsilon_i$? Explique.

Exercício 2 — o que λ faz, e por que padronizar.

- Para a Ridge, use a solução fechada $\hat{\beta}^{\text{ridge}} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{Y}$ para descrever o que acontece com as estimativas quando $\lambda \rightarrow 0$ e quando $\lambda \rightarrow \infty$. Em qual dos dois extremos o viés é maior? E a variância?
- O intercepto β_0 não entra na penalização. Dê um argumento concreto para essa escolha. *Sugestão:* pense no que aconteceria se você somasse 1000 a todos os y_i .
- Suponha que a covariável x_1 esteja medida em metros e que você resolva passá-la para centímetros, sem mexer em mais nada. O que acontece com $\hat{\beta}_1$ do MQO? E com a solução da Ridge, para um mesmo λ ? Que conclusão prática se tira daí?

Exercício 3 — Ridge e Lasso com números. No caso ortonormal ($\mathbf{X}^\top \mathbf{X} = \mathbf{I}$) as duas soluções têm forma fechada em função do MQO:

$$\hat{\beta}_j^{\text{ridge}} = \frac{\hat{\beta}_j}{1 + \lambda}, \quad \hat{\beta}_j^{\text{lasso}} = \text{sin}(\hat{\beta}_j) \left(\left| \hat{\beta}_j \right| - \frac{\lambda}{2} \right)_+,$$

onde $(u)_+ = \max(u, 0)$. Tome $\lambda = 1$ e $\hat{\beta}^{\text{MQO}} = (2,00; 0,30; -0,80)$.

- Calcule $\hat{\beta}^{\text{ridge}}$ e $\hat{\beta}^{\text{lasso}}$.
- Algum coeficiente foi zerado? Por qual dos dois métodos, e qual é a condição exata para que isso aconteça com o coeficiente j ?
- Compare o quanto *cada método* encolheu o maior coeficiente (2,00) e o menor em módulo (0,30), em valor absoluto. Descreva em uma frase a diferença de comportamento.
- A partir de qual valor de λ o Lasso zeraria *todos* os três coeficientes?

Exercício 4 ★ — a solução fechada da Ridge.

- Minimizando $S_\lambda(\beta) = \|\mathbf{Y} - \mathbf{X}\beta\|^2 + \lambda \|\beta\|^2$, obtenha $\hat{\beta}^{\text{ridge}} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{Y}$. *Sugestão:* o gradiente de $\|\mathbf{Y} - \mathbf{X}\beta\|^2$ está na demonstração das equações normais, na nota de aula.

- (b) Mostre que, para todo $\lambda > 0$, a matriz $\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}$ é invertível — **mesmo quando** $d > n$, caso em que o MQO nem está definido.
- (c) Explique, em duas ou três linhas, por que o item (b) é uma das razões de o Ridge ser útil em alta dimensão.

Os exercícios marcados com $\star$ são opcionais e vão além do que a prova cobra.