

Aula 03 — Seleção de Modelos e Validação Cruzada

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §1.4–1.5; ISLP cap. 5

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- explicar por que o erro de treino é um estimador *otimista* do risco;
- descrever *data splitting* (treino/validação) e estimar o risco com a parte de validação;
- definir *validação cruzada* LOOCV e *k*-dobras e relacioná-las;
- discutir o balanço viés–variância *na própria estimativa do risco* e a escolha de *k*;
- usar a validação cruzada para **selecionar hiperparâmetros** sem vazamento;
- descrever o *bootstrap* para quantificar incerteza de uma estimativa.

Esta é a aula *operacional* mais importante do curso. Nas Aulas 01 e 02 apareceram hiperparâmetros — o grau do polinômio, o λ do Lasso — e nos dois casos a resposta para “como escolher?” foi “na Aula 03”. Chegamos nela. A mesma ferramenta vai escolher o *k* do KNN, a profundidade da árvore, o *C* da SVM. Comece pela pergunta:

*se eu ajustar um polinômio de grau 50 a 50 pontos, qual o erro no treino?
e isso quer dizer que é um bom modelo?*

O erro é *exatamente zero* — 51 parâmetros passam por 50 pontos sem esforço — e o modelo é péssimo. Um critério de qualidade que dá nota máxima ao pior modelo possível não serve como critério. Precisamos de outro.

1 O problema: estimar o risco

Da Aula 01, o risco de uma função de predição g é $R(g) = \mathbb{E}[L(Y, g(\mathbf{X}))]$, esperança sobre uma observação *nova*. Para *selecionar* um modelo (escolher entre candidatos $g \in \mathcal{G}$, ou escolher um hiperparâmetro) precisamos comparar riscos — mas $R(g)$ é desconhecido porque depende de P . Logo, **tudo se resume a estimar bem o risco**.

1.1 Por que não usar o erro de treino?

O candidato ingênuo é o *erro quadrático médio no treino* (risco empírico):

$$\text{EQM}(g) = \frac{1}{n} \sum_{i=1}^n (Y_i - g(\mathbf{X}_i))^2. \quad (1)$$

O problema: g foi *escolhida para ajustar exatamente esses pontos*. O $\text{EQM}(1)$ é um estimador **otimista** (enviesado para baixo) de $R(g)$, e o viés cresce com a complexidade do modelo.

Atenção

Levado ao extremo, minimizar o erro de treino leva ao superajuste perfeito: um modelo flexível o bastante *interpola* os dados (erro de treino zero, em aritmética exata — ver a §3 da Aula prática 03 para o que o ponto flutuante faz com isso) e generaliza pessimamente. **Nunca** selecione modelos nem reporte desempenho com o erro de treino.

Observação 1.1. Penalização (AIC, BIC) é uma alternativa: estima-se $R(g) \approx \text{EQM}(g) + P(g)$, com $P(g)$ crescente na complexidade (p.ex. $P(g) \propto p/\hat{\sigma}^2$ no AIC). Funciona, mas exige um modelo probabilístico e contagem de “parâmetros” — nem sempre disponível (KNN, florestas). A validação cruzada é *agnóstica ao modelo* e por isso a preferimos.

2 Data splitting (conjunto de validação)

A ideia mais simples: separe os dados *aleatoriamente* em treino (p.ex. 70%) e validação (p.ex. 30%):

$$\underbrace{(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_s, Y_s)}_{\text{treino}}, \underbrace{(\mathbf{X}_{s+1}, Y_{s+1}), \dots, (\mathbf{X}_n, Y_n)}_{\text{validação}}.$$

Ajuste g só no treino e estime o risco só na validação:

$$\hat{R}(g) = \frac{1}{n-s} \sum_{i=s+1}^n (Y_i - g(\mathbf{X}_i))^2. \quad (2)$$

Como a validação não foi usada para estimar g , (2) é um estimador *consistente* de $R(g)$ pela lei dos grandes números.

Atenção: o aleatoriamente não é decoração

Se o banco vier ordenado por alguma variável — por data, por classe, por quem coletou —, cortar pelos índices originais produz dois conjuntos que não são amostras da mesma distribuição, e a estimativa fica sem sentido. Quem montou o banco pode ter ordenado por um motivo que você desconhece. Em `scikit-learn` isso é o `train_test_split(..., shuffle=True)`, que já é o padrão — mas vale saber por que existe.

Atenção: Limitações do data splitting

1. **Desperdício de dados:** g é treinada com apenas $s < n$ observações; com poucos dados isso prejudica o ajuste.
2. **Variabilidade:** a estimativa depende da divisão sorteada — outra semente dá outro número. Pode ser instável.

A validação cruzada resolve os dois usando *toda* a amostra.

3 Validação cruzada

3.1 Leave-one-out (LOOCV)

Deixe *uma* observação de fora por vez. Seja g_{-i} o modelo ajustado sem a i -ésima observação. O estimador é

$$\hat{R}_{\text{LOO}}(g) = \frac{1}{n} \sum_{i=1}^n (Y_i - g_{-i}(\mathbf{X}_i))^2. \quad (3)$$

Cada Y_i é predito por um modelo que *não* o viu. LOOCV é *aproximadamente não-viesado* para o risco esperado e não tem aleatoriedade de divisão.

Observação 3.1 (por que “aproximadamente não-viesado”). A conta é curta e vale ver. Se $R(g)$ é o risco esperado do procedimento treinado com n observações, então, num conjunto com $n + 1$ observações,

$$\mathbb{E} \left[\frac{1}{n+1} \sum_{i=1}^{n+1} (Y_i - g_{-i}(\mathbf{X}_i))^2 \right] = \frac{1}{n+1} \sum_{i=1}^{n+1} \mathbb{E} [(Y_i - g_{-i}(\mathbf{X}_i))^2] = \frac{1}{n+1} \sum_{i=1}^{n+1} R(g) = R(g),$$

porque cada g_{-i} é treinado com exatamente n observações e tem, portanto, a mesma distribuição. O “aproximadamente” está no descompasso de uma unidade: o LOOCV calculado com n dados é não viesado para o risco do procedimento com $n - 1$ dados, não com n .

O custo aparente é alto (n ajustes), mas nem sempre:

Proposição 3.2 (Atalho do LOOCV para modelos lineares). *Para um ajuste linear (MQO, Ridge, splines) com matriz de projeção $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$, vale*

$$\hat{R}_{LOO} = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{g}(\mathbf{X}_i)}{1 - h_{ii}} \right)^2,$$

onde h_{ii} é o i -ésimo elemento diagonal de $\mathbf{H}$ (leverage) e $\hat{g}$ é ajustado com todos os dados.

Ou seja, um *único* ajuste basta. Esta é uma das fórmulas mais elegantes da área: o LOOCV “de graça”. Vale notar o que ela diz: o resíduo de validação é o resíduo de treino *inflado* pelo fator $1/(1 - h_{ii})$, e h_{ii} mede o quanto a observação i influencia sua própria predição. Pontos de alta alavancagem são justamente aqueles cujo resíduo de treino mais engana.

3.2 Validação cruzada com k dobras

Divida os dados aleatoriamente em k lotes (dobras) disjuntos de tamanho $\approx n/k$, com índices $L_1, \dots, L_k$. Para cada j , treine g_{-j} sem o lote L_j e avalie nesse lote:

$$\hat{R}_{k-CV}(g) = \frac{1}{n} \sum_{j=1}^k \sum_{i \in L_j} (Y_i - g_{-j}(\mathbf{X}_i))^2. \quad (4)$$

Cada observação é usada para validação *exatamente uma vez* e para treino $k - 1$ vezes. Quando $k = n$ recuperamos o LOOCV (3). Valores típicos: $k = 5$ ou $k = 10$.

Ideia central

A validação cruzada estima o risco *de um procedimento* (“ajustar este tipo de modelo a dados como estes”), não de um g específico. Por isso, depois de escolher o hiperparâmetro por CV, **reajustamos o modelo final usando todos os dados**.

3.3 A validação cruzada funciona? Uma verificação

Dá para conferir, porque na população sintética da Aula 01 nós conhecemos o risco verdadeiro. A Figura 2 põe lado a lado o que o analista realmente tem (uma amostra de $n = 50$ pontos e a CV calculada nela) e o que ele nunca terá (o risco verdadeiro, obtido simulando 300 amostras).

Ideia central: o que a CV precisa acertar

Repare que a curva azul não coincide com a vinho: a CV *subestima* um pouco o risco. Isso não é problema. Para **selecionar** um modelo, o que importa é *onde* está o mínimo, não o valor no mínimo. O [ISLP] faz essa observação explicitamente: em três exemplos




Figura 1: Validação cruzada com $k = 5$ dobras. Em cada rodada um lote diferente fica de fora do ajuste e serve para avaliar. Ao final, *toda* observação foi usada para validar (uma vez) e para treinar ($k - 1$ vezes) — é assim que a validação cruzada resolve o desperdício de dados do *data splitting*.




Figura 2: Validação cruzada de 5 dobras calculada sobre *uma única* amostra de $n = 50$, contra o risco verdadeiro e o erro de treino. As barras são de um erro-padrão. A CV reproduz a forma em “U” e localiza o mínimo no grau 4, contra o grau 5 do risco verdadeiro — e, o mais importante, não se deixa enganar pelo erro de treino, que continua descendo. Note também as barras se abrindo à direita: a CV *avisa* quando está insegura.

diferentes as curvas de CV ora subestimam, ora superestimam o risco, mas todas identificam corretamente o nível de flexibilidade certo. Se você quer *reportar* o desempenho, aí sim precisa do valor — e para isso usa-se um conjunto de teste separado, ou CV aninhada.

3.4 Viés, variância e a escolha de k

O argumento clássico para a escolha de k é ele mesmo um balanço viés–variância *da estimativa do risco*:

- **k grande (LOOCV):** cada g_{-j} treina com $\approx n$ dados $\Rightarrow$ *pouco viés*. Em contrapartida os n modelos são quase idênticos entre si e suas predições, muito correlacionadas — e a média de quantidades correlacionadas não se beneficia da lei dos grandes números como a de quantidades independentes. O argumento conclui: *variância alta*.
- **k pequeno (p.ex. 5):** cada g_{-j} treina com bem menos dados $\Rightarrow$ *mais viés*, no sentido pessimista: o procedimento avaliado não é bem o que você vai usar no final. Em troca, as dobras são mais independentes.

A Figura 3 mede as duas coisas na nossa população.




Figura 3: Estimativa do risco de um polinômio de grau 5 sobre $n = 50$ pontos, repetida em 300 amostras independentes. À esquerda, viés e desvio-padrão da estimativa (escala logarítmica): com $k = 2$ os dois são desastrosos — treinar com 25 pontos é coisa muito diferente de treinar com 50 —, e a partir de $k = 5$ tudo estabiliza. À direita, o custo, que cresce linearmente: a LOOCV pede *dez vezes* mais ajustes que $k = 5$.

Atenção: o que este experimento mostra — e o que não mostra

O viés se comporta como previsto: cai de 0,43 em $k = 2$ para 0,006 em $k = 10$. Já o desvio-padrão **não** cresce com k aqui: vai de 2,20 ($k = 2$) a 0,13 (LOOCV), decrescendo o tempo todo. O efeito de treinar com poucos dados domina de longe o efeito da correlação entre dobras. Não tome “LOOCV tem variância alta” como lei — é um argumento sobre um dos termos, e o outro pode ser maior. A conclusão prática sobrevive intacta, só que por outro motivo: de $k = 5$ para frente não há praticamente nada a ganhar em precisão, e o custo continua subindo. Daí $k = 5$ ou $k = 10$.

Atenção: A regra de ouro contra vazamento

Toda etapa que “aprende” algo dos dados — padronização, seleção de variáveis, escolha de λ — deve ocorrer *dentro* de cada dobra, usando apenas o treino daquela dobra. Padronizar com a média/desvio de todo o conjunto antes da CV é *data leakage* e produz estimativas otimistas. (É por isso que usamos *pipelines*, Aula 07.)

3.5 Selecionando hiperparâmetros

O uso central: para cada valor de um hiperparâmetro θ (p.ex. λ do Lasso), calcule $\hat{R}_{k-CV}(\theta)$ e escolha $\hat{\theta} = \arg \min_{\theta} \hat{R}_{k-CV}(\theta)$.

Atenção: Regra “1-EP”

Como $\hat{R}_{k-CV}$ tem erro padrão, muitas vezes prefere-se a *regra de um erro-padrão*: escolher o modelo *mais simples* cujo risco estimado esteja a no máximo um erro-padrão do mínimo. Favorece parcimônia (é o `lambda.1se` do `glmnet`). Na Figura 2 ela escolheria o grau 3 em vez do 4: como as barras de erro dos graus 3 a 6 se sobrepõem, os dados não distinguem esses modelos, e nesse empate a regra manda ficar com o mais simples.

Atenção: Validação *aninhada*

Se você usa CV para *escolher* θ e para *reportar* o desempenho, precisa de **CV aninhada**: um laço externo estima o desempenho, um laço interno escolhe θ . Usar a mesma CV para as duas coisas subestima o risco — é o mesmo pecado do erro de treino, um andar acima. O [AME] descreve a versão com três conjuntos: *treino* ajusta, *validação* escolhe o hiperparâmetro, e o *teste*, tocado uma única vez no fim, estima o risco do vencedor. Quanto mais modelos você comparar na validação, mais otimista ela fica — por isso o teste existe.

4 O bootstrap

A validação cruzada estima o *risco*; o **bootstrap** estima a *incerteza* (variância, viés, intervalos) de praticamente qualquer estatística $\hat{\theta}$ calculada a partir dos dados.

Ideia central

Não conhecemos P , mas temos a amostra. O bootstrap usa a *distribuição empírica* (reamostrar dos dados *com reposição*) como substituta de P , imitando o ato de coletar novas amostras.

Algoritmo. Para $b = 1, \dots, B$:

1. sorteie n observações *com reposição* da amostra original (amostra bootstrap $\mathcal{D}^{*b}$);
2. calcule a estatística $\hat{\theta}^{*b}$ em $\mathcal{D}^{*b}$.

A dispersão de $\{\hat{\theta}^{*1}, \dots, \hat{\theta}^{*B}\}$ estima a distribuição amostral de $\hat{\theta}$; por exemplo, $\widehat{EP}(\hat{\theta})$ é o desvio-padrão dessas réplicas, e um intervalo de confiança de 95% pode ser dado pelos percentis 2,5% e 97,5%.

Exemplo 4.1 (O exemplo do [ISLP]. : como dividir um investimento] Você quer investir em dois ativos com retornos aleatórios X e Y , pondo uma fração α em X e $1 - \alpha$ em Y . Para minimizar o risco da carteira, $\text{Var}(\alpha X + (1 - \alpha)Y)$, a fração ótima é

$$\alpha = \frac{\sigma_Y^2 - \sigma_{XY}}{\sigma_X^2 + \sigma_Y^2 - 2\sigma_{XY}}.$$

Na prática você não conhece σ_X^2 , σ_Y^2 e σ_{XY} : estima-os dos dados e obtém $\hat{\alpha}$. Qual o erro-padrão de $\hat{\alpha}$? Boa sorte tentando derivá-lo analiticamente — é uma razão de estimativas correlacionadas. Com bootstrap são cinco linhas de código: reamostre, recalcule $\hat{\alpha}^{*b}$, tome o desvio-padrão. É aí que está a força do método: funciona para estatísticas cuja distribuição amostral ninguém sabe escrever.

Observação 4.2. Cada amostra bootstrap deixa de fora, em média, $\approx 1/e \approx 37\%$ das observações originais (as *out-of-bag*). A conta: uma observação específica escapa de um sorteio com probabilidade $1 - 1/n$, e de n sorteios com probabilidade $(1 - 1/n)^n \rightarrow e^{-1} \approx 0,368$. Essa ideia reaparece no *bagging* e nas florestas aleatórias (Aula 06), onde as observações OOB dão uma estimativa de risco “de graça” — sem separar dados nem rodar CV.

5 Prática em Python

```

1 from sklearn.model_selection import cross_val_score, KFold, GridSearchCV
2 from sklearn.pipeline import make_pipeline
3 from sklearn.preprocessing import StandardScaler
4 from sklearn.linear_model import Ridge
5
6 # 1. CV simples para estimar o risco de UM procedimento (MSE -> negativo no sklearn)
7 modelo = make_pipeline(StandardScaler(), Ridge(alpha=1.0))
8 scores = cross_val_score(modelo, X, y, cv=KFold(5, shuffle=True, random_state=0),
9                           scoring="neg_mean_squared_error")
10 print("risco estimado:", -scores.mean(), "+/-", scores.std())
11
12 # 2. Selecionar o hiperparametro lambda (=alpha) por CV, SEM vazamento
13 # (o StandardScaler e reajustado dentro de cada dobra)
14 grade = {"ridge__alpha": [0.01, 0.1, 1, 10, 100]}
15 busca = GridSearchCV(modelo, grade, cv=5, scoring="neg_mean_squared_error")
16 busca.fit(X, y)
17 print("melhor alpha:", busca.best_params_)

```

Atenção

Duas armadilhas de `scikit-learn` nesse trecho. Primeira: as funções de *score* seguem a convenção “maior é melhor”, então o EQM aparece negado (`neg_mean_squared_error`) — daí o sinal de menos ao imprimir. Segunda: passar `cv=5` sem `shuffle=True` usa as dobras *na ordem do arquivo*, com o problema descrito no início da aula. Prefira construir o `KFold` explicitamente.

O notebook Aula prática 03 refaz tudo isto: implementa as k dobras à mão, confere o atalho do LOOCV, mede o que a Figura 3 mostra e fecha escolhendo o λ de uma Ridge no `superconductivity.csv`.

Resumo

- O erro de treino é otimista; estimar o risco exige dados *não* usados no ajuste.
- *Data splitting*: simples, mas desperdiça dados e é instável.
- *LOOCV* (3): quase não-viesado; atalho fechado para modelos lineares (Prop. 3.2).
- *k-dobras* (4): usa toda a amostra (Fig. 1); $k = 5$ ou 10 bastam — além disso só cresce o custo (Fig. 3).

- A CV pode errar o *nível* do risco e ainda assim acertar *onde* está o mínimo (Fig. 2) — e é isso que a seleção de modelos precisa.
- Use CV para escolher *tuning parameters*; cuidado com *vazamento* (faça tudo dentro da dobra) e com CV aninhada para reportar desempenho.
- *Bootstrap*: reamostragem com reposição para medir incerteza de estimativas; conecta com OOB e *bagging*.

Leitura recomendada. [AME] §1.4 (função de risco e Teorema 1), §1.5.1 (*data splitting*, validação cruzada, a Observação 1.5 sobre o LOOCV não-viesado e o intervalo de confiança para o risco). [ISLP] Capítulo 5: §5.1 (validação cruzada — vale muito olhar as Figuras 5.6 e 5.8, que são a versão deles da nossa Figura 2), §5.1.4 (o argumento viés–variância para a escolha de k) e §5.2 (*bootstrap*, com o exemplo do investimento).

Para praticar. Lista teorica 03.pdf (teórica, com gabarito) e Lista prática 03.ipynb (prática, para completar as lacunas), nesta mesma pasta.