

Lista Teórica 03 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 03 — Seleção de Modelos e Validação Cruzada

Exercício 1 — o otimismo tem fórmula. Ajustando $p+1$ parâmetros por mínimos quadrados a n pontos, o erro de treino esperado vale, quando o viés já é desprezível,

$$\mathbb{E}[\text{EQM}_{\text{treino}}] \approx \sigma^2 \left(1 - \frac{p+1}{n}\right).$$

Tome $\sigma^2 = 0,49$ e $n = 50$, que é a população da Aula 01.

- (a) Calcule o erro de treino esperado para $p = 1$, $p = 5$ e $p = 12$.
- (b) A Lista Teórica 01 traz os valores *medidos* sobre 400 amostras: 0,9417 para $p = 1$, 0,4348 para $p = 5$ e 0,3642 para $p = 12$. A fórmula acerta em dois dos três casos e erra feio no terceiro. Em qual, e por quê?
- (c) Segundo a fórmula, o que acontece quando $p+1 = n$? Interprete o resultado.
- (d) Um colega propõe: “se o otimismo tem fórmula, basta somar $\sigma^2(p+1)/n$ ao erro de treino e pronto, temos o risco — não precisamos de validação cruzada”. Dê **duas** razões para isso não funcionar na prática.

Solução

(a) Basta substituir:

$$p = 1 : 0,49 \left(1 - \frac{2}{50}\right) = 0,4704, \quad p = 5 : 0,49 \left(1 - \frac{6}{50}\right) = 0,4312, \quad p = 12 : 0,49 \left(1 - \frac{13}{50}\right) = 0,3626.$$

(b) A fórmula erra em $p = 1$: prevê 0,4704 e o medido é 0,9417, o dobro. Nos outros dois ela é ótima (0,4312 contra 0,4348; 0,3626 contra 0,3642, menos de 0,5% de diferença).

A razão está na hipótese que a fórmula carrega: *viés desprezível*. Ela descreve quanto do *ruído* o modelo consegue absorver, e supõe que a parte sistemática já foi capturada. Com $p = 1$ estamos ajustando uma reta a $r(x) = \sin(1,5x) + 0,3x$: o viés é enorme, e o erro de treino é dominado por ele, não pelo ruído. Do grau 5 em diante o polinômio já reproduz r , o viés some, e sobra exatamente o que a fórmula descreve.

(c) Quando $p+1 = n$ a fórmula dá $\mathbb{E}[\text{EQM}_{\text{treino}}] = 0$: o modelo interpola os n pontos exatamente, com resíduo nulo em todos. Não é sinal de qualidade nenhuma — é o caso extremo do otimismo, em que o erro de treino perde *toda* a informação sobre o risco. Com $n = 50$, isso acontece em $p = 49$.

E se você tentar reproduzir isso no computador, **não vai dar zero**. A §3 da Aula prática 03 ajusta exatamente esse polinômio de grau 49 aos 50 pontos e mede erro de treino 0,3049. O motivo é aritmética de ponto flutuante, não matemática: com $x \in [-3, 3]$, a coluna x^{49} varre umas vinte e quatro ordens de grandeza, a matriz de delineamento perde posto *numérico* muito antes de perder posto algébrico, e o `lstsq` por trás do `LinearRegression` devolve a solução de **norma mínima** em vez da que interpola. A conclusão do item sobrevive intacta — 0,3049 ainda é menor que o erro de treino do grau 5, e o ajuste é catastrófico fora da amostra — mas o zero é um zero de papel.

(d) Duas razões:

- (i) σ^2 é **desconhecido**. Na população sintética sabemos que vale 0,49 porque nós a construímos; num banco real, não. E estimar σ^2 a partir do resíduo do próprio modelo é circular — o resíduo já está contaminado pelo mesmo otimismo.
- (ii) **A fórmula só vale para essa família de método**. Ela depende de o ajuste ser linear nos parâmetros e de haver exatamente $p + 1$ deles. Não existe “ p ” para um KNN, uma floresta aleatória ou um *boosting* com parada antecipada, nem para um procedimento que *escolheu* as covariáveis olhando os dados. A validação cruzada não precisa saber nada disso: ela mede o procedimento inteiro, seja ele qual for.

Vale acrescentar a razão de fundo do item (b): a fórmula supõe viés desprezível, e o momento em que mais precisamos de uma estimativa de risco confiável é justamente quando não sabemos se o modelo é flexível o bastante.

Exercício 2 — o atalho do LOOCV, na mão. A Proposição da Aula 03 diz que, para um ajuste linear com matriz de projeção $\mathbf{H}$,

$$\hat{R}_{\text{LOO}} = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{g}(\mathbf{X}_i)}{1 - h_{ii}} \right)^2,$$

com $\hat{g}$ ajustado usando *todos* os dados. Vamos conferir no menor modelo linear possível: o que só tem intercepto, $\hat{g}(\mathbf{x}) = \bar{Y}$.

Tome $n = 4$ e $Y = (2, 4, 4, 6)$.

- (a) Para esse modelo, $\mathbf{X}$ é a coluna de uns. Mostre que $h_{ii} = 1/n$ para todo i .
- (b) Calcule o erro quadrático médio de **treino**.
- (c) Calcule $\hat{R}_{\text{LOO}}$ pela fórmula do atalho.
- (d) Calcule $\hat{R}_{\text{LOO}}$ pela **força bruta**: deixe cada observação de fora, ajuste (isto é, tire a média das outras três), meça o erro na que ficou de fora e faça a média dos quatro. Confira que bate com o item (c).
- (e) Compare os itens (b) e (d). Por quanto o erro de treino subestima?

Solução

(a) Com $\mathbf{X} = \mathbf{1}$ (coluna de uns, $n \times 1$), temos $\mathbf{X}^\top \mathbf{X} = n$ e

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top = \frac{1}{n} \mathbf{1}\mathbf{1}^\top,$$

a matriz cujas entradas são todas $1/n$. Em particular $h_{ii} = 1/n$. (Faz sentido: $\hat{g}(\mathbf{X}_i) = \bar{Y}$ dá o mesmo peso $1/n$ a cada observação, inclusive à própria i .) Aqui $h_{ii} = 1/4$.

(b) $\bar{Y} = (2 + 4 + 4 + 6)/4 = 4$, resíduos $(-2, 0, 0, 2)$, e

$$\text{EQM}_{\text{treino}} = \frac{1}{4}(4 + 0 + 0 + 4) = \mathbf{2}.$$

(c) Com $1 - h_{ii} = 1 - \frac{1}{4} = \frac{3}{4}$, cada resíduo é inflado por $1/(3/4) = 4/3$:

$$\hat{R}_{\text{LOO}} = \frac{1}{4} \left[\left(\frac{-2}{3/4} \right)^2 + 0 + 0 + \left(\frac{2}{3/4} \right)^2 \right] = \frac{1}{4} \left[\frac{64}{9} + \frac{64}{9} \right] = \frac{32}{9} \approx \mathbf{3,5556}.$$

(d) Força bruta, uma linha por observação deixada de fora:

	fora	restantes	média	erro
$Y_1 = 2$		4, 4, 6	$14/3$	$(2 - 14/3)^2 = 64/9$
$Y_2 = 4$		2, 4, 6	4	0
$Y_3 = 4$		2, 4, 6	4	0
$Y_4 = 6$		2, 4, 4	$10/3$	$(6 - 10/3)^2 = 64/9$

Média: $\frac{1}{4}(64/9 + 0 + 0 + 64/9) = 32/9 \approx 3,5556$. Bate com (c) exatamente — o atalho não é aproximação, é identidade.

(e) $32/9$ contra 2: a razão é $16/9 \approx 1,78$. O erro de treino subestima o risco em cerca de **44%** (2 é 56% de 3,5556), e isso num modelo com *um* parâmetro só. Note que a razão é exatamente $1/(1 - h_{ii})^2 = (4/3)^2$, o que mostra de onde vem o otimismo: quanto maior a alavancagem de um ponto, mais o resíduo de treino dele engana.

Exercício 3 — a regra de um erro-padrão. A tabela abaixo traz a validação cruzada de 5 dobras para polinômios de grau 1 a 10, numa amostra de $n = 120$ da população da Aula 01. Cada linha traz a média das 5 dobras e o erro-padrão dessa média.

grau	1	2	3	4	5	6	7	8	9	10
EQM (CV)	0,9413	0,9436	0,5858	0,6649	0,5134	0,5155	0,5137	0,5177	0,5197	0,5106
erro-padrão	0,1383	0,1381	0,1119	0,1454	0,0583	0,0595	0,0656	0,0653	0,0662	0,0675

- Qual grau tem o menor EQM estimado? Comente o resultado.
- Aplice a **regra de um erro-padrão**: escolha o modelo mais simples cujo EQM estimado esteja a no máximo um erro-padrão do mínimo. Qual grau ela escolhe?
- A nota de aula diz que o mínimo do risco *verdadeiro* desta população está no grau 5. Qual dos dois critérios acertou?
- Justifique a regra: por que faz sentido não confiar na diferença entre 0,5106 e 0,5134?

Solução

(a) O menor EQM é 0,5106, no **grau 10** — o modelo *mais flexível* da grade. Se o critério fosse só “pegue o mínimo”, a validação cruzada teria escolhido justamente o candidato que a Aula 01 nos ensinou a desconfiar. Note também que a curva é praticamente plana do grau 5 ao grau 10: todos os valores estão entre 0,5106 e 0,5197.

(b) O mínimo é 0,5106 com erro-padrão 0,0675, então o limite é

$$0,5106 + 0,0675 = 0,5781.$$

Estão abaixo desse limite os graus 5 (0,5134), 6 (0,5155), 7 (0,5137), 8 (0,5177), 9 (0,5197) e 10 (0,5106). O mais simples deles é o **grau 5**. (Os graus 3 e 4 ficam de fora: 0,5858 e 0,6649 passam do limite.)

(c) A **regra de um erro-padrão**, que acertou o grau 5 na mosca. O critério do mínimo escolheu o grau 10, um modelo com o dobro de parâmetros e o mesmo desempenho.

(d) Porque a diferença é muito menor que a incerteza da própria estimativa. Os dois números diferem em 0,0028, enquanto o erro-padrão de cada um é da ordem de 0,065 — vinte vezes maior. Dizer que o grau 10 é melhor que o grau 5 com base nesses dados é ler ruído como sinal.

Há ainda um argumento que a tabela não mostra e que reforça a regra: estamos tomando o *mínimo de dez* estimativas ruidosas. Mesmo que os dez modelos fossem exatamente equivalentes, o vencedor pareceria melhor que os outros só por sorte — é o assunto do Exercício 4. Diante de um empate estatístico, a regra desempata pelo critério que não depende dos dados: preferir o modelo mais simples, que tende a ter menor variância e é mais fácil de interpretar.

Exercício 4 — por que quem escolheu não pode reportar. Suponha que você compare $M = 10$ modelos que, sem que você saiba, têm **exatamente o mesmo** risco verdadeiro $R = 1$. A validação cruzada lhe dá, para cada um, uma estimativa

$$\hat{R}_m = 1 + \varepsilon_m, \quad \varepsilon_1, \dots, \varepsilon_{10} \stackrel{\text{i.i.d.}}{\sim} N(0; 0,2^2).$$

Você escolhe o modelo de menor $\hat{R}_m$ e reporta esse valor como estimativa do risco.

- Sabendo que a esperança do *máximo* de 10 normais padrão independentes vale aproximadamente 1,539, calcule $\mathbb{E}[\min_m \hat{R}_m]$. *Sugestão:* $\min_m(1 + \varepsilon_m) = 1 - \max_m(-\varepsilon_m)$, e $-\varepsilon_m$ tem a mesma distribuição de ε_m .
- Por quantos por cento o valor reportado subestima o risco verdadeiro?
- Todos os modelos eram igualmente bons. De onde veio o viés?
- Descreva o procedimento que resolve o problema e diga qual conjunto de dados faz cada papel nele.

Solução

(a) Escreva $\varepsilon_m = 0,2 Z_m$ com $Z_m \sim N(0, 1)$ i.i.d. Então

$$\min_m \hat{R}_m = 1 + 0,2 \min_m Z_m = 1 - 0,2 \max_m (-Z_m),$$

e como $-Z_m$ também é $N(0, 1)$,

$$\mathbb{E}[\min_m \hat{R}_m] = 1 - 0,2 \cdot \mathbb{E}[\max_m Z_m] \approx 1 - 0,2 \times 1,539 = \mathbf{0,692}.$$

(b) O risco verdadeiro é 1 e o reportado é 0,692: uma subestimação de cerca de **31%**. E note que ela não desaparece com mais dados de validação — diminuir o desvio 0,2 ajuda, mas aumentar M piora, e comparar mais modelos é exatamente o que se costuma fazer.

(c) Do fato de que **selecionar é otimizar**. O mínimo de dez variáveis aleatórias não é uma delas escolhida ao acaso: é a que teve a maior sorte. A estimativa $\hat{R}_m$ era não-viesada *antes* de você olhar para ela; ao usar essas mesmas estimativas para escolher, você transformou o valor reportado no mínimo de dez sorteios, e o mínimo é enviesado para baixo. É o mesmo mecanismo do erro de treino do Exercício 1, num nível acima: lá o modelo foi escolhido para ir bem naqueles pontos, aqui o *hiperparâmetro* foi.

(d) **Validação cruzada aninhada**. A ideia é dar papéis diferentes a dados diferentes:

- o laço **interno** usa apenas a parte de treino de cada dobra externa, e nele a CV escolhe o hiperparâmetro — pode enviesar à vontade, porque ninguém vai reportar esse número;
- o laço **externo** avalia o *procedimento inteiro* (“rodar a busca e ajustar o vencedor”) em dados que não participaram nem do ajuste nem da escolha. É esse número que se reporta.

Em uma frase: quem escolheu não pode reportar. A alternativa mais simples, quando há dados de sobra, é separar um conjunto de teste no começo e não tocar nele até o fim.