

Lista Teórica 03

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 03 — Seleção de Modelos e Validação Cruzada

Exercício 1 — o otimismo tem fórmula. Ajustando $p+1$ parâmetros por mínimos quadrados a n pontos, o erro de treino esperado vale, quando o viés já é desprezível,

$$\mathbb{E}[\text{EQM}_{\text{treino}}] \approx \sigma^2 \left(1 - \frac{p+1}{n}\right).$$

Tome $\sigma^2 = 0,49$ e $n = 50$, que é a população da Aula 01.

- Calcule o erro de treino esperado para $p = 1$, $p = 5$ e $p = 12$.
- A Lista Teórica 01 traz os valores *medidos* sobre 400 amostras: 0,9417 para $p = 1$, 0,4348 para $p = 5$ e 0,3642 para $p = 12$. A fórmula acerta em dois dos três casos e erra feio no terceiro. Em qual, e por quê?
- Segundo a fórmula, o que acontece quando $p+1 = n$? Interprete o resultado.
- Um colega propõe: “se o otimismo tem fórmula, basta somar $\sigma^2(p+1)/n$ ao erro de treino e pronto, temos o risco — não precisamos de validação cruzada”. Dê **duas** razões para isso não funcionar na prática.

Exercício 2 — o atalho do LOOCV, na mão. A Proposição da Aula 03 diz que, para um ajuste linear com matriz de projeção $\mathbf{H}$,

$$\hat{R}_{\text{LOO}} = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{g}(\mathbf{X}_i)}{1 - h_{ii}} \right)^2,$$

com $\hat{g}$ ajustado usando *todos* os dados. Vamos conferir no menor modelo linear possível: o que só tem intercepto, $\hat{g}(\mathbf{x}) = \bar{Y}$.

Tome $n = 4$ e $Y = (2, 4, 4, 6)$.

- Para esse modelo, $\mathbf{X}$ é a coluna de uns. Mostre que $h_{ii} = 1/n$ para todo i .
- Calcule o erro quadrático médio de **treino**.
- Calcule $\hat{R}_{\text{LOO}}$ pela fórmula do atalho.
- Calcule $\hat{R}_{\text{LOO}}$ pela **força bruta**: deixe cada observação de fora, ajuste (isto é, tire a média das outras três), meça o erro na que ficou de fora e faça a média dos quatro. Confira que bate com o item (c).
- Compare os itens (b) e (d). Por quanto o erro de treino subestima?

Exercício 3 — a regra de um erro-padrão. A tabela abaixo traz a validação cruzada de 5 dobras para polinômios de grau 1 a 10, numa amostra de $n = 120$ da população da Aula 01. Cada linha traz a média das 5 dobras e o erro-padrão dessa média.

grau	1	2	3	4	5	6	7	8	9	10
EQM (CV)	0,9413	0,9436	0,5858	0,6649	0,5134	0,5155	0,5137	0,5177	0,5197	0,5106
erro-padrão	0,1383	0,1381	0,1119	0,1454	0,0583	0,0595	0,0656	0,0653	0,0662	0,0675

- (a) Qual grau tem o menor EQM estimado? Comente o resultado.
- (b) Aplique a **regra de um erro-padrão**: escolha o modelo mais simples cujo EQM estimado esteja a no máximo um erro-padrão do mínimo. Qual grau ela escolhe?
- (c) A nota de aula diz que o mínimo do risco *verdadeiro* desta população está no grau 5. Qual dos dois critérios acertou?
- (d) Justifique a regra: por que faz sentido não confiar na diferença entre 0,5106 e 0,5134?

Exercício 4 — por que quem escolheu não pode reportar. Suponha que você compare $M = 10$ modelos que, sem que você saiba, têm **exatamente o mesmo** risco verdadeiro $R = 1$. A validação cruzada lhe dá, para cada um, uma estimativa

$$\hat{R}_m = 1 + \varepsilon_m, \quad \varepsilon_1, \dots, \varepsilon_{10} \stackrel{\text{i.i.d.}}{\sim} N(0; 0,2^2).$$

Você escolhe o modelo de menor $\hat{R}_m$ e reporta esse valor como estimativa do risco.

- (a) Sabendo que a esperança do *máximo* de 10 normais padrão independentes vale aproximadamente 1,539, calcule $\mathbb{E}[\min_m \hat{R}_m]$. *Sugestão*: $\min_m (1 + \varepsilon_m) = 1 - \max_m (-\varepsilon_m)$, e $-\varepsilon_m$ tem a mesma distribuição de ε_m .
- (b) Por quantos por cento o valor reportado subestima o risco verdadeiro?
- (c) Todos os modelos eram igualmente bons. De onde veio o viés?
- (d) Descreva o procedimento que resolve o problema e diga qual conjunto de dados faz cada papel nele.