

Aula 04 — Métodos Não Paramétricos (KNN)

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §4.1–4.3; ISLP §3.5 e §7.1–7.5

Objetivos da aula

Ao final desta aula o aluno deve ser capaz de:

- explicar o que distingue um método *não paramétrico* de um paramétrico e por que ele troca viés por variância;
- descrever a estratégia de *bases* (séries ortogonais, *splines*) para flexibilizar a regressão linear;
- definir o estimador de k **vizinhos mais próximos** (KNN) e o papel de k no balanço viés–variância;
- enxergar todos esses métodos como *médias locais* / *suavizadores lineares*.

Em sala

Mudança de paradigma em relação às Aulas 01–02: lá fixávamos a forma de r (linear) e estimávamos poucos parâmetros. Aqui deixamos *os dados ditarem a forma*. Pergunta: “e se eu não quiser supor forma alguma para $r(\mathbf{x})$?”

1 O que é um método não paramétrico?

Um método **paramétrico** supõe que $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ pertence a uma família indexada por um número *fixo e finito* de parâmetros (ex.: regressão linear, $p + 1$ coeficientes). Um método **não paramétrico** não impõe uma forma funcional fixa: a complexidade efetiva do modelo *cresce com n* . A suposição é mais fraca — tipicamente apenas que r é *suave*.

Ideia central

Em relação aos paramétricos, métodos não paramétricos **reduzem o viés** (capturam relações arbitrárias) ao custo de **aumentar a variância**. Continuamos no mundo da Aula 01: o segredo é controlar a flexibilidade por um *tuning parameter* (o k do KNN, o número de nós de um *spline*), escolhido por validação cruzada (Aula 03).

Observação 1.1. Há uma ponte importante com a Aula 02: penalizar (Ridge, Lasso) e usar um método não paramétrico buscam o mesmo ponto do balanço viés–variância, atacando parcelas opostas. A penalização é para o modelo flexível demais para a amostra, e corta **variância**; o não paramétrico é para o modelo rígido demais para a verdade, e corta **viés**. A Figura 3.8 do [AME] (§3.9) desenha a relação entre os dois.

2 Estratégia de bases: séries ortogonais e *splines*

A primeira ideia para ganhar flexibilidade sem sair do arcabouço linear é **ampliar o conjunto de atributos** com funções $\phi_1, \dots, \phi_I$ das covariáveis e ajustar

$$g(x) = \sum_{j=1}^I \beta_j \phi_j(x),$$

que é *linear nos* β_j — estimável por mínimos quadrados (Aula 02). Aqui a flexibilidade é controlada por I (número de funções da base).

2.1 Séries ortogonais

Usa-se uma base ortonormal de L^2 (Fourier, polinômios ortogonais, *wavelets*). Aproxima-se r por suas primeiras I componentes na base; I é o *tuning parameter* (mais termos $\Rightarrow$ mais flexível). É a ideia por trás de “regressão polinomial” vista na Aula 01 (a base dos monômios $1, x, x^2, \dots$).

2.2 *Splines*

Splines são funções polinomiais por partes, “coladas” suavemente em pontos chamados **nós** (*knots*) $t_1, \dots, t_p$. Uma base conveniente para *splines* de grau k é

$$f_1(x) = 1, f_2(x) = x, \dots, f_{k+1}(x) = x^k, \quad f_{k+1+j}(x) = (x - t_j)_+^k, \quad j = 1, \dots, p,$$

onde $(u)_+ = \max(u, 0)$. Com isso $I = k + 1 + p$, e novamente estimam-se os coeficientes por mínimos quadrados. Variantes importantes: *B-splines* (base numericamente estável), *natural splines* (lineares fora dos nós extremos, reduzindo a variância na fronteira) e *smoothing splines* (penalizam a curvatura — caso particular de RKHS, §4.6).

Em sala

Mostre graficamente: poucos nós $\rightarrow$ curva rígida (subajuste); muitos nós $\rightarrow$ curva “nervosa” (superajuste). O número/posição dos nós é o que controla a complexidade. Conecte: “isto é a Aula 01 de novo”.

3 k vizinhos mais próximos (KNN)

O KNN é talvez o método não paramétrico mais intuitivo: para prever em $\mathbf{x}$, faça a *média das respostas dos k pontos de treino mais próximos de $\mathbf{x}$* .

Definição 3.1 (Regressão KNN). Seja $\mathcal{N}_{\mathbf{x}}$ o conjunto dos índices das k observações de treino mais próximas de $\mathbf{x}$ (segundo uma distância d , em geral euclidiana): $\mathcal{N}_{\mathbf{x}} = \{i : d(\mathbf{X}_i, \mathbf{x}) \leq d_{\mathbf{x}}^k\}$, onde $d_{\mathbf{x}}^k$ é a distância do k -ésimo vizinho. Então

$$\hat{r}(\mathbf{x}) = \frac{1}{k} \sum_{i \in \mathcal{N}_{\mathbf{x}}} Y_i. \quad (1)$$

O parâmetro k controla a flexibilidade:

- k **pequeno** (ex.: $k = 1$): vizinhança minúscula, segue cada ponto $\Rightarrow$ *viés baixo, variância alta* (curva “nervosa”, superajuste).
- k **grande**: média sobre muitos pontos; quando $k \rightarrow n$, $\hat{r}$ tende à média global (constante) $\Rightarrow$ *viés alto, variância baixa* (subajuste).

Escolhe-se k por validação cruzada.

Atenção

KNN exige uma noção de distância e, portanto, **depende fortemente da escala** das covariáveis: uma variável em unidade grande domina a distância. *Padronize* antes (Aula 06). Além disso, sofre da *maldição da dimensionalidade*: em p alto, “vizinhos” deixam de ser próximos.

4 Uma visão unificadora: suavizadores lineares

KNN, *séries* e *splines* são todos **suavizadores lineares**: a predição é uma combinação linear das respostas,

$$\hat{r}(\mathbf{x}) = \sum_{i=1}^n \ell_i(\mathbf{x}) Y_i,$$

com pesos $\ell_i(\mathbf{x})$ que dependem só das covariáveis (não de $\mathbf{Y}$). Para o KNN, $\ell_i(\mathbf{x}) = \frac{1}{k} \mathbf{1}\{i \in \mathcal{N}_{\mathbf{x}}\}$; para uma base, $\ell_i(\mathbf{x})$ vem do ajuste de mínimos quadrados na base. Essa estrutura comum explica por que todos têm o mesmo dilema (o botão de flexibilidade $\leftrightarrow$ viés-variância) e por que valem atalhos como o do LOOCV (Aula 03, Prop. do *leverage*).

Resumo

- Métodos não paramétricos não fixam a forma de r ; reduzem viés e aumentam variância em relação aos paramétricos.
- *Bases* (*séries*, *splines*): linearizam o problema; flexibilidade via número de termos/nós.
- **KNN** (1): média dos k vizinhos; k controla viés-variância.
- Todos são *suavizadores lineares*; *padronize* as covariáveis e cuidado com a dimensão.

Leitura recomendada. [AME] §4.1–4.3 (*séries*, *splines*, KNN); [ISLP] §3.5 (comparação regressão linear $\times$ KNN) e §7.1–7.5 (*Moving Beyond Linearity: splines*).