

Lista Teórica 04 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 04 — Métodos Não Paramétricos (KNN)

Exercício 1 — o KNN nos dois extremos. Considere a amostra abaixo, com $n = 5$ e uma única covariável:

x_i	0	1	3	6	10
y_i	2	3	7	5	12

- Calcule $\hat{r}(4)$ pelo KNN com $k = 1$, $k = 3$ e $k = 5$.
- Para uma amostra genérica sem x_i repetidos, qual é o erro quadrático médio de *treino* do KNN com $k = 1$? E com $k = n$?
- Descreva, em uma frase cada, a cara da função $\hat{r}$ ajustada nos dois extremos.
- Qual dos dois extremos tem viés alto e qual tem variância alta? Relacione com a Aula 01.

Solução

(a) As distâncias a $x_0 = 4$ são $|0 - 4| = 4$, $|1 - 4| = 3$, $|3 - 4| = 1$, $|6 - 4| = 2$, $|10 - 4| = 6$. Em ordem: $x = 3$ (d. 1), $x = 6$ (d. 2), $x = 1$ (d. 3), $x = 0$ (d. 4), $x = 10$ (d. 6). Logo

$$k = 1 : \hat{r}(4) = 7; \quad k = 3 : \hat{r}(4) = \frac{7+5+3}{3} = 5; \quad k = 5 : \hat{r}(4) = \frac{2+3+7+5+12}{5} = 5,8.$$

(b) Com $k = 1$ o erro de treino é **exatamente zero**: o vizinho mais próximo de $\mathbf{X}_i$ é o próprio $\mathbf{X}_i$ (distância 0), então $\hat{r}(\mathbf{X}_i) = Y_i$ para todo i . Com $k = n$ todos os pontos são vizinhos de todos, $\hat{r}(\mathbf{x}) \equiv \bar{Y}$, e o erro de treino é $\frac{1}{n} \sum_i (Y_i - \bar{Y})^2$: a *variância amostral* de Y (a menos do fator $n/(n-1)$).

(c) Com $k = 1$, $\hat{r}$ é uma função **escada** que passa por todos os pontos: constante em cada célula de Voronoi, saltando no meio do caminho entre observações vizinhas. Com $k = n$, $\hat{r}$ é uma **reta horizontal** na altura $\bar{Y}$.

(d) $k = 1$ é o extremo de **variância alta** e viés baixo: cada predição depende de uma única observação, e trocar a amostra muda tudo. $k = n$ é o extremo de **viés alto** e variância zero: a predição não depende de $\mathbf{x}$, e por isso não pode acompanhar r — é literalmente o preditor constante do Exercício 2 da Lista Teórica 01, cujo risco é $\text{Var}(Y)$. O k é o *tuning parameter* que percorre o balanço da Aula 01, com a diferença de que aqui **mais flexível é k menor**, ao contrário do grau do polinômio.

Exercício 2 — o KNN é um suavizador linear. Todos os métodos desta aula se escrevem como $\hat{r}(\mathbf{x}) = \sum_i w_i(\mathbf{x}) Y_i$ — são **suavizadores lineares**. Avaliando nos próprios pontos de treino, $\hat{\mathbf{Y}} = \mathbf{H}\mathbf{Y}$, onde $H_{ij} = w_j(\mathbf{X}_i)$.

- Para o KNN com k vizinhos e x_i distintos, mostre que $h_{ii} = 1/k$ para todo i , e conclua que $\text{tr}(\mathbf{H}) = n/k$.
- A quantidade $\text{tr}(\mathbf{H})$ é o **número efetivo de parâmetros** do ajuste. Calcule-a para $n = 100$ e $k = 1$, $k = 5$, $k = 25$. Compare com o número de parâmetros de um polinômio de grau p e comente.

- (c) Aplique a fórmula do LOOCV da Aula 03, $\hat{R}_{\text{LOO}} = \frac{1}{n} \sum_i ((Y_i - \hat{r}(\mathbf{X}_i))/(1 - h_{ii}))^2$, ao KNN. O que acontece quando $k = 1$? O resultado faz sentido?

Solução

(a) Fixe i e considere a predição no próprio ponto de treino $\mathbf{X}_i$. Os k vizinhos mais próximos de $\mathbf{X}_i$ incluem o próprio $\mathbf{X}_i$, que está a distância 0 — e é o único a essa distância, já que os pontos são distintos. O KNN dá peso $1/k$ a cada um dos k vizinhos, então o peso da observação i sobre a própria predição é $h_{ii} = 1/k$. Somando na diagonal,

$$\text{tr}(\mathbf{H}) = \sum_{i=1}^n h_{ii} = n \cdot \frac{1}{k} = \frac{n}{k}.$$

(b) Com $n = 100$:

k	1	5	25
$\text{tr}(\mathbf{H}) = n/k$	100	20	4

Com $k = 1$ o KNN gasta 100 parâmetros efetivos para 100 observações: um parâmetro por ponto, que é a definição de interpolar — e casa com o erro de treino zero do Exercício 1(b). Com $k = 25$ ele usa 4, menos que um polinômio de grau 4.

A comparação com o polinômio é a moral do exercício: $p + 1$ conta parâmetros *explícitos*, e $\text{tr}(\mathbf{H})$ generaliza isso para métodos que não têm parâmetros nenhum no sentido usual. É a mesma quantidade nos dois casos — para o MQO com $p + 1$ colunas, $\text{tr}(\mathbf{H}) = p + 1$ — e é ela que aparece na fórmula do otimismo do Exercício 1 da Lista Teórica 03. Ou seja: “complexidade” tem uma definição operacional que não depende de o modelo ser paramétrico.

(c) Com $k = 1$ temos $h_{ii} = 1$, logo $1 - h_{ii} = 0$: a fórmula divide por zero. E o numerador também é zero, porque $\hat{r}(\mathbf{X}_i) = Y_i$. Ou seja, $0/0$ — a fórmula não diz nada.

E ela está certa em não dizer, por um motivo que vale para todo k : **a fórmula não calcula o LOOCV do KNN**. Ela foi deduzida supondo que o ajuste sem a observação i é o mesmo tipo de ajuste, com os pesos das outras observações apenas reescalados. No KNN, tirar $\mathbf{X}_i$ muda quem são os vizinhos de $\mathbf{X}_i$: o próprio ponto sai da lista, e entra o $(k + 1)$ -ésimo mais próximo, que antes tinha peso zero.

Veja o que a fórmula calcula no lugar do LOOCV. Chame de S_i a soma das respostas dos outros $k - 1$ vizinhos de $\mathbf{X}_i$. Então $\hat{r}(\mathbf{X}_i) = (Y_i + S_i)/k$, e com $h_{ii} = 1/k$,

$$\frac{Y_i - \hat{r}(\mathbf{X}_i)}{1 - 1/k} = \frac{(k - 1)Y_i - S_i}{k} \cdot \frac{k}{k - 1} = Y_i - \frac{S_i}{k - 1}.$$

Isso é o resíduo de validação do KNN com $k - 1$ vizinhos: sem a observação i , os $k - 1$ vizinhos mais próximos de $\mathbf{X}_i$ são exatamente esses “outros $k - 1$ ”. Aplicada ao KNN, **a fórmula devolve o LOOCV do $(k - 1)$ -NN**, e não o do k -NN. Em $k = 1$ isso seria o LOOCV de um KNN com zero vizinhos, que não existe — daí o $0/0$.

O LOOCV verdadeiro, por sua vez, é barato sem fórmula nenhuma: para cada ponto de treino, peça $k + 1$ vizinhos, descarte o próprio ponto e tire a média dos outros k . A Lista prática 04 mede o erro de usar a fórmula no lugar disso: 27% em $k = 2$, e para lados opostos conforme k . É o que a conta acima prevê quando o LOOCV, como função de k , tem forma de U: abaixo do k ótimo, o $(k - 1)$ -NN é pior que o k -NN e a fórmula superestima; acima dele, é melhor, e ela subestima.