

Lista Teórica 04 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 04 — Métodos Não Paramétricos (KNN)

Exercício 1 — o KNN nos dois extremos. Considere a amostra abaixo, com $n = 5$ e uma única covariável:

x_i	0	1	3	6	10
y_i	2	3	7	5	12

- Calcule $\hat{r}(4)$ pelo KNN com $k = 1$, $k = 3$ e $k = 5$.
- Para uma amostra genérica sem x_i repetidos, qual é o erro quadrático médio de *treino* do KNN com $k = 1$? E com $k = n$?
- Descreva, em uma frase cada, a cara da função $\hat{r}$ ajustada nos dois extremos.
- Qual dos dois extremos tem viés alto e qual tem variância alta? Relacione com a Aula 01.

Solução

(a) As distâncias a $x_0 = 4$ são $|0 - 4| = 4$, $|1 - 4| = 3$, $|3 - 4| = 1$, $|6 - 4| = 2$, $|10 - 4| = 6$. Em ordem: $x = 3$ (d. 1), $x = 6$ (d. 2), $x = 1$ (d. 3), $x = 0$ (d. 4), $x = 10$ (d. 6). Logo

$$k = 1 : \hat{r}(4) = 7; \quad k = 3 : \hat{r}(4) = \frac{7+5+3}{3} = 5; \quad k = 5 : \hat{r}(4) = \frac{2+3+7+5+12}{5} = 5,8.$$

(b) Com $k = 1$ o erro de treino é **exatamente zero**: o vizinho mais próximo de $\mathbf{X}_i$ é o próprio $\mathbf{X}_i$ (distância 0), então $\hat{r}(\mathbf{X}_i) = Y_i$ para todo i . Com $k = n$ todos os pontos são vizinhos de todos, $\hat{r}(\mathbf{x}) \equiv \bar{Y}$, e o erro de treino é $\frac{1}{n} \sum_i (Y_i - \bar{Y})^2$: a *variância amostral* de Y (a menos do fator $n/(n-1)$).

(c) Com $k = 1$, $\hat{r}$ é uma função **escada** que passa por todos os pontos: constante em cada célula de Voronoi, saltando no meio do caminho entre observações vizinhas. Com $k = n$, $\hat{r}$ é uma **reta horizontal** na altura $\bar{Y}$.

(d) $k = 1$ é o extremo de **variância alta** e viés baixo: cada predição depende de uma única observação, e trocar a amostra muda tudo. $k = n$ é o extremo de **viés alto** e variância zero: a predição não depende de $\mathbf{x}$, e por isso não pode acompanhar r — é literalmente o preditor constante do Exercício 2 da Lista Teórica 01, cujo risco é $\text{Var}(Y)$. O k é o *tuning parameter* que percorre o balanço da Aula 01, com a diferença de que aqui **mais flexível é k menor**, ao contrário do grau do polinômio.

Exercício 2 — os pesos do Nadaraya–Watson. O estimador de Nadaraya–Watson é

$$\hat{r}(\mathbf{x}) = \sum_{i=1}^n w_i(\mathbf{x}) Y_i, \quad w_i(\mathbf{x}) = \frac{K(\mathbf{x}, \mathbf{X}_i)}{\sum_{j=1}^n K(\mathbf{x}, \mathbf{X}_j)}.$$

- Mostre que $\sum_{i=1}^n w_i(\mathbf{x}) = 1$, qualquer que seja o kernel $K \geq 0$ (desde que o denominador não se anule). Por que essa propriedade importa? *Sugestão*: o que $\hat{r}$ devolve se todos os Y_i valem a mesma constante c ?

- (b) Tome o kernel **uniforme**, $K(\mathbf{x}, \mathbf{X}_i) = \mathbb{I}\{|x - x_i| \leq h\}$. Mostre que $\hat{r}(x)$ vira a média simples dos y_i com $|x - x_i| \leq h$, e calcule $\hat{r}(4)$ na amostra do Exercício 1 para $h = 2,5$ e $h = 4$.
- (c) Mostre que $\hat{r}(\mathbf{x})$ da fórmula acima é exatamente o minimizador

$$\hat{\beta}_0 = \arg \min_{\beta_0} \sum_{i=1}^n w_i(\mathbf{x}) (Y_i - \beta_0)^2.$$

Em uma frase: que modelo estamos ajustando em cada ponto $\mathbf{x}$?

Solução

(a) Some diretamente:

$$\sum_{i=1}^n w_i(\mathbf{x}) = \sum_{i=1}^n \frac{K(\mathbf{x}, \mathbf{X}_i)}{\sum_j K(\mathbf{x}, \mathbf{X}_j)} = \frac{\sum_i K(\mathbf{x}, \mathbf{X}_i)}{\sum_j K(\mathbf{x}, \mathbf{X}_j)} = 1,$$

porque numerador e denominador são a mesma soma. Importa porque garante que $\hat{r}$ é uma **média ponderada**, e não uma soma ponderada qualquer: se todos os $Y_i = c$, então $\hat{r}(\mathbf{x}) = c \sum_i w_i(\mathbf{x}) = c$. Um estimador que não reproduzisse uma constante seria enviesado até no caso mais fácil possível. É também o que mantém $\hat{r}(\mathbf{x})$ dentro do intervalo $[\min_i Y_i, \max_i Y_i]$.

(b) Com o kernel uniforme, $K(\mathbf{x}, \mathbf{X}_i)$ vale 1 para os pontos a distância no máximo h e 0 para os demais. Chamando de $V = \{i : |x - x_i| \leq h\}$ o conjunto dos vizinhos, o denominador é $|V|$ e

$$w_i(x) = \begin{cases} 1/|V|, & i \in V \\ 0, & \text{caso contrário,} \end{cases} \quad \text{logo} \quad \hat{r}(x) = \frac{1}{|V|} \sum_{i \in V} Y_i.$$

Na amostra do Exercício 1, em $x = 4$:

- $h = 2,5$: entram $x = 3$ e $x = 6$ (distâncias 1 e 2); $\hat{r}(4) = \frac{7+5}{2} = 6$;
- $h = 4$: entram $x = 3, 6, 1$ e 0 (distâncias 1, 2, 3, 4); $\hat{r}(4) = \frac{7+5+3+2}{4} = 4,25$.

Compare com o KNN: em $x = 4$, o $k = 3$ deu 5 e o NW com $h = 2,5$ deu 6. São regras de vizinhança diferentes — o KNN fixa o *número* de vizinhos e deixa o raio variar; o NW fixa o *raio* e deixa o número variar.

(c) Derivando em β_0 :

$$\frac{\partial}{\partial \beta_0} \sum_i w_i(\mathbf{x}) (Y_i - \beta_0)^2 = -2 \sum_i w_i(\mathbf{x}) (Y_i - \beta_0) = 0 \implies \sum_i w_i(\mathbf{x}) Y_i = \beta_0 \sum_i w_i(\mathbf{x}) = \beta_0,$$

usando o item (a) na última igualdade. A segunda derivada é $2 \sum_i w_i(\mathbf{x}) = 2 > 0$, então é mínimo. Em cada ponto $\mathbf{x}$ estamos ajustando uma **constante** por mínimos quadrados ponderados, com pesos que decaem com a distância a $\mathbf{x}$ — um polinômio local de grau zero.

Exercício 3 — o viés de fronteira, calculado exatamente. Este exercício mostra em conta fechada o que a figura da nota mostra em desenho. Suponha o caso mais favorável possível: $r(x) = x$ em $[0, 1]$, **sem ruído** ($Y_i = r(X_i) = X_i$), e uma amostra tão densa que podemos tratar os X_i como espalhados uniformemente em $[0, 1]$. Use o kernel uniforme de janela h , com $0 < h < 1/2$.

- (a) Calcule $\hat{r}_{\text{NW}}(x_0)$ num ponto **interior**, $h < x_0 < 1 - h$. Qual é o viés?
- (b) Calcule $\hat{r}_{\text{NW}}(0)$, na **fronteira**. Qual é o viés? *Sugestão*: quais pontos estão a distância $\leq h$ de 0?
- (c) Agora a regressão linear local: em vez de uma constante, ajuste uma *reta* por mínimos quadrados aos pontos da janela e avalie em x_0 . Qual o viés em $x_0 = 0$? Justifique sem fazer contas.
- (d) Explique em duas ou três linhas por que a diferença aparece só na fronteira, e o que isso implica na prática quando p é grande.

Solução

(a) Os pontos da janela são os de $[x_0 - h, x_0 + h]$, um intervalo simétrico em torno de x_0 e inteiramente dentro de $[0, 1]$. Como $Y_i = X_i$, a média deles é a média de uma uniforme em $[x_0 - h, x_0 + h]$, ou seja x_0 . Portanto

$$\hat{r}_{\text{NW}}(x_0) = x_0 = r(x_0), \quad \text{viés} = 0.$$

(b) Em $x_0 = 0$ a janela seria $[-h, h]$, mas não existem observações à esquerda de 0: sobram apenas os pontos de $[0, h]$. A média de uma uniforme em $[0, h]$ é $h/2$, então

$$\hat{r}_{\text{NW}}(0) = \frac{h}{2}, \quad \text{viés} = \frac{h}{2} - r(0) = \frac{h}{2} > 0.$$

Note que o viés **não some com mais dados**: ele depende só de h . Some apenas se $h \rightarrow 0$, e aí a variância explode. E o sinal é informativo — na fronteira esquerda o estimador puxa para *cima*, porque todos os vizinhos disponíveis estão do lado de r maior.

(c) Viés **zero**. A regressão linear local ajusta uma reta aos pontos de $[0, h]$; como nesse trecho $Y_i = X_i$ exatamente, a reta de mínimos quadrados é a própria $y = x$, e avaliá-la em 0 dá 0. O argumento geral: a janela ser assimétrica só atrapalha o grau 0 porque a média dos vizinhos é puxada pela inclinação de r ; ao estimar essa inclinação explicitamente, o grau 1 a desconta. Formalmente, o linear local elimina o termo de primeira ordem da expansão de Taylor de r , e sobra viés de ordem h^2 em vez de h .

(d) No interior a janela é simétrica em torno de x_0 , e os vizinhos à esquerda compensam exatamente os da direita: as contribuições de primeira ordem se cancelam. Na fronteira essa simetria se quebra — todos os vizinhos estão do mesmo lado — e a inclinação de r passa a enviesar a média.

A implicação prática é desconfortável: em dimensão p , a fração de pontos que está “perto da fronteira” cresce muito rápido com p . Numa bola ou num cubo em $\mathbb{R}^{20}$, praticamente *toda* observação é um ponto de fronteira em alguma direção. Ou seja, o que em $p = 1$ é um defeito localizado nas duas pontas vira, em p grande, o comportamento típico. É a maldição da dimensionalidade vista por outro ângulo, e é o assunto da Aula 05.

Exercício 4 — o KNN é um suavizador linear. Todos os métodos desta aula se escrevem como $\hat{r}(\mathbf{x}) = \sum_i w_i(\mathbf{x}) Y_i$ — são **suavizadores lineares**. Avaliando nos próprios pontos de treino, $\hat{\mathbf{Y}} = \mathbf{H}\mathbf{Y}$, onde $H_{ij} = w_j(\mathbf{X}_i)$.

- (a) Para o KNN com k vizinhos e x_i distintos, mostre que $h_{ii} = 1/k$ para todo i , e conclua que $\text{tr}(\mathbf{H}) = n/k$.
- (b) A quantidade $\text{tr}(\mathbf{H})$ é o **número efetivo de parâmetros** do ajuste. Calcule-a para $n = 100$ e $k = 1, k = 5, k = 25$. Compare com o número de parâmetros de um polinômio de grau p e comente.

- (c) Aplique a fórmula do LOOCV da Aula 03, $\hat{R}_{\text{LOO}} = \frac{1}{n} \sum_i ((Y_i - \hat{r}(\mathbf{X}_i))/(1 - h_{ii}))^2$, ao KNN. O que acontece quando $k = 1$? O resultado faz sentido?

Solução

(a) Fixe i e considere a predição no próprio ponto de treino $\mathbf{X}_i$. Os k vizinhos mais próximos de $\mathbf{X}_i$ incluem o próprio $\mathbf{X}_i$, que está a distância 0 — e é o único a essa distância, já que os pontos são distintos. O KNN dá peso $1/k$ a cada um dos k vizinhos, então o peso da observação i sobre a própria predição é $h_{ii} = 1/k$. Somando na diagonal,

$$\text{tr}(\mathbf{H}) = \sum_{i=1}^n h_{ii} = n \cdot \frac{1}{k} = \frac{n}{k}.$$

(b) Com $n = 100$:

k	1	5	25
$\text{tr}(\mathbf{H}) = n/k$	100	20	4

Com $k = 1$ o KNN gasta 100 parâmetros efetivos para 100 observações: um parâmetro por ponto, que é a definição de interpolar — e casa com o erro de treino zero do Exercício 1(b). Com $k = 25$ ele usa 4, menos que um polinômio de grau 4.

A comparação com o polinômio é a moral do exercício: $p + 1$ conta parâmetros *explícitos*, e $\text{tr}(\mathbf{H})$ generaliza isso para métodos que não têm parâmetros nenhum no sentido usual. É a mesma quantidade nos dois casos — para o MQO com $p + 1$ colunas, $\text{tr}(\mathbf{H}) = p + 1$ — e é ela que aparece na fórmula do otimismo do Exercício 1 da Lista Teórica 03. Ou seja: “complexidade” tem uma definição operacional que não depende de o modelo ser paramétrico.

(c) Com $k = 1$ temos $h_{ii} = 1$, logo $1 - h_{ii} = 0$: a fórmula divide por zero. E o numerador também é zero, porque $\hat{r}(\mathbf{X}_i) = Y_i$. Ou seja, $0/0$ — a fórmula não diz nada.

E está certa em não dizer. O atalho vale para ajustes lineares em que nenhuma observação determina sozinha a própria predição; com $k = 1$ ela a determina inteiramente, e o resíduo de treino perdeu *toda* a informação sobre o erro de validação. Não há como recuperar o LOOCV de um único ajuste nesse caso: é preciso rodar a força bruta, refazendo o ajuste n vezes. Para $k \geq 2$ a fórmula funciona normalmente, com o fator de inflação $1/(1 - 1/k) = k/(k - 1)$.