

## Lista Teórica 04 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 04 — Métodos Não Paramétricos (KNN)

**Exercício 1 — o KNN nos dois extremos.** Considere a amostra abaixo, com  $n = 5$  e uma única covariável:

|       |   |   |   |   |    |
|-------|---|---|---|---|----|
| $x_i$ | 0 | 1 | 3 | 6 | 10 |
| $y_i$ | 2 | 3 | 7 | 5 | 12 |

- Calcule  $\hat{r}(4)$  pelo KNN com  $k = 1$ ,  $k = 3$  e  $k = 5$ .
- Para uma amostra genérica sem  $x_i$  repetidos, qual é o erro quadrático médio de *treino* do KNN com  $k = 1$ ? E com  $k = n$ ?
- Descreva, em uma frase cada, a cara da função  $\hat{r}$  ajustada nos dois extremos.
- Qual dos dois extremos tem viés alto e qual tem variância alta? Relacione com a Aula 01.

### Solução

(a) As distâncias a  $x_0 = 4$  são  $|0 - 4| = 4$ ,  $|1 - 4| = 3$ ,  $|3 - 4| = 1$ ,  $|6 - 4| = 2$ ,  $|10 - 4| = 6$ . Em ordem:  $x = 3$  (d. 1),  $x = 6$  (d. 2),  $x = 1$  (d. 3),  $x = 0$  (d. 4),  $x = 10$  (d. 6). Logo

$$k = 1 : \hat{r}(4) = 7; \quad k = 3 : \hat{r}(4) = \frac{7+5+3}{3} = 5; \quad k = 5 : \hat{r}(4) = \frac{2+3+7+5+12}{5} = 5,8.$$

(b) Com  $k = 1$  o erro de treino é **exatamente zero**: o vizinho mais próximo de  $\mathbf{X}_i$  é o próprio  $\mathbf{X}_i$  (distância 0), então  $\hat{r}(\mathbf{X}_i) = Y_i$  para todo  $i$ . Com  $k = n$  todos os pontos são vizinhos de todos,  $\hat{r}(\mathbf{x}) \equiv \bar{Y}$ , e o erro de treino é  $\frac{1}{n} \sum_i (Y_i - \bar{Y})^2$ : a *variância amostral* de  $Y$  (a menos do fator  $n/(n-1)$ ).

(c) Com  $k = 1$ ,  $\hat{r}$  é uma função **escada** que passa por todos os pontos: constante em cada célula de Voronoi, saltando no meio do caminho entre observações vizinhas. Com  $k = n$ ,  $\hat{r}$  é uma **reta horizontal** na altura  $\bar{Y}$ .

(d)  $k = 1$  é o extremo de **variância alta** e viés baixo: cada predição depende de uma única observação, e trocar a amostra muda tudo.  $k = n$  é o extremo de **viés alto** e variância zero: a predição não depende de  $\mathbf{x}$ , e por isso não pode acompanhar  $r$  — é literalmente o preditor constante do Exercício 2 da Lista Teórica 01, cujo risco é  $\text{Var}(Y)$ . O  $k$  é o *tuning parameter* que percorre o balanço da Aula 01, com a diferença de que aqui **mais flexível é  $k$  menor**, ao contrário do grau do polinômio.

**Exercício 2 — os pesos do Nadaraya–Watson.** O estimador de Nadaraya–Watson é

$$\hat{r}(\mathbf{x}) = \sum_{i=1}^n w_i(\mathbf{x}) Y_i, \quad w_i(\mathbf{x}) = \frac{K(\mathbf{x}, \mathbf{X}_i)}{\sum_{j=1}^n K(\mathbf{x}, \mathbf{X}_j)}.$$

- Mostre que  $\sum_{i=1}^n w_i(\mathbf{x}) = 1$ , qualquer que seja o kernel  $K \geq 0$  (desde que o denominador não se anule). Por que essa propriedade importa? *Sugestão*: o que  $\hat{r}$  devolve se todos os  $Y_i$  valem a mesma constante  $c$ ?

- (b) Tome o kernel **uniforme**,  $K(\mathbf{x}, \mathbf{X}_i) = \mathbb{I}\{|x - x_i| \leq h\}$ . Mostre que  $\hat{r}(x)$  vira a média simples dos  $y_i$  com  $|x - x_i| \leq h$ , e calcule  $\hat{r}(4)$  na amostra do Exercício 1 para  $h = 2,5$  e  $h = 4$ .
- (c) Mostre que  $\hat{r}(\mathbf{x})$  da fórmula acima é exatamente o minimizador

$$\hat{\beta}_0 = \arg \min_{\beta_0} \sum_{i=1}^n w_i(\mathbf{x}) (Y_i - \beta_0)^2.$$

Em uma frase: que modelo estamos ajustando em cada ponto  $\mathbf{x}$ ?

### Solução

- (a) Some diretamente:

$$\sum_{i=1}^n w_i(\mathbf{x}) = \sum_{i=1}^n \frac{K(\mathbf{x}, \mathbf{X}_i)}{\sum_j K(\mathbf{x}, \mathbf{X}_j)} = \frac{\sum_i K(\mathbf{x}, \mathbf{X}_i)}{\sum_j K(\mathbf{x}, \mathbf{X}_j)} = 1,$$

porque numerador e denominador são a mesma soma. Importa porque garante que  $\hat{r}$  é uma **média ponderada**, e não uma soma ponderada qualquer: se todos os  $Y_i = c$ , então  $\hat{r}(\mathbf{x}) = c \sum_i w_i(\mathbf{x}) = c$ . Um estimador que não reproduzisse uma constante seria enviesado até no caso mais fácil possível. É também o que mantém  $\hat{r}(\mathbf{x})$  dentro do intervalo  $[\min_i Y_i, \max_i Y_i]$ .

- (b) Com o kernel uniforme,  $K(\mathbf{x}, \mathbf{X}_i)$  vale 1 para os pontos a distância no máximo  $h$  e 0 para os demais. Chamando de  $V = \{i : |x - x_i| \leq h\}$  o conjunto dos vizinhos, o denominador é  $|V|$  e

$$w_i(x) = \begin{cases} 1/|V|, & i \in V \\ 0, & \text{caso contrário,} \end{cases} \quad \text{logo} \quad \hat{r}(x) = \frac{1}{|V|} \sum_{i \in V} Y_i.$$

Na amostra do Exercício 1, em  $x = 4$ :

- $h = 2,5$ : entram  $x = 3$  e  $x = 6$  (distâncias 1 e 2);  $\hat{r}(4) = \frac{7+5}{2} = 6$ ;
- $h = 4$ : entram  $x = 3, 6, 1$  e  $0$  (distâncias 1, 2, 3, 4);  $\hat{r}(4) = \frac{7+5+3+2}{4} = 4,25$ .

Compare com o KNN: em  $x = 4$ , o  $k = 3$  deu 5 e o NW com  $h = 2,5$  deu 6. São regras de vizinhança diferentes — o KNN fixa o *número* de vizinhos e deixa o raio variar; o NW fixa o *raio* e deixa o número variar.

- (c) Derivando em  $\beta_0$ :

$$\frac{\partial}{\partial \beta_0} \sum_i w_i(\mathbf{x}) (Y_i - \beta_0)^2 = -2 \sum_i w_i(\mathbf{x}) (Y_i - \beta_0) = 0 \implies \sum_i w_i(\mathbf{x}) Y_i = \beta_0 \sum_i w_i(\mathbf{x}) = \beta_0,$$

usando o item (a) na última igualdade. A segunda derivada é  $2 \sum_i w_i(\mathbf{x}) = 2 > 0$ , então é mínimo. Em cada ponto  $\mathbf{x}$  estamos ajustando uma **constante** por mínimos quadrados ponderados, com pesos que decaem com a distância a  $\mathbf{x}$  — um polinômio local de grau zero.

**Exercício 3 — o viés de fronteira, calculado exatamente.** Este exercício mostra em conta fechada o que a figura da nota mostra em desenho. Suponha o caso mais favorável possível:  $r(x) = x$  em  $[0, 1]$ , **sem ruído** ( $Y_i = r(X_i) = X_i$ ), e uma amostra tão densa que podemos tratar os  $X_i$  como espalhados uniformemente em  $[0, 1]$ . Use o kernel uniforme de janela  $h$ , com  $0 < h < 1/2$ .

- (a) Calcule  $\hat{r}_{\text{NW}}(x_0)$  num ponto **interior**,  $h < x_0 < 1 - h$ . Qual é o viés?
- (b) Calcule  $\hat{r}_{\text{NW}}(0)$ , na **fronteira**. Qual é o viés? *Sugestão*: quais pontos estão a distância  $\leq h$  de 0?
- (c) Agora a regressão linear local: em vez de uma constante, ajuste uma *reta* por mínimos quadrados aos pontos da janela e avalie em  $x_0$ . Qual o viés em  $x_0 = 0$ ? Justifique sem fazer contas.
- (d) Explique em duas ou três linhas por que a diferença aparece só na fronteira, e o que isso implica na prática quando  $d$  é grande.

### Solução

(a) Os pontos da janela são os de  $[x_0 - h, x_0 + h]$ , um intervalo simétrico em torno de  $x_0$  e inteiramente dentro de  $[0, 1]$ . Como  $Y_i = X_i$ , a média deles é a média de uma uniforme em  $[x_0 - h, x_0 + h]$ , ou seja  $x_0$ . Portanto

$$\hat{r}_{\text{NW}}(x_0) = x_0 = r(x_0), \quad \text{viés} = 0.$$

(b) Em  $x_0 = 0$  a janela seria  $[-h, h]$ , mas não existem observações à esquerda de 0: sobram apenas os pontos de  $[0, h]$ . A média de uma uniforme em  $[0, h]$  é  $h/2$ , então

$$\hat{r}_{\text{NW}}(0) = \frac{h}{2}, \quad \text{viés} = \frac{h}{2} - r(0) = \frac{h}{2} > 0.$$

Note que o viés **não some com mais dados**: ele depende só de  $h$ . Some apenas se  $h \rightarrow 0$ , e aí a variância explode. E o sinal é informativo — na fronteira esquerda o estimador puxa para *cima*, porque todos os vizinhos disponíveis estão do lado de  $r$  maior.

(c) Viés **zero**. A regressão linear local ajusta uma reta aos pontos de  $[0, h]$ ; como nesse trecho  $Y_i = X_i$  exatamente, a reta de mínimos quadrados é a própria  $y = x$ , e avaliá-la em 0 dá 0. O argumento geral: a janela ser assimétrica só atrapalha o grau 0 porque a média dos vizinhos é puxada pela inclinação de  $r$ ; ao estimar essa inclinação explicitamente, o grau 1 a desconta. Formalmente, o linear local elimina o termo de primeira ordem da expansão de Taylor de  $r$ , e sobra viés de ordem  $h^2$  em vez de  $h$ .

(d) No interior a janela é simétrica em torno de  $x_0$ , e os vizinhos à esquerda compensam exatamente os da direita: as contribuições de primeira ordem se cancelam. Na fronteira essa simetria se quebra — todos os vizinhos estão do mesmo lado — e a inclinação de  $r$  passa a enviesar a média.

A implicação prática é desconfortável: em dimensão  $d$ , a fração de pontos que está “perto da fronteira” cresce muito rápido com  $d$ . Numa bola ou num cubo em  $\mathbb{R}^{20}$ , praticamente *toda* observação é um ponto de fronteira em alguma direção. Ou seja, o que em  $d = 1$  é um defeito localizado nas duas pontas vira, em  $d$  grande, o comportamento típico. É a maldição da dimensionalidade vista por outro ângulo, e é o assunto da Aula 05.

**Exercício 4 — o KNN é um suavizador linear.** Todos os métodos desta aula se escrevem como  $\hat{r}(\mathbf{x}) = \sum_i w_i(\mathbf{x}) Y_i$  — são **suavizadores lineares**. Avaliando nos próprios pontos de treino,  $\hat{\mathbf{Y}} = \mathbf{H}\mathbf{Y}$ , onde  $H_{ij} = w_j(\mathbf{X}_i)$ .

- (a) Para o KNN com  $k$  vizinhos e  $x_i$  distintos, mostre que  $h_{ii} = 1/k$  para todo  $i$ , e conclua que  $\text{tr}(\mathbf{H}) = n/k$ .
- (b) A quantidade  $\text{tr}(\mathbf{H})$  é o **número efetivo de parâmetros** do ajuste. Calcule-a para  $n = 100$  e  $k = 1, k = 5, k = 25$ . Compare com o número de parâmetros de um polinômio de grau  $p$  e comente.

- (c) Aplique a fórmula do LOOCV da Aula 03,  $\hat{R}_{\text{LOO}} = \frac{1}{n} \sum_i ((Y_i - \hat{r}(\mathbf{X}_i))/(1 - h_{ii}))^2$ , ao KNN. O que acontece quando  $k = 1$ ? O resultado faz sentido?

### Solução

(a) Fixe  $i$  e considere a predição no próprio ponto de treino  $\mathbf{X}_i$ . Os  $k$  vizinhos mais próximos de  $\mathbf{X}_i$  incluem o próprio  $\mathbf{X}_i$ , que está a distância 0 — e é o único a essa distância, já que os pontos são distintos. O KNN dá peso  $1/k$  a cada um dos  $k$  vizinhos, então o peso da observação  $i$  sobre a própria predição é  $h_{ii} = 1/k$ . Somando na diagonal,

$$\text{tr}(\mathbf{H}) = \sum_{i=1}^n h_{ii} = n \cdot \frac{1}{k} = \frac{n}{k}.$$

(b) Com  $n = 100$ :

| $k$                           | 1   | 5  | 25 |
|-------------------------------|-----|----|----|
| $\text{tr}(\mathbf{H}) = n/k$ | 100 | 20 | 4  |

Com  $k = 1$  o KNN gasta 100 parâmetros efetivos para 100 observações: um parâmetro por ponto, que é a definição de interpolar — e casa com o erro de treino zero do Exercício 1(b). Com  $k = 25$  ele usa 4, menos que um polinômio de grau 4.

A comparação com o polinômio é a moral do exercício:  $p + 1$  conta parâmetros *explícitos*, e  $\text{tr}(\mathbf{H})$  generaliza isso para métodos que não têm parâmetros nenhum no sentido usual. É a mesma quantidade nos dois casos — para o MQO com  $p + 1$  colunas,  $\text{tr}(\mathbf{H}) = p + 1$  — e é ela que aparece na fórmula do otimismo do Exercício 1 da Lista Teórica 03. Ou seja: “complexidade” tem uma definição operacional que não depende de o modelo ser paramétrico.

(c) Com  $k = 1$  temos  $h_{ii} = 1$ , logo  $1 - h_{ii} = 0$ : a fórmula divide por zero. E o numerador também é zero, porque  $\hat{r}(\mathbf{X}_i) = Y_i$ . Ou seja,  $0/0$  — a fórmula não diz nada.

E está certa em não dizer. O atalho vale para ajustes lineares em que nenhuma observação determina sozinha a própria predição; com  $k = 1$  ela a determina inteiramente, e o resíduo de treino perdeu *toda* a informação sobre o erro de validação. Não há como recuperar o LOOCV de um único ajuste nesse caso: é preciso rodar a força bruta, refazendo o ajuste  $n$  vezes. Para  $k \geq 2$  a fórmula funciona normalmente, com o fator de inflação  $1/(1 - 1/k) = k/(k - 1)$ .