

Lista Teórica 04

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 04 — Métodos Não Paramétricos (KNN)

Exercício 1 — o KNN nos dois extremos. Considere a amostra abaixo, com $n = 5$ e uma única covariável:

x_i	0	1	3	6	10
y_i	2	3	7	5	12

- (a) Calcule $\hat{r}(4)$ pelo KNN com $k = 1$, $k = 3$ e $k = 5$.
- (b) Para uma amostra genérica sem x_i repetidos, qual é o erro quadrático médio de *treino* do KNN com $k = 1$? E com $k = n$?
- (c) Descreva, em uma frase cada, a cara da função $\hat{r}$ ajustada nos dois extremos.
- (d) Qual dos dois extremos tem viés alto e qual tem variância alta? Relacione com a Aula 01.

Exercício 2 — os pesos do Nadaraya–Watson. O estimador de Nadaraya–Watson é

$$\hat{r}(\mathbf{x}) = \sum_{i=1}^n w_i(\mathbf{x}) Y_i, \quad w_i(\mathbf{x}) = \frac{K(\mathbf{x}, \mathbf{X}_i)}{\sum_{j=1}^n K(\mathbf{x}, \mathbf{X}_j)}.$$

- (a) Mostre que $\sum_{i=1}^n w_i(\mathbf{x}) = 1$, qualquer que seja o kernel $K \geq 0$ (desde que o denominador não se anule). Por que essa propriedade importa? *Sugestão:* o que $\hat{r}$ devolve se todos os Y_i valem a mesma constante c ?
- (b) Tome o kernel **uniforme**, $K(\mathbf{x}, \mathbf{X}_i) = \mathbb{I}\{|x - x_i| \leq h\}$. Mostre que $\hat{r}(x)$ vira a média simples dos y_i com $|x - x_i| \leq h$, e calcule $\hat{r}(4)$ na amostra do Exercício 1 para $h = 2,5$ e $h = 4$.
- (c) Mostre que $\hat{r}(\mathbf{x})$ da fórmula acima é exatamente o minimizador

$$\hat{\beta}_0 = \arg \min_{\beta_0} \sum_{i=1}^n w_i(\mathbf{x}) (Y_i - \beta_0)^2.$$

Em uma frase: que modelo estamos ajustando em cada ponto $\mathbf{x}$?

Exercício 3 — o viés de fronteira, calculado exatamente. Este exercício mostra em conta fechada o que a figura da nota mostra em desenho. Suponha o caso mais favorável possível: $r(x) = x$ em $[0, 1]$, **sem ruído** ($Y_i = r(X_i) = X_i$), e uma amostra tão densa que podemos tratar os X_i como espalhados uniformemente em $[0, 1]$. Use o kernel uniforme de janela h , com $0 < h < 1/2$.

- (a) Calcule $\hat{r}_{\text{NW}}(x_0)$ num ponto **interior**, $h < x_0 < 1 - h$. Qual é o viés?
- (b) Calcule $\hat{r}_{\text{NW}}(0)$, na **fronteira**. Qual é o viés? *Sugestão:* quais pontos estão a distância $\leq h$ de 0?
- (c) Agora a regressão linear local: em vez de uma constante, ajuste uma *reta* por mínimos quadrados aos pontos da janela e avalie em x_0 . Qual o viés em $x_0 = 0$? Justifique sem fazer contas.

- (d) Explique em duas ou três linhas por que a diferença aparece só na fronteira, e o que isso implica na prática quando d é grande.

Exercício 4 — o KNN é um suavizador linear. Todos os métodos desta aula se escrevem como $\hat{r}(\mathbf{x}) = \sum_i w_i(\mathbf{x})Y_i$ — são **suavizadores lineares**. Avaliando nos próprios pontos de treino, $\hat{\mathbf{Y}} = \mathbf{H}\mathbf{Y}$, onde $H_{ij} = w_j(\mathbf{X}_i)$.

- (a) Para o KNN com k vizinhos e x_i distintos, mostre que $h_{ii} = 1/k$ para todo i , e conclua que $\text{tr}(\mathbf{H}) = n/k$.
- (b) A quantidade $\text{tr}(\mathbf{H})$ é o **número efetivo de parâmetros** do ajuste. Calcule-a para $n = 100$ e $k = 1$, $k = 5$, $k = 25$. Compare com o número de parâmetros de um polinômio de grau p e comente.
- (c) Aplique a fórmula do LOOCV da Aula 03, $\hat{R}_{\text{LOO}} = \frac{1}{n} \sum_i ((Y_i - \hat{r}(\mathbf{X}_i))/(1 - h_{ii}))^2$, ao KNN. O que acontece quando $k = 1$? O resultado faz sentido?