Aula 05 — Árvores de Regressão e *Ensembles*

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §4.8–4.9; ISLP cap. 8

Objetivos da aula

Ao final desta aula o aluno deve ser capaz de:

- descrever como uma **árvore de regressão** particiona o espaço de covariáveis e prediz por médias locais;
- explicar a construção em duas etapas: *crescimento* por divisões binárias recursivas e *poda* por custo–complexidade;
- justificar, via redução de variância, por que **agregar** estimadores ajuda;
- descrever **bagging** e explicar como as **florestas aleatórias** *descorrelacionam* as árvores, e o papel de m.

Em sala

Árvores são o método mais *interpretável* que veremos — e, sozinhas, das piores em predição. A história da aula é como transformá-las, via agregação, em um dos métodos *mais poderosos* que existem (as florestas). Pergunta de abertura: *"como combinar muitos modelos ruins para obter um ótimo?"*

1 Árvores de regressão

Uma árvore parte o espaço de covariáveis em regiões disjuntas $R_1, \dots, R_J$ por *particionamento recursivo* e prediz, em cada região, a média das respostas de treino ali contidas:

$$g(\boldsymbol{x}) = \frac{1}{|\{i : \boldsymbol{X}_i \in R_k\}|} \sum_{i:\boldsymbol{X}_i \in R_k} Y_i, \qquad \text{para } \boldsymbol{x} \in R_k. \tag{1}$$

Para prever, percorre-se a árvore do topo às folhas seguindo as condições ("$x_j < t$?") em cada nó.

Ideia central

Vantagens estruturais das árvores: (i) altamente **interpretáveis**; (ii) lidam *nativamente* com covariáveis discretas (cortes do tipo $x_j \in \{\text{verde}, \text{vermelho}\}$ — sem precisar criar *dummies*); (iii) fazem **seleção de variáveis** automática; (iv) capturam **interações** sem que precisemos especificá-las.

1.1 Etapa 1 — crescimento (divisões binárias recursivas)

Idealmente escolheríamos a partição que minimiza o EQM $P(T) = \sum_R \sum_{i:\boldsymbol{X}_i \in R} (Y_i - \widehat{y}_R)^2 / n$. Mas buscar a árvore ótima é computacionalmente inviável (NP-difícil). Usa-se então uma heurística

gananciosa: a cada passo, escolhe-se a covariável x_j e o corte t que mais reduzem a soma de quadrados ao dividir uma região em $R_1 = \{x_j < t\}$ e $R_2 = \{x_j \geq t\}$:

$$\min_{j,\,t} \sum_{i:\boldsymbol{X}_i \in R_1} (Y_i - \widehat{y}_{R_1})^2 + \sum_{i:\boldsymbol{X}_i \in R_2} (Y_i - \widehat{y}_{R_2})^2. \tag{2}$$

Repete-se recursivamente em cada região-filha, até um critério de parada (ex.: menos de 5 observações por folha). Isso gera uma árvore grande T_0, que ajusta bem o treino mas tende a **superajustar**.

Em sala

Pergunta: *"a árvore gananciosa acha a solução de* $y = \text{sinal}(x_1x_2x_3)$*?"* Oito regiões resolvem exatamente, e caberiam em profundidade 3 — então a resposta intuitiva é sim. A §3 da `Aula prática 05` mede: o melhor corte da raiz reduz 0,194% do RSS dali, e nos dois filhos que ele produz os melhores cortes reduzem 0,447% e 0,942%; e o RSS de teste fica **acima** do de chutar a média até a profundidade 5 — pior a cada nível — caindo a 13% dele só com a árvore cheia, de 59 folhas. Vale desenhar os octantes no quadro e mostrar que qualquer corte deixa os dois lados com média zero.
E o corolário que interessa para a próxima subseção: com `min_impurity_decrease=0,005` a árvore fica com **uma folha**. A parada precoce não é uma poda mais barata — é uma poda que decide antes de ter informação.

1.2 Etapa 2 — poda por custo–complexidade

Para reduzir a variância, *podamos* T_0. A poda por custo–complexidade introduz um parâmetro $\alpha \geq 0$ e busca a subárvore $T \subseteq T_0$ que minimiza

$$\sum_{k=1}^{|T|} \sum_{i:\boldsymbol{X}_i \in R_k} (Y_i - \widehat{y}_{R_k})^2 + \alpha\,|T|\,, \tag{3}$$

onde $|T|$ é o número de folhas. O termo $\alpha\,|T|$ penaliza árvores grandes — é o mesmo espírito da regularização da Aula 02 (trocamos viés por menos variância). α é o **tuning parameter**, escolhido por **validação cruzada** (Aula 03): $\alpha = 0$ devolve T_0; $\alpha \to \infty$ colapsa para a raiz (média global).

Atenção

Crescer e podar usam objetivos diferentes *de propósito*: cresce-se de forma gananciosa (olhando só um passo à frente) e corrige-se globalmente na poda. Não confunda profundidade máxima (parâmetro de crescimento) com α (parâmetro de poda) — ambos controlam complexidade, mas em etapas distintas.

2 Por que agregar? Redução de variância

Árvores isoladas têm *alta variância*: pequenas mudanças nos dados mudam bastante a árvore. A ideia dos *ensembles* é **combinar** muitas funções para reduzir essa variância.

Proposição 2.1 (Média de preditores reduz o risco)**.** *Sejam* $g_1, \ldots, g_B$ *estimadores* não-viesados *(*$\mathbb{E}[g_b(\boldsymbol{x})] = r(\boldsymbol{x})$*), de mesma variância* $v(\boldsymbol{x}) = \text{Var}(g_b(\boldsymbol{x}))$ *e* não-correlacionados*. Então a média* $\bar{g} = \frac{1}{B}\sum_b g_b$ *tem risco*

$$\mathbb{E}[(Y - \bar{g}(\boldsymbol{x}))^2 \mid \boldsymbol{x}] = \text{Var}(Y \mid \boldsymbol{x}) + \frac{v(\boldsymbol{x})}{B} \;\leq\; \mathbb{E}[(Y - g_b(\boldsymbol{x}))^2 \mid \boldsymbol{x}].$$

Demonstração. Pela decomposição viés–variância (Aula 01), o risco de qualquer preditor g é $\mathrm{Var}(Y \mid \boldsymbol{x}) + \text{viés}^2 + \mathrm{Var}(g(\boldsymbol{x}))$. Como cada g_b é não-viesado, $\bar{g}$ também é (viés $= 0$). Para a variância, sendo os g_b não-correlacionados e de variância $v(\boldsymbol{x})$, $\mathrm{Var}(\bar{g}(\boldsymbol{x})) = \frac{1}{B^2}\sum_b \mathrm{Var}(g_b(\boldsymbol{x})) = v(\boldsymbol{x})/B$. Substituindo obtém-se a igualdade; como $v(\boldsymbol{x})/B \le v(\boldsymbol{x})$, o risco não aumenta. □

Ideia central

Duas hipóteses da Prop. 2.1 guiam tudo o que segue: ela supõe preditores (i) **não-viesados** — por isso, em geral, usam-se árvores profundas, sem poda, de viés baixo — e (ii) **pouco correlacionados** — o ponto fraco, que as florestas aleatórias atacam diretamente. Quanto menor a correlação, mais a variância cai. Não podar é a escolha usual, não uma exigência: medido na população da figura das florestas, o *bagging* de árvores podadas ($\alpha = 0{,}2$) teve erro 1,328, contra 1,373 com árvores profundas, porque a média não elimina o piso $\rho\, v$.

3 Bagging

Bagging (*bootstrap aggregating*) gera diversidade reamostrando os dados. Para $b = 1, \ldots, B$: sorteie uma amostra **bootstrap** (com reposição, tamanho n) e ajuste nela uma árvore *profunda* (não podada) g_b. A predição é a média:

$$g(\boldsymbol{x}) = \frac{1}{B}\sum_{b=1}^{B} g_b(\boldsymbol{x}). \tag{4}$$

4 Florestas aleatórias

O problema do *bagging*: as árvores ficam **correlacionadas**. Se há uma covariável muito forte, quase todas as árvores a usam no topo e ficam parecidas — e a Prop. 2.1 rende pouco quando $\mathrm{Cor}(g_b)$ é alta.

Ideia central

Florestas aleatórias (Breiman) *descorrelacionam* as árvores: em *cada nó*, sorteia-se um subconjunto de apenas $m < p$ covariáveis e a divisão só pode usar uma delas. Isso impede que a variável dominante apareça sempre, diversificando as árvores e reduzindo mais a variância.

Detalhes:

- m é o *tuning parameter*; regra empírica $m \approx p/3$ em regressão (e $m \approx \sqrt{p}$ em classificação). $m = p$ recupera o *bagging*.
- O risco é **robusto a** B: ele estabiliza e *não há superajuste* ao aumentar B — não vale a pena fazer CV em B, basta usar B "grande o bastante".
- A taxa de convergência das florestas depende essencialmente do número de *variáveis relevantes* — elas se adaptam à *esparsidade*.

Resumo

- **Árvore**: partição recursiva (1); cresce gananciosamente (2) e poda por custo–complexidade (3) (α por CV). Interpretável, mas alta variância.
- Agregar reduz variância se os preditores são não-viesados e pouco correlacionados (Prop. 2.1).

- **Bagging** (4): árvores profundas em amostras bootstrap, agregadas pela média.
- **Florestas**: *descorrelacionam* sorteando $m \approx p/3$ variáveis por nó; robustas a B; adaptam-se à esparsidade.

Leitura recomendada. [AME] §4.8 (árvores) e §4.9 (*bagging* e florestas); [ISLP] §8.1 e §8.2 (*Tree-Based Methods*).