

Lista Teórica 05 — Gabarito



Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 05 — Árvores de Regressão e Ensembles


Exercício 1 — da partição à árvore, e de volta.

- (a) A figura da esquerda mostra um particionamento binário recursivo do espaço (X_1, X_2) . Os números dentro de cada retângulo são a média de Y naquela região. **Desenhe a árvore de regressão correspondente**, com as condições nos nós internos e as médias nas folhas.
- (b) A figura da direita mostra uma árvore de regressão. **Desenhe o particionamento correspondente** do quadrado $[0, 4] \times [0, 4]$, com as médias dentro de cada região.
- (c) No item (a), a variável X_1 é usada em dois cortes diferentes. Isso é permitido? O que isso permite representar que um único corte por variável não permitiria?




Solução

(a) A raiz corta em $X_1 < 2$, porque é o único corte que atravessa o quadrado inteiro — todo corte posterior só vale dentro de um dos lados.



(b) A raiz corta em $X_2 < 2$: uma linha *horizontal* atravessando todo o quadrado. Acima dela ($X_2 \geq 2$) fica uma única região com média 15. Abaixo, o corte $X_1 < 1$ divide a faixa inferior em duas.



Note que o corte $X_1 < 1$ só existe *abaixo* de $X_2 = 2$: ele não continua para cima. É a diferença entre um particionamento recursivo e uma grade.

(c) É permitido, e é essencial. Nada impede que a mesma variável seja cortada várias vezes, em ramos diferentes ou no mesmo ramo com limiares distintos.

O que isso permite representar é uma relação **não monótona**. Na partição do item (a), o valor de Y em função de X_1 (para $X_2 \geq 1$) vai de 7 para 12 e volta para 6: sobe e desce. Um único corte em X_1 só conseguiria “abaixo do limiar vale isso, acima vale aquilo” — uma função degrau monótona.

De forma mais geral, é essa liberdade que dá às árvores a capacidade de aproximar qualquer função por partes constantes, e é também o que as torna capazes de capturar **interações** sem que ninguém as declare: no item (b), o efeito de X_1 existe quando $X_2 < 2$ e simplesmente não existe quando $X_2 \geq 2$.

Exercício 2 — escolhendo o corte. Uma árvore de regressão escolhe, em cada nó, o corte que mais reduz a soma de quadrados dentro dos filhos:

$$\text{ganho} = \underbrace{\sum_{i \in \text{nó}} (y_i - \bar{y}_{\text{nó}})^2}_{\text{RSS do pai}} - \left[\underbrace{\sum_{i \in E} (y_i - \bar{y}_E)^2}_{\text{RSS à esquerda}} + \underbrace{\sum_{i \in D} (y_i - \bar{y}_D)^2}_{\text{RSS à direita}} \right].$$

Considere quatro observações com uma única covariável:

x_i	1	2	3	4
y_i	1	2	9	10

- Calcule o RSS do nó raiz.
- Calcule o ganho dos três cortes possíveis: $x < 1,5$, $x < 2,5$ e $x < 3,5$. Qual é o escolhido?
- Por que só existem três cortes a testar, e não infinitos?
- Suponha que a árvore fosse crescida até cada folha ter uma observação só. Qual seria o RSS final? Relacione com o Exercício 1 da Lista Teórica 01.

Solução

(a) $\bar{y} = (1 + 2 + 9 + 10)/4 = 5,5$ e

$$\text{RSS} = (1 - 5,5)^2 + (2 - 5,5)^2 + (9 - 5,5)^2 + (10 - 5,5)^2 = 20,25 + 12,25 + 12,25 + 20,25 = \mathbf{65}.$$

(b) Corte a corte:

corte	esquerda	direita	RSS filhos	ganho
$x < 1,5$	$\{1\}, \bar{y} = 1, \text{RSS } 0$	$\{2, 9, 10\}, \bar{y} = 7, \text{RSS } 38$	38	27
$x < 2,5$	$\{1, 2\}, \bar{y} = 1,5, \text{RSS } 0,5$	$\{9, 10\}, \bar{y} = 9,5, \text{RSS } 0,5$	1	64
$x < 3,5$	$\{1, 2, 9\}, \bar{y} = 4, \text{RSS } 38$	$\{10\}, \bar{y} = 10, \text{RSS } 0$	38	27

O corte escolhido é $x < 2,5$, com ganho 64 de um total de 65 — ele explica 98,5% da variação. Faz todo o sentido olhando os dados: há dois grupos claros, $\{1, 2\}$ e $\{9, 10\}$, e esse corte é exatamente o que os separa.

(c) Porque o que importa não é o valor exato do limiar, e sim *qual partição das observações* ele produz. Qualquer limiar entre 2 e 3 gera a mesma partição $\{1, 2\} \mid \{9, 10\}$ e portanto o mesmo ganho. Com n valores distintos de x há exatamente $n - 1$ partições possíveis, e por convenção testa-se o ponto médio entre valores consecutivos. É isso que torna a busca exaustiva viável: são $n - 1$ candidatos por variável, não infinitos.

(d) O RSS final seria **zero**: cada folha teria uma observação e a média dela seria o próprio y_i . É o mesmo fenômeno do Exercício 1 da Lista Teórica 01, em que o polinômio de grau $n - 1$ interpola os n pontos — erro de treino nulo e nenhuma informação sobre o risco. Uma árvore totalmente crescida é um interpolador, e é por isso que existe a poda (e, mais adiante, o *bagging*).

Uma diferença entre os dois casos vale ser notada: o zero da árvore é *zero de verdade também no computador*, porque a média de um único número é esse número. Já o do polinômio é só algébrico — em ponto flutuante ele não interpola, como a §3 da Aula prática 03 mede.

Exercício 3 — B grande estraga? depende do ensemble.

- No *bagging* e nas florestas aleatórias, cada árvore é ajustada a uma reamostra dos dados, **sem olhar** para as árvores anteriores. Aumentar B pode piorar o desempenho fora da amostra? Justifique usando a fórmula da variância da média.
- No *boosting*, cada árvore é ajustada aos **resíduos** do que já foi construído. Aumentar B pode piorar? Justifique.
- A nota de aula relata a medição correspondente: o erro do *boosting* atinge o mínimo em $B = 32$ e, em $B = 1500$, está 16% acima. Que mecanismo produz essa curva em U, e qual hiperparâmetro do `scikit-learn` evita o problema sem que você precise adivinhar B ?
- Cite uma quantidade que o *bagging* fornece de graça e que dispensa validação cruzada para estimar o risco. Por que ela é gratuita?

Solução

(a) **Não** — ou, mais precisamente, não de forma sistemática. As árvores do *bagging* são identicamente distribuídas e não dependem umas das outras, então a média $\bar{g} = \frac{1}{B} \sum_b g_b$ tem

$$\text{Var}(\bar{g}(\mathbf{x})) = \rho v(\mathbf{x}) + \frac{1 - \rho}{B} v(\mathbf{x}),$$

que é **decrecente em B** . O viés, por sua vez, não muda com B : a média de estimadores de mesma esperança tem essa mesma esperança. Logo nem viés nem variância pioram, e B é um parâmetro de *custo computacional*, não de complexidade. Na prática, escolhe-se o maior B que o orçamento de tempo permite.

(b) **Pode, e piora.** No *boosting* as árvores não são independentes: a árvore $b + 1$ é ajustada ao que sobrou do erro das b primeiras. O ensemble é uma soma, não uma média, e cada termo novo *reduz o erro de treino*. Com B suficientemente grande o *boosting* passa a ajustar o ruído das observações de treino — exatamente o superajuste da Aula 01, com B no papel do grau do polinômio. Aqui B é um parâmetro de complexidade, e tem de ser escolhido por validação cruzada.

(c) O mecanismo é o da curva em U: no começo, cada árvore nova reduz viés (o ensemble ainda não capturou a estrutura de r); a partir de certo ponto, a estrutura já foi capturada e as árvores seguintes só conseguem perseguir o ruído, o que aumenta a variância. O mínimo está onde as duas forças se equilibram — aqui, $B = 32$.

A ferramenta que evita adivinhar é a **parada antecipada**: `n_iter_no_change` (com `validation_fraction` e `tol`) faz o `GradientBoostingRegressor` separar uma parte dos dados, acompanhar o erro nela a cada iteração e parar quando ele deixa de melhorar. Você põe um B máximo generoso e o algoritmo escolhe onde parar.

(d) O erro ***out-of-bag*** (OOB), disponível em `oob_score_`. Ele é gratuito porque cada árvore do *bagging* é ajustada a uma amostra bootstrap que deixa de fora, em média, $(1 - 1/n)^n \rightarrow e^{-1} \approx 36,8\%$ das observações. Cada observação i , portanto, é “de fora” para cerca de um terço das árvores, e a predição feita para ela usando *apenas* essas árvores é honesta — nenhuma delas a viu no treino. Fazendo isso para todo i , obtém-se uma estimativa de risco sem ajustar nada a mais. É essencialmente uma validação cruzada que veio junto com o método.

Exercício 4 — o piso da variância. Sejam $g_1, \dots, g_B$ estimadores de mesma variância $v(\mathbf{x})$ e correlação $\text{Cov}(g_a(\mathbf{x}), g_b(\mathbf{x})) = \rho v(\mathbf{x})$ para $a \neq b$.

- Mostre que $\text{Var}(\bar{g}(\mathbf{x})) = \rho v(\mathbf{x}) + \frac{1-\rho}{B} v(\mathbf{x})$. *Sugestão:* $\text{Var}(\sum_b g_b) = \sum_b \text{Var}(g_b) + \sum_{a \neq b} \text{Cov}(g_a, g_b)$, e há $B(B-1)$ pares ordenados com $a \neq b$.
- Tome $v(\mathbf{x}) = 1$ e $\rho = 0,6$. Calcule a variância para $B = 1, 10, 100$ e $B \rightarrow \infty$. Que **porcentagem** da redução total possível já se obteve em $B = 10$?
- Agora suponha que você consiga baixar ρ de 0,6 para 0,3. Compare esse ganho com o de aumentar B de 10 para 1000.
- Como as florestas aleatórias reduzem ρ na prática, e qual é o custo dessa redução?

Solução

(a) Escreva $\bar{g} = \frac{1}{B} \sum_b g_b$. Então

$$\text{Var}(\bar{g}) = \frac{1}{B^2} \text{Var}\left(\sum_{b=1}^B g_b\right) = \frac{1}{B^2} \left[\underbrace{\sum_b \text{Var}(g_b)}_{Bv} + \underbrace{\sum_{a \neq b} \text{Cov}(g_a, g_b)}_{B(B-1)\rho v} \right] = \frac{Bv + B(B-1)\rho v}{B^2}.$$

Dividindo por B dentro do colchete,

$$\text{Var}(\bar{g}) = \frac{v}{B} + \frac{(B-1)\rho v}{B} = \rho v + \frac{v}{B} - \frac{\rho v}{B} = \rho v + \frac{1-\rho}{B} v.$$

Quando $\rho = 0$ recuperamos v/B , que é a Proposição da nota; quando $B \rightarrow \infty$ sobra ρv .

(b) Com $v = 1$ e $\rho = 0,6$, $\text{Var} = 0,6 + 0,4/B$:

B	1	10	100	∞
$\text{Var}(\bar{g})$	1,0000	0,6400	0,6040	0,6000

A redução total possível é $1,0 - 0,6 = 0,4$. Em $B = 10$ já obtivemos $1,0 - 0,64 = 0,36$, ou seja **90%** dela. As outras 990 árvores até $B = 1000$ compram os 10% restantes.

(c) Baixar ρ de 0,6 para 0,3 leva o piso de 0,600 a 0,300: um ganho de 0,30. Aumentar B de 10 para 1000 leva a variância de 0,6400 a 0,6004: um ganho de 0,04.

O ganho de descorrelacionar é, portanto, **sete vezes maior** — e note que ele é maior até do que *todo* o efeito possível de B com $\rho = 0,6$ fixo, que valia 0,40 no total. É por isso que a floresta aleatória é uma ideia melhor do que simplesmente rodar mais árvores.

(d) A floresta aleatória sorteia, **em cada nó**, um subconjunto de $m < p$ covariáveis candidatas ao corte (tipicamente $m \approx p/3$ em regressão e $m \approx \sqrt{p}$ em classificação). Assim, quando existe uma covariável muito forte, ela não aparece na raiz de todas as árvores: nas árvores em que não foi sorteada, a estrutura sai completamente diferente. Menos estrutura comum entre as árvores é menos ρ .

O custo é **viés**: proibir a árvore de usar a melhor covariável em parte dos nós a torna individualmente pior. A aposta da floresta é que essa perda de qualidade individual é mais que compensada pela queda de ρ — e a fórmula do item (c) mostra por que a aposta costuma valer a pena. Levada ao extremo ($m = 1$, corte totalmente ao acaso) chega-se às *extremely randomized trees*, que trocam ainda mais viés por ainda menos correlação.