

Aula 05 — Métodos Não Paramétricos: Aspectos Teóricos

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §4.13 e cap. 5

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- entender o que é uma *taxa de convergência* e por que ela mede a qualidade de um estimador não paramétrico;
- enunciar as hipóteses de *suavidade* (Lipschitz, Sobolev) e seu papel;
- deduzir a taxa de convergência do **KNN** via decomposição viés-variância;
- enunciar a taxa de *séries ortogonais* e a noção de *taxa minimax*;
- explicar a **maldição da dimensionalidade** e sua consequência sobre o tamanho de amostra necessário;
- descrever as hipóteses de *esparsidade* e *redundância* e quais métodos se adaptam a elas.

Esta aula responde *por que* os métodos da Aula 04 funcionam — e, mais importante, *quando não funcionam*. Kant tem uma frase que serve de lema: “*experiência sem teoria é cega*”. Guarde esta pergunta concreta, que ficará sem resposta até a Seção 4.1:

*no problema das resenhas da Amazon, por que o KNN foi tão pior
que o Lasso e o boosting?*

Não é detalhe de implementação nem azar de amostra. A resposta é inteiramente teórica, e está nesta aula.

1 Por que estudar taxas de convergência?

Queremos comparar estimadores não pela performance em *um* conjunto de dados, mas pela rapidez com que o risco $\mathbb{E}[(\hat{r}(\mathbf{X}) - r(\mathbf{X}))^2]$ tende a zero conforme $n \rightarrow \infty$. Uma **taxa de convergência** expressa esse decaimento em função de n (e da dimensão p , da suavidade etc.). Por exemplo, uma taxa $n^{-1/2}$ é mais rápida (melhor) que $n^{-1/5}$.

Ideia central

Estimação não paramétrica só é possível sob **suposições de suavidade**: se r pudesse oscilar arbitrariamente, nenhuma quantidade finita de dados a determinaria. Suavidade é o que permite “emprestar força” de observações vizinhas.

Vale tornar isso concreto. Se r pudesse valer qualquer coisa em cada ponto, saber r em mil pontos não diria *nada* sobre r num ponto novo — e nenhum método poderia funcionar. Toda a Aula 04 se apoia numa aposta implícita: pontos próximos em $\mathbf{x}$ têm respostas próximas. Suavidade é essa aposta, escrita formalmente.

Duas medidas de suavidade que usaremos:

Lipschitz r é L -Lipschitz se $|r(\mathbf{x}) - r(\mathbf{x}')| \leq L \|\mathbf{x} - \mathbf{x}'\|$ para todos $\mathbf{x}, \mathbf{x}'$. Controla *quão rápido* r pode variar. É a hipótese mínima: diz que andar uma distância δ não pode mudar r em mais que $L\delta$.

Sobolev r tem suavidade m se $\int (D^m r(x))^2 dx \leq K_1$ (m derivadas de quadrado integrável). Quanto maior m , mais suave.

2 A taxa de convergência do KNN

Considere o estimador KNN $\hat{r}_k(\mathbf{x}) = \frac{1}{k} \sum_{i \in \mathcal{N}_x} Y_i$ (Aula 04). Sob suavidade Lipschitz, conseguimos limitar seu risco. O primeiro passo é a peça central — e a mais reveladora — do argumento.

Lema 2.1 (Distância média aos k vizinhos). Se $\mathbf{X}$ é limitado e $p \geq 3$, então

$$\mathbb{E} \left[\left(\frac{1}{k} \sum_{i \in \mathcal{N}_X} \|\mathbf{X}_i - \mathbf{X}\| \right)^2 \right] \leq C \left(\frac{k}{n} \right)^{2/p}.$$

Ideia central: de onde vem esse $2/p$

O expoente não é mágica; é volume. Numa bola de raio ρ em $\mathbb{R}^p$, o volume cresce como ρ^p . Se os n pontos estão espalhados num conjunto de volume 1, uma bola de raio ρ contém, em média, $\approx n\rho^p$ deles. Para que ela contenha os k vizinhos que queremos, precisamos de $n\rho^p \approx k$, ou seja

$$\rho \approx \left(\frac{k}{n} \right)^{1/p}.$$

Elevando ao quadrado (porque o lema fala do quadrado da distância) sai o $(k/n)^{2/p}$. **Todo o resto da aula é consequência desse expoente $1/p$.**

Em palavras: quanto mais vizinhos (k) eu exijo, mais *longe* eles ficam. E o $1/p$ no expoente diz que, em dimensão alta, essa distância cresce de forma brutal — a raiz p -ésima de um número pequeno está perto de 1.

Exemplo 2.2 (um número para sentir o problema). Tome $n = 10\,000$ pontos e $k = 10$ vizinhos, num cubo de lado 1. Então $\rho \approx (10/10\,000)^{1/p} = (0,001)^{1/p}$:

p	1	2	5	10	20
raio ρ necessário	0,001	0,032	0,25	0,50	0,71

Em $p = 1$, os dez vizinhos cabem num intervalo de comprimento 0,001: são *de fato* vizinhos. Em $p = 20$, para reunir dez pontos você precisa de uma bola que cobre *setenta por cento* da largura do cubo — ou seja, quase tudo. A palavra “vizinho” perdeu o sentido, e com ela a justificativa do método.

Teorema 2.3 (Risco do KNN). Sob as hipóteses do Lema 2.1, com r L -Lipschitz e $\sup_{\mathbf{x}} \text{Var}(Y | \mathbf{x}) \leq \sigma^2 < \infty$,

$$\mathbb{E}[(\hat{r}_k(\mathbf{X}) - r(\mathbf{X}))^2] \leq K \left(\frac{k}{n} \right)^{2/p} + \frac{\sigma^2}{k}.$$

Otimizando em k (tomando $k \asymp n^{2/(2+p)}$), obtém-se

$$\mathbb{E}[(\hat{r}_k(\mathbf{X}) - r(\mathbf{X}))^2] \leq K' n^{-2/(2+p)}.$$

Demonstração. Condicione nas covariáveis $\tilde{\mathbf{x}} = (\mathbf{x}_1, \dots, \mathbf{x}_n, \mathbf{x})$. Pela decomposição viés–variância (Aula 01),

$$\mathbb{E}[(\hat{r}_k(\mathbf{x}) - r(\mathbf{x}))^2 \mid \tilde{\mathbf{x}}] = \underbrace{\left(\frac{1}{k} \sum_{i \in \mathcal{N}_{\mathbf{x}}} r(\mathbf{x}_i) - r(\mathbf{x})\right)^2}_{\text{viés}^2} + \underbrace{\text{Var}(\hat{r}_k(\mathbf{x}) \mid \tilde{\mathbf{x}})}_{\text{variância}}.$$

Viés: como r é L -Lipschitz, $|\frac{1}{k} \sum_{i \in \mathcal{N}_{\mathbf{x}}} r(\mathbf{x}_i) - r(\mathbf{x})| \leq \frac{L}{k} \sum_{i \in \mathcal{N}_{\mathbf{x}}} \|\mathbf{x}_i - \mathbf{x}\|$. *Variância:* as respostas são independentes dadas as covariáveis e cada uma tem variância $\leq \sigma^2$; a média de k delas tem variância $\text{Var}(\hat{r}_k(\mathbf{x}) \mid \tilde{\mathbf{x}}) \leq \sigma^2/k$. Logo

$$\mathbb{E}[(\hat{r}_k(\mathbf{x}) - r(\mathbf{x}))^2 \mid \tilde{\mathbf{x}}] \leq \left(\frac{L}{k} \sum_{i \in \mathcal{N}_{\mathbf{x}}} \|\mathbf{x}_i - \mathbf{x}\|\right)^2 + \frac{\sigma^2}{k}.$$

Tomando esperança e aplicando o Lema 2.1 ao primeiro termo, resulta $\mathbb{E}[(\hat{r}_k(\mathbf{X}) - r(\mathbf{X}))^2] \leq K(k/n)^{2/p} + \sigma^2/k$. Para minimizar em k , iguale (a menos de constantes) os dois termos: $(k/n)^{2/p} \asymp 1/k$, isto é, $k^{1+2/p} \asymp n^{2/p}$, ou seja $k \asymp n^{2/(2+p)}$, e substituindo obtém-se a taxa $n^{-2/(2+p)}$. $\square$

Ideia central

A prova exhibe explicitamente o balanço viés–variância da Aula 01: o termo $(k/n)^{2/p}$ cresce com k (viés — vizinhos mais distantes, respostas menos parecidas com $r(\mathbf{x})$) e σ^2/k decresce com k (variância — média sobre mais observações). O k ótimo equilibra os dois, e a validação cruzada (Aula 03) é a maneira prática de encontrá-lo sem conhecer L , σ^2 nem p .

Observação 2.4. O truque de “igualar os dois termos” para achar o k ótimo merece uma nota: ele funciona porque um termo cresce e o outro decresce em k , então o mínimo da soma está onde eles se cruzam, a menos de constantes. É um recurso padrão em análise de taxas, e você vai reencontrá-lo na próxima subseção com J no lugar de k .

2.1 Séries ortogonais e taxa minimax

Para séries ortogonais (base de Fourier) com suavidade de Sobolev m , um argumento análogo (viés do truncamento em J termos $\leq K_1 J^{-2m}$; variância $\leq K_2 J/n$) dá

$$\mathbb{E}[(\hat{r}_J(\mathbf{X}) - r(\mathbf{X}))^2] \leq K_1 J^{-2m} + K_2 \frac{J}{n}, \quad \text{e com } J \asymp n^{1/(2m+1)} : \quad \mathbb{E}[\dots] \leq K n^{-2m/(2m+1)}.$$

Note que mais suavidade (m maior) $\Rightarrow$ taxa mais rápida.

Observação 2.5 (Taxa minimax). Essas taxas não são apenas *limitantes superiores* de um método específico: para a classe $\mathcal{S}$ de funções suaves elas coincidem com a **taxa minimax**

$$\inf_{\hat{r}} \sup_{r \in \mathcal{S}} \mathbb{E}[(\hat{r}(\mathbf{X}) - r(\mathbf{X}))^2] \asymp n^{-\alpha/(\alpha+p)},$$

ou seja, *nenhum* estimador faz essencialmente melhor no pior caso. Um estimador que atinge essa taxa é dito *minimax-ótimo*. (α liga-se à suavidade.) Leia o $\inf_{\hat{r}} \sup_r$ como um jogo: você escolhe o estimador, e um adversário, sabendo da sua escolha, escolhe a r mais difícil dentro de $\mathcal{S}$. A taxa minimax é o melhor que você garante contra o pior adversário. Isso importa porque transforma a próxima seção de “o KNN tem um problema” em “o problema tem um problema”.




Figura 1: À esquerda, a taxa $n^{-2/(2+p)}$ em escala log-log: em $p = 1$ a reta desce com inclinação $-2/3$; em $p = 20$, com $-1/11$ — quase horizontal. Aumentar a amostra deixa de adiantar. À direita, a leitura prática: quantas observações são necessárias para atingir risco 0,05. Em $p = 1$ bastam 90; em $p = 10$ já são $6,4 \times 10^7$; em $p = 20$, 2×10^{14} — vinte e cinco mil vezes a população da Terra.

3 A maldição da dimensionalidade

Olhe a taxa minimax $n^{-\alpha/(\alpha+p)}$: para p grande, o expoente $\alpha/(\alpha+p)$ se aproxima de 0 — a convergência fica *lentíssima*.

Teorema 3.1 (Tamanho de amostra explode com p). *Para garantir risco $\leq \delta$ na classe $\mathcal{S}$, é necessário*

$$n \gtrsim \left(\frac{K}{\delta}\right)^{(\alpha+p)/\alpha},$$

um crescimento *exponencial* em p .

Mesmo dimensões moderadas exigem amostras astronômicas. Esta é a **maldição da dimensionalidade** (Bellman, 1966).

Ideia central: A intuição da vizinhança vazia

Para estimar $r(\mathbf{x})$ por média local, preciso de pontos *perto* de $\mathbf{x}$. Em $\mathbb{R}^p$ com p grande, qualquer vizinhança de raio fixo tem volume desprezível: com alta probabilidade *não há nenhum dado dentro dela*. Para capturar k vizinhos preciso de um raio $\asymp (k/n)^{1/p}$, que cresce com p — os “vizinhos” deixam de ser próximos, e o viés explode (é exatamente o Lema 2.1).

Dá para medir isso diretamente, sem nenhuma teoria: espalhe 1000 pontos ao acaso num cubo $[0, 1]^p$ e veja o quão longe fica o vizinho mais próximo de um ponto qualquer (Figura 2).

Atenção

A maldição diz que, **sem suposições extras**, estimação não paramétrica é impossível em alta dimensão para n realista. E, pela taxa minimax, a saída *não* é procurar um método melhor — já sabemos que nenhum existe. A saída é uma *estrutura* adicional no problema, que tire a classe $\mathcal{S}$ do pior caso. As duas mais úteis: esparsidade e redundância.




Figura 2: Distância ao vizinho mais próximo entre $n = 1000$ pontos uniformes em $[0, 1]^p$, medida como fração do diâmetro do cubo. Em $p = 1$ ela é praticamente zero; em $p = 10$ já é 16% do diâmetro; em $p = 100$, um terço. Dito de outro modo: em dimensão alta *todos os pontos estão a distâncias parecidas de todos os outros*, e “os k mais próximos” vira uma seleção quase arbitrária.

4 Escapando da maldição

4.1 Esparsidade

A hipótese de **esparsidade** diz que r depende apenas de um subconjunto $S \subset \{1, \dots, p\}$ de covariáveis:

$$r(\mathbf{x}) = r((x_i)_{i \in S}), \quad |S| = s \ll p.$$

Embora haja p covariáveis, só s importam. Sob esparsidade a dimensão *efetiva* é s , e a taxa melhora para $\approx n^{-\alpha/(\alpha+s)}$.

Voltemos à pergunta da abertura. No problema das resenhas da Amazon, cada covariável é a contagem de uma palavra, e a esmagadora maioria das palavras não diz nada sobre a nota da resenha: o problema é *esparso*. Isso explica os dois lados do resultado:

- Métodos que **selecionam variáveis** — Lasso (Aula 02), árvores e florestas, *boosting* (Aula 06) — descartam as irrelevantes e passam a operar na dimensão efetiva s . Para eles, o p gigante quase não custa.
- O KNN **não faz seleção de variáveis**. Ele soma *todas* as coordenadas na distância euclidiana, com peso igual. Cada palavra irrelevante acrescenta ruído à distância, e com milhares delas a distância passa a medir essencialmente ruído. Os “vizinhos” encontrados não são vizinhos no que importa.

Ideia central

Este é o ponto da aula que mais vale levar: o KNN não perdeu por ser fraco, e sim por ser *indiferente à estrutura do problema*. Um método que trata todas as covariáveis igualmente está apostando que todas importam igualmente — e quando essa aposta está errada, ele paga o preço integral da dimensão p , mesmo que a dimensão efetiva seja $s = 20$.

Observação 4.1. Métodos que se adaptam à esparsidade: *Lasso* (Aula 02), *florestas aleatórias* (cuja taxa, por Biau 2012, depende só do número de variáveis relevantes, pois divisões inúteis raramente são escolhidas) e *SpAM* (modelos aditivos esparsos, que combinam aditividade com ℓ_1).

4.2 Redundância

A hipótese de **redundância** diz que as covariáveis, embora em número p , vivem (aproximadamente) sobre uma *subvariedade* de dimensão intrínseca $u \ll p$. Exemplos:

- altura, peso e IMC: três variáveis, mas duas determinam a terceira;
- imagens: *pixels* adjacentes são quase iguais — enorme redundância.

Sob redundância, KNN e regressão local *se adaptam automaticamente* à dimensão intrínseca: sua taxa passa a ser $n^{-4/(4+u)}$, muito mais rápida que $n^{-4/(4+p)}$ quando $u \ll p$. SVR com kernel gaussiano e séries *espectrais* (base construída a partir dos dados) também exploram redundância.

Ideia central

Esparsidade $\neq$ redundância, e a diferença decide o método. *Esparsidade*: poucas covariáveis importam, as demais são lixo — seleção de variáveis ajuda, e o KNN não se salva. *Redundância*: todas podem importar, mas elas são correlacionadas e os dados ocupam só uma fatia fina do espaço — aqui o KNN *se vira bem sozinho*, porque os vizinhos são medidos dentro da subvariedade, e a redução de dimensionalidade (PCA, aula extra) ajuda ainda mais.

5 Síntese prática

Situação	O que ajuda	Métodos
p pequeno, r suave	nada extra	KNN, NW, regressão local
Poucas covariáveis relevantes	seleção de variáveis	Lasso, florestas, XGBoost, SpAM
Covariáveis redundantes	dimensão intrínseca	KNN/local, SVR, séries espectrais, PCA

O notebook **Aula prática 05** é um laboratório de simulação: mede o expoente $1/p$ do raio que reúne k vizinhos, estima a taxa de convergência do KNN em $p = 1, 2, 4, 8$, abre o risco em viés² e variância para ver as duas parcelas se cruzarem no k ótimo, e separa esparsidade de redundância medindo a dimensão intrínseca — inclusive a do `superconductivity.csv`.

Atenção

Mensagem para levar para casa: **não existe almoço grátis**. A escolha do método deve refletir a *estrutura* que você acredita existir nos dados. A teoria desta aula é o que torna essa escolha informada em vez de adivinhação — e é também o que impede você de culpar a implementação quando um método vai mal por razões que eram previsíveis no papel.

Resumo

- Taxas de convergência medem a qualidade assintótica; só existem sob *suavidade* (Lipschitz, Sobolev).
- KNN: risco $\leq K(k/n)^{2/p} + \sigma^2/k$, ótimo em $k \asymp n^{2/(2+p)}$, taxa $n^{-2/(2+p)}$ (Teo. 2.3). O expoente $1/p$ nasce do volume da bola em $\mathbb{R}^p$ (Lema 2.1).
- Séries (m -suaves): taxa $n^{-2m/(2m+1)}$; ambas atingem a taxa *minimax* $n^{-\alpha/(\alpha+p)}$ — ou seja, não há método melhor.
- **Maldição da dimensionalidade**: a taxa degrada com p (Fig. 1) e os vizinhos deixam de ser vizinhos (Fig. 2).

- *Esparsidade* (poucas relevantes) → Lasso/florestas; o KNN vai mal porque usa todas as covariáveis com peso igual. *Redundância* (dimensão intrínseca baixa) → KNN/local, séries espectrais, PCA.

Leitura recomendada. [AME] §4.13 (as contas de taxa do KNN e das séries ortogonais, das quais o Teo. 2.3 desta aula é a versão detalhada) e Capítulo 5 inteiro: §5.1 (maldição da dimensionalidade e taxas), §5.1.1 (esparsidade), §5.1.2 (redundância), §5.2 (KNN e regressão local sob redundância) e §5.5–5.6 (florestas aleatórias e SpAM).

Para praticar. `Lista teorica 05.pdf` (teórica, com gabarito) e `Lista prática 05.ipynb` (prática, para completar as lacunas), nesta mesma pasta.