

Aula 05 — Métodos Não Paramétricos: Aspectos Teóricos

Curso de Aprendizado de Máquina — UFRJ

Leitura recomendada: AME §4.13 e cap. 5

Objetivos da aula

Ao final desta aula o aluno deve ser capaz de:

- entender o que é uma *taxa de convergência* e por que ela mede a qualidade de um estimador não paramétrico;
- enunciar as hipóteses de *suavidade* (Lipschitz, Sobolev) e seu papel;
- deduzir a taxa de convergência do **KNN** via decomposição viés-variância;
- enunciar a taxa de *séries ortogonais* e a noção de *taxa minimax*;
- explicar a **maldição da dimensionalidade** e sua consequência sobre o tamanho de amostra necessário;
- descrever as hipóteses de *esparsidade* e *redundância* e quais métodos se adaptam a elas.

Em sala

Esta aula responde *por que* os métodos da Aula 04 funcionam — e quando *não* funcionam. Frase-guia (Kant): “*experiência sem teoria é cega.*” Pergunta de abertura, retomando o exemplo da Amazon (Aula 04): “*por que o KNN foi tão pior que o Lasso/XGBoost naquele problema de texto?*” A resposta é toda teórica.

1 Por que estudar taxas de convergência?

Queremos comparar estimadores não pela performance em *um* conjunto de dados, mas pela rapidez com que o risco $\mathbb{E}[(\hat{r}(\mathbf{X}) - r(\mathbf{X}))^2]$ tende a zero conforme $n \rightarrow \infty$. Uma **taxa de convergência** expressa esse decaimento em função de n (e da dimensão d , da suavidade etc.). Por exemplo, uma taxa $n^{-1/2}$ é mais rápida (melhor) que $n^{-1/5}$.

Ideia central

Estimação não paramétrica só é possível sob **suposições de suavidade**: se r pudesse oscilar arbitrariamente, nenhuma quantidade finita de dados a determinaria. Suavidade é o que permite “emprestar força” de observações vizinhas.

Duas medidas de suavidade que usaremos:

Lipschitz r é L -Lipschitz se $|r(\mathbf{x}) - r(\mathbf{x}')| \leq L \|\mathbf{x} - \mathbf{x}'\|$ para todos $\mathbf{x}, \mathbf{x}'$. Controla *quão rápido* r pode variar.

Sobolev r tem suavidade m se $\int (D^m r(x))^2 dx \leq K_1$ (m derivadas de quadrado integrável). Quanto maior m , mais suave.

2 A taxa de convergência do KNN

Considere o estimador KNN $\hat{r}_k(\mathbf{x}) = \frac{1}{k} \sum_{i \in \mathcal{N}_x} Y_i$ (Aula 04). Sob suavidade Lipschitz, conseguimos limitar seu risco.

Lema 2.1 (Distância média aos k vizinhos). *Se $\mathbf{X}$ é limitado e $d \geq 3$, então*

$$\mathbb{E} \left[\left(\frac{1}{k} \sum_{i \in \mathcal{N}_X} \|\mathbf{X}_i - \mathbf{X}\| \right)^2 \right] \leq C \left(\frac{k}{n} \right)^{2/d}.$$

Em palavras: quanto mais vizinhos (k) eu exijo, mais *longe* eles ficam — e essa distância cresce com $(k/n)^{1/d}$. O expoente $1/d$ é o germen da maldição da dimensionalidade.

Teorema 2.2 (Risco do KNN). *Sob as hipóteses do Lema 2.1, com r L -Lipschitz e $\sup_{\mathbf{x}} \text{Var}(Y | \mathbf{x}) \leq \sigma^2 < \infty$,*

$$\mathbb{E}[(\hat{r}_k(\mathbf{X}) - r(\mathbf{X}))^2] \leq K \left(\frac{k}{n} \right)^{2/d} + \frac{\sigma^2}{k}.$$

Otimizando em k (tomando $k \asymp n^{2/(2+d)}$), obtém-se

$$\mathbb{E}[(\hat{r}_k(\mathbf{X}) - r(\mathbf{X}))^2] \leq K' n^{-2/(2+d)}.$$

Demonstração. Condicione nas covariáveis $\tilde{\mathbf{x}} = (\mathbf{x}_1, \dots, \mathbf{x}_n, \mathbf{x})$. Pela decomposição viés-variância (Aula 01),

$$\mathbb{E}[(\hat{r}_k(\mathbf{x}) - r(\mathbf{x}))^2 | \tilde{\mathbf{x}}] = \underbrace{\left(\frac{1}{k} \sum_{i \in \mathcal{N}_x} r(\mathbf{x}_i) - r(\mathbf{x}) \right)^2}_{\text{viés}^2} + \underbrace{\text{Var}(\hat{r}_k(\mathbf{x}) | \tilde{\mathbf{x}})}_{\text{variância}}.$$

Viés: como r é L -Lipschitz, $|\frac{1}{k} \sum_{i \in \mathcal{N}_x} r(\mathbf{x}_i) - r(\mathbf{x})| \leq \frac{L}{k} \sum_{i \in \mathcal{N}_x} \|\mathbf{x}_i - \mathbf{x}\|$. *Variância:* as respostas são independentes dadas as covariáveis e cada uma tem variância $\leq \sigma^2$; a média de k delas tem variância $\text{Var}(\hat{r}_k(\mathbf{x}) | \tilde{\mathbf{x}}) \leq \sigma^2/k$. Logo

$$\mathbb{E}[(\hat{r}_k(\mathbf{x}) - r(\mathbf{x}))^2 | \tilde{\mathbf{x}}] \leq \left(\frac{L}{k} \sum_{i \in \mathcal{N}_x} \|\mathbf{x}_i - \mathbf{x}\| \right)^2 + \frac{\sigma^2}{k}.$$

Tomando esperança e aplicando o Lema 2.1 ao primeiro termo, resulta $\mathbb{E}[(\hat{r}_k(\mathbf{X}) - r(\mathbf{X}))^2] \leq K(k/n)^{2/d} + \sigma^2/k$. Para minimizar em k , iguale (a menos de constantes) os dois termos: $(k/n)^{2/d} \asymp 1/k$, isto é, $k^{1+2/d} \asymp n^{2/d}$, ou seja $k \asymp n^{2/(2+d)}$, e substituindo obtém-se a taxa $n^{-2/(2+d)}$. $\square$

Ideia central

A prova exhibe explicitamente o balanço viés-variância da Aula 01: o termo $(k/n)^{2/d}$ *cresce* com k (viés) e σ^2/k *decrece* com k (variância). O k ótimo equilibra os dois — e a validação cruzada (Aula 03) é a maneira prática de encontrá-lo.

2.1 Séries ortogonais e taxa minimax

Para séries ortogonais (base de Fourier) com suavidade de Sobolev m , um argumento análogo (viés do truncamento em J termos $\leq K_1 J^{-2m}$; variância $\leq K_2 J/n$) dá

$$\mathbb{E}[(\hat{r}_J(\mathbf{X}) - r(\mathbf{X}))^2] \leq K_1 J^{-2m} + K_2 \frac{J}{n}, \quad \text{e com } J \asymp n^{1/(2m+1)} : \quad \mathbb{E}[\dots] \leq K n^{-2m/(2m+1)}.$$

Note que mais suavidade (m maior) $\Rightarrow$ taxa mais rápida.

Observação 2.3 (Taxa minimax). Essas taxas não são apenas *limitantes superiores* de um método específico: para a classe $\mathcal{S}$ de funções suaves elas coincidem com a **taxa minimax**

$$\inf_{\hat{r}} \sup_{r \in \mathcal{S}} \mathbb{E}[(\hat{r}(\mathbf{X}) - r(\mathbf{X}))^2] \asymp n^{-\alpha/(\alpha+d)},$$

ou seja, *nenhum* estimador faz essencialmente melhor no pior caso. Um estimador que atinge essa taxa é dito *minimax-ótimo*. (α liga-se à suavidade.)

3 A maldição da dimensionalidade

Olhe a taxa minimax $n^{-\alpha/(\alpha+d)}$: para d grande, o expoente $\alpha/(\alpha+d)$ se aproxima de 0 — a convergência fica *lentíssima*.

Teorema 3.1 (Tamanho de amostra explode com d). *Para garantir risco $\leq \delta$ na classe $\mathcal{S}$, é necessário*

$$n \gtrsim \left(\frac{K}{\delta}\right)^{(\alpha+d)/\alpha},$$

um crescimento exponencial em d .

Mesmo dimensões moderadas exigem amostras astronômicas. Esta é a **maldição da dimensionalidade** (Bellman, 1966).

Ideia central: A intuição da vizinhança vazia

Para estimar $r(\mathbf{x})$ por média local, preciso de pontos *perto* de $\mathbf{x}$. Em $\mathbb{R}^d$ com d grande, qualquer vizinhança de raio fixo tem volume desprezível: com alta probabilidade *não há nenhum dado dentro dela*. Para capturar k vizinhos preciso de um raio $\asymp (k/n)^{1/d}$, que cresce com d — os “vizinhos” deixam de ser próximos, e o viés explode (é exatamente o Lema 2.1).

Atenção

A maldição diz que, **sem suposições extras**, estimação não paramétrica é impossível em alta dimensão para n realista. A saída não é um método melhor — é uma *estrutura* adicional no problema. As duas mais úteis: esparsidade e redundância.

4 Escapando da maldição

4.1 Esparsidade

A hipótese de **esparsidade** diz que r depende apenas de um subconjunto $S \subset \{1, \dots, d\}$ de covariáveis:

$$r(\mathbf{x}) = r((x_i)_{i \in S}), \quad |S| = s \ll d.$$

Embora haja d covariáveis, só s importam. Sob esparsidade a dimensão *efetiva* é s , e a taxa melhora para $\approx n^{-\alpha/(\alpha+s)}$.

Em sala

Eis a resposta da pergunta de abertura (Amazon): no problema de texto, a maioria das palavras é irrelevante para a nota — problema *esparso*. Métodos que **selecionam variáveis** (Lasso, árvores/florestas, XGBoost) prosperam; o KNN, que usa *todas* as covariáveis na distância com peso igual, é arrastado pelas irrelevantes e vai mal. KNN *não*

faz seleção de variáveis.

Observação 4.1. Métodos que se adaptam à esparsidade: *Lasso* (Aula 02), *florestas aleatórias* (cuja taxa, por Biau 2012, depende só do número de variáveis relevantes, pois divisões inúteis raramente são escolhidas) e *SpAM* (modelos aditivos esparsos, que combinam aditividade com ℓ_1).

4.2 Redundância

A hipótese de **redundância** diz que as covariáveis, embora em número d , vivem (aproximadamente) sobre uma *subvariedade* de dimensão intrínseca $u \ll d$. Exemplos:

- altura, peso e IMC: três variáveis, mas duas determinam a terceira;
- imagens: *pixels* adjacentes são quase iguais — enorme redundância.

Sob redundância, KNN e regressão local *se adaptam automaticamente* à dimensão intrínseca: sua taxa passa a ser $n^{-4/(4+u)}$, muito mais rápida que $n^{-4/(4+d)}$ quando $u \ll d$. SVR com kernel gaussiano e séries *espectrais* (base construída a partir dos dados) também exploram redundância.

Ideia central

Esparsidade $\neq$ redundância. *Esparsidade*: poucas covariáveis importam (seleção de variáveis ajuda). *Redundância*: muitas covariáveis, mas correlacionadas/numa subvariedade (redução de dimensionalidade ajuda — tema da Aula extra de PCA). Métodos diferentes exploram cada uma.

5 Síntese prática

Situação	O que ajuda	Métodos
d pequeno, r suave	nada extra	KNN, NW, regressão local
Poucas covariáveis relevantes	seleção de variáveis	Lasso, florestas, XGBoost, SpAM
Covariáveis redundantes	dimensão intrínseca	KNN/local, SVR, séries espectrais, PCA

Atenção

Mensagem para levar para casa: **não existe almoço grátis**. A escolha do método deve refletir a *estrutura* que você acredita existir nos dados. A teoria desta aula é o que torna essa escolha informada em vez de adivinhação.

Resumo

- Taxas de convergência medem a qualidade assintótica; só existem sob *suavidade* (Lipschitz, Sobolev).
- KNN: risco $\leq K(k/n)^{2/d} + \sigma^2/k$, ótimo em $k \asymp n^{2/(2+d)}$, taxa $n^{-2/(2+d)}$ (Teo. 2.2).
- Séries (m -suaves): taxa $n^{-2m/(2m+1)}$; ambas atingem a taxa *minimax* $n^{-\alpha/(\alpha+d)}$.
- **Maldição da dimensionalidade**: a taxa degrada com d e o n necessário cresce exponencialmente.

- *Esparsidade* (poucas relevantes) → Lasso/florestas; *redundância* (dimensão intrínseca baixa) → KNN/local, séries espectrais, PCA.

Leitura recomendada. [AME] §4.13 (taxas do KNN e séries ortogonais), Capítulo 5 (§5.1 maldição da dimensionalidade, §5.1.1 esparsidade, §5.1.2 redundância, §5.5–5.6 florestas e SpAM).