

Lista Teórica 05 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 05 — Métodos Não Paramétricos: Aspectos Teóricos

Exercício 1 — o preço de cada dimensão. O Teorema da Aula 05 diz que o KNN com k bem escolhido atinge risco

$$\mathbb{E}[(\hat{r}_k(\mathbf{X}) - r(\mathbf{X}))^2] \leq K' n^{-2/(2+p)}.$$

Suponha que, em $p = 1$, $n = 100$ observações bastem para atingir um risco alvo δ (tratando a desigualdade como igualdade).

- Isolando n , mostre que $n = (K'/\delta)^{(2+p)/2}$.
- Use o dado de $p = 1$ para achar K'/δ e calcule quantas observações seriam necessárias, para o *mesmo* risco, em $p = 2$, $p = 5$, $p = 10$ e $p = 20$.
- O crescimento é polinomial ou exponencial em p ? Justifique olhando a fórmula.
- Um colega diz: “mas com n grande o KNN converge para o classificador ótimo em qualquer dimensão, isso é um teorema”. Ele está certo. Por que, então, o resultado acima é uma má notícia?

Solução

(a) De $\delta = K' n^{-2/(2+p)}$ vem $n^{2/(2+p)} = K'/\delta$ e, elevando a $(2+p)/2$,

$$n = \left(\frac{K'}{\delta}\right)^{(2+p)/2}.$$

(b) Em $p = 1$ o expoente é $3/2$, então $100 = (K'/\delta)^{3/2}$ e $K'/\delta = 100^{2/3} \approx 21,54$. Substituindo:

p	1	2	5	10	20
expoente $(2+p)/2$	1,5	2	3,5	6	11
n necessário	100	464	$4,6 \times 10^4$	10^8	$4,6 \times 10^{14}$

Cem observações em $p = 1$ viram **cem milhões** em $p = 10$. Em $p = 20$ seriam $4,6 \times 10^{14}$, cerca de sessenta mil vezes a população da Terra.

(c) **Exponencial.** O p aparece no *expoente*: escrevendo $c = K'/\delta$, temos $n = c^{(2+p)/2} = c \cdot (\sqrt{c})^p$. Cada dimensão nova multiplica n por um fator constante $\sqrt{c}$ — aqui, $\sqrt{21,54} \approx 4,64$. É exatamente o que a tabela mostra: de $p = 10$ para $p = 20$, dez multiplicações por 4,64, ou seja um fator de 4,6 milhões.

(d) As duas afirmações são compatíveis porque falam de coisas diferentes. A consistência é um resultado *assintótico*: garante que o erro vai a zero quando $n \rightarrow \infty$, mas não diz *a que velocidade*. A taxa $n^{-2/(2+p)}$ diz a velocidade — e em $p = 20$ o expoente é $-1/11$, de modo que para dividir o erro por 2 é preciso multiplicar n por $2^{11} = 2048$.

Em outras palavras: a garantia existe, mas o n que a torna útil não existe. Consistência é uma condição *necessária* para levar um método a sério, não uma razão para usá-lo em dimensão alta.

Exercício 2 — a vizinhança que deixou de ser vizinha. Espalhe n pontos uniformemente no cubo $[0, 1]^p$. Para que uma bola de raio ρ em torno de um ponto contenha em média k deles, é preciso $n\rho^p \approx k$, ou seja

$$\rho \approx \left(\frac{k}{n}\right)^{1/p}.$$

- (a) Com $k = 10$ e $n = 10\,000$, calcule ρ para $p = 1, 2, 5, 10$ e 20 . (Repare que $k/n = 0,001$ em todos os casos.)
- (b) Interprete o valor de $p = 20$ em palavras: que fração da largura do cubo o raio cobre? O que resta da palavra “vizinho”?
- (c) Ainda em $p = 20$, quantas observações seriam necessárias para que os 10 vizinhos mais próximos coubessem num raio de $\rho = 0,1$?

Solução

(a) Com $k/n = 10^{-3}$, temos $\rho = (10^{-3})^{1/p} = 10^{-3/p}$:

p	1	2	5	10	20
ρ	0,001	0,032	0,251	0,501	0,708

(b) Em $p = 20$ o raio necessário é 0,708: a bola cobre cerca de **71% da largura do cubo em cada direção**. Um “vizinho” a essa distância está tão longe de $\mathbf{x}$ quanto um ponto qualquer sorteado ao acaso.

E aí o método perde o argumento que o justifica. O KNN estima $r(\mathbf{x})$ pela média dos Y dos vizinhos porque supõe que, se $\mathbf{x}_i$ está perto de $\mathbf{x}$, então $r(\mathbf{x}_i)$ está perto de $r(\mathbf{x})$ — é a hipótese de Lipschitz. Com vizinhos a 71% da largura do domínio, essa hipótese não diz nada de útil, e o viés do Teorema, que vale $(k/n)^{2/p}$, deixa de ser pequeno.

(c) Queremos $\rho = (10/n)^{1/20} = 0,1$, isto é $10/n = 0,1^{20} = 10^{-20}$, logo

$$n = 10 \times 10^{20} = \mathbf{10^{21}}.$$

Um sextilhão de observações — mais do que grãos de areia na Terra — só para que dez vizinhos caibam num décimo da largura do cubo.

Exercício 3 — de onde sai o expoente. A demonstração do Teorema chega a

$$\mathbb{E}[(\hat{r}_k(\mathbf{X}) - r(\mathbf{X}))^2] \leq \underbrace{K\left(\frac{k}{n}\right)^{2/p}}_{\text{viés}^2} + \underbrace{\frac{\sigma^2}{k}}_{\text{variância}}.$$

- (a) Explique, em uma frase cada, por que o primeiro termo cresce com k e o segundo decresce.
- (b) Minimize a soma em k e mostre que o ótimo satisfaz $k \asymp n^{2/(2+p)}$. *Sugestão:* derive em k e iguale a zero, ou simplesmente iguale os dois termos — a menos de constantes dá o mesmo.
- (c) Substitua de volta e obtenha a taxa $n^{-2/(2+p)}$.
- (d) O que acontece com o k ótimo quando p cresce, com n fixo? Comente o que isso significa na prática.

Solução

(a) O **viés**² cresce com k porque pedir mais vizinhos obriga a ir buscá-los mais longe, e quanto mais longe estão os $\mathbf{x}_i$, menos $r(\mathbf{x}_i)$ se parece com $r(\mathbf{x})$ — é o fator $(k/n)^{2/p}$, que é o raio ao quadrado. A **variância** decresce com k porque $\hat{r}_k$ é a média de k respostas condicionalmente independentes, e a variância de uma média de k termos é σ^2/k .

(b) Igualando os dois termos, que é o atalho usual (o mínimo de uma soma de uma função crescente e uma decrescente está, a menos de constantes, onde elas se cruzam):

$$\left(\frac{k}{n}\right)^{2/p} \asymp \frac{1}{k} \implies k^{2/p} k \asymp n^{2/p} \implies k^{(2+p)/p} \asymp n^{2/p} \implies k \asymp n^{2/(2+p)}.$$

Pela derivada dá o mesmo: $\frac{p}{dk} [Kn^{-2/p}k^{2/p} + \sigma^2k^{-1}] = \frac{2K}{p}n^{-2/p}k^{2/p-1} - \sigma^2k^{-2} = 0$, o que leva a $k^{2/p+1} = \frac{p\sigma^2}{2K}n^{2/p}$ e à mesma ordem.

(c) Levando $k \asymp n^{2/(2+p)}$ ao termo de variância (o mais fácil dos dois):

$$\frac{\sigma^2}{k} \asymp \sigma^2 n^{-2/(2+p)}.$$

No termo de viés dá o mesmo, por construção — foi assim que escolhemos k . Logo a soma é da ordem de $n^{-2/(2+p)}$.

(d) O expoente $2/(2+p)$ vai a zero quando $p \rightarrow \infty$, então $k \asymp n^{2/(2+p)} \rightarrow n^0 = \text{constante}$. Ou seja: em dimensão alta, o k ótimo **para de crescer com n** .

O que isso significa é desanimador. Em dimensão baixa, ganhar mais dados permite usar mais vizinhos, e a variância cai. Em dimensão alta os vizinhos adicionais estão tão longe que o viés que eles trazem anula o ganho de variância — então o método fica preso a uma média sobre um punhado de pontos, por mais dados que você colete. É a tradução, em termos de k , da taxa lenta do Exercício 1.

Exercício 4 — como escapar: aditividade. A maldição vale para métodos que estimam r sem nenhuma suposição de forma. Se estivermos dispostos a supor que r é **aditiva**,

$$r(\mathbf{x}) = f_1(x_1) + f_2(x_2) + \cdots + f_p(x_p),$$

cada f_j é uma função de **uma** variável e pode ser estimada à taxa unidimensional $n^{-2/3}$. Somando os p erros, o risco fica da ordem de $pn^{-2/3}$.

- Com $p = 10$ e $n = 10\,000$, calcule as duas taxas: $n^{-2/(2+p)}$ (sem suposição) e $pn^{-2/3}$ (aditiva). Qual a razão entre elas?
- Quantas observações o método sem suposição precisaria para alcançar o erro que o aditivo alcança com 10 000?
- Onde entra p em cada uma das duas taxas? É essa a diferença essencial.
- Qual é o preço da suposição? Dê um exemplo de r que o modelo aditivo não consegue representar, por mais dados que se tenha.

Solução

(a) Com $n = 10^4$ e $p = 10$:

$$n^{-2/(2+p)} = (10^4)^{-1/6} = 10^{-2/3} \approx \mathbf{0,215}, \quad pn^{-2/3} = 10 \times (10^4)^{-2/3} = 10 \times 10^{-8/3} \approx \mathbf{0,0215}.$$

A razão é exatamente **10**: a suposição de aditividade divide o erro por dez, com os mesmos dados e sem mudar nada no experimento.

(b) Queremos $n^{-1/6} = 0,0215$, ou seja $n = 0,0215^{-6} = 10^{10}$. **Dez bilhões** de observações para igualar o que a suposição entrega com dez mil — um fator de um milhão.

(c) Na taxa sem suposição, p está no **expoente**: $n^{-2/(2+p)}$. É por isso que ela degrada exponencialmente. Na taxa aditiva, p é um **fator multiplicativo**: $p \cdot n^{-2/3}$, com expoente $-2/3$ fixo, o mesmo de um problema unidimensional. Dobrar p dobra o erro, em vez de exigir que n seja elevado a uma potência maior.

Essa é a lição geral do curso, e ela não é sobre aditividade em particular: **a maldição da dimensionalidade é uma consequência de não supor nada**. Toda estrutura que você esteja disposto a supor — aditividade, linearidade, esparsidade, suavidade de ordem maior — compra uma taxa melhor. A pergunta nunca é “como escapar da maldição”, é “que suposição eu aceito fazer”.

(d) O preço são as **interações**. O modelo aditivo não representa nenhuma função em que o efeito de x_1 dependa do valor de x_2 . O exemplo canônico é o produto,

$$r(x_1, x_2) = x_1 x_2,$$

que não se escreve como $f_1(x_1) + f_2(x_2)$. Um caso concreto no espírito da Aula 11: o efeito de uma dose de medicamento sobre a pressão pode ser positivo num grupo de pacientes e negativo em outro; um modelo aditivo é obrigado a escolher um único efeito médio para a dose e vai errar nos dois grupos.

Note o contraste com o Exercício 1: lá o problema era o n ser insuficiente, o que mais dados resolveriam. Aqui o viés é da *classe de modelos*, e não some com n nenhum.