

Lista Teórica 06

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 06 — Pré-processamento e *Pipelines*

Exercício 1 — revisando o notebook de um colega. Um colega lhe manda o notebook dele na véspera de entregar o relatório e pede uma olhada. Ele leu a Aula 06 na diagonal, e o resultado é um pouco de cada coisa: em alguns trechos fez exatamente o certo; em outros cometeu um deslize que não muda nada; e em pelo menos um está prestes a reportar um número que não existe.

Para separar os três casos você tem uma pergunta só, e ela não é “quanto essa etapa aprendeu dos dados”. É: **essa etapa olhou o Y ?**

Diga, para cada trecho, se o vazamento é **grave**, **leve**, ou se não há vazamento nenhum — e justifique em uma linha, aplicando a pergunta.

- (a) Ele padronizou as covariáveis com a média e o desvio do banco inteiro, e só depois separou treino e teste.
- (b) De 10 000 covariáveis, ficou com as 50 mais correlacionadas com Y — correlação calculada no banco inteiro — e rodou a validação cruzada só nessas 50.
- (c) Ajustou um PCA no banco inteiro, guardou as 20 primeiras componentes, e aí separou treino e teste.
- (d) Preencheu os faltantes com a mediana da própria coluna, calculada no banco inteiro.
- (e) O banco tem uma linha por consulta, e o mesmo paciente aparece em várias delas. Ele rodou KFold sobre as linhas.
- (f) Pôs o `StandardScaler` dentro de um `Pipeline`, e passou o *pipeline* inteiro para o `GridSearchCV`.

Exercício 2 — a receita inteira, num objeto só. Você chega a um banco e recebe a tarefa de sempre: prever inadimplência. O arquivo tem seis colunas. Três são numéricas — **idade**, **renda** e **saldo** —, e a **renda** vem com buracos, porque nem todo cliente informa. Duas são texto, **estado** e **profissao**, e essas vieram completas. A sexta é a resposta, **inadimplente**, que vale 0 ou 1.

O que você quer fazer com elas é o que a aula descreveu: preencher os faltantes das numéricas pela mediana, padronizá-las, transformar as duas categóricas em indicadoras, e ajustar uma regressão logística com penalização ℓ_2 , escolhendo o C por validação cruzada de cinco dobras. E quer tudo isso sem que o número que você vai apresentar no fim saia otimista.

- (a) Escreva o código, com `ColumnTransformer`, `Pipeline` e `GridSearchCV`.
- (b) Se a grade de C tem seis valores, quantas vezes a mediana da **renda** acaba sendo calculada ao longo de toda a busca? Justifique, e compare com o que aconteceria se você a imputasse uma vez só, no começo.
- (c) Se você trocar de lugar as duas etapas do ramo numérico — padronizar *e depois* imputar —, o código ainda roda? O que muda na coluna **renda** que chega ao modelo, e qual das duas ordens você usaria?