

Aula 07 — Classificação e Classificadores Gaussianos

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §7.1–7.3 e §8.1; ISLP §2.2.3, §4.3 e §4.4

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- formular o problema de classificação com a *perda 0–1* e derivar o **classificador de Bayes**;
- descrever a estratégia *plug-in*: estimar $\mathbb{P}(Y = c \mid \mathbf{x})$ e classificar pela maior probabilidade;
- estimar essa probabilidade pelo Teorema de Bayes, com o **Bayes ingênuo** (covariáveis contínuas ou discretas) e com a **análise discriminante** (LDA e QDA);
- entender por que LDA tem fronteira *linear* e QDA *quadrática*;
- escolher entre LDA e QDA pelo balanço viés–variância;
- estimá-la diretamente, com uma **regressão logística** ajustada por máxima verossimilhança, e reconhecer sua versão penalizada e a multiclasse;
- contrastar as abordagens *generativa* e *discriminativa*.

Começa aqui o Bloco II, e a boa notícia é que *quase tudo* do Bloco I se transfere: risco, balanço viés–variância, validação cruzada, *pipelines*. A única mudança é que Y agora é *qualitativo*, e por isso a perda natural deixa de ser a quadrática e passa a ser a 0–1. Comece pela pergunta:

*qual é o melhor classificador possível, se eu conhecesse
a distribuição dos dados?*

Essa pergunta tem resposta exata e curta — Teorema 1.1 — e ela desempenha, aqui, exatamente o papel que $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ desempenhou na Aula 01: define o alvo que todo método vai tentar aproximar.

1 O problema de classificação

Agora Y assume valores num conjunto finito de **classes** $\mathcal{C}$ (ex.: $\mathcal{C} = \{0, 1\}$ no caso binário). Um **classificador** é uma função $g : \mathbb{R}^p \rightarrow \mathcal{C}$, e queremos, como em regressão, que ela acerte observações novas: $g(\mathbf{x}_{n+1}) \approx y_{n+1}$.

O primeiro passo é decidir o que esse “ $\approx$ ” quer dizer. A perda quadrática $(Y - g(\mathbf{X}))^2$ não serve: se Y é “*spam*” ou “*não spam*”, não existe a diferença $Y - g(\mathbf{X})$. Codificar as classes por números não resolve, porque a conta passa a depender de uma escolha arbitrária — com três classes codificadas como 1, 2 e 3, confundir a classe 1 com a 3 custaria 4, e com a 2 custaria 1, como se houvesse uma ordem entre as classes. Em classificação só há duas situações: $g(\mathbf{x}) = y$, um acerto, e $g(\mathbf{x}) \neq y$, um erro. A perda que registra exatamente isso é a **perda 0–1**, $L(y, g(\mathbf{x})) = \mathbf{1}\{y \neq g(\mathbf{x})\}$, e o risco correspondente é a *probabilidade de erro*:

$$R(g) = \mathbb{E}[\mathbf{1}\{Y \neq g(\mathbf{X})\}] = \mathbb{P}(Y \neq g(\mathbf{X})). \quad (1)$$

Teorema 1.1 (Classificador de Bayes). *Sob a perda 0–1, o classificador que minimiza (1) é*

$$g^*(\mathbf{x}) = \arg \max_{c \in \mathcal{C}} \mathbb{P}(Y = c \mid \mathbf{X} = \mathbf{x}).$$

No caso binário $\mathcal{C} = \{0, 1\}$: $g^*(\mathbf{x}) = 1 \iff \mathbb{P}(Y = 1 \mid \mathbf{x}) \geq \frac{1}{2}$.

Demonstração. (Caso binário, classes c_1, c_2 .) Condicionando em $\mathbf{X}$,

$$R(g) = \mathbb{P}(Y \neq g(\mathbf{X})) = \int [\mathbf{1}\{g(\mathbf{x}) = c_2\} \mathbb{P}(Y = c_1 \mid \mathbf{x}) + \mathbf{1}\{g(\mathbf{x}) = c_1\} \mathbb{P}(Y = c_2 \mid \mathbf{x})] f(\mathbf{x}) d\mathbf{x}.$$

Para cada $\mathbf{x}$, o integrando é minimizado escolhendo $g(\mathbf{x}) = c_1$ quando $\mathbb{P}(Y = c_1 \mid \mathbf{x}) \geq \mathbb{P}(Y = c_2 \mid \mathbf{x})$ e $g(\mathbf{x}) = c_2$ caso contrário — isto é, a classe de maior probabilidade a posteriori. Como cada $\mathbf{x}$ é otimizado pontualmente, o classificador resultante minimiza o risco global. $\square$

Ideia central

Note o padrão: como na Aula 01, em que se mostrou que r minimiza o erro quadrático esperado, a prova otimiza *ponto a ponto* e depois integra. É a mesma técnica — e é por isso que os dois resultados se parecem tanto. Em regressão, o alvo é a *média* condicional; em classificação, a *moda* condicional. O classificador de Bayes g^* é o “oráculo”: nenhum classificador faz melhor. Seu risco R^* é o análogo do *erro irreduzível*. Mas g^* é *desconhecido*, pois depende de $\mathbb{P}(Y = c \mid \mathbf{x})$. Todo método desta aula é uma tentativa de aproximá-lo.

Observação 1.2 (O que se transfere da Parte I). A estimação do risco (1) é feita por *data splitting*/validação cruzada (Aula 03), agora medindo a *proporção de erros* na validação. O balanço viés–variância também vale: $R(g) - R^*$ decompõe-se num termo tipo variância (classe $\mathcal{G}$ grande demais) e num termo tipo viés (classe pequena demais). E, como em regressão, compare *poucos* modelos no teste — faça o *tuning* por CV dentro do treino.

Atenção

A acurácia ($1 - \text{risco 0–1}$) pode **enganar** em dados desbalanceados: com 10 doentes em 1000, o classificador trivial “todos saudáveis” acerta 99% — e é inútil. Precisaremos de outras métricas (matriz de confusão, sensibilidade, precisão) — tema da Aula 08.

2 Classificadores *plug-in*

O Teorema 1.1 sugere uma receita direta, dita *plug-in*:

1. estime $\hat{\mathbb{P}}(Y = c \mid \mathbf{x})$ para cada classe $c \in \mathcal{C}$;
2. classifique $\hat{g}(\mathbf{x}) = \arg \max_{c \in \mathcal{C}} \hat{\mathbb{P}}(Y = c \mid \mathbf{x})$.

Os métodos diferem em *como* estimam $\mathbb{P}(Y = c \mid \mathbf{x})$. Há duas grandes famílias:

Generativos modelam $f(\mathbf{x} \mid Y = c)$ e $\mathbb{P}(Y = c)$ e invertem com o Teorema de Bayes — é o caso do Bayes ingênuo, do LDA e do QDA, as próximas seções.

Discriminativos

modelam $\mathbb{P}(Y = c \mid \mathbf{x})$ *diretamente* — é o caso da regressão logística, que fecha a aula.

3 Modelos generativos: o Teorema de Bayes

A primeira família não modela $\mathbb{P}(Y = c \mid \mathbf{x})$ diretamente; modela como os dados de cada classe são gerados, e inverte:

$$\mathbb{P}(Y = c \mid \mathbf{x}) = \frac{f(\mathbf{x} \mid Y = c) \mathbb{P}(Y = c)}{\sum_{s \in \mathcal{C}} f(\mathbf{x} \mid Y = s) \mathbb{P}(Y = s)}, \quad (2)$$

em que $f(\mathbf{x} \mid Y = c)$ é a densidade de $\mathbf{X}$ dentro da classe c — ou a função de probabilidade, se $\mathbf{X}$ for discreto. Estima-se $\mathbb{P}(Y = c)$ pelas *proporções amostrais* de cada classe e $f(\mathbf{x} \mid Y = c)$ por algum modelo. Como o denominador de (2) é o mesmo para todas as classes, basta comparar os numeradores:

$$\hat{g}(\mathbf{x}) = \arg \max_{c \in \mathcal{C}} \hat{f}(\mathbf{x} \mid Y = c) \hat{\mathbb{P}}(Y = c).$$

Os métodos das duas próximas seções se distinguem pelo modelo de $f(\mathbf{x} \mid Y = c)$.

Ideia central: a inversão que dá nome à família

Repare no que (2) pede. Em vez de perguntar “dado este $\mathbf{x}$, qual a classe?”, pergunta-se “se a classe fosse c , que $\mathbf{x}$ eu esperaria ver?” — e o Teorema de Bayes inverte a resposta. Daí o nome *generativo*: o modelo descreve como os dados são **gerados**, e por isso permite *simular* observações novas de cada classe, coisa que um modelo discriminativo, como a regressão logística do fim da aula, não faz.

4 Bayes ingênuo

O Bayes ingênuo supõe **independência condicional** das covariáveis dada a classe:

$$f(\mathbf{x} \mid Y = c) = \prod_{j=1}^p f(x_j \mid Y = c). \quad (3)$$

É a hipótese “ingênua” que dá nome ao método: dentro de cada classe, as componentes de $\mathbf{X}$ são tratadas como independentes. Ela quase nunca é literalmente verdadeira, mas é *conveniente* e frequentemente gera bons classificadores. A conveniência é enorme: em vez de estimar uma densidade em $\mathbb{R}^p$ — tarefa condenada pela maldição da dimensionalidade — estimam-se p densidades em $\mathbb{R}^1$. É a esparsidade de suposições comprando viabilidade.

4.1 Covariáveis contínuas

Cada $f(x_j \mid Y = c)$ pode ser *qualquer* densidade em $\mathbb{R}$, e escolhê-la é um problema de inferência univariada, resolvido só com as observações da covariável j que pertencem à classe c . Por isso vale olhar os dados antes: um histograma por classe mostra se a normal é razoável, se a variável é positiva e assimétrica, se há caudas pesadas — e ter à mão um bom repertório de modelos probabilísticos paga aqui. Se nenhum modelo paramétrico servir, cada $f(x_j \mid Y = c)$ pode ser estimada de forma não paramétrica.

A escolha mais comum é a gaussiana, $X_j \mid Y = c \sim N(\mu_{j,c}, \sigma_{j,c}^2)$, com os estimadores de máxima verossimilhança

$$\hat{\mu}_{j,c} = \frac{1}{|\mathcal{C}_c|} \sum_{i \in \mathcal{C}_c} x_{i,j}, \quad \hat{\sigma}_{j,c}^2 = \frac{1}{|\mathcal{C}_c|} \sum_{i \in \mathcal{C}_c} (x_{i,j} - \hat{\mu}_{j,c})^2,$$

em que $\mathcal{C}_c = \{i : y_i = c\}$ reúne as observações de treino da classe c . É o que faz o **GaussianNB** do **scikit-learn**, que ainda soma às variâncias um termo minúsculo, para estabilidade numérica.

4.2 Covariáveis discretas

Se $\mathbf{X}$ é discreto, (2) vale com probabilidades no lugar das densidades, e a hipótese ingênua fatora $\mathbb{P}(\mathbf{X} = \mathbf{x} \mid Y = c) = \prod_{j=1}^p \mathbb{P}(X_j = x_j \mid Y = c)$. A estimação é análoga: proporções calculadas dentro de cada classe. O `scikit-learn` traz as variantes mais comuns:

- **BernoulliNB**: cada X_j é binária, $X_j \mid Y = c \sim \text{Bernoulli}(\theta_{j,c})$;
- **CategoricalNB**: cada X_j é categórica, com uma probabilidade por nível e por classe;
- **MultinomialNB**: $\mathbf{X}$ é um vetor de contagens — quantas vezes cada palavra aparece num texto, por exemplo — modelado por uma multinomial;
- **ComplementNB**: uma variante do multinomial, pensada para classes desbalanceadas.

O caso multinomial merece uma observação. As contagens de uma multinomial *não* são independentes entre si — elas somam o tamanho do texto —, mas a hipótese ingênua continua lá, agora sobre as palavras: dada a classe, cada palavra do texto é sorteada independentemente das outras. É a versão que funciona tão bem em texto, e ela reaparece na Aula E3.

Atenção

Numericamente, o produto (3) de muitos termos pequenos sofre *underflow* (vira 0). Trabalhe sempre em **escala logarítmica**: $\hat{g}(\mathbf{x}) = \arg \max_c [\sum_j \log \hat{f}(x_j \mid Y = c) + \log \hat{\mathbb{P}}(Y = c)]$.

Atenção: o preço do “ingênuo”

Quando as covariáveis são de fato correlacionadas, o Bayes ingênuo conta a mesma evidência várias vezes — se três colunas dizem quase a mesma coisa, ele as trata como três testemunhas independentes. O efeito é curioso e importante: a *ordenação* das observações costuma sair boa (ele acerta quem é mais provável de ser da classe 1), mas as *probabilidades* saem grudadas em 0 e 1. A Aula 08 mede isso.

5 Análise discriminante: LDA e QDA

A análise discriminante abandona a independência: modela o vetor $\mathbf{X}$ inteiro, dentro de cada classe, como **gaussiano multivariado**. Lembre que $\mathbf{Z} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ em $\mathbb{R}^p$ tem densidade

$$f(\mathbf{z}) = \frac{1}{\sqrt{(2\pi)^p \det \boldsymbol{\Sigma}}} \exp\left(-\frac{1}{2}(\mathbf{z} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{z} - \boldsymbol{\mu})\right), \quad (4)$$

com $\boldsymbol{\mu} \in \mathbb{R}^p$ e $\boldsymbol{\Sigma}$ uma matriz $p \times p$ simétrica e positiva definida. A correlação entre as covariáveis, que o Bayes ingênuo jogava fora, mora nas entradas fora da diagonal de $\boldsymbol{\Sigma}$. As duas versões diferem na covariância:

- **QDA** (*Quadratic Discriminant Analysis*): cada classe tem sua própria covariância, $\mathbf{X} \mid Y = c \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)$;
- **LDA** (*Linear Discriminant Analysis*): as classes têm médias próprias, mas *compartilham* a covariância, $\mathbf{X} \mid Y = c \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma})$.

Os parâmetros são estimados por máxima verossimilhança. As médias são as de cada classe, e as covariâncias medem a dispersão em torno delas — uma por classe no QDA, uma só, reunindo

todas as classes, no LDA:

$$\begin{aligned}\hat{\boldsymbol{\mu}}_c &= \frac{1}{|\mathcal{C}_c|} \sum_{i \in \mathcal{C}_c} \mathbf{x}_i, \\ \hat{\boldsymbol{\Sigma}}_c &= \frac{1}{|\mathcal{C}_c|} \sum_{i \in \mathcal{C}_c} (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_c)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_c)^\top \quad (\text{QDA}), \\ \hat{\boldsymbol{\Sigma}} &= \frac{1}{n} \sum_{c \in \mathcal{C}} \sum_{i \in \mathcal{C}_c} (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_c)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_c)^\top \quad (\text{LDA}).\end{aligned}$$

Com essas estimativas no lugar dos parâmetros, o classificador é o *plug-in* de (2).

Proposição 5.1 (LDA tem fronteira linear). *Sob $\mathbf{X} \mid Y = c \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma})$ (covariância comum), o classificador de Bayes (2) equivale a $\hat{g}(\mathbf{x}) = \arg \max_c \delta_c(\mathbf{x})$, com a função discriminante linear*

$$\delta_c(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_c - \frac{1}{2} \boldsymbol{\mu}_c^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_c + \log \mathbb{P}(Y = c).$$

As fronteiras entre classes $\{\mathbf{x} : \delta_c(\mathbf{x}) = \delta_{c'}(\mathbf{x})\}$ são **hiperplanos**.

Demonstração. Classificar por $\arg \max_c \mathbb{P}(Y = c \mid \mathbf{x})$ equivale a $\arg \max_c \log(f(\mathbf{x} \mid Y = c) \mathbb{P}(Y = c))$ (o denominador de (2) não depende de c). Com a densidade gaussiana (4), $\log f(\mathbf{x} \mid Y = c) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_c)^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_c) + \text{const.}$ Expandindo o quadrado, o termo $\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x}$ é igual para todas as classes (pois $\boldsymbol{\Sigma}$ é comum) e pode ser descartado do $\arg \max$. Sobram exatamente os termos lineares em $\mathbf{x}$ de $\delta_c(\mathbf{x})$. A diferença $\delta_c - \delta_{c'}$ é afim em $\mathbf{x}$, logo cada fronteira é um hiperplano. $\square$

Observação 5.2. Em QDA, $\boldsymbol{\Sigma}_c$ varia com c , e dois termos deixam de cancelar: a forma quadrática $\mathbf{x}^\top \boldsymbol{\Sigma}_c^{-1} \mathbf{x}$ e o $\log \det \boldsymbol{\Sigma}_c$ que vem da constante de normalização de (4). A função discriminante fica

$$\delta_c(\mathbf{x}) = -\frac{1}{2} \mathbf{x}^\top \boldsymbol{\Sigma}_c^{-1} \mathbf{x} + \mathbf{x}^\top \boldsymbol{\Sigma}_c^{-1} \boldsymbol{\mu}_c - \frac{1}{2} \boldsymbol{\mu}_c^\top \boldsymbol{\Sigma}_c^{-1} \boldsymbol{\mu}_c - \frac{1}{2} \log \det \boldsymbol{\Sigma}_c + \log \mathbb{P}(Y = c),$$

quadrática em $\mathbf{x}$, e as fronteiras $\{\mathbf{x} : \delta_c(\mathbf{x}) = \delta_{c'}(\mathbf{x})\}$ são superfícies quádricas em $\mathbb{R}^p$ — em $\mathbb{R}^2$, cônicas: elipses, parábolas, hipérboles. No fim da aula, a Figura 2 põe a fronteira do QDA ao lado das dos outros três métodos.

5.1 LDA ou QDA? Uma questão de viés e variância

QDA é mais flexível (menos viés), mas estima muito mais parâmetros. A conta, com K classes em $\mathbb{R}^p$: os dois estimam K vetores de médias, Kp números; o LDA estima *uma* matriz de covariância, com $p(p+1)/2$ entradas livres, e o QDA estima *uma por classe*, $Kp(p+1)/2$. Com $p = 10$ e duas classes, são 55 parâmetros de covariância contra 110 — e cada um deles precisa de dados.

Ideia central

Esta figura é a Aula 01 vestida de classificação. O modelo *correto* pode perder para o modelo *errado* quando não há dados suficientes para estimá-lo — exatamente o que o Exemplo 1.7 do [AME] mostrou lá atrás com polinômios de grau 5 e 2. Regra de bolso: LDA com poucas amostras de treino, QDA com muitas ou quando a hipótese de covariância comum for inverossímil. As duas metades da regra importam: o que o QDA tem a *perder* depende de n contra os $(K-1)p(p+1)/2$ parâmetros que ele estima a mais; o que ele tem a *ganhar* depende de quanto as covariâncias das classes de fato diferem — se diferem pouco, não há viés do LDA a corrigir. E, como sempre, valide de forma cruzada em vez de decidir por regra de bolso.




Figura 1: Acurácia dos dois métodos em função de n , com $p = 10$ covariáveis e covariâncias genuinamente diferentes por classe — ou seja, num cenário em que o **QDA está certo e o LDA está errado**. Ainda assim, com $n = 30$ o LDA ganha (0,748 contra 0,692): não há dados para estimar 110 parâmetros de covariância, e a variância do QDA supera o viés do LDA. A partir de $n = 50$ o jogo vira, e em $n = 4000$ o QDA abre sete pontos percentuais. Médias de 120 repetições, avaliadas em 20 000 observações novas.

6 Regressão logística (discriminativo)

O Bayes ingênuo, o LDA e o QDA chegam a $\mathbb{P}(Y = c \mid \mathbf{x})$ por um caminho indireto: modelam como os dados de cada classe são gerados e invertem com o Teorema de Bayes. E se estimássemos $\mathbb{P}(Y = c \mid \mathbf{x})$ *diretamente*, sem passar pelas densidades? É o que fazem os métodos discriminativos, e a regressão logística é o principal deles. No caso binário $\mathcal{C} = \{0, 1\}$ basta modelar $\mathbb{P}(Y = 1 \mid \mathbf{x})$, com um cuidado: uma probabilidade vive em $[0, 1]$, enquanto uma função linear $\beta_0 + \beta^\top \mathbf{x}$ vive em toda a reta. A regressão logística resolve isso modelando

$$\mathbb{P}(Y = 1 \mid \mathbf{x}) = \frac{e^{\beta_0 + \sum_{i=1}^p \beta_i x_i}}{1 + e^{\beta_0 + \sum_{i=1}^p \beta_i x_i}} = \sigma(\beta_0 + \beta^\top \mathbf{x}), \quad (5)$$

onde $\sigma(u) = e^u / (1 + e^u)$ é a função logística, que leva $\mathbb{R}$ em $(0, 1)$. Equivalentemente, o *log-odds* é linear: $\log \frac{\mathbb{P}(Y=1|\mathbf{x})}{\mathbb{P}(Y=0|\mathbf{x})} = \beta_0 + \beta^\top \mathbf{x}$. Como em regressão, *não* supomos que isso seja exatamente verdade — esperamos que leve a um bom classificador. Note que a fronteira de decisão $\{\mathbf{x} : \mathbb{P}(Y = 1 \mid \mathbf{x}) = \frac{1}{2}\}$ é o conjunto em que o *log-odds* se anula: um **hiperplano**, como no LDA.

Ideia central: por que a logística e não outra curva em $[0, 1]$

A função σ tem duas propriedades que a tornam a escolha natural. Primeira: ela é a inversa do *logit* $\log \frac{p}{1-p}$, que leva $[0, 1]$ em toda a reta — ou seja, ela transforma um problema restrito num problema linear irrestrito. Segunda: a linearidade do *log-odds* dá a interpretação que os usuários querem — aumentar x_j em uma unidade multiplica a razão de chances por e^{β_j} , qualquer que seja o ponto de partida. (O efeito sobre a *probabilidade*, esse sim, depende de onde se está na curva.) Você vai reencontrar σ na Aula 09 e em qualquer rede neural.

6.1 Estimação por máxima verossimilhança

Dada uma amostra i.i.d., a verossimilhança condicional é

$$L(\beta) = \prod_{k=1}^n \pi(\mathbf{x}_k)^{Y_k} (1 - \pi(\mathbf{x}_k))^{1-Y_k}, \quad \pi(\mathbf{x}_k) = \mathbb{P}(Y_k = 1 \mid \mathbf{x}_k, \beta). \quad (6)$$

Maximiza-se o log da verossimilhança (6). Ao contrário do MQO, não há solução fechada: usam-se métodos numéricos (Newton–Raphson / IRLS). Como na regressão linear, pode-se **penalizar** (ℓ_1/ℓ_2) para reduzir variância — é literalmente a Aula 02 aplicada a outra função-objetivo.

Atenção: separação perfeita

Se existir um hiperplano que separa as duas classes *sem erro* no treino, a verossimilhança (6) não tem máximo: empurrar $\|\beta\| \rightarrow \infty$ faz as probabilidades tenderem a 0 e 1 e a verossimilhança crescer sem parar. O otimizador roda até o limite de iterações e devolve coeficientes gigantescos e sem sentido. Acontece com frequência quando p é grande em relação a n . A solução é a penalização — e é por isso que o `scikit-learn` aplica ℓ_2 por padrão na `LogisticRegression`.

6.2 Mais de duas classes

Para $|C| > 2$: ou ajusta-se uma logística *um-contra-todos* por classe (e normaliza-se), ou usa-se a **regressão logística multinomial** (*softmax*), que garante que as probabilidades estimadas somem 1.

7 Discriminativo × generativo

Com os quatro métodos na mão, vale compará-los. A Figura 2 põe as fronteiras de todos lado a lado, numa mesma amostra de duas classes gaussianas, e a tabela abaixo resume o que distingue as duas famílias.




Figura 2: Fronteiras de decisão em duas classes gaussianas com covariâncias *diferentes* ($n = 400$). Logística e LDA chegam a retas quase idênticas por caminhos completamente distintos — uma modelando $\mathbb{P}(Y \mid \mathbf{x})$ direto, a outra modelando $f(\mathbf{x} \mid Y)$ e invertendo. O QDA, livre da hipótese de covariância comum, curva a fronteira e acompanha o formato de cada nuvem: é o modelo correto para estes dados. O Bayes ingênuo também curva, mas erra o ângulo: ele supõe as duas covariáveis independentes dentro de cada classe, e aqui elas não são.

	Discriminativo (logística)	Generativo (LDA/QDA/NB)
Modela	$\mathbb{P}(Y \mathbf{x})$ direto	$f(\mathbf{x} Y)$ e $\mathbb{P}(Y)$
Suposições	poucas (forma do <i>log-odds</i>)	distribucionais (gaussiana, indep.)
Quando brilha	muitos dados; suposições gaussianas falsas	classes bem separadas; poucos dados; suposições aproximadamente corretas
Bônus	—	gera dados; lida com classes raras

Ideia central

Se as suposições gaussianas valem, LDA/QDA são (quase) ótimos e eficientes com poucos dados. Se não valem, a logística — que assume menos — tende a ser mais robusta com bastante dado. Um detalhe curioso fecha o círculo: sob as hipóteses do LDA, o *log-odds* sai **exatamente** linear em $\mathbf{x}$ (Prop. 5.1), que é justamente o que a logística (5) supõe. Os dois modelos coincidem em forma e diferem só em como estimam os coeficientes — o que explica os dois primeiros painéis da Figura 2. Na dúvida: experimente ambos e compare por validação cruzada.

8 Prática em Python

```

1 from sklearn.naive_bayes import GaussianNB
2 from sklearn.discriminant_analysis import (LinearDiscriminantAnalysis as LDA,
3                                             QuadraticDiscriminantAnalysis as QDA)
4 from sklearn.linear_model import LogisticRegression
5 from sklearn.pipeline import make_pipeline
6 from sklearn.preprocessing import StandardScaler
7
8 nb, lda, qda = GaussianNB(), LDA(), QDA()
9
10 # Logística penalizada (C = 1/lambda); padronizar no pipeline (Aula 06)
11 logit = make_pipeline(StandardScaler(),
12                      LogisticRegression(C=1.0, max_iter=1000))
13
14 for nome, modelo in [("NB", nb), ("LDA", lda), ("QDA", qda), ("logit", logit)]:
15     modelo.fit(X_tr, y_tr)
16     print(nome, "acurácia:", modelo.score(X_te, y_te))
17     # probabilidades plug-in: modelo.predict_proba(X_te)

```

Atenção

Três pegadinhas. Primeira: em `LogisticRegression`, o parâmetro é o C , que é o **inverso** da penalização — C pequeno significa regularização forte, ao contrário do α do Ridge/Lasso. Segunda: `modelo.score` devolve *acurácia*, e a caixa de atenção lá do começo desta aula explica por que isso pode ser uma medida péssima — leia a Aula 08 antes de tirar conclusões dessas linhas. Terceira: o QDA das versões recentes do `scikit-learn` *recusa* o ajuste quando a covariância estimada de alguma classe é singular ou quase — por exemplo, quando a classe tem no máximo p observações, ou quando há colunas quase colineares. No segundo caso, o argumento `reg_param` puxa as covariâncias levemente na direção da identidade e resolve (a §8 da Aula prática 07 precisa dele); com menos observações na classe do que covariáveis, nem ele.

O notebook **Comparação entre classificadores paramétricos** põe o Bayes ingênuo, o LDA e o QDA lado a lado em três conjuntos de dados artificiais, junto com três SVMs, que são assunto da Aula 09. A **Aula prática 07** calcula o erro de Bayes numa população conhecida, compara os quatro métodos desta aula e mede a troca LDA×QDA em $p = 2$ e $p = 10$.

Resumo

- Perda 0–1 (1); o **classificador de Bayes** $g^*(\mathbf{x}) = \arg \max_c \mathbb{P}(Y = c \mid \mathbf{x})$ é ótimo (Teo. 1.1) mas desconhecido — é a moda condicional, como r era a média condicional.
- *Plug-in*: estimar $\mathbb{P}(Y = c \mid \mathbf{x})$ e tomar o $\arg \max$ — ou pelo Teorema de Bayes (2), modelando $f(\mathbf{x} \mid Y = c)$ (generativo), ou diretamente (discriminativo).
- **Bayes ingênuo**: independência condicional (3), com um modelo univariado por covariável (`GaussianNB`, `BernoulliNB`, `MultinomialNB`, ...) — barato, mas descalibra quando as covariáveis são correlacionadas.
- **LDA** (covariância comum $\rightarrow$ fronteira linear, Prop. 5.1) e **QDA** (covariância por classe $\rightarrow$ quadrática), com parâmetros por máxima verossimilhança. Ver Fig. 2.
- LDA $\times$ QDA é viés $\times$ variância (Fig. 1): o modelo correto pode perder por falta de dados.
- **Logística** (5): discriminativa, ajustada por máxima verossimilhança, penalizável e multiclasse; respeita $[0, 1]$ por construção, e cuidado com a separação perfeita.
- Generativo (eficiente sob suposições corretas e com poucos dados) $\times$ discriminativo (menos suposições, robusto com muito dado).
- Cuidado com acurácia em dados desbalanceados $\Rightarrow$ Aula 08.

Leitura recomendada. [AME] §7.1 (risco 0–1 e o classificador de Bayes, com o Teorema 9 que é o nosso Teo. 1.1), §7.2–7.3 (estimação do risco e viés–variância em classificação) e §8.1 (a receita *plug-in*, com a logística em §8.1.2, o Bayes ingênuo em §8.1.3 e a análise discriminante em §8.1.4 — atenção: as duas densidades normais escritas ali omitem o $\frac{1}{2}$ do expoente; a correta é a (4)). [ISLP] §2.2.3 (o classificador de Bayes e o erro de Bayes), §4.3 (a logística, com a interpretação dos coeficientes em razão de chances) e §4.4 (os modelos generativos: a Figura 4.9 deles é a versão da nossa Figura 2 para LDA e QDA, e o §4.4.3 traz a conta de parâmetros que está por trás da Figura 1).

Para praticar. `Lista teorica 07.pdf` (teórica, com gabarito) e `Lista prática 07.ipynb` (prática, para completar as lacunas), nesta mesma pasta.