

Aula 07 — Classificação e Classificadores Gaussianos

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME cap. 7 e §8.1; ISLP cap. 4

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- formular o problema de classificação com a *perda 0–1* e derivar o **classificador de Bayes**;
- descrever a estratégia *plug-in*: estimar $\mathbb{P}(Y = c \mid \mathbf{x})$ e classificar pela maior probabilidade;
- ajustar uma **regressão logística** por máxima verossimilhança e reconhecer sua versão penalizada/multiclasse;
- descrever os *modelos generativos* via Teorema de Bayes: **Bayes ingênuo**, **LDA** e **QDA**;
- entender por que LDA tem fronteira *linear* e QDA *quadrática*;
- contrastar abordagens *discriminativas* e *generativas*.

Começa aqui o Bloco II, e a boa notícia é que *quase tudo* do Bloco I se transfere: risco, balanço viés–variância, validação cruzada, *pipelines*. A única mudança é que Y agora é *qualitativo*, e por isso a perda natural deixa de ser a quadrática e passa a ser a 0–1. Comece pela pergunta:

*qual é o melhor classificador possível, se eu conhecesse
a distribuição dos dados?*

Essa pergunta tem resposta exata e curta — Teorema 1.1 — e ela desempenha, aqui, exatamente o papel que $r(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$ desempenhou na Aula 01: define o alvo que todo método vai tentar aproximar.

1 O problema de classificação

Agora Y assume valores num conjunto finito de **classes** $\mathcal{C}$ (ex.: $\mathcal{C} = \{0, 1\}$ no caso binário). Um **classificador** é uma função $g : \mathbb{R}^p \rightarrow \mathcal{C}$. A perda natural é a **perda 0–1**, $L(y, g(\mathbf{x})) = \mathbf{1}\{y \neq g(\mathbf{x})\}$, e o risco é a *probabilidade de erro*:

$$R(g) = \mathbb{E}[\mathbf{1}\{Y \neq g(\mathbf{X})\}] = \mathbb{P}(Y \neq g(\mathbf{X})). \quad (1)$$

Teorema 1.1 (Classificador de Bayes). *Sob a perda 0–1, o classificador que minimiza (1) é*

$$g^*(\mathbf{x}) = \arg \max_{c \in \mathcal{C}} \mathbb{P}(Y = c \mid \mathbf{X} = \mathbf{x}).$$

No caso binário $\mathcal{C} = \{0, 1\}$: $g^*(\mathbf{x}) = 1 \iff \mathbb{P}(Y = 1 \mid \mathbf{x}) \geq \frac{1}{2}$.

Demonstração. (Caso binário, classes c_1, c_2 .) Condicionando em $\mathbf{X}$,

$$R(g) = \mathbb{P}(Y \neq g(\mathbf{X})) = \int [\mathbf{1}\{g(\mathbf{x}) = c_2\} \mathbb{P}(Y = c_1 \mid \mathbf{x}) + \mathbf{1}\{g(\mathbf{x}) = c_1\} \mathbb{P}(Y = c_2 \mid \mathbf{x})] f(\mathbf{x}) d\mathbf{x}.$$

Para cada $\mathbf{x}$, o integrando é minimizado escolhendo $g(\mathbf{x}) = c_1$ quando $\mathbb{P}(Y = c_1 \mid \mathbf{x}) \geq \mathbb{P}(Y = c_2 \mid \mathbf{x})$ e $g(\mathbf{x}) = c_2$ caso contrário — isto é, a classe de maior probabilidade a posteriori. Como cada $\mathbf{x}$ é otimizado pontualmente, o classificador resultante minimiza o risco global. $\square$

Ideia central

Note o padrão: como na Proposição 3.1 da Aula 01, a prova otimiza *ponto a ponto* e depois integra. É a mesma técnica — e é por isso que os dois resultados se parecem tanto. Em regressão, o alvo é a *média* condicional; em classificação, a *moda* condicional. O classificador de Bayes g^* é o “oráculo”: nenhum classificador faz melhor. Seu risco R^* é o análogo do *erro irreduzível*. Mas g^* é *desconhecido*, pois depende de $\mathbb{P}(Y = c \mid \mathbf{x})$. Todo método desta aula é uma tentativa de aproximá-lo.

Observação 1.2 (O que se transfere da Parte I). A estimação do risco (1) é feita por *data splitting*/validação cruzada (Aula 03), agora medindo a *proporção de erros* na validação. O balanço viés-variância também vale: $R(g) - R^*$ decompõe-se num termo tipo variância (classe $\mathcal{G}$ grande demais) e num termo tipo viés (classe pequena demais). E, como em regressão, compare *poucos* modelos no teste — faça o *tuning* por CV dentro do treino.

Atenção

A acurácia ($1 - \text{risco } 0-1$) pode **enganar** em dados desbalanceados: com 10 doentes em 1000, o classificador trivial “todos saudáveis” acerta 99% — e é inútil. Precisaremos de outras métricas (matriz de confusão, sensibilidade, precisão) — tema da Aula 08.

2 Classificadores *plug-in*

O Teorema 1.1 sugere uma receita direta, dita ***plug-in***:

1. estime $\hat{\mathbb{P}}(Y = c \mid \mathbf{x})$ para cada classe $c \in \mathcal{C}$;
2. classifique $\hat{g}(\mathbf{x}) = \arg \max_{c \in \mathcal{C}} \hat{\mathbb{P}}(Y = c \mid \mathbf{x})$.

Os métodos diferem em *como* estimam $\mathbb{P}(Y = c \mid \mathbf{x})$. Há duas grandes famílias:

Discriminativos

modelam $\mathbb{P}(Y = c \mid \mathbf{x})$ *diretamente* (regressão logística; ou regressão sobre indicadores).

Generativos modelam $f(\mathbf{x} \mid Y = c)$ e $\mathbb{P}(Y = c)$ e invertem com o Teorema de Bayes (Bayes ingênuo, LDA, QDA).

2.1 Via regressão sobre indicadores

Como $\mathbb{P}(Y = c \mid \mathbf{x}) = \mathbb{E}[\mathbf{1}\{Y = c\} \mid \mathbf{x}]$, podemos usar *qualquer* método de regressão (Parte I) sobre $Z = \mathbf{1}\{Y = c\}$. É uma boa notícia: tudo o que você aprendeu nas Aulas 02 a 06 continua valendo. Mas a regressão linear pode dar estimativas fora de $[0, 1]$ — e uma “probabilidade” de 1,3 é constrangedora. (KNN e árvores, por construção, não têm esse problema: eles fazem médias de indicadores, que estão sempre em $[0, 1]$.) Daí o apelo de um modelo que respeite $[0, 1]$ por construção: a logística.

3 Regressão logística (discriminativo)

No caso binário $\mathcal{C} = \{0, 1\}$, a regressão logística modela

$$\mathbb{P}(Y = 1 \mid \mathbf{x}) = \frac{e^{\beta_0 + \sum_{i=1}^p \beta_i x_i}}{1 + e^{\beta_0 + \sum_{i=1}^p \beta_i x_i}} = \sigma(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x}), \quad (2)$$

onde $\sigma(u) = e^u / (1 + e^u)$ é a função logística. Equivalentemente, o *log-odds* é linear: $\log \frac{\mathbb{P}(Y=1|\mathbf{x})}{\mathbb{P}(Y=0|\mathbf{x})} = \beta_0 + \beta^\top \mathbf{x}$. Como em regressão, *não* supomos que isso seja exatamente verdade — esperamos que leve a um bom classificador.

Ideia central: por que a logística e não outra curva em $[0, 1]$

A função σ tem duas propriedades que a tornam a escolha natural. Primeira: ela é a inversa do *logit* $\log \frac{p}{1-p}$, que leva $[0, 1]$ em toda a reta — ou seja, ela transforma um problema restrito num problema linear irrestrito. Segunda: a linearidade do *log-odds* dá a interpretação que os usuários querem — aumentar x_j em uma unidade multiplica a razão de chances por e^{β_j} , qualquer que seja o ponto de partida. Você vai reencontrar σ na Aula 09 e em qualquer rede neural.

3.1 Estimação por máxima verossimilhança

Dada uma amostra i.i.d., a verossimilhança condicional é

$$L(\beta) = \prod_{k=1}^n \pi(\mathbf{x}_k)^{Y_k} (1 - \pi(\mathbf{x}_k))^{1-Y_k}, \quad \pi(\mathbf{x}_k) = \mathbb{P}(Y_k = 1 \mid \mathbf{x}_k, \beta). \quad (3)$$

Maximiza-se o log da verossimilhança (3). Ao contrário do MQO, não há solução fechada: usam-se métodos numéricos (Newton–Raphson / IRLS). Como na regressão linear, pode-se **penalizar** (ℓ_1/ℓ_2) para reduzir variância — é literalmente a Aula 02 aplicada a outra função-objetivo.

Atenção: separação perfeita

Se existir um hiperplano que separa as duas classes *sem erro* no treino, a verossimilhança (3) não tem máximo: empurrar $\|\beta\| \rightarrow \infty$ faz as probabilidades tenderem a 0 e 1 e a verossimilhança crescer sem parar. O otimizador roda até o limite de iterações e devolve coeficientes gigantescos e sem sentido. Acontece com frequência quando p é grande em relação a n . A solução é a penalização — e é por isso que o `scikit-learn` aplica ℓ_2 por padrão na `LogisticRegression`.

3.2 Mais de duas classes

Para $|\mathcal{C}| > 2$: ou ajusta-se uma logística *um-contra-todos* por classe (e normaliza-se), ou usa-se a **regressão logística multinomial** (*softmax*), que garante que as probabilidades estimadas somem 1.

4 Modelos generativos: Teorema de Bayes

Os modelos generativos partem de

$$\mathbb{P}(Y = c \mid \mathbf{x}) = \frac{f(\mathbf{x} \mid Y = c) \mathbb{P}(Y = c)}{\sum_{s \in \mathcal{C}} f(\mathbf{x} \mid Y = s) \mathbb{P}(Y = s)}. \quad (4)$$

Estima-se $\mathbb{P}(Y = c)$ pelas *proporções amostrais* e $f(\mathbf{x} \mid Y = c)$ por algum modelo. As três escolhas abaixo se distinguem pelo modelo de $f(\mathbf{x} \mid Y = c)$.

Ideia central: a inversão que dá nome à família

Repare no que (4) pede. Em vez de perguntar “dado este $\mathbf{x}$, qual a classe?”, pergunta-se “se a classe fosse c , que $\mathbf{x}$ eu esperaria ver?” — e o Teorema de Bayes inverte a resposta.

Daí o nome *generativo*: o modelo descreve como os dados são **gerados**, e por isso permite *simular* observações novas de cada classe, coisa que a logística não faz.

4.1 Bayes ingênuo

Supõe **independência condicional** das covariáveis dada a classe:

$$f(\mathbf{x} \mid Y = c) = \prod_{j=1}^p f(x_j \mid Y = c). \quad (5)$$

A suposição quase nunca é literalmente verdadeira, mas é *conveniente* e frequentemente gera bons classificadores. A conveniência é enorme: em vez de estimar uma densidade em $\mathbb{R}^p$ — tarefa condenada pela maldição da dimensionalidade — estimam-se p densidades em $\mathbb{R}^1$. É a esparsidade de suposições comprando viabilidade. Para covariáveis contínuas, modela-se cada $X_j \mid Y = c \sim N(\mu_{j,c}, \sigma_{j,c}^2)$; para discretas, usa-se multinomial (ótimo em texto — ponte com a Aula extra E3).

Atenção

Numericamente, o produto (5) de muitos termos pequenos sofre *underflow* (vira 0). Trabalhe sempre em **escala logarítmica**: $\hat{g}(\mathbf{x}) = \arg \max_c [\sum_j \log \hat{f}(x_j \mid Y = c) + \log \hat{\mathbb{P}}(Y = c)]$.

Atenção: o preço do “ingênuo”

Quando as covariáveis são de fato correlacionadas, o Bayes ingênuo conta a mesma evidência várias vezes — se três colunas dizem quase a mesma coisa, ele as trata como três testemunhas independentes. O efeito é curioso e importante: a *ordenação* das observações costuma sair boa (ele acerta quem é mais provável de ser da classe 1), mas as *probabilidades* saem grudadas em 0 e 1. A Aula 08 mede isso.

4.2 Análise discriminante: LDA e QDA

Aqui modela-se o vetor inteiro como **gaussiano multivariado**: $\mathbf{X} \mid Y = c \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)$. A distinção:

- **QDA** (*Quadratic Discriminant Analysis*): cada classe tem sua própria covariância $\boldsymbol{\Sigma}_c$.
- **LDA** (*Linear Discriminant Analysis*): supõe covariância *comum* $\boldsymbol{\Sigma}_c = \boldsymbol{\Sigma}$ para todas as classes.

Proposição 4.1 (LDA tem fronteira linear). *Sob $\mathbf{X} \mid Y = c \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma})$ (covariância comum), o classificador de Bayes (4) equivale a $\hat{g}(\mathbf{x}) = \arg \max_c \delta_c(\mathbf{x})$, com a função discriminante linear*

$$\delta_c(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_c - \frac{1}{2} \boldsymbol{\mu}_c^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_c + \log \mathbb{P}(Y = c).$$

As fronteiras entre classes $\{\mathbf{x} : \delta_c(\mathbf{x}) = \delta_{c'}(\mathbf{x})\}$ são **hiperplanos**.

Demonstração. Classificar por $\arg \max_c \mathbb{P}(Y = c \mid \mathbf{x})$ equivale a $\arg \max_c \log(f(\mathbf{x} \mid Y = c) \mathbb{P}(Y = c))$ (o denominador de (4) não depende de c). Com a densidade gaussiana, $\log f(\mathbf{x} \mid Y = c) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_c)^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_c) + \text{const}$. Expandindo o quadrado, o termo $\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x}$ é igual para todas as classes (pois $\boldsymbol{\Sigma}$ é comum) e pode ser descartado do $\arg \max$. Sobram exatamente os termos lineares em $\mathbf{x}$ de $\delta_c(\mathbf{x})$. A diferença $\delta_c - \delta_{c'}$ é afim em $\mathbf{x}$, logo cada fronteira é um hiperplano. $\square$

Observação 4.2. Em QDA, Σ_c varia com c , então o termo $\mathbf{x}^\top \Sigma_c^{-1} \mathbf{x}$ não cancela: as funções discriminantes ficam **quadráticas** em $\mathbf{x}$ e as fronteiras são curvas (parábolas, elipses, hipérbolas). A Figura 1 mostra as quatro fronteiras lado a lado.




Figura 1: Fronteiras de decisão em duas classes gaussianas com covariâncias *diferentes* ($n = 400$). Logística e LDA chegam a retas quase idênticas por caminhos completamente distintos — uma modelando $\mathbb{P}(Y | \mathbf{x})$ direto, a outra modelando $f(\mathbf{x} | Y)$ e invertendo. O QDA, livre da hipótese de covariância comum, curva a fronteira e acompanha o formato de cada nuvem. O Bayes ingênuo também curva, mas erra o ângulo: ele supõe as duas covariáveis independentes dentro de cada classe, e aqui elas não são.

4.3 LDA ou QDA? Uma questão de viés e variância

QDA é mais flexível (menos viés) mas estima muito mais parâmetros. A conta: em p dimensões, LDA estima *uma* matriz de covariância, com $p(p+1)/2$ entradas livres; QDA estima *uma por classe*. Com $p = 10$ e duas classes, são 55 parâmetros contra 110 — e cada um deles precisa de dados.




Figura 2: Acurácia dos dois métodos em função de n , com $p = 10$ covariáveis e covariâncias genuinamente diferentes por classe — ou seja, num cenário em que o **QDA está certo e o LDA está errado**. Ainda assim, com $n = 30$ o LDA ganha (0,748 contra 0,692): não há dados para estimar 110 parâmetros de covariância, e a variância do QDA supera o viés do LDA. A partir de $n = 50$ o jogo vira, e em $n = 4000$ o QDA abre sete pontos percentuais. Médias de 120 repetições, avaliadas em 20 000 observações novas.

Ideia central

Esta figura é a Aula 01 vestida de classificação. O modelo *correto* pode perder para o modelo *errado* quando não há dados suficientes para estimá-lo — exatamente o que o Exemplo 1.7 do [AME] mostrou lá atrás com polinômios de grau 5 e 2. Regra de bolso: LDA com poucos dados ou p grande, QDA com muitos dados. E, como sempre, valide de forma cruzada em vez de decidir por regra de bolso.

5 Discriminativo $\times$ generativo

	Discriminativo (logística)	Generativo (LDA/QDA/NB)
Modela	$\mathbb{P}(Y \mid \mathbf{x})$ direto	$f(\mathbf{x} \mid Y)$ e $\mathbb{P}(Y)$
Suposições	poucas (forma do <i>log-odds</i>)	distribucionais (gaussiana, indep.)
Quando brilha	muitos dados; suposições gaussianas falsas	classes bem separadas; poucos dados; suposições corretas
Bônus	—	gera dados; lida com classes raras

Ideia central

Se as suposições gaussianas valem, LDA/QDA são (quase) ótimos e eficientes com poucos dados. Se não valem, a logística — que assume menos — tende a ser mais robusta com bastante dado. Um detalhe curioso fecha o círculo: sob as hipóteses do LDA, o *log-odds* sai **exatamente** linear em $\mathbf{x}$ (Prop. 4.1), que é justamente o que a logística (2) supõe. Os dois modelos coincidem em forma e diferem só em como estimam os coeficientes — o que explica os dois primeiros painéis da Figura 1. Na dúvida: experimente ambos e compare por validação cruzada.

6 Prática em Python

```

1 from sklearn.linear_model import LogisticRegression
2 from sklearn.discriminant_analysis import (LinearDiscriminantAnalysis as LDA,
3                                             QuadraticDiscriminantAnalysis as QDA)
4 from sklearn.naive_bayes import GaussianNB
5 from sklearn.pipeline import make_pipeline
6 from sklearn.preprocessing import StandardScaler
7
8 # Logística penalizada ( $C = 1/\text{lambda}$ ); padronizar no pipeline (Aula 06)
9 logit = make_pipeline(StandardScaler(),
10                       LogisticRegression(penalty="l2", C=1.0, max_iter=1000))
11
12 lda, qda, nb = LDA(), QDA(), GaussianNB()
13 for nome, modelo in [("logit", logit), ("LDA", lda), ("QDA", qda), ("NB", nb)]:
14     modelo.fit(X_tr, y_tr)
15     print(nome, "acuracia:", modelo.score(X_te, y_te))
16     # probabilidades plug-in: modelo.predict_proba(X_te)

```

Atenção

Duas pegadinhas. Primeira: em `LogisticRegression`, o parâmetro é o `C`, que é o **inverso** da penalização — *C pequeno* significa regularização *forte*, ao contrário do `alpha` do Ridge/Lasso. Segunda: `modelo.score` devolve *acurácia*, e a caixa de atenção lá do começo desta aula explica por que isso pode ser uma medida péssima. Leia a Aula 08 antes de tirar conclusões dessas quatro linhas.

O notebook `Comparação entre classificadores paramétricos` confronta esses métodos; `Aula prática 07` calcula o erro de Bayes numa população conhecida e mede a troca LDA $\times$ QDA em $p = 2$ e $p = 10$.

Resumo

- Perda 0–1 (1); o **classificador de Bayes** $g^*(\mathbf{x}) = \arg \max_c \mathbb{P}(Y = c \mid \mathbf{x})$ é ótimo (Teo. 1.1) mas desconhecido — é a moda condicional, como r era a média condicional.
- *Plug-in*: estimar $\mathbb{P}(Y = c \mid \mathbf{x})$ e tomar o $\arg \max$.
- **Logística** (2): discriminativa, MV, penalizável, multinomial; respeita $[0, 1]$; cuidado com separação perfeita.
- Generativos via Bayes (4): **Bayes ingênuo** (indep. condicional — barata, mas descalibra), **LDA** (covariância comum $\rightarrow$ fronteira linear, Prop. 4.1), **QDA** (covariância por classe $\rightarrow$ quadrática). Ver Fig. 1.
- LDA $\times$ QDA é viés $\times$ variância (Fig. 2): o modelo correto pode perder por falta de dados.
- Cuidado com acurácia em dados desbalanceados $\Rightarrow$ Aula 08.

Leitura recomendada. [AME] Capítulo 7 (risco 0–1 e o classificador de Bayes, com o Teorema 9 que é o nosso Teo. 1.1) e §8.1 (*plug-in*, logística, Bayes ingênuo, LDA/QDA). [ISLP] Capítulo 4: §4.3 (logística, com a interpretação dos coeficientes em razão de chances) e §4.4 (modelos generativos — a Figura 4.9 deles é a versão da nossa Figura 1, e §4.5 compara todos os métodos num cenário simulado, complementando a nossa Figura 2).

Para praticar. `Lista teorica 07.pdf` (teórica, com gabarito) e `Lista prática 07.ipynb` (prática, para completar as lacunas), nesta mesma pasta.