

Aula 07 — Classificação e Classificadores Gaussianos

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §7.1–7.3 e §8.1; ISLP §2.2.3 e §4.4

Objetivos da aula

Ao final desta aula o aluno deve ser capaz de:

- formular o problema de classificação com a *perda 0–1* e derivar o **classificador de Bayes**;
- descrever a estratégia *plug-in*: estimar $\mathbb{P}(Y = c \mid \mathbf{x})$ e classificar pela maior probabilidade;
- estimar essa probabilidade pelo Teorema de Bayes: **Bayes ingênuo** (contínuo e discreto), **LDA** e **QDA**;
- entender por que LDA tem fronteira *linear* e QDA *quadrática*;
- escolher entre LDA e QDA pelo balanço viés–variância.

Em sala

Início do Bloco II. A boa notícia: *quase tudo* da Parte I se transfere — risco, viés–variância, validação cruzada. A mudança é que Y agora é *qualitativo* e a perda natural não é a quadrática, mas a 0–1. Pergunta de abertura: “qual é o melhor classificador possível, se eu conhecesse a distribuição dos dados?”

1 O problema de classificação

Agora Y assume valores num conjunto finito de **classes** $\mathcal{C}$ (ex.: $\mathcal{C} = \{0, 1\}$ no caso binário). Um **classificador** é uma função $g : \mathbb{R}^p \rightarrow \mathcal{C}$. A perda quadrática não serve: não há $Y - g(\mathbf{X})$ entre rótulos, e codificar as classes por números impõe uma ordem que não existe. Só há acerto e erro, e a perda natural é a **perda 0–1**, $L(y, g(\mathbf{x})) = \mathbf{1}\{y \neq g(\mathbf{x})\}$. O risco é a *probabilidade de erro*:

$$R(g) = \mathbb{E}[\mathbf{1}\{Y \neq g(\mathbf{X})\}] = \mathbb{P}(Y \neq g(\mathbf{X})). \quad (1)$$

Em sala

Antes de escrever a perda 0–1, pergunte: “por que não usar $(Y - g(\mathbf{X}))^2$?” Com três classes codificadas como 1, 2 e 3, confundir a 1 com a 3 custaria quatro vezes mais que confundi-la com a 2. Deixe a turma chegar a que só existem acerto e erro — e a perda que registra isso é a indicadora do erro.

Teorema 1.1 (Classificador de Bayes). *Sob a perda 0–1, o classificador que minimiza (1) é*

$$g^*(\mathbf{x}) = \arg \max_{c \in \mathcal{C}} \mathbb{P}(Y = c \mid \mathbf{X} = \mathbf{x}).$$

No caso binário $\mathcal{C} = \{0, 1\}$: $g^*(\mathbf{x}) = 1 \iff \mathbb{P}(Y = 1 \mid \mathbf{x}) \geq \frac{1}{2}$.

Demonstração. (Caso binário, classes c_1, c_2 .) Condicionando em $\mathbf{X}$,

$$R(g) = \mathbb{P}(Y \neq g(\mathbf{X})) = \int [\mathbf{1}\{g(\mathbf{x}) = c_2\} \mathbb{P}(Y = c_1 | \mathbf{x}) + \mathbf{1}\{g(\mathbf{x}) = c_1\} \mathbb{P}(Y = c_2 | \mathbf{x})] f(\mathbf{x}) d\mathbf{x}.$$

Para cada $\mathbf{x}$, o integrando é minimizado escolhendo $g(\mathbf{x}) = c_1$ quando $\mathbb{P}(Y = c_1 | \mathbf{x}) \geq \mathbb{P}(Y = c_2 | \mathbf{x})$ e $g(\mathbf{x}) = c_2$ caso contrário — isto é, a classe de maior probabilidade a posteriori. Como cada $\mathbf{x}$ é otimizado pontualmente, o classificador resultante minimiza o risco global. $\square$

Ideia central

O classificador de Bayes g^* é o “oráculo”: nenhum classificador faz melhor. Seu risco R^* é o análogo do *erro irreduzível* da regressão (Aula 01). Mas g^* é *desconhecido*, pois depende de $\mathbb{P}(Y = c | \mathbf{x})$. Todo método de classificação é uma tentativa de *aproximá-lo*.

Observação 1.2 (O que se transfere da Parte I). A estimação do risco (1) é feita por *data splitting*/validação cruzada (Aula 03), agora medindo a *proporção de erros* na validação. O balanço viés-variância também vale: $R(g) - R^*$ decompõe-se num termo tipo variância (classe $\mathcal{G}$ grande demais) e num termo tipo viés (classe pequena demais). E, como em regressão, compare *poucos* modelos no teste — faça o *tuning* por CV dentro do treino (a probabilidade de escolher errado cresce com o número de modelos comparados, via Hoeffding + união).

Atenção

A acurácia ($1 - \text{risco } 0-1$) pode **enganar** em dados desbalanceados: com 10 doentes em 1000, o classificador trivial “todos saudáveis” acerta 99% — e é inútil. Precisaremos de outras métricas (matriz de confusão, sensibilidade, precisão) — tema da Aula 08.

2 Classificadores *plug-in*

O Teorema 1.1 sugere uma receita direta, dita *plug-in*:

1. estime $\hat{\mathbb{P}}(Y = c | \mathbf{x})$ para cada classe $c \in \mathcal{C}$;
2. classifique $\hat{g}(\mathbf{x}) = \arg \max_{c \in \mathcal{C}} \hat{\mathbb{P}}(Y = c | \mathbf{x})$.

Os métodos diferem em *como* estimam $\mathbb{P}(Y = c | \mathbf{x})$ — a regressão logística, por exemplo, a modela diretamente. Esta aula desenvolve os que partem do **Teorema de Bayes**:

$$\mathbb{P}(Y = c | \mathbf{x}) = \frac{f(\mathbf{x} | Y = c) \mathbb{P}(Y = c)}{\sum_{s \in \mathcal{C}} f(\mathbf{x} | Y = s) \mathbb{P}(Y = s)}. \quad (2)$$

Estima-se $\mathbb{P}(Y = c)$ pelas *proporções amostrais* e $f(\mathbf{x} | Y = c)$ por algum modelo; como o denominador não depende de c , basta maximizar o numerador. Os métodos abaixo se distinguem pelo modelo de $f(\mathbf{x} | Y = c)$.

3 Bayes ingênuo

Supõe **independência condicional** das covariáveis dada a classe:

$$f(\mathbf{x} | Y = c) = \prod_{j=1}^p f(x_j | Y = c). \quad (3)$$

A suposição quase nunca é literalmente verdadeira, mas é *conveniente* (troca uma densidade em $\mathbb{R}^p$ por p densidades em $\mathbb{R}$) e frequentemente gera bons classificadores. Cada $f(x_j | Y = c)$

pode ser qualquer modelo univariado, estimado só com as observações da classe c — paramétrico ou não. Para covariáveis contínuas, o mais comum é $X_j | Y = c \sim N(\mu_{j,c}, \sigma_{j,c}^2)$, com média e variância amostrais por classe e por covariável (**GaussianNB**). Para discretas, a fatoração vale com probabilidades, estimadas por proporções dentro de cada classe: **BernoulliNB** (binárias), **CategoricalNB** (categóricas), **MultinomialNB** e **ComplementNB** (contagens, como palavras num texto — ponte com a Aula extra E3).

Em sala

Pergunte: “que modelo você usaria para X_j se ela fosse um tempo de espera? Uma contagem? Uma variável binária?” O ponto é que o Bayes ingênuo não é só gaussiano: escolher cada $f(x_j | Y = c)$ é inferência univariada, e vale olhar os histogramas por classe antes de escolher.

Atenção

Numericamente, o produto (3) de muitos termos pequenos sofre *underflow* (vira 0). Trabalhe sempre em **escala logarítmica**: $\hat{g}(\mathbf{x}) = \arg \max_c [\sum_j \log \hat{f}(x_j | Y = c) + \log \hat{\mathbb{P}}(Y = c)]$.

4 Análise discriminante: LDA e QDA

Aqui modela-se o vetor inteiro como **gaussiano multivariado**: $\mathbf{X} | Y = c \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)$, com densidade

$$f(\mathbf{x} | Y = c) = \frac{1}{\sqrt{(2\pi)^p \det \boldsymbol{\Sigma}_c}} \exp \left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_c)^\top \boldsymbol{\Sigma}_c^{-1}(\mathbf{x} - \boldsymbol{\mu}_c) \right).$$

A distinção:

- **QDA** (*Quadratic Discriminant Analysis*): cada classe tem sua própria covariância $\boldsymbol{\Sigma}_c$.
- **LDA** (*Linear Discriminant Analysis*): supõe covariância *comum* $\boldsymbol{\Sigma}_c = \boldsymbol{\Sigma}$ para todas as classes.

Parâmetros por máxima verossimilhança: $\hat{\boldsymbol{\mu}}_c$ é a média da classe c ; no QDA, $\hat{\boldsymbol{\Sigma}}_c$ é a covariância amostral da classe c (divisor $|\mathcal{C}_c|$); no LDA, $\hat{\boldsymbol{\Sigma}}$ reúne as dispersões de todas as classes em torno das próprias médias, com divisor n .

Proposição 4.1 (LDA tem fronteira linear). *Sob $\mathbf{X} | Y = c \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma})$ (covariância comum), o classificador de Bayes (2) equivale a $\hat{g}(\mathbf{x}) = \arg \max_c \delta_c(\mathbf{x})$, com a função discriminante linear*

$$\delta_c(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_c - \frac{1}{2} \boldsymbol{\mu}_c^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_c + \log \mathbb{P}(Y = c).$$

As fronteiras entre classes $\{\mathbf{x} : \delta_c(\mathbf{x}) = \delta_{c'}(\mathbf{x})\}$ são **hiperplanos**.

Demonstração. Classificar por $\arg \max_c \mathbb{P}(Y = c | \mathbf{x})$ equivale a $\arg \max_c \log(f(\mathbf{x} | Y = c) \mathbb{P}(Y = c))$ (o denominador de (2) não depende de c). Com a densidade gaussiana, $\log f(\mathbf{x} | Y = c) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_c)^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_c) + \text{const.}$ Expandindo o quadrado, o termo $\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x}$ é igual para todas as classes (pois $\boldsymbol{\Sigma}$ é comum) e pode ser descartado do $\arg \max$. Sobram exatamente os termos lineares em $\mathbf{x}$ de $\delta_c(\mathbf{x})$. A diferença $\delta_c - \delta_{c'}$ é afim em $\mathbf{x}$, logo cada fronteira é um hiperplano. $\square$

Observação 4.2. Em QDA, $\boldsymbol{\Sigma}_c$ varia com c , então $\mathbf{x}^\top \boldsymbol{\Sigma}_c^{-1} \mathbf{x}$ e $\log \det \boldsymbol{\Sigma}_c$ não cancelam:

$$\delta_c(\mathbf{x}) = -\frac{1}{2} \mathbf{x}^\top \boldsymbol{\Sigma}_c^{-1} \mathbf{x} + \mathbf{x}^\top \boldsymbol{\Sigma}_c^{-1} \boldsymbol{\mu}_c - \frac{1}{2} \boldsymbol{\mu}_c^\top \boldsymbol{\Sigma}_c^{-1} \boldsymbol{\mu}_c - \frac{1}{2} \log \det \boldsymbol{\Sigma}_c + \log \mathbb{P}(Y = c)$$

é **quadrática** em $\mathbf{x}$, e as fronteiras são superfícies quádricas.

4.1 LDA ou QDA?

Com K classes em $\mathbb{R}^p$, o LDA estima $Kp + p(p+1)/2$ parâmetros (médias e uma covariância); o QDA, $Kp + Kp(p+1)/2$ (uma covariância por classe). Trade-off viés-variância (Aula 01): QDA é mais flexível (menos viés), mas estima muito mais parâmetros (mais variância). Prefira LDA com poucas amostras de treino; QDA com muitas, ou quando a hipótese de covariância comum for inverossímil.

Em sala

Faça a conta com a turma para $p = 10$ e duas classes: 55 parâmetros de covariância no LDA, 110 no QDA. Pergunte: “com $n = 20$, dez observações por classe, o QDA consegue sequer estimar Σ_c ?” Não: a covariância amostral de dez pontos em $\mathbb{R}^{10}$ tem posto no máximo 9 e não é invertível — e o `scikit-learn` recusa o ajuste. A Aula prática 07 mostra isso na tabela do §6.

5 Prática em Python

```

1 from sklearn.discriminant_analysis import (LinearDiscriminantAnalysis as LDA,
2                                             QuadraticDiscriminantAnalysis as QDA)
3 from sklearn.naive_bayes import GaussianNB
4
5 for nome, modelo in [("NB", GaussianNB()), ("LDA", LDA()), ("QDA", QDA())]:
6     modelo.fit(X_tr, y_tr)
7     print(nome, "acurácia:", modelo.score(X_te, y_te))
8     # probabilidades plug-in: modelo.predict_proba(X_te)

```

O notebook *Comparação entre classificadores paramétricos* confronta esses métodos; Aula prática 07 calcula o erro de Bayes numa população conhecida e mede a troca LDA×QDA em $p = 2$ e $p = 10$.

Resumo

- Perda 0–1 (1); o **classificador de Bayes** $g^*(\mathbf{x}) = \arg \max_c \mathbb{P}(Y = c \mid \mathbf{x})$ é ótimo (Teo. 1.1) mas desconhecido.
- *Plug-in*: estimar $\mathbb{P}(Y = c \mid \mathbf{x})$ e tomar o $\arg \max$; aqui, pelo Teorema de Bayes (2).
- **Bayes ingênuo**: independência condicional (3), com um modelo univariado por covariável, contínua ou discreta.
- **LDA** (covariância comum $\rightarrow$ fronteira linear, Prop. 4.1) e **QDA** (covariância por classe $\rightarrow$ quadrática), com parâmetros por máxima verossimilhança.
- LDA $\times$ QDA é viés $\times$ variância: a conta de parâmetros decide com poucos dados.
- Cuidado com acurácia em dados desbalanceados $\Rightarrow$ Aula 08.

Leitura recomendada. [AME] §7.1 (risco 0–1, classificador de Bayes, Teorema 9), §7.2–7.3 e §8.1 (*plug-in*, com Bayes ingênuo em §8.1.3 e LDA/QDA em §8.1.4; as densidades normais de lá omitem o $\frac{1}{2}$ do expoente); [ISLP] §2.2.3 (classificador de Bayes) e §4.4 (modelos generativos).