Aula 07 — Classificação e Classificadores Gaussianos

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §7.1–7.3 e §8.1; ISLP §2.2.3, §4.3 e §4.4

Objetivos da aula

Ao final desta aula o aluno deve ser capaz de:

- formular o problema de classificação com a *perda 0–1* e derivar o **classificador de Bayes**;
- descrever a estratégia *plug-in*: estimar $\mathbb{P}(Y = c \mid \boldsymbol{x})$ e classificar pela maior probabilidade;
- estimar essa probabilidade pelo Teorema de Bayes: **Bayes ingênuo** (contínuo e discreto), **LDA** e **QDA**;
- entender por que LDA tem fronteira *linear* e QDA *quadrática*;
- escolher entre LDA e QDA pelo balanço viés–variância;
- estimá-la diretamente com uma **regressão logística**, ajustada por máxima verossimilhança, e reconhecer sua versão penalizada/multiclasse;
- contrastar abordagens *generativas* e *discriminativas*.

Em sala

Início da classificação. A boa notícia: *quase tudo* o que vimos em regressão se transfere — risco, viés–variância, validação cruzada. A mudança é que Y agora é *qualitativo* e a perda natural não é a quadrática, mas a 0–1. Pergunta de abertura: *"qual é o melhor classificador possível, se eu conhecesse a distribuição dos dados?"*

1 O problema de classificação

Agora Y assume valores num conjunto finito de **classes** $\mathcal{C}$ (ex.: $\mathcal{C} = \{0, 1\}$ no caso binário). Um **classificador** é uma função $g : \mathbb{R}^p \to \mathcal{C}$. A perda quadrática não serve: não há $Y - g(\boldsymbol{X})$ entre rótulos, e codificar as classes por números impõe uma ordem que não existe. Só há acerto e erro, e a perda natural é a **perda 0–1**, $L(y, g(\boldsymbol{x})) = \mathbf{1}\{y \neq g(\boldsymbol{x})\}$. O risco é a *probabilidade de erro*:

$$R(g) = \mathbb{E}\big[\mathbf{1}\{Y \neq g(\boldsymbol{X})\}\big] = \mathbb{P}(Y \neq g(\boldsymbol{X})). \tag{1}$$

Em sala

Antes de escrever a perda 0–1, pergunte: *"por que não usar* $(Y - g(\boldsymbol{X}))^2$*?"* Com três classes codificadas como 1, 2 e 3, confundir a 1 com a 3 custaria quatro vezes mais que confundi-la com a 2. Deixe a turma chegar a que só existem acerto e erro — e a perda que registra isso é a indicadora do erro.

Teorema 1.1 (Classificador de Bayes)**.** *Sob a perda 0–1, o classificador que minimiza (1) é*

$$g^*(\boldsymbol{x}) = \arg\max_{c \in \mathcal{C}} \ \mathbb{P}(Y = c \mid \boldsymbol{X} = \boldsymbol{x}).$$

No caso binário $\mathcal{C} = \{0, 1\}$*:* $g^*(\boldsymbol{x}) = 1 \iff \mathbb{P}(Y = 1 \mid \boldsymbol{x}) \geq \frac{1}{2}$.

Demonstração. (Caso binário, classes c_1, c_2.) Condicionando em $\boldsymbol{X}$,

$$R(g) = \mathbb{P}(Y \neq g(\boldsymbol{X})) = \int \left[\mathbf{1}\{g(\boldsymbol{x}) = c_2\}\, \mathbb{P}(Y = c_1 \mid \boldsymbol{x}) + \mathbf{1}\{g(\boldsymbol{x}) = c_1\}\, \mathbb{P}(Y = c_2 \mid \boldsymbol{x})\right] f(\boldsymbol{x})\, d\boldsymbol{x}.$$

Para *cada* $\boldsymbol{x}$, o integrando é minimizado escolhendo $g(\boldsymbol{x}) = c_1$ quando $\mathbb{P}(Y = c_1 \mid \boldsymbol{x}) \geq \mathbb{P}(Y = c_2 \mid \boldsymbol{x})$ e $g(\boldsymbol{x}) = c_2$ caso contrário — isto é, a classe de maior probabilidade a posteriori. Como cada $\boldsymbol{x}$ é otimizado pontualmente, o classificador resultante minimiza o risco global. □

Ideia central

O classificador de Bayes g^* é o "oráculo": nenhum classificador faz melhor. Seu risco R^* é o análogo do *erro irredutível* da regressão (Aula 01). Mas g^* é *desconhecido*, pois depende de $\mathbb{P}(Y = c \mid \boldsymbol{x})$. Todo método de classificação é uma tentativa de *aproximá-lo*.

Observação 1.2 (O que se transfere da regressão)**.** A estimação do risco (1) é feita por *data splitting*/validação cruzada (Aula 03), agora medindo a *proporção de erros* na validação. O balanço viés–variância também vale: $R(g) - R^*$ decompõe-se num termo tipo variância (classe $\mathcal{G}$ grande demais) e num termo tipo viés (classe pequena demais). E, como em regressão, compare *poucos* modelos no teste — faça o *tuning* por CV dentro do treino (a probabilidade de escolher errado cresce com o número de modelos comparados, via Hoeffding + união).

Atenção

A acurácia (1 − risco 0–1) pode **enganar** em dados desbalanceados: com 10 doentes em 1000, o classificador trivial "todos saudáveis" acerta 99% — e é inútil. Precisaremos de outras métricas (matriz de confusão, sensibilidade, especificidade) — tema da Aula 08.

2 Classificadores *plug-in*

O Teorema 1.1 sugere uma receita direta, dita ***plug-in***:

1. estime $\widehat{\mathbb{P}}(Y = c \mid \boldsymbol{x})$ para cada classe $c \in \mathcal{C}$;
2. classifique $\widehat{g}(\boldsymbol{x}) = \arg\max_{c \in \mathcal{C}} \widehat{\mathbb{P}}(Y = c \mid \boldsymbol{x})$.

Os métodos diferem em *como* estimam $\mathbb{P}(Y = c \mid \boldsymbol{x})$. Há duas grandes famílias:

Generativos modelam $f(\boldsymbol{x} \mid Y = c)$ e $\mathbb{P}(Y = c)$ e invertem com o Teorema de Bayes (Bayes ingênuo, LDA, QDA).

Discriminativos modelam $\mathbb{P}(Y = c \mid \boldsymbol{x})$ *diretamente* (regressão logística).

3 Modelos generativos: o Teorema de Bayes

A primeira família modela como os dados de cada classe são gerados, e inverte:

$$\mathbb{P}(Y = c \mid \boldsymbol{x}) = \frac{f(\boldsymbol{x} \mid Y = c)\, \mathbb{P}(Y = c)}{\sum_{s \in \mathcal{C}} f(\boldsymbol{x} \mid Y = s)\, \mathbb{P}(Y = s)}. \tag{2}$$

Estima-se $\mathbb{P}(Y = c)$ pelas *proporções amostrais* e $f(\boldsymbol{x} \mid Y = c)$ por algum modelo; como o denominador não depende de c, basta maximizar o numerador. Os métodos abaixo se distinguem pelo modelo de $f(\boldsymbol{x} \mid Y = c)$.

4 Bayes ingênuo

Supõe **independência condicional** das covariáveis dada a classe:

$$f(\boldsymbol{x} \mid Y = c) = \prod_{j=1}^{p} f(x_j \mid Y = c). \tag{3}$$

A suposição quase nunca é literalmente verdadeira, mas é *conveniente* (troca uma densidade em $\mathbb{R}^p$ por p densidades em $\mathbb{R}$) e frequentemente gera bons classificadores. Cada $f(x_j \mid Y = c)$ pode ser qualquer modelo univariado, estimado só com as observações da classe c — paramétrico ou não. Para covariáveis contínuas, o mais comum é $X_j \mid Y = c \sim N(\mu_{j,c}, \sigma^2_{j,c})$, com média e variância amostrais por classe e por covariável (`GaussianNB`). Para discretas, a fatoração vale com probabilidades, estimadas por proporções dentro de cada classe: `BernoulliNB` (binárias), `CategoricalNB` (categóricas), `MultinomialNB` e `ComplementNB` (contagens, como palavras num texto — ponte com a Aula extra E3).

Em sala

Pergunte: *"que modelo você usaria para X_j se ela fosse um tempo de espera? Uma contagem? Uma variável binária?"* O ponto é que o Bayes ingênuo não é só gaussiano: escolher cada $f(x_j \mid Y = c)$ é inferência univariada, e vale olhar os histogramas por classe antes de escolher.

Atenção

Numericamente, o produto (3) de muitos termos pequenos sofre *underflow* (vira 0). Trabalhe sempre em **escala logarítmica**: $\widehat{g}(\boldsymbol{x}) = \arg\max_c \left[\sum_j \log \widehat{f}(x_j \mid Y = c) + \log \widehat{\mathbb{P}}(Y = c) \right]$.

5 Análise discriminante: LDA e QDA

Aqui modela-se o vetor inteiro como **gaussiano multivariado**: $\boldsymbol{X} \mid Y = c \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)$, com densidade

$$f(\boldsymbol{x} \mid Y = c) = \frac{1}{\sqrt{(2\pi)^p \det \boldsymbol{\Sigma}_c}} \exp\Big(-\tfrac{1}{2} (\boldsymbol{x} - \boldsymbol{\mu}_c)^\top \boldsymbol{\Sigma}_c^{-1} (\boldsymbol{x} - \boldsymbol{\mu}_c) \Big).$$

A distinção:

- **QDA** (*Quadratic Discriminant Analysis*): cada classe tem sua própria covariância $\boldsymbol{\Sigma}_c$.
- **LDA** (*Linear Discriminant Analysis*): supõe covariância *comum* $\boldsymbol{\Sigma}_c = \boldsymbol{\Sigma}$ para todas as classes.

Parâmetros por máxima verossimilhança: $\widehat{\boldsymbol{\mu}}_c$ é a média da classe c; no QDA, $\widehat{\boldsymbol{\Sigma}}_c$ é a covariância amostral da classe c (divisor $|\mathcal{C}_c|$); no LDA, $\widehat{\boldsymbol{\Sigma}}$ reúne as dispersões de todas as classes em torno das próprias médias, com divisor n.

Proposição 5.1 (LDA tem fronteira linear)**.** *Sob $\boldsymbol{X} \mid Y = c \sim N(\boldsymbol{\mu}_c, \boldsymbol{\Sigma})$ (covariância comum), o classificador de Bayes (2) equivale a $\widehat{g}(\boldsymbol{x}) = \arg\max_c \delta_c(\boldsymbol{x})$, com a* função discriminante linear

$$\delta_c(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_c - \tfrac{1}{2} \boldsymbol{\mu}_c^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_c + \log \mathbb{P}(Y = c).$$

*As fronteiras entre classes $\{\boldsymbol{x} : \delta_c(\boldsymbol{x}) = \delta_{c'}(\boldsymbol{x})\}$ são **hiperplanos**.*

Demonstração. Classificar por $\arg\max_c \mathbb{P}(Y=c \mid \boldsymbol{x})$ equivale a $\arg\max_c \log\big(f(\boldsymbol{x} \mid Y=c)\mathbb{P}(Y=c)\big)$ (o denominador de (2) não depende de c). Com a densidade gaussiana, $\log f(\boldsymbol{x} \mid Y=c) = -\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_c)^\top \boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_c) + \text{const}$. Expandindo o quadrado, o termo $\boldsymbol{x}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{x}$ é *igual para todas as classes* (pois $\boldsymbol{\Sigma}$ é comum) e pode ser descartado do arg max. Sobram exatamente os termos lineares em $\boldsymbol{x}$ de $\delta_c(\boldsymbol{x})$. A diferença $\delta_c - \delta_{c'}$ é afim em $\boldsymbol{x}$, logo cada fronteira é um hiperplano. □

Observação 5.2. Em QDA, $\boldsymbol{\Sigma}_c$ varia com c, então $\boldsymbol{x}^\top\boldsymbol{\Sigma}_c^{-1}\boldsymbol{x}$ e $\log\det\boldsymbol{\Sigma}_c$ *não* cancelam:

$$\delta_c(\boldsymbol{x}) = -\tfrac{1}{2}\,\boldsymbol{x}^\top\boldsymbol{\Sigma}_c^{-1}\boldsymbol{x} + \boldsymbol{x}^\top\boldsymbol{\Sigma}_c^{-1}\boldsymbol{\mu}_c - \tfrac{1}{2}\boldsymbol{\mu}_c^\top\boldsymbol{\Sigma}_c^{-1}\boldsymbol{\mu}_c - \tfrac{1}{2}\log\det\boldsymbol{\Sigma}_c + \log\mathbb{P}(Y=c)$$

é **quadrática** em $\boldsymbol{x}$, e as fronteiras são superfícies quádricas.

5.1 LDA ou QDA?

Com K classes em $\mathbb{R}^p$, o LDA estima $Kp + p(p+1)/2$ parâmetros (médias e uma covariância); o QDA, $Kp + Kp(p+1)/2$ (uma covariância por classe). Trade-off viés–variância (Aula 01): QDA é mais flexível (menos viés), mas estima muito mais parâmetros (mais variância). Prefira LDA com poucas amostras de treino; QDA com muitas, ou quando a hipótese de covariância comum for inverossímil.

Em sala

Faça a conta com a turma para $p = 10$ e duas classes: 55 parâmetros de covariância no LDA, 110 no QDA. Pergunte: *"com $n = 20$, dez observações por classe, o QDA consegue sequer estimar $\boldsymbol{\Sigma}_c$?"* Não: a covariância amostral de dez pontos em $\mathbb{R}^{10}$ tem posto no máximo 9 e não é invertível — e o `scikit-learn` recusa o ajuste. A `Aula prática 07` mostra a recusa, com a mensagem de erro, no §6.

6 Regressão logística (discriminativo)

Os três métodos anteriores chegam a $\mathbb{P}(Y=c \mid \boldsymbol{x})$ pelo Teorema de Bayes; a regressão logística, principal representante da família discriminativa, vai direto a ela. No caso binário $\mathcal{C} = \{0,1\}$, a regressão logística modela

$$\mathbb{P}(Y=1 \mid \boldsymbol{x}) = \frac{e^{\beta_0+\sum_{i=1}^p \beta_i x_i}}{1+e^{\beta_0+\sum_{i=1}^p \beta_i x_i}} = \sigma(\beta_0 + \boldsymbol{\beta}^\top\boldsymbol{x}), \tag{4}$$

onde $\sigma(u) = e^u/(1+e^u)$ é a função logística. Equivalentemente, o *log-odds* é linear: $\log\frac{\mathbb{P}(Y=1|\boldsymbol{x})}{\mathbb{P}(Y=0|\boldsymbol{x})} = \beta_0 + \boldsymbol{\beta}^\top\boldsymbol{x}$ — e a fronteira de decisão, onde ele se anula, é um hiperplano, como no LDA. Como em regressão, *não* supomos que isso seja exatamente verdade — esperamos que leve a um bom classificador.

Em sala

Pergunte: *"por que não modelar $\mathbb{P}(Y=1 \mid \boldsymbol{x})$ com uma reta?"* Porque a reta sai de $[0,1]$. A σ resolve isso, e de quebra dá a interpretação que todo mundo usa: aumentar x_j em uma unidade multiplica a razão de chances por e^{β_j}, qualquer que seja o ponto de partida.

6.1 Estimação por máxima verossimilhança

Dada uma amostra i.i.d., a verossimilhança condicional é

$$L(\boldsymbol{\beta}) = \prod_{k=1}^{n} \pi(\boldsymbol{x}_k)^{Y_k}\big(1-\pi(\boldsymbol{x}_k)\big)^{1-Y_k}, \qquad \pi(\boldsymbol{x}_k) = \mathbb{P}(Y_k=1 \mid \boldsymbol{x}_k, \boldsymbol{\beta}). \tag{5}$$

Maximiza-se o log da verossimilhança (5). Ao contrário do MQO, não há solução fechada: usam-se métodos numéricos (Newton–Raphson / IRLS). Como na regressão linear, pode-se **penalizar** (ℓ_1/ℓ_2) para reduzir variância — e, com separação perfeita no treino, a penalização deixa de ser opção: sem ela a verossimilhança não tem máximo e os coeficientes explodem. É por isso que o `scikit-learn` aplica ℓ_2 por padrão.

6.2 Mais de duas classes

Para $|\mathcal{C}| > 2$: ou ajusta-se uma logística *um-contra-todos* por classe (e normaliza-se), ou usa-se a **regressão logística multinomial** (*softmax*), que garante que as probabilidades estimadas somem 1.

7 Discriminativo × generativo

	Discriminativo (logística)	**Generativo (LDA/QDA/NB)**
Modela	$\mathbb{P}(Y \mid \boldsymbol{x})$ direto	$f(\boldsymbol{x} \mid Y)$ e $\mathbb{P}(Y)$
Suposições	poucas (forma do *log-odds*)	distribucionais (gaussiana, indep.)
Quando brilha	muitos dados; suposições gaussianas falsas	classes bem separadas; poucos dados; suposições aproximadamente corretas
Bônus	—	gera dados; lida com classes raras

Ideia central

Se as suposições gaussianas valem, LDA/QDA são (quase) ótimos e eficientes com poucos dados. Se não valem, a logística — que assume menos — tende a ser mais robusta com bastante dado. E sob as hipóteses do LDA o *log-odds* sai exatamente linear (Prop. 5.1), que é o que a logística (4) supõe: os dois coincidem em forma e diferem em como estimam. Na dúvida: experimente ambos e compare por validação cruzada.

Resumo

- Perda 0–1 (1); o **classificador de Bayes** $g^*(\boldsymbol{x}) = \arg\max_c \mathbb{P}(Y = c \mid \boldsymbol{x})$ é ótimo (Teo. 1.1) mas desconhecido.
- *Plug-in*: estimar $\mathbb{P}(Y = c \mid \boldsymbol{x})$ e tomar o arg max — pelo Teorema de Bayes (2) (generativo) ou direto (discriminativo).
- **Bayes ingênuo**: independência condicional (3), com um modelo univariado por covariável, contínua ou discreta.
- **LDA** (covariância comum → fronteira linear, Prop. 5.1) e **QDA** (covariância por classe → quadrática), com parâmetros por máxima verossimilhança.
- LDA × QDA é viés × variância: a conta de parâmetros decide com poucos dados.
- **Logística** (4): discriminativa, MV, penalizável, multiclasse; respeita $[0, 1]$.
- Cuidado com acurácia em dados desbalanceados ⇒ Aula 08.

Leitura recomendada. [AME] §7.1 (risco 0–1, classificador de Bayes, Teorema 9), §7.2–7.3 e §8.1 (*plug-in*, com a logística em §8.1.2, o Bayes ingênuo em §8.1.3 e LDA/QDA em §8.1.4; as densidades normais de lá omitem o $\frac{1}{2}$ do expoente); [ISLP] §2.2.3 (classificador de Bayes), §4.3 (logística) e §4.4 (modelos generativos).