

Lista Teórica 07 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 07 — Classificação e Classificadores Gaussianos

Exercício 1 — o classificador de Bayes, em uma dimensão. Seja $Y \in \{0, 1\}$ e, condicionalmente a Y ,

$$X \mid Y = 0 \sim N(-1, 1), \quad X \mid Y = 1 \sim N(+1, 1).$$

- (a) Com $\mathbb{P}(Y = 1) = \mathbb{P}(Y = 0) = 1/2$, mostre que o classificador de Bayes decide por $Y = 1$ quando $x > 0$.
- (b) Calcule o **erro de Bayes** nesse caso, em função de Φ (a função de distribuição acumulada da normal padrão), e dê o valor numérico. *Dado:* $\Phi(-1) = 0,1587$.
- (c) Agora suponha $\mathbb{P}(Y = 1) = 0,1$. Mostre que o corte passa a ser $x^* = \frac{1}{2} \ln 9 \approx 1,0986$, e calcule o novo erro de Bayes. *Dados:* $\Phi(-2,0986) = 0,0179$ e $\Phi(0,0986) = 0,5393$.
- (d) Compare o resultado de (c) com o erro do classificador que responde sempre $Y = 0$. O que isso antecipa sobre a Aula 08?

Solução

(a) O classificador de Bayes escolhe a classe de maior probabilidade a posteriori. Pelo Teorema de Bayes, com f_0 e f_1 as densidades de X dado $Y = 0$ e dado $Y = 1$ e $\pi_k = \mathbb{P}(Y = k)$,

$$\mathbb{P}(Y = 1 \mid X = x) = \frac{\pi_1 f_1(x)}{\pi_0 f_0(x) + \pi_1 f_1(x)},$$

e o denominador, positivo, é o mesmo para as duas classes. Com duas classes, o classificador de Bayes decide por $Y = 1$ quando $\mathbb{P}(Y = 1 \mid X = x) > \mathbb{P}(Y = 0 \mid X = x)$, isto é, quando $\pi_1 f_1(x) > \pi_0 f_0(x)$. Com $\pi_0 = \pi_1$ as priors cancelam, e as constantes $1/\sqrt{2\pi}$ das duas densidades também; como a exponencial é crescente,

$$\exp\left(-\frac{(x-1)^2}{2}\right) > \exp\left(-\frac{(x+1)^2}{2}\right) \iff -(x-1)^2 > -(x+1)^2 \iff (x+1)^2 > (x-1)^2.$$

Expandindo, $x^2 + 2x + 1 > x^2 - 2x + 1 \iff 4x > 0 \iff x > 0$. O corte é o ponto médio entre as duas médias, como a simetria já sugeria. Em $x = 0$ as duas classes empatam, $\mathbb{P}(Y = 1 \mid X = 0) = \frac{1}{2}$, e qualquer das duas respostas é ótima; como $\mathbb{P}(X = 0) = 0$, a escolha nesse ponto não altera o risco.

(b) O classificador de Bayes é $g^*(x) = \mathbf{1}\{x > 0\}$, e o seu risco é a probabilidade de ele errar. Condicionando em Y (lei da probabilidade total),

$$R^* = \frac{1}{2} \mathbb{P}(X > 0 \mid Y = 0) + \frac{1}{2} \mathbb{P}(X \leq 0 \mid Y = 1).$$

Sob $Y = 0$, $Z = X + 1 \sim N(0, 1)$, então $\mathbb{P}(X > 0 \mid Y = 0) = \mathbb{P}(Z > 1) = 1 - \Phi(1) = \Phi(-1)$. Sob $Y = 1$, $Z = X - 1 \sim N(0, 1)$, e $\mathbb{P}(X \leq 0 \mid Y = 1) = \mathbb{P}(Z \leq -1) = \Phi(-1)$: as duas parcelas são iguais, como a simetria sugeria. Logo

$$R^* = \Phi(-1) = \mathbf{0,1587}.$$

Quase 16% de erro é o *piso*: nenhum classificador, construído com quaisquer dados, tem risco menor. É o análogo em classificação do σ^2 da Aula 01.

(c) Agora as prioris não cancelam. Decidimos por $Y = 1$ quando

$$0,1 \exp\left(-\frac{(x-1)^2}{2}\right) > 0,9 \exp\left(-\frac{(x+1)^2}{2}\right).$$

Tomando logaritmo,

$$\ln 0,1 - \frac{(x-1)^2}{2} > \ln 0,9 - \frac{(x+1)^2}{2} \iff \ln \frac{0,1}{0,9} > \frac{(x-1)^2 - (x+1)^2}{2} = -2x,$$

ou seja $-\ln 9 > -2x$, isto é $x > \frac{1}{2} \ln 9 \approx 1,0986$.

O erro fica

$$R^* = 0,9 \mathbb{P}(X > x^* | Y = 0) + 0,1 \mathbb{P}(X < x^* | Y = 1) = 0,9 \Phi(-2,0986) + 0,1 \Phi(0,0986),$$

usando $\mathbb{P}(X > x^* | Y = 0) = 1 - \Phi(x^* + 1) = \Phi(-x^* - 1)$ e $\mathbb{P}(X < x^* | Y = 1) = \Phi(x^* - 1)$. Numericamente,

$$R^* = 0,9 \times 0,0179 + 0,1 \times 0,5393 = 0,01611 + 0,05393 = \mathbf{0,0700}.$$

(d) O classificador que responde sempre $Y = 0$ erra exatamente $\mathbb{P}(Y = 1) = \mathbf{0,10}$. O classificador de Bayes erra 0,0700 — melhor, mas não muito: a diferença é de 3 pontos percentuais.

E vale olhar de onde vem o erro de Bayes: das duas parcelas, 0,0539 vêm de classificar como 0 observações que eram 1. Ou seja, o classificador ótimo **erra mais da metade dos positivos** ($\mathbb{P}(X < x^* | Y = 1) = 0,5393$) — e ainda assim é ótimo. Mover o corte para a esquerda, de x^* para $t < x^*$, acertaria os positivos que caem em $(t, x^*]$, mas erraria os negativos que caem no mesmo intervalo, e o risco mudaria de

$$\int_t^{x^*} [0,9 f_0(x) - 0,1 f_1(x)] dx > 0,$$

porque à esquerda de x^* vale $0,9 f_0(x) > 0,1 f_1(x)$ — é a própria definição do corte. Acertar mais positivos custaria mais falsos positivos, entre os 90% de negativos, do que os falsos negativos que se evitam.

É exatamente a situação em que a acurácia deixa de ser informativa, e é o assunto da Aula 08. Quando a prevalência é desbalanceada, um número de acurácia próximo do trivial pode esconder tanto o classificador ótimo quanto um inútil.

Exercício 2 — por que a fronteira do LDA é linear. No modelo gaussiano com covariância comum, as K classes têm prioris $\pi_k = \mathbb{P}(Y = k)$ e $\mathbf{X} | Y = k \sim N(\boldsymbol{\mu}_k, \boldsymbol{\Sigma})$, com $\boldsymbol{\Sigma}$ simétrica e positiva definida; f_k é a densidade de $\mathbf{X}$ dado $Y = k$.

- (a) Escreva $\ln(\pi_k f_k(\mathbf{x}))$ e mostre que, ao comparar duas classes, os termos que dependem de $\mathbf{x}$ de forma *quadrática* se cancelam.
- (b) Conclua que o classificador de Bayes decide pela classe que maximiza a *função discriminante linear*

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k + \ln \pi_k.$$

- (c) Em que ponto exato do item (a) a hipótese de covariância comum é usada? O que sobra se cada classe tiver a sua, $\boldsymbol{\Sigma}_k$?
- (d) No caso $p = 1$, $\boldsymbol{\Sigma} = \sigma^2$, $\mu_0 = -1$, $\mu_1 = +1$ e $\pi_0 = \pi_1$, recupere o corte do Exercício 1(a) a partir de $\delta_1(x) = \delta_0(x)$.

Solução

(a) Primeiro, por que olhar para $\ln(\pi_k f_k(\mathbf{x}))$. O classificador de Bayes escolhe o k que maximiza $\mathbb{P}(Y = k \mid \mathbf{X} = \mathbf{x}) = \pi_k f_k(\mathbf{x}) / f(\mathbf{x})$, em que $f(\mathbf{x}) = \sum_s \pi_s f_s(\mathbf{x})$ não depende de k ; como o logaritmo é crescente, maximizar $\pi_k f_k(\mathbf{x})$ ou o seu logaritmo dá a mesma classe. A densidade gaussiana multivariada dá

$$\ln(\pi_k f_k(\mathbf{x})) = \ln \pi_k - \frac{p}{2} \ln(2\pi) - \frac{1}{2} \ln \det \Sigma - \frac{1}{2} (\mathbf{x} - \mu_k)^\top \Sigma^{-1} (\mathbf{x} - \mu_k).$$

Expandindo a forma quadrática, e usando que Σ^{-1} é simétrica — então os dois termos cruzados, $\mathbf{x}^\top \Sigma^{-1} \mu_k$ e $\mu_k^\top \Sigma^{-1} \mathbf{x}$, são o mesmo número —,

$$(\mathbf{x} - \mu_k)^\top \Sigma^{-1} (\mathbf{x} - \mu_k) = \underbrace{\mathbf{x}^\top \Sigma^{-1} \mathbf{x}}_{\text{não depende de } k} - 2 \mathbf{x}^\top \Sigma^{-1} \mu_k + \mu_k^\top \Sigma^{-1} \mu_k.$$

Ao comparar duas classes k e ℓ , subtraímos as duas expressões. Os termos $-\frac{p}{2} \ln(2\pi)$, $-\frac{1}{2} \ln \det \Sigma$ e $-\frac{1}{2} \mathbf{x}^\top \Sigma^{-1} \mathbf{x}$ são **idênticos** nas duas e desaparecem — e é justamente o último deles que era quadrático em $\mathbf{x}$.

(b) Descartando os termos comuns a todas as classes — que somam a mesma quantidade a cada uma e, por isso, não mudam qual delas é a maior —, sobra

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \ln \pi_k,$$

em que o primeiro termo vem de $-\frac{1}{2} \cdot (-2 \mathbf{x}^\top \Sigma^{-1} \mu_k)$. Ela é **afim em $\mathbf{x}$** : um produto interno com o vetor fixo $\Sigma^{-1} \mu_k$, mais uma constante. As classes k e ℓ empatam no conjunto $\{\mathbf{x} : \delta_k(\mathbf{x}) = \delta_\ell(\mathbf{x})\}$, isto é,

$$\mathbf{x}^\top \Sigma^{-1} (\mu_k - \mu_\ell) = \frac{1}{2} (\mu_k^\top \Sigma^{-1} \mu_k - \mu_\ell^\top \Sigma^{-1} \mu_\ell) + \ln \frac{\pi_\ell}{\pi_k},$$

que é um **hiperplano** sempre que $\mu_k \neq \mu_\ell$: como Σ^{-1} é invertível, o vetor normal $\Sigma^{-1} (\mu_k - \mu_\ell)$ só se anula quando as médias coincidem. Com duas classes, esse hiperplano é a fronteira; com mais, a fronteira entre k e ℓ é o pedaço dele em que as duas empatam e superam as demais.

(c) A hipótese é usada exatamente ao afirmar que $\mathbf{x}^\top \Sigma^{-1} \mathbf{x}$ e $\ln \det \Sigma$ *não dependem de k* . Com covariâncias distintas teríamos $\mathbf{x}^\top \Sigma_k^{-1} \mathbf{x}$ e $\ln \det \Sigma_k$, que dependem de k e **não se cancelam**: se $\Sigma_k \neq \Sigma_\ell$, então $\Sigma_k^{-1} \neq \Sigma_\ell^{-1}$, e a diferença $\mathbf{x}^\top (\Sigma_k^{-1} - \Sigma_\ell^{-1}) \mathbf{x}$ não é identicamente nula.

Sobra então

$$\delta_k(\mathbf{x}) = -\frac{1}{2} \mathbf{x}^\top \Sigma_k^{-1} \mathbf{x} + \mathbf{x}^\top \Sigma_k^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma_k^{-1} \mu_k - \frac{1}{2} \ln \det \Sigma_k + \ln \pi_k,$$

que é *quadrática* em $\mathbf{x}$ — é o QDA. A fronteira entre duas classes passa a ser uma quádriga; em $\mathbb{R}^2$, uma cônica (elipse, parábola, hipérbole ou um caso degenerado delas, como um par de retas). Em uma frase: **dentro do modelo gaussiano, o que torna a fronteira linear não é a normalidade, é a covariância comum** — com covariâncias diferentes, as mesmas normais dão fronteira quadrática.

(d) Com $p = 1$, $\Sigma^{-1} = 1/\sigma^2$ e $\pi_0 = \pi_1$ (então $\ln \pi_k$ cancela):

$$\delta_1(x) = \frac{x \cdot 1}{\sigma^2} - \frac{1}{2\sigma^2}, \quad \delta_0(x) = \frac{x \cdot (-1)}{\sigma^2} - \frac{1}{2\sigma^2}.$$

Igualando: $x/\sigma^2 = -x/\sigma^2$, ou seja $2x/\sigma^2 = 0$, isto é $\mathbf{x} = \mathbf{0}$. É o corte do Exercício 1(a), e note que, com prioris iguais, ele *não depende de σ^2* — a variância muda o quanto se erra, não onde fica a fronteira. Com prioris diferentes o $\ln \pi_k$ não cancela, e $\delta_1(x) = \delta_0(x)$ dá $x = \frac{\sigma^2}{2} \ln \frac{\pi_0}{\pi_1}$: aí a variância também desloca o corte. Com $\sigma^2 = 1$, $\pi_0 = 0,9$ e $\pi_1 = 0,1$, é o $x^* = \frac{1}{2} \ln 9$ do Exercício 1(c).

Exercício 3 — quantos parâmetros cada um estima. Considere $K = 2$ classes em $\mathbb{R}^p$.

- (a) Conte os parâmetros livres do LDA e do QDA. Considere: as médias das classes, a(s) matriz(es) de covariância — lembrando que uma matriz simétrica $p \times p$ tem $p(p+1)/2$ entradas livres — e as prioris.
- (b) Preencha a tabela para $p = 2$, $p = 10$ e $p = 50$.
- (c) Mostre que a diferença QDA menos LDA vale $p(p+1)/2$ e comente a ordem de grandeza.
- (d) A tabela abaixo traz a acurácia do LDA e do QDA em $p = 2$ e $p = 10$, em função do tamanho n do treino (média sobre 60 amostras, avaliada em 20 mil observações novas). Nas duas dimensões, as classes são gaussianas com covariâncias diferentes: o QDA é o modelo correto. O traço marca onde o QDA não pôde ser ajustado. Nas duas o QDA passa à frente entre $n = 30$ e $n = 50$ — mas o que acontece *antes* disso é muito diferente. Use a contagem de (b) para explicar, inclusive o traço, e diga por que a regra “prefira LDA com poucos dados” está incompleta.

		$n = 20$	30	50	100	300	1000
$p = 2$	LDA	0,8602	0,8681	0,8724	0,8775	0,8785	0,8793
	QDA	0,8508	0,8669	0,8737	0,8806	0,8824	0,8834
$p = 10$	LDA	0,7053	0,7422	0,7773	0,8013	0,8175	0,8241
	QDA	—	0,7030	0,7896	0,8440	0,8792	0,8905

Solução

(a) Com $K = 2$:

- **médias:** dois vetores de $\mathbb{R}^p$, logo $2p$ parâmetros, nos dois métodos;
- **covariância:** o LDA estima *uma* matriz comum, $p(p+1)/2$; o QDA estima *duas*, $2 \cdot p(p+1)/2 = p(p+1)$;
- **prioris:** π_0 e π_1 somam 1, então há $K - 1 = 1$ parâmetro livre.

$$\#LDA = 2p + \frac{p(p+1)}{2} + 1, \quad \#QDA = 2p + p(p+1) + 1.$$

(b)

p	2	10	50
LDA	8	76	1 376
QDA	11	131	2 651
diferença	3	55	1 275

(c) A diferença é $(2p + p(p+1) + 1) - (2p + \frac{p(p+1)}{2} + 1) = \frac{p(p+1)}{2}$: a segunda matriz de covariância, exatamente. Ela cresce como $p^2/2$, ou seja **quadraticamente**. Em $p = 2$ são 3 parâmetros a mais — nada. Em $p = 50$ são 1 275 a mais, quase o tamanho do modelo inteiro do LDA (1 376): o QDA fica com quase o dobro dos parâmetros.

(d) Na grade medida, a virada cai no mesmo intervalo nas duas dimensões — entre $n = 30$ e $n = 50$ — e justamente por isso ela é a parte *menos* informativa da tabela. O que muda é o **tamanho** da vantagem de cada lado:

	$p = 2$	$p = 10$
LDA – QDA em $n = 30$ (antes da virada)	+0,0012	+0,0392
QDA – LDA em $n = 1000$ (depois)	+0,0041	+0,0664
custo da matriz extra, $p(p+1)/2$	3	55

Em $p = 10$ a escolha importa muito, nos dois sentidos. O traço em $n = 20$ é a contagem de (b) levada ao extremo: são 10 observações por classe para estimar, em cada uma, uma matriz com 55 parâmetros. Pior: a covariância amostral de 10 pontos em $\mathbb{R}^{10}$ tem posto no máximo 9, porque os dez vetores, centrados na média da classe, somam zero e ficam num subespaço de dimensão no máximo 9. Ela não é invertível, e o QDA, que precisa de $\hat{\Sigma}_k^{-1}$ e de $\ln \det \hat{\Sigma}_k$, não está definido — só uma versão regularizada, que puxa $\hat{\Sigma}_k$ na direção de uma matriz invertível, poderia ser ajustada. Com $n = 30$, quinze observações por classe, a covariância já é invertível e o QDA ajusta, mas fica 3,9 pontos atrás do LDA. Com $n = 1000$ ele fica a menos de um ponto do classificador de Bayes, que acerta 0,8964 nessa população, e 6,6 pontos à frente do LDA.

Em $p = 2$ os dois métodos ficam a menos de um ponto percentual um do outro em toda a tabela. A matriz extra custa só 3 parâmetros, então o QDA tem pouco a *perder*. E, nesta população, ele também tem pouco a *ganhar*: o classificador de Bayes acerta 0,8841, e o LDA ajustado com um milhão de observações, 0,8805 — praticamente a melhor reta possível, que acerta 0,8806. Nem com infinitos dados o QDA, que converge para o classificador de Bayes, abriria mais que 0,4 ponto sobre o LDA. Não é que as covariâncias sejam iguais: as correlações são parecidas (−0,47 e −0,45), mas a variância de X_2 é 3,85 numa classe e 1,83 na outra. É que, onde as classes se misturam, essa diferença pouco curva a fronteira de Bayes. E isso não é uma propriedade de $p = 2$: numa população em $\mathbb{R}^2$ com correlações de sinais opostos, o QDA ganha do LDA com folga desde $n = 20$ — é o que mede a **Aula prática 07**.

Portanto a regra “prefira LDA com poucos dados” está incompleta em dois sentidos. Primeiro, **o que decide não é n sozinho, e sim n contra o que o QDA estima a mais**: $p(p+1)/2$ parâmetros, e mais de p observações por classe para que cada covariância amostral seja sequer invertível — um custo que só pesa quando p é grande. Segundo, a regra fala só do que o QDA tem a perder: **o que ele tem a ganhar é a diferença entre o erro do LDA com dados infinitos e o erro de Bayes**, ou seja, o quanto a fronteira ótima se afasta de um hiperplano onde há dados. Isso nenhuma contagem de parâmetros informa — é assunto para a validação cruzada.

É a mesma lógica do balanço viés–variância da Aula 01: o QDA é o modelo mais flexível, e modelos flexíveis só compensam quando há dados para sustentá-los e estrutura para capturar.