

## Lista Teórica 07

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 07 — Classificação e Classificadores Gaussianos

**Exercício 1 — o classificador de Bayes, em uma dimensão.** Seja  $Y \in \{0, 1\}$  e, condicionalmente a  $Y$ ,

$$X \mid Y = 0 \sim N(-1, 1), \quad X \mid Y = 1 \sim N(+1, 1).$$

- (a) Com  $\mathbb{P}(Y = 1) = \mathbb{P}(Y = 0) = 1/2$ , mostre que o classificador de Bayes decide por  $Y = 1$  quando  $x > 0$ .
- (b) Calcule o **erro de Bayes** nesse caso, em função de  $\Phi$  (a função de distribuição acumulada da normal padrão), e dê o valor numérico. *Dado:*  $\Phi(-1) = 0,1587$ .
- (c) Agora suponha  $\mathbb{P}(Y = 1) = 0,1$ . Mostre que o corte passa a ser  $x^* = \frac{1}{2} \ln 9 \approx 1,0986$ , e calcule o novo erro de Bayes. *Dados:*  $\Phi(-2,0986) = 0,0179$  e  $\Phi(0,0986) = 0,5393$ .
- (d) Compare o resultado de (c) com o erro do classificador que responde sempre  $Y = 0$ . O que isso antecipa sobre a Aula 08?

**Exercício 2 — por que a fronteira do LDA é linear.** No modelo gaussiano com covariância comum, as  $K$  classes têm prioris  $\pi_k = \mathbb{P}(Y = k)$  e  $\mathbf{X} \mid Y = k \sim N(\boldsymbol{\mu}_k, \boldsymbol{\Sigma})$ , com  $\boldsymbol{\Sigma}$  simétrica e positiva definida;  $f_k$  é a densidade de  $\mathbf{X}$  dado  $Y = k$ .

- (a) Escreva  $\ln(\pi_k f_k(\mathbf{x}))$  e mostre que, ao comparar duas classes, os termos que dependem de  $\mathbf{x}$  de forma *quadrática* se cancelam.
- (b) Conclua que o classificador de Bayes decide pela classe que maximiza a *função discriminante linear*

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k + \ln \pi_k.$$

- (c) Em que ponto exato do item (a) a hipótese de covariância comum é usada? O que sobra se cada classe tiver a sua,  $\boldsymbol{\Sigma}_k$ ?
- (d) No caso  $p = 1$ ,  $\boldsymbol{\Sigma} = \sigma^2$ ,  $\mu_0 = -1$ ,  $\mu_1 = +1$  e  $\pi_0 = \pi_1$ , recupere o corte do Exercício 1(a) a partir de  $\delta_1(x) = \delta_0(x)$ .

**Exercício 3 — quantos parâmetros cada um estima.** Considere  $K = 2$  classes em  $\mathbb{R}^p$ .

- (a) Conte os parâmetros livres do LDA e do QDA. Considere: as médias das classes, a(s) matriz(es) de covariância — lembrando que uma matriz simétrica  $p \times p$  tem  $p(p+1)/2$  entradas livres — e as prioris.
- (b) Preencha a tabela para  $p = 2$ ,  $p = 10$  e  $p = 50$ .
- (c) Mostre que a diferença QDA menos LDA vale  $p(p+1)/2$  e comente a ordem de grandeza.
- (d) A tabela abaixo traz a acurácia do LDA e do QDA em  $p = 2$  e  $p = 10$ , em função do tamanho  $n$  do treino (média sobre 60 amostras, avaliada em 20 mil observações novas). Nas duas dimensões, as classes são gaussianas com covariâncias diferentes: o QDA é o modelo correto. O traço marca onde o QDA não pôde ser ajustado. Nas duas o QDA passa à frente entre  $n = 30$  e  $n = 50$  — mas o que acontece *antes* disso é muito diferente. Use a contagem de (b) para explicar, inclusive o traço, e diga por que a regra “prefira LDA com poucos dados” está incompleta.

|          |     | $n = 20$ | 30     | 50     | 100    | 300    | 1000   |
|----------|-----|----------|--------|--------|--------|--------|--------|
| $p = 2$  | LDA | 0,8602   | 0,8681 | 0,8724 | 0,8775 | 0,8785 | 0,8793 |
|          | QDA | 0,8508   | 0,8669 | 0,8737 | 0,8806 | 0,8824 | 0,8834 |
| $p = 10$ | LDA | 0,7053   | 0,7422 | 0,7773 | 0,8013 | 0,8175 | 0,8241 |
|          | QDA | —        | 0,7030 | 0,7896 | 0,8440 | 0,8792 | 0,8905 |