

Lista Teórica 07

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 07 — Classificação e Classificadores Gaussianos

Exercício 1 — o classificador de Bayes, em uma dimensão. Seja $Y \in \{0, 1\}$ e, condicionalmente a Y ,

$$X | Y = 0 \sim N(-1, 1), \quad X | Y = 1 \sim N(+1, 1).$$

- (a) Com $\mathbb{P}(Y = 1) = \mathbb{P}(Y = 0) = 1/2$, mostre que o classificador de Bayes decide por $Y = 1$ quando $x > 0$.
- (b) Calcule o **erro de Bayes** nesse caso, em função de Φ (a distribuição acumulada da normal padrão), e dê o valor numérico. *Dado:* $\Phi(-1) = 0,1587$.
- (c) Agora suponha $\mathbb{P}(Y = 1) = 0,1$. Mostre que o corte passa a ser $x^* = \frac{1}{2} \ln 9 \approx 1,0986$, e calcule o novo erro de Bayes. *Dados:* $\Phi(-2,0986) = 0,0179$ e $\Phi(0,0986) = 0,5393$.
- (d) Compare o resultado de (c) com o erro do classificador que responde sempre $Y = 0$. O que isso antecipa sobre a Aula 08?

Exercício 2 — por que a fronteira do LDA é uma reta. No modelo gaussiano com covariância **comum**, $X | Y = k \sim N(\boldsymbol{\mu}_k, \boldsymbol{\Sigma})$ com prioris π_k .

- (a) Escreva $\ln(\pi_k f_k(\mathbf{x}))$ e mostre que, ao comparar duas classes, os termos que dependem de $\mathbf{x}$ de forma *quadrática* se cancelam.
- (b) Conclua que o classificador decide pela classe que maximiza a *função discriminante linear*

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k + \ln \pi_k.$$

- (c) Em que ponto exato do item (a) a hipótese $\boldsymbol{\Sigma}_0 = \boldsymbol{\Sigma}_1$ é usada? O que sobra se ela for relaxada?
- (d) No caso $p = 1$, $\boldsymbol{\Sigma} = \sigma^2$, $\mu_0 = -1$, $\mu_1 = +1$ e $\pi_0 = \pi_1$, recupere o corte do Exercício 1(a) a partir de $\delta_1(x) = \delta_0(x)$.

Exercício 3 — quantos parâmetros cada um estima. Considere $K = 2$ classes em $\mathbb{R}^p$.

- (a) Conte os parâmetros livres do LDA e do QDA. Considere: as médias das classes, a(s) matriz(es) de covariância — lembrando que uma matriz simétrica $p \times p$ tem $p(p+1)/2$ entradas livres — e as prioris.
- (b) Preencha a tabela para $p = 2$, $p = 10$ e $p = 50$.
- (c) Mostre que a diferença QDA menos LDA vale $p(p+1)/2$ e comente a ordem de grandeza.
- (d) A tabela abaixo traz a acurácia medida (média sobre 60 amostras, avaliada em 20 mil observações novas) do LDA e do QDA, nas mesmas duas dimensões. Em ambas o QDA passa a ganhar a partir de $n = 50$ — mas o que acontece *antes* disso é muito diferente. Use a contagem de (b) para explicar, e diga por que a regra “prefira LDA com poucos dados” está incompleta.

		$n = 20$	30	50	100	300	1000
$p = 2$	LDA	0,8602	0,8681	0,8724	0,8775	0,8785	0,8793
	QDA	0,8508	0,8669	0,8737	0,8806	0,8824	0,8834
$p = 10$	LDA	0,7053	0,7422	0,7773	0,8013	0,8175	0,8241
	QDA	0,5475	0,7030	0,7896	0,8440	0,8792	0,8905

Exercício 4 — naive Bayes gaussiano é QDA com as mãos amarradas. O GaussianNB supõe que, *dentro de cada classe*, as covariáveis são independentes: Σ_k é **diagonal**, com entradas $\sigma_{k1}^2, \dots, \sigma_{kd}^2$.

- (a) Quantos parâmetros ele estima, com $K = 2$? Acrescente a coluna à tabela do Exercício 3.
- (b) Mostre que a função discriminante do naive Bayes gaussiano é

$$\delta_k(\mathbf{x}) = \ln \pi_k - \frac{1}{2} \sum_{j=1}^p \left[\ln \sigma_{kj}^2 + \frac{(x_j - \mu_{kj})^2}{\sigma_{kj}^2} \right],$$

e diga se a fronteira é linear ou quadrática.

- (c) A suposição de independência é quase sempre *falsa*. Dê uma razão pela qual o método ainda assim costuma classificar bem.
- (d) Descreva uma situação em que a suposição custa caro, isto é, em que a correlação entre covariáveis carrega informação essencial sobre a classe.