

Lista Teórica 07

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 07 — Pré-processamento e *Pipelines*

Exercício 1 — a pergunta que separa grave de leve. O critério da Aula 07 para classificar um vazamento não é “quanto a etapa aprende dos dados”, e sim uma pergunta só: **a etapa olha o Y ?**

Classifique cada situação abaixo como vazamento **grave**, **leve** ou **nenhum**, e justifique em uma linha aplicando esse critério.

- (a) Padronizar todas as covariáveis usando a média e o desvio-padrão calculados no conjunto *completo*, antes de separar treino e teste.
- (b) Selecionar, entre 10 000 covariáveis, as 50 mais correlacionadas com Y usando todos os dados, e só então rodar a validação cruzada com essas 50.
- (c) Ajustar o PCA no conjunto completo, reduzir a 20 componentes, e só então separar treino e teste.
- (d) Imputar valores faltantes pela *mediana da coluna*, calculada no conjunto completo.
- (e) Num banco em que cada paciente aparece em várias linhas (uma por consulta), fazer `KFold` sobre as linhas.
- (f) Padronizar dentro de um *Pipeline*, com `GridSearchCV` por fora.

Exercício 2 — por que um custa 0,40 e o outro custa nada. A nota traz duas medições. Com $\mathbf{X}$ e y gerados **independentemente** (isto é, y é ruído puro, e o R^2 verdadeiro de qualquer modelo é 0):

- selecionar as covariáveis mais correlacionadas com y *antes* da validação cruzada produz $R^2 = +0,40$;
 - padronizar fora da dobra, num problema com sinal de verdade e escalas muito díspares, produz 0,8466 — contra 0,8466 fazendo certo.
- (a) Explique o mecanismo do primeiro número. Se y é ruído puro, de onde sai um R^2 positivo?
 - (b) Suponha d covariáveis independentes de y , e que você fique com as m de maior correlação amostral com y . O que acontece com o R^2 inflado quando d cresce, com n e m fixos? Por quê?
 - (c) Explique por que a padronização não consegue produzir o mesmo efeito, por mais que ela use o conjunto todo.
 - (d) Se o efeito da padronização é desprezível, por que ainda assim se recomenda pô-la dentro do *Pipeline*?

Exercício 3 — escrevendo o pipeline. Um banco tem as seguintes colunas:

- **idade**, **renda**, **saldo** — numéricas, com valores faltantes em **renda**;

- **estado, profissao** — categóricas, sem faltantes;
- **inadimplente** — a resposta, binária.

A receita desejada é: imputar as numéricas pela mediana, padronizá-las, codificar as categóricas em variáveis indicadoras, e ajustar uma regressão logística com penalização ℓ_2 , escolhendo o C por validação cruzada de 5 dobras.

- Escreva o código, usando `ColumnTransformer`, `Pipeline` e `GridSearchCV`.
- Na sua solução, quantas vezes a mediana de **renda** é calculada ao longo de toda a busca, se a grade de C tem 6 valores? Justifique.
- Por que a ordem imputar $\rightarrow$ padronizar importa, e não o contrário?

Exercício 4 — a divisão que nenhum pipeline conserta. Um laboratório mede a expressão de 20 000 genes em 60 pacientes, três amostras por paciente (180 linhas), e quer prever se o tumor responde ao tratamento. Um analista monta o **Pipeline** correto — imputação e padronização dentro dele — e reporta acurácia de 0,95 por validação cruzada de 10 dobras sobre as 180 linhas.

- Qual é o problema, e por que o **Pipeline** não o resolve?
- Qual é o número aproximado de pacientes que aparecem *ao mesmo tempo* no treino e na validação de uma dobra típica? Justifique.
- Como corrigir? Escreva a chamada.
- O laboratório também quer selecionar os 200 genes mais associados à resposta. Onde essa etapa tem de ficar?