

Lista Teórica 08 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 08 — Classificação e Classificadores Gaussianos

Exercício 1 — o classificador de Bayes, em uma dimensão. Seja $Y \in \{0, 1\}$ e, condicionalmente a Y ,

$$X | Y = 0 \sim N(-1, 1), \quad X | Y = 1 \sim N(+1, 1).$$

- Com $\mathbb{P}(Y = 1) = \mathbb{P}(Y = 0) = 1/2$, mostre que o classificador de Bayes decide por $Y = 1$ quando $x > 0$.
- Calcule o **erro de Bayes** nesse caso, em função de Φ (a distribuição acumulada da normal padrão), e dê o valor numérico. *Dado:* $\Phi(-1) = 0,1587$.
- Agora suponha $\mathbb{P}(Y = 1) = 0,1$. Mostre que o corte passa a ser $x^* = \frac{1}{2} \ln 9 \approx 1,0986$, e calcule o novo erro de Bayes. *Dados:* $\Phi(-2,0986) = 0,0179$ e $\Phi(0,0986) = 0,5393$.
- Compare o resultado de (c) com o erro do classificador que responde sempre $Y = 0$. O que isso antecipa sobre a Aula 09?

Solução

(a) O classificador de Bayes escolhe a classe de maior probabilidade a posteriori, o que com duas classes equivale a decidir por $Y = 1$ quando $\pi_1 f_1(x) > \pi_0 f_0(x)$. Com $\pi_0 = \pi_1$ as prioris cancelam e a condição vira $f_1(x) > f_0(x)$, isto é

$$\exp\left(-\frac{(x-1)^2}{2}\right) > \exp\left(-\frac{(x+1)^2}{2}\right) \iff -(x-1)^2 > -(x+1)^2 \iff (x+1)^2 > (x-1)^2.$$

Expandindo, $x^2 + 2x + 1 > x^2 - 2x + 1 \iff 4x > 0 \iff x > 0$. O corte é o ponto médio entre as duas médias, como a simetria já sugeria.

(b) O erro é a probabilidade de errar, decomposta pelas duas classes:

$$R^* = \frac{1}{2} \mathbb{P}(X > 0 | Y = 0) + \frac{1}{2} \mathbb{P}(X < 0 | Y = 1).$$

Sob $Y = 0$, $X \sim N(-1, 1)$, então $\mathbb{P}(X > 0) = \mathbb{P}(Z > 1) = 1 - \Phi(1) = \Phi(-1)$. Por simetria, o segundo termo é igual. Logo

$$R^* = \Phi(-1) = \mathbf{0,1587}.$$

Quase 16% de erro é o *piso*: nenhum classificador, com quaisquer dados, faz melhor. É o análogo em classificação do σ^2 da Aula 01.

(c) Agora as prioris não cancelam. Decidimos por $Y = 1$ quando

$$0,1 \exp\left(-\frac{(x-1)^2}{2}\right) > 0,9 \exp\left(-\frac{(x+1)^2}{2}\right).$$

Tomando logaritmo,

$$\ln 0,1 - \frac{(x-1)^2}{2} > \ln 0,9 - \frac{(x+1)^2}{2} \iff \ln \frac{0,1}{0,9} > \frac{(x-1)^2 - (x+1)^2}{2} = -2x,$$

ou seja $-\ln 9 > -2x$, isto é $x > \frac{1}{2} \ln 9 \approx 1,0986$.

O erro fica

$$R^* = 0,9 \mathbb{P}(X > x^* \mid Y = 0) + 0,1 \mathbb{P}(X < x^* \mid Y = 1) = 0,9 \Phi(-2,0986) + 0,1 \Phi(0,0986),$$

usando $\mathbb{P}(X > x^* \mid Y = 0) = 1 - \Phi(x^* + 1) = \Phi(-x^* - 1)$ e $\mathbb{P}(X < x^* \mid Y = 1) = \Phi(x^* - 1)$. Numericamente,

$$R^* = 0,9 \times 0,0179 + 0,1 \times 0,5393 = 0,0161 + 0,0539 = \mathbf{0,0701}.$$

(d) O classificador que responde sempre $Y = 0$ erra exatamente $\mathbb{P}(Y = 1) = \mathbf{0,10}$. O classificador de Bayes erra 0,0701 — melhor, mas não muito: a diferença é de menos de 3 pontos percentuais.

E vale olhar de onde vem o erro de Bayes: das duas parcelas, 0,0539 vêm de classificar como 0 observações que eram 1. Ou seja, o classificador ótimo **erra mais da metade dos positivos** (0,5393 deles!) — e ainda assim é ótimo, porque acertar mais positivos custaria muitos falsos positivos entre os 90% de negativos.

É exatamente a situação em que a acurácia deixa de ser informativa, e é o assunto da Aula 09. Quando a prevalência é desbalanceada, um número de acurácia próximo do trivial pode esconder tanto um classificador excelente quanto um inútil.

Exercício 2 — por que a fronteira do LDA é uma reta. No modelo gaussiano com covariância **comum**, $X \mid Y = k \sim N(\boldsymbol{\mu}_k, \boldsymbol{\Sigma})$ com prioris π_k .

- Escreva $\ln(\pi_k f_k(\mathbf{x}))$ e mostre que, ao comparar duas classes, os termos que dependem de $\mathbf{x}$ de forma *quadrática* se cancelam.
- Conclua que o classificador decide pela classe que maximiza a *função discriminante linear*

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k + \ln \pi_k.$$
- Em que ponto exato do item (a) a hipótese $\boldsymbol{\Sigma}_0 = \boldsymbol{\Sigma}_1$ é usada? O que sobra se ela for relaxada?
- No caso $p = 1$, $\boldsymbol{\Sigma} = \sigma^2$, $\mu_0 = -1$, $\mu_1 = +1$ e $\pi_0 = \pi_1$, recupere o corte do Exercício 1(a) a partir de $\delta_1(x) = \delta_0(x)$.

Solução

(a) A densidade gaussiana multivariada dá

$$\ln(\pi_k f_k(\mathbf{x})) = \ln \pi_k - \frac{p}{2} \ln(2\pi) - \frac{1}{2} \ln |\boldsymbol{\Sigma}| - \frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}_k).$$

Expandindo a forma quadrática:

$$(\mathbf{x} - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) = \underbrace{\mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x}}_{\text{não depende de } k} - 2 \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k + \boldsymbol{\mu}_k^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k.$$

Ao comparar duas classes k e ℓ , subtraímos as duas expressões. Os termos $-\frac{p}{2} \ln(2\pi)$, $-\frac{1}{2} \ln |\boldsymbol{\Sigma}|$ e $-\frac{1}{2} \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x}$ são **idênticos** nas duas e desaparecem — e é justamente o último deles que era quadrático em $\mathbf{x}$.

(b) O que sobra depois de descartar os termos comuns e multiplicar por $-\frac{1}{2} \cdot (-2) = 1$ é

$$\delta_k(\mathbf{x}) = \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_k + \ln \pi_k,$$

que é **afim em $\mathbf{x}$** : um produto interno com o vetor fixo $\Sigma^{-1}\mu_k$, mais uma constante. A fronteira entre duas classes é o conjunto $\{\mathbf{x} : \delta_k(\mathbf{x}) = \delta_\ell(\mathbf{x})\}$, isto é $\mathbf{x}^\top \Sigma^{-1}(\mu_k - \mu_\ell) = \text{const}$ — um **hiperplano**.

(c) A hipótese é usada exatamente ao afirmar que $\mathbf{x}^\top \Sigma^{-1}\mathbf{x}$ e $\ln |\Sigma|$ *não dependem de k* . Com covariâncias distintas teríamos $\mathbf{x}^\top \Sigma_k^{-1}\mathbf{x}$ e $\ln |\Sigma_k|$, que dependem de k e portanto **não se cancelam**.

Sobra então

$$\delta_k(\mathbf{x}) = -\frac{1}{2}\mathbf{x}^\top \Sigma_k^{-1}\mathbf{x} + \mathbf{x}^\top \Sigma_k^{-1}\mu_k - \frac{1}{2}\mu_k^\top \Sigma_k^{-1}\mu_k - \frac{1}{2}\ln |\Sigma_k| + \ln \pi_k,$$

que é *quadrática* em $\mathbf{x}$ — é o QDA, e a fronteira vira uma cônica (elipse, parábola ou hipérbole, conforme o caso). Em uma frase: **a linearidade do LDA não vem da gaussianidade, vem da covariância comum**.

(d) Com $p = 1$, $\Sigma^{-1} = 1/\sigma^2$ e $\pi_0 = \pi_1$ (então $\ln \pi_k$ cancela):

$$\delta_1(x) = \frac{x \cdot 1}{\sigma^2} - \frac{1}{2\sigma^2}, \quad \delta_0(x) = \frac{x \cdot (-1)}{\sigma^2} - \frac{1}{2\sigma^2}.$$

Igualando: $x/\sigma^2 = -x/\sigma^2$, ou seja $2x/\sigma^2 = 0$, isto é $\mathbf{x} = \mathbf{0}$. É o corte do Exercício 1(a), e note que ele *não depende de σ^2* — a variância muda o quanto se erra, não onde fica a fronteira.

Exercício 3 — quantos parâmetros cada um estima. Considere $K = 2$ classes em $\mathbb{R}^p$.

- Conte os parâmetros livres do LDA e do QDA. Considere: as médias das classes, a(s) matriz(es) de covariância — lembrando que uma matriz simétrica $p \times p$ tem $p(p+1)/2$ entradas livres — e as prioris.
- Preencha a tabela para $p = 2$, $p = 10$ e $p = 50$.
- Mostre que a diferença QDA menos LDA vale $p(p+1)/2$ e comente a ordem de grandeza.
- A tabela abaixo traz a acurácia medida (média sobre 60 amostras, avaliada em 20 mil observações novas) do LDA e do QDA, nas mesmas duas dimensões. Em ambas o QDA passa a ganhar a partir de $n = 50$ — mas o que acontece *antes* disso é muito diferente. Use a contagem de (b) para explicar, e diga por que a regra “prefira LDA com poucos dados” está incompleta.

		$n = 20$	30	50	100	300	1000
$p = 2$	LDA	0,8602	0,8681	0,8724	0,8775	0,8785	0,8793
	QDA	0,8508	0,8669	0,8737	0,8806	0,8824	0,8834
$p = 10$	LDA	0,7053	0,7422	0,7773	0,8013	0,8175	0,8241
	QDA	0,5475	0,7030	0,7896	0,8440	0,8792	0,8905

Solução

(a) Com $K = 2$:

- médias:** dois vetores de $\mathbb{R}^p$, logo $2p$ parâmetros, nos dois métodos;
- covariância:** o LDA estima *uma* matriz comum, $p(p+1)/2$; o QDA estima *duas*, $2 \cdot p(p+1)/2 = p(p+1)$;

- **prioris:** π_0 e π_1 somam 1, então há $K - 1 = 1$ parâmetro livre.

$$\#LDA = 2p + \frac{p(p+1)}{2} + 1, \quad \#QDA = 2p + p(p+1) + 1.$$

(b)

p	2	10	50
LDA	8	76	1 376
QDA	11	131	2 651
diferença	3	55	1 275

(c) A diferença é $(2p + p(p+1) + 1) - (2p + \frac{p(p+1)}{2} + 1) = \frac{p(p+1)}{2}$: a segunda matriz de covariância, exatamente. Ela cresce como $p^2/2$, ou seja **quadraticamente**. Em $p = 2$ são 3 parâmetros a mais — nada. Em $p = 50$ são 1 275 a mais, quase o dobro do modelo inteiro do LDA.

(d) O ponto de virada é o mesmo nas duas dimensões — $n = 50$ — e justamente por isso ele é a parte *menos* informativa da tabela. O que muda é o **tamanho** da vantagem de cada lado:

	$p = 2$	$p = 10$
LDA – QDA em $n = 20$ (antes da virada)	+0,0094	+0,1578
QDA – LDA em $n = 1000$ (depois)	+0,0041	+0,0664
custo da matriz extra, $p(p+1)/2$	3	55

Em $p = 2$ os dois métodos são praticamente equivalentes em toda a tabela: a maior diferença é de menos de um ponto percentual. A matriz de covariância extra custa 3 parâmetros, e 3 parâmetros a mais ou a menos não mudam nada, nem para bem nem para mal.

Em $p = 10$ os dois erram feio, em direções opostas. Com $n = 20$, o QDA precisa estimar 131 parâmetros a partir de 20 observações — as matrizes de covariância mal são invertíveis — e despenca para 0,5475, quase o acaso, 16 pontos abaixo do LDA. Com $n = 1000$ ele reproduz a estrutura verdadeira e ganha 6,6 pontos.

Portanto a regra “prefira LDA com poucos dados” está incompleta em dois sentidos. Primeiro, **o que decide não é n sozinho, e sim n contra $p(p+1)/2$** , que é o custo da matriz extra. Segundo, e mais útil na prática: **em dimensão baixa a escolha quase não importa**; ela só passa a importar quando p é grande, e aí importa muito, nos dois sentidos. Gastar validação cruzada decidindo entre LDA e QDA em $p = 2$ é desperdício; em $p = 50$ é obrigatório.

É a mesma lógica do balanço viés–variância da Aula 01: o QDA é o modelo mais flexível, e modelos flexíveis só compensam quando há dados para sustentá-los.

Exercício 4 — naive Bayes gaussiano é QDA com as mãos amarradas. O GaussianNB supõe que, *dentro de cada classe*, as covariáveis são independentes: Σ_k é **diagonal**, com entradas $\sigma_{k1}^2, \dots, \sigma_{kd}^2$.

- (a) Quantos parâmetros ele estima, com $K = 2$? Acrescente a coluna à tabela do Exercício 3.

- (b) Mostre que a função discriminante do naive Bayes gaussiano é

$$\delta_k(\mathbf{x}) = \ln \pi_k - \frac{1}{2} \sum_{j=1}^p \left[\ln \sigma_{kj}^2 + \frac{(x_j - \mu_{kj})^2}{\sigma_{kj}^2} \right],$$

e diga se a fronteira é linear ou quadrática.

- (c) A suposição de independência é quase sempre *falsa*. Dê uma razão pela qual o método ainda assim costuma classificar bem.
- (d) Descreva uma situação em que a suposição custa caro, isto é, em que a correlação entre covariáveis carrega informação essencial sobre a classe.

Solução

- (a) São $2p$ médias, $2p$ variâncias (uma por covariável e por classe) e 1 priori: $\#NB = 4p + 1$. Comparando:

p	2	10	50
naive Bayes ($4p + 1$)	9	41	201
LDA	8	76	1376
QDA	11	131	2651

Note a inversão: em $p = 2$ o naive Bayes custa *mais* que o LDA (9 contra 8), porque estima duas variâncias por covariável em vez de uma covariância comum. Em $p = 50$ ele custa 201 contra 1376 — quase sete vezes menos. O crescimento é **linear** em p , contra o quadrático dos outros dois, e é isso que o torna viável em dimensão alta (a Aula E3 o usa com dezenas de milhares de colunas).

- (b) Com Σ_k diagonal, a densidade conjunta fatora: $f_k(\mathbf{x}) = \prod_{j=1}^p f_{kj}(x_j)$, com f_{kj} a densidade de $N(\mu_{kj}, \sigma_{kj}^2)$. Então

$$\ln(\pi_k f_k(\mathbf{x})) = \ln \pi_k + \sum_{j=1}^p \left[-\frac{1}{2} \ln(2\pi) - \frac{1}{2} \ln \sigma_{kj}^2 - \frac{(x_j - \mu_{kj})^2}{2\sigma_{kj}^2} \right],$$

e descartando $-\frac{p}{2} \ln(2\pi)$, que é comum a todas as classes, chega-se à expressão do enunciado. A fronteira é **quadrática**: o termo $(x_j - \mu_{kj})^2 / \sigma_{kj}^2$ depende de k pelo denominador, então o termo em x_j^2 não cancela entre classes. O naive Bayes gaussiano é, portanto, um **QDA restrito a covariâncias diagonais** — e não uma versão simplificada do LDA. (Se as variâncias fossem forçadas a ser iguais entre as classes, aí sim ele viraria um LDA diagonal, com fronteira linear.)

- (c) Porque para *classificar* basta acertar qual δ_k é o maior, e não estimar bem as probabilidades. Erros na modelagem da dependência tendem a deslocar todos os δ_k na mesma direção, preservando a ordem entre eles. Some-se a isso o argumento de variância do item (a): com $4p + 1$ parâmetros em vez de 2651, as estimativas são muito mais estáveis, e o viés introduzido pela suposição falsa é compensado pela variância que se economiza.

O preço aparece na **calibração**: as probabilidades do naive Bayes são notoriamente ruins, tipicamente empurradas para 0 ou 1, porque ele multiplica evidências correlacionadas como se fossem independentes e conta a mesma informação várias vezes. É exatamente a medição da Aula 09 — AUC praticamente empatada com a logística (0,776 contra 0,774) e Brier muito pior (0,1523 contra 0,0653). *Ordenar bem não é estimar bem*.

- (d) Quando a informação está na **correlação**, e não nas médias. Um exemplo em $p = 2$: suponha que nas duas classes cada covariável tenha média zero e variância um, mas que na

classe 0 elas sejam positivamente correlacionadas ($\rho = +0,9$) e na classe 1, negativamente ($\rho = -0,9$). As nuvens são duas elipses cruzadas, perfeitamente distinguíveis — mas as médias e as variâncias marginais são *idênticas* nas duas classes.

O naive Bayes vê exatamente médias e variâncias marginais, então para ele as duas classes são indistinguíveis. Simulando 4 000 observações por classe e medindo a acurácia por validação cruzada de 5 dobras:

GaussianNB	0,5104
LDA	0,4949
QDA	0,8575

O naive Bayes e o LDA acertam o mesmo que jogar uma moeda; o QDA, que estima as duas matrizes de covariância inteiras, chega a 86%. É o caso em que a suposição de independência não custa precisão — custa *tudo*.

(O LDA falha pelo mesmo motivo, e é instrutivo: ele estima uma covariância *comum*, e a média das duas matrizes tem correlação ≈ 0 . A informação está justamente na *diferença* entre elas.)