Aula 08 — Métricas para Classificação

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §7.4 e §9.1; ISLP §4.4.2

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- explicar por que a acurácia pode ser uma medida enganosa, quando uma das classes é rara ou quando os dois tipos de erro têm custos diferentes;
- construir a **matriz de confusão** e definir a sensibilidade, a especificidade e as taxas de verdadeiros e de falsos positivos como estimativas de probabilidades;
- deduzir o **corte ótimo** de um classificador *plug-in* sob uma perda assimétrica;
- definir a **curva ROC** e a **AUC**.

A Aula 07 terminou com um aviso: a acurácia pode enganar. Esta aula desenvolve esse aviso a partir de uma pergunta simples:

numa população em que 1% *das pessoas tem certa doença, um teste que declara todo mundo saudável acerta* 99% *das vezes. Ele é um bom teste?*

Não é: ele não encontra doente nenhum. A acurácia, porém, não registra isso, porque soma num único número dois erros de natureza muito diferente. O que segue constrói medidas que separam esses erros e mostra como escolher entre elas conforme a pergunta que se quer responder.

1 Por que a acurácia não basta

Considere a classificação binária, com $Y \in \{0, 1\}$, e um classificador g. A Aula 07 avaliou g pelo risco 0–1,

$$R(g) = \mathbb{P}(g(\boldsymbol{X}) \neq Y),$$

cujo complemento, $1 - R(g)$, é a **acurácia**. Esse critério trata todo erro como igual, e há duas situações frequentes em que isso não serve.

- *Custos assimétricos.* Num exame de rastreamento, deixar de detectar um doente (um *falso negativo*) costuma ser muito mais grave que mandar um saudável para um exame confirmatório (um *falso positivo*). O risco 0–1 dá aos dois o mesmo peso.
- *Uma classe rara.* Se $\pi_1 = \mathbb{P}(Y = 1)$ é pequena, o classificador trivial $g \equiv 0$ tem risco π_1 e acurácia $1 - \pi_1$, alta, sem acertar positivo nenhum. Mais que isso: se as covariáveis informam pouco sobre Y, pode acontecer de $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) < 1/2$ para todo $\boldsymbol{x}$, e então o próprio classificador de Bayes é $g \equiv 0$ ([AME] §9.1). Os métodos que aproximam o classificador de Bayes passam a aproximar o classificador trivial.

Atenção

O desbalanceamento, sozinho, não é um defeito do problema. Se os dois erros custam o mesmo, o classificador de Bayes minimiza exatamente o que interessa, a probabilidade

de erro, por mais rara que seja uma das classes. A dificuldade aparece quando os custos diferem: o classificador de Bayes pesa os dois erros igualmente e deixa de ser o classificador desejado. A Seção 3 mostra como levar esses custos em conta.

2 Matriz de confusão e métricas

Para avaliar um classificador g já construído, usa-se uma *amostra de teste* $(\boldsymbol{X}_1, Y_1), \ldots, (\boldsymbol{X}_m, Y_m)$: observações i.i.d. com a distribuição de $(\boldsymbol{X}, Y)$ e independentes dos dados usados para construir g. A classe $Y = 1$ é chamada de *positiva*; em geral, é a classe de interesse, como o doente ou a fraude. Cruzar o que g prediz com o valor verdadeiro produz quatro contagens,

$$\mathrm{VP} = \#\{i : g(\boldsymbol{X}_i) = 1,\ Y_i = 1\}, \qquad \mathrm{FP} = \#\{i : g(\boldsymbol{X}_i) = 1,\ Y_i = 0\},$$

$$\mathrm{FN} = \#\{i : g(\boldsymbol{X}_i) = 0,\ Y_i = 1\}, \qquad \mathrm{VN} = \#\{i : g(\boldsymbol{X}_i) = 0,\ Y_i = 0\},$$

os verdadeiros e falsos positivos e negativos, que se organizam na **matriz de confusão** da Figura 1. Os totais das colunas, $P = \mathrm{VP} + \mathrm{FN}$ e $N = \mathrm{FP} + \mathrm{VN}$, são os números de positivos e de negativos verdadeiros da amostra, e $P + N = m$.

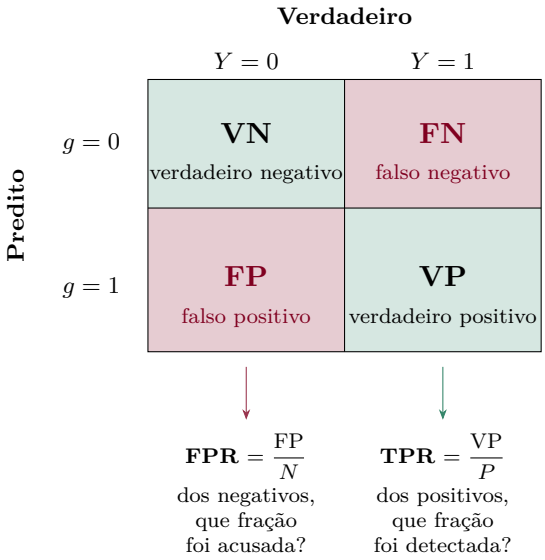


Figura 1: A matriz de confusão, com o predito nas linhas e o verdadeiro nas colunas, como no [AME] (Tabela 7.1) e no [ISLP] (Tabela 4.6). As duas taxas da curva ROC dividem pelo total de uma coluna, isto é, olham uma classe verdadeira de cada vez: a taxa de falsos positivos (FPR), a dos negativos; a de verdadeiros positivos (TPR), a dos positivos. O `confusion_matrix` do `scikit-learn` devolve a transposta desta tabela, com o verdadeiro nas linhas.

Cada medida desta seção é a estimativa de uma probabilidade sobre uma observação nova $(\boldsymbol{X}, Y)$, independente dos dados usados para construir g. As duas principais condicionam na classe verdadeira:

$$\text{sensibilidade:} \quad S = \mathbb{P}\big(g(\boldsymbol{X}) = 1 \mid Y = 1\big), \qquad \widehat{S} = \frac{\mathrm{VP}}{P},$$

$$\text{especificidade:} \quad E = \mathbb{P}\big(g(\boldsymbol{X}) = 0 \mid Y = 0\big), \qquad \widehat{E} = \frac{\mathrm{VN}}{N}.$$

Cada estimador é a proporção correspondente na amostra de teste: $\widehat{S}$, por exemplo, é a fração de acertos entre os P positivos e, pela lei dos grandes números, converge para S à medida que o número de positivos cresce. A sensibilidade também se chama *revocação* (*recall*).

Nenhuma das duas depende da prevalência $\pi_1 = \mathbb{P}(Y = 1)$. Com g fixado, S é a probabilidade de que $\boldsymbol{X}$ caia na região $\{\boldsymbol{x} : g(\boldsymbol{x}) = 1\}$ quando $\boldsymbol{X}$ segue a distribuição dos positivos, e E, a de que caia fora dela quando segue a dos negativos. Mudar só a proporção de doentes, mantida a distribuição de $\boldsymbol{X}$ dentro de cada classe, não altera nenhuma das duas.

Atenção

Todas essas estimativas devem ser calculadas numa amostra independente da usada para construir g. No treino, elas superestimam o desempenho, pelo mesmo motivo que o erro de treino subestima o risco (Aula 03).

As taxas da curva ROC. Na curva ROC (Seção 4) e no `scikit-learn`, essas quantidades aparecem com outro nome: a sensibilidade é a **taxa de verdadeiros positivos**, $\mathrm{TPR} = S$, e o complemento da especificidade é a **taxa de falsos positivos**, $\mathrm{FPR} = 1 - E$, isto é, a probabilidade $\mathbb{P}(g(\boldsymbol{X}) = 1 \mid Y = 0)$ de acusar um negativo. O complemento da sensibilidade, $1 - S$, é a taxa de falsos negativos. Na amostra, a TPR e a FPR são estimadas por VP/P e FP/N (a função `roc_curve` devolve justamente `fpr` e `tpr`). As duas dividem por um total de coluna; por isso, dados P e N, as duas estimativas reconstroem a matriz inteira:

$$\mathrm{VP} = \widehat{\mathrm{TPR}} \cdot P, \qquad \mathrm{FN} = (1 - \widehat{\mathrm{TPR}})\, P, \qquad \mathrm{FP} = \widehat{\mathrm{FPR}} \cdot N, \qquad \mathrm{VN} = (1 - \widehat{\mathrm{FPR}})\, N.$$

É esse par que a curva ROC vai acompanhar.

Observação 2.1. Quem vem de testes de hipóteses já conhece as duas. Tome $Y = 0$ como a hipótese nula e a decisão $g(\boldsymbol{X}) = 1$ como sua rejeição: a FPR é a probabilidade do erro do tipo I, e a TPR, o poder do teste.

Exemplo 2.2 (A doença rara em números)**.** Numa amostra de teste com $m = 1000$ pacientes, dos quais $P = 10$ são doentes ([AME] §7.4), compare o classificador trivial $g_1 \equiv 0$ com um classificador hipotético g_2, que encontra 8 dos 10 doentes e dá alarme falso para 40 dos 990 saudáveis:

g_1	$Y = 0$	$Y = 1$
0	990	10
1	0	0

g_2	$Y = 0$	$Y = 1$
0	950	2
1	40	8

As taxas de erro são $10/1000 = 0{,}010$ para g_1 e $42/1000 = 0{,}042$ para g_2: pelo risco estimado, g_1 é melhor. As taxas por classe dizem outra coisa: $\widehat{S} = 0$ para g_1 e $\widehat{S} = 8/10 = 0{,}8$ para g_2, ao custo de uma taxa de falsos positivos de $40/990 \approx 0{,}040$. A taxa de erro soma os dois tipos de erro e divide pelo tamanho da amostra: os 10 doentes que g_1 deixa passar são só 1% dos 1000 pacientes, enquanto os 40 alarmes falsos de g_2 são 4%. Por isso ela prefere o classificador que não encontra doente nenhum.

3 Perdas assimétricas e o corte ótimo

Para levar em conta custos diferentes, atribua um custo $\ell_0 > 0$ a cada falso negativo e um custo $\ell_1 > 0$ a cada falso positivo. O índice indica a decisão tomada no erro: ℓ_0 é o custo de decidir 0 quando $Y = 1$, e ℓ_1, o de decidir 1 quando $Y = 0$. O critério passa a ser o custo esperado

$$R_\ell(g) = \ell_1\, \mathbb{P}(g(\boldsymbol{X}) = 1,\, Y = 0) + \ell_0\, \mathbb{P}(g(\boldsymbol{X}) = 0,\, Y = 1) \tag{1}$$

([AME] §9.1). Com $\ell_0 = \ell_1 = 1$ ele volta a ser o risco 0–1.

Proposição 3.1 (Corte ótimo sob perda assimétrica)**.** *Seja* $\eta(\boldsymbol{x}) = \mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$*. O classificador*

$$g^*(\boldsymbol{x}) = \mathbf{1}\Big\{\ \eta(\boldsymbol{x}) > \tfrac{\ell_1}{\ell_0+\ell_1}\ \Big\}$$

minimiza (1) *entre todos os classificadores.*

Demonstração. Dado $\boldsymbol{X} = \boldsymbol{x}$, a decisão $g(\boldsymbol{x})$ está fixada e só Y é aleatório; por isso

$$\mathbb{P}(g(\boldsymbol{X}) = 1,\, Y = 0 \mid \boldsymbol{X} = \boldsymbol{x}) = \mathbf{1}\{g(\boldsymbol{x}) = 1\}\ (1 - \eta(\boldsymbol{x})),$$
$$\mathbb{P}(g(\boldsymbol{X}) = 0,\, Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) = \mathbf{1}\{g(\boldsymbol{x}) = 0\}\ \eta(\boldsymbol{x}).$$

Tomando a esperança em $\boldsymbol{X}$,

$$R_\ell(g) = \mathbb{E}\Big[\, \ell_1\,(1 - \eta(\boldsymbol{X}))\,\mathbf{1}\{g(\boldsymbol{X}) = 1\} + \ell_0\,\eta(\boldsymbol{X})\,\mathbf{1}\{g(\boldsymbol{X}) = 0\}\,\Big].$$

Para cada $\boldsymbol{x}$, o termo dentro da esperança vale $\ell_1(1 - \eta(\boldsymbol{x}))$ se $g(\boldsymbol{x}) = 1$ e $\ell_0\,\eta(\boldsymbol{x})$ se $g(\boldsymbol{x}) = 0$. O primeiro é menor exatamente quando $\ell_1(1 - \eta(\boldsymbol{x})) < \ell_0\,\eta(\boldsymbol{x})$, isto é, quando $\eta(\boldsymbol{x}) > \ell_1/(\ell_0 + \ell_1)$. Logo g^* minimiza o integrando em cada $\boldsymbol{x}$ e, portanto, a esperança. Nos pontos em que $\eta(\boldsymbol{x}) = \ell_1/(\ell_0+\ell_1)$ as duas decisões custam o mesmo, e qualquer escolha ali também é ótima. □

Com $\ell_0 = \ell_1$, o corte é $1/2$ e g^* é o classificador de Bayes da Aula 07. Se errar um positivo custa dez vezes mais que errar um negativo, $\ell_0 = 10\,\ell_1$, o corte cai para $1/11 \approx 0{,}09$: basta uma probabilidade de 9% para chamar alguém de positivo. Só a razão ℓ_0/ℓ_1 importa, e o modelo não muda: as probabilidades estimadas são as mesmas, muda apenas o número com que elas são comparadas. Na prática, como η é desconhecida, o classificador *plug-in* usa uma estimativa $\widehat{\eta}$ no lugar dela.

4 Escolhendo o corte: curva ROC e AUC

Um classificador *plug-in* usa uma estimativa $\widehat{\eta}(\boldsymbol{x})$ de $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$ e um corte p_0,

$$g_{p_0}(\boldsymbol{x}) = \mathbf{1}\{\widehat{\eta}(\boldsymbol{x}) \geq p_0\}\,,$$

e o corte pode ser escolhido depois de ajustado o modelo. Cada p_0 dá um classificador, com sua taxa de verdadeiros positivos e sua taxa de falsos positivos, $\mathrm{TPR}(p_0)$ e $\mathrm{FPR}(p_0)$. A **curva ROC** (*Receiver Operating Characteristic*) é o conjunto desses pontos,

$$\{\ (\mathrm{FPR}(p_0),\ \mathrm{TPR}(p_0)) : p_0 \in [0, 1]\ \},$$

isto é, a sensibilidade contra 1−especificidade à medida que o corte percorre $[0, 1]$. Na amostra de teste só os valores distintos de $\widehat{\eta}(\boldsymbol{X}_i)$ importam como cortes, e a curva estimada é a poligonal que liga os pontos correspondentes.

As duas taxas diminuem ou ficam iguais quando p_0 aumenta. De fato, se $p_0 < p_0'$, todo $\boldsymbol{x}$ com $\widehat{\eta}(\boldsymbol{x}) \geq p_0'$ também tem $\widehat{\eta}(\boldsymbol{x}) \geq p_0$: o conjunto dos classificados como positivos só encolhe quando o corte sobe, de modo que VP e FP diminuem ou ficam iguais, enquanto P e N não dependem do corte. Descendo o corte de 1 a 0, as duas taxas crescem juntas: encontrar mais positivos, em geral, custa acusar mais negativos, e a curva mostra quanto se paga de uma pela outra. Propriedades:

- com p_0 acima de todas as probabilidades estimadas, ninguém é classificado como positivo: ponto $(0, 0)$; com $p_0 = 0$, todos são: ponto $(1, 1)$;
- o canto $(0, 1)$ corresponde a um classificador sem erro nenhum;
- a diagonal corresponde a decidir sem olhar $\boldsymbol{x}$: sortear $g = 1$ com probabilidade q, independentemente de $\boldsymbol{X}$, dá $\mathrm{TPR} = \mathrm{FPR} = q$;

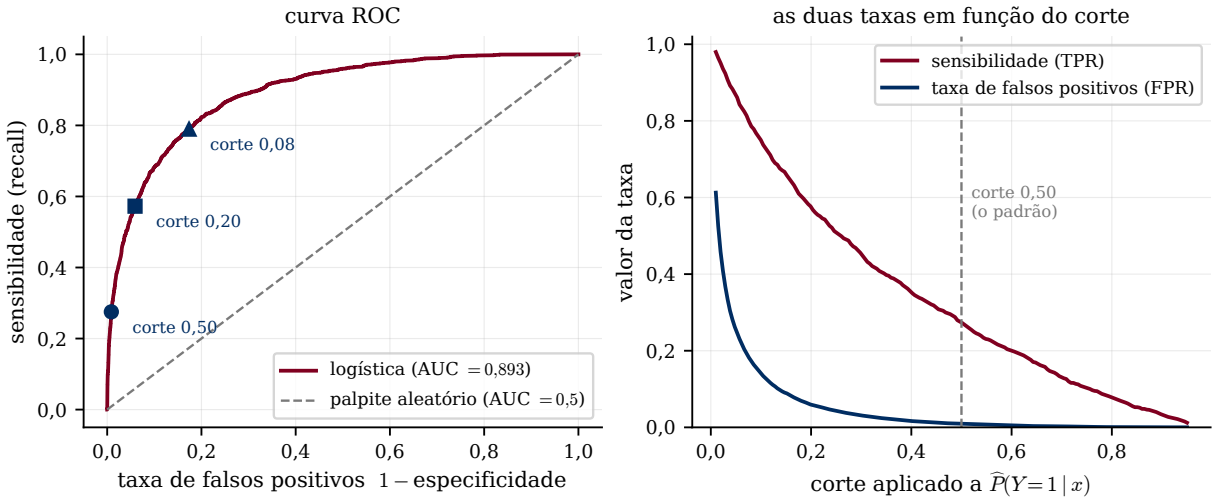


Figura 2: Uma regressão logística ajustada a um problema com prevalência de 7,9% e avaliada em 20 000 observações novas. À esquerda, a curva ROC: cada ponto é um corte diferente aplicado ao mesmo modelo. À direita, a sensibilidade (TPR) e a taxa de falsos positivos (FPR) em função do corte: as duas diminuem quando o corte sobe. No corte padrão, 0,50, a sensibilidade é de só 0,27, porque poucas observações chegam a essa probabilidade, e a taxa de falsos positivos fica abaixo de 0,01. A acurácia nesse corte é 0,935, contra 0,921 do classificador que declara todos negativos: o modelo inteiro rende 1,4 ponto percentual de acurácia, e a acurácia não é a medida adequada a este problema.

- a **AUC** (*area under the curve*) é a área sob a curva, um número entre 0 e 1. A curva do classificador perfeito passa pelo canto $(0, 1)$ e deixa abaixo de si o quadrado unitário inteiro, com AUC $= 1$; a diagonal deixa um triângulo, com AUC $= 1/2$.

Fixados os custos, o corte a usar é o da Proposição 3.1, com $\widehat{\eta}$ no lugar de η; a curva ROC mostra o que cada um dos outros cortes daria, e a AUC resume num número o desempenho do modelo ao longo de todos eles.

Atenção

A curva ROC também deve ser estimada numa amostra de teste: no treino, as duas taxas saem otimistas, como o erro de treino, que subestima o risco (Aula 03).

Resumo

- A acurácia soma os dois erros num número só; numa classe rara, o classificador trivial já tem acurácia alta (Fig. 2).
- A matriz de confusão (Fig. 1) estima a sensibilidade (TPR) e a especificidade ($1 - \text{FPR}$), que não dependem da prevalência.
- Com custos ℓ_0 e ℓ_1, o corte ótimo é $\ell_1/(\ell_0 + \ell_1)$ (Prop. 3.1).
- A curva ROC traça a TPR contra a FPR à medida que o corte varia, e a AUC é a área sob ela.

Leitura recomendada. [AME] §7.4 (a matriz de confusão e as medidas derivadas dela) e §9.1 (perdas assimétricas e cortes, de onde vem a nossa Prop. 3.1, e a curva ROC). [ISLP] §4.4.2: a matriz de confusão, a curva ROC e a AUC no exemplo do `Default` (Figura 4.8), e as Tabelas 4.6 e 4.7.