

Aula 08 — Métricas para Classificação

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §7.4 e cap. 9; ISLP §4.4–4.5

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- explicar por que a acurácia pode ser uma medida enganosa, quando uma das classes é rara ou quando os dois tipos de erro têm custos diferentes;
- construir a **matriz de confusão**, definir sensibilidade, especificidade, precisão, valor preditivo negativo e F_1 como estimativas de probabilidades, e escrever o risco em termos das taxas de erro de cada classe;
- deduzir o **corte ótimo** de um classificador *plug-in* sob uma perda assimétrica;
- definir a **curva ROC**, interpretar a **AUC** e reconhecer quando a curva precisão–revocação informa mais;
- comparar as estratégias para dados desbalanceados: mover o corte, reponderar e reamostrar;
- distinguir *classificar bem* de *estimar bem probabilidades* e avaliar a calibração com regras de pontuação próprias.

A Aula 07 terminou com um aviso: a acurácia pode enganar. Esta aula desenvolve esse aviso a partir de uma pergunta simples:

numa população em que 1% das pessoas tem certa doença, um teste que declara todo mundo saudável acerta 99% das vezes. Ele é um bom teste?

Não é: ele não encontra doente nenhum. A acurácia, porém, não registra isso, porque soma num único número dois erros de natureza muito diferente. O que segue constrói medidas que separam esses erros e mostra como escolher entre elas conforme a pergunta que se quer responder.

1 Por que a acurácia não basta

Considere a classificação binária, com $Y \in \{0, 1\}$, e um classificador g . A Aula 07 avaliou g pelo risco 0–1,

$$R(g) = \mathbb{P}(g(\mathbf{X}) \neq Y),$$

cujo complemento, $1 - R(g)$, é a **acurácia**. Esse critério trata todo erro como igual, e há duas situações frequentes em que isso não serve.

- *Custos assimétricos*. Num exame de rastreamento, deixar de detectar um doente (um *falso negativo*) costuma ser muito mais grave que mandar um saudável para um exame confirmatório (um *falso positivo*). O risco 0–1 dá aos dois o mesmo peso.
- *Uma classe rara*. Se $\pi_1 = \mathbb{P}(Y = 1)$ é pequena, o classificador trivial $g \equiv 0$ tem risco π_1 e acurácia $1 - \pi_1$, alta, sem acertar positivo nenhum. Mais que isso: se as covariáveis informam pouco sobre Y , pode acontecer de $\mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}) < 1/2$ para todo $\mathbf{x}$, e então o próprio classificador de Bayes é $g \equiv 0$ ([AME] §9.1). Os métodos que aproximam o classificador de Bayes passam a aproximar o classificador trivial.

Atenção

O desbalanceamento, sozinho, não é um defeito do problema. Se os dois erros custam o mesmo, o classificador de Bayes minimiza exatamente o que interessa, a probabilidade de erro, por mais rara que seja uma das classes. A dificuldade aparece quando os custos diferem: o classificador de Bayes pesa os dois erros igualmente e deixa de ser o classificador desejado. As técnicas das Seções 3 a 5 são maneiras de levar esses custos em conta.

2 Matriz de confusão e métricas

Para avaliar um classificador g já construído, usa-se uma *amostra de teste* $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_m, Y_m)$: observações i.i.d. com a distribuição de $(\mathbf{X}, Y)$ e independentes dos dados usados para construir g . A classe $Y = 1$ é chamada de *positiva*; em geral, é a classe de interesse, como o doente ou a fraude. Cruzar o que g prediz com o valor verdadeiro produz quatro contagens,

$$VP = \#\{i : g(\mathbf{X}_i) = 1, Y_i = 1\}, \quad FP = \#\{i : g(\mathbf{X}_i) = 1, Y_i = 0\},$$

$$FN = \#\{i : g(\mathbf{X}_i) = 0, Y_i = 1\}, \quad VN = \#\{i : g(\mathbf{X}_i) = 0, Y_i = 0\},$$

os verdadeiros e falsos positivos e negativos, que se organizam na **matriz de confusão** da Figura 1. Os totais das colunas, $P = VP + FN$ e $N = FP + VN$, são os números de positivos e de negativos verdadeiros da amostra, e $P + N = m$.




Figura 1: A matriz de confusão, com o predito nas linhas e o verdadeiro nas colunas, como no [AME] (Tabela 7.1) e no [ISLP] (Tabela 4.6). Precisão e sensibilidade têm o mesmo numerador, VP, e denominadores diferentes: a precisão divide pelo total da linha, o que o classificador previu; a sensibilidade, pelo total da coluna, o que de fato era. O `confusion_matrix` do `scikit-learn` devolve a transposta desta tabela, com o verdadeiro nas linhas.

Cada medida desta seção é a estimativa de uma probabilidade sobre uma observação nova $(\mathbf{X}, Y)$, independente dos dados usados para construir g . As quatro principais condicionam ou

na classe verdadeira, ou na decisão:

$$\begin{aligned}
 \text{sensibilidade: } S &= \mathbb{P}(g(\mathbf{X}) = 1 \mid Y = 1), & \hat{S} &= \frac{VP}{P}, \\
 \text{especificidade: } E &= \mathbb{P}(g(\mathbf{X}) = 0 \mid Y = 0), & \hat{E} &= \frac{VN}{N}, \\
 \text{precisão: } VPP &= \mathbb{P}(Y = 1 \mid g(\mathbf{X}) = 1), & \widehat{VPP} &= \frac{VP}{VP + FP}, \\
 \text{valor preditivo negativo: } VPN &= \mathbb{P}(Y = 0 \mid g(\mathbf{X}) = 0), & \widehat{VPN} &= \frac{VN}{VN + FN}.
 \end{aligned}$$

Cada estimador é a proporção correspondente na amostra de teste: $\hat{S}$, por exemplo, é a fração de acertos entre os P positivos e, pela lei dos grandes números, converge para S à medida que o número de positivos cresce. A sensibilidade também se chama *revocação* (*recall*), e a precisão, *valor preditivo positivo*, daí a sigla VPP.

As duas primeiras condicionam na classe verdadeira e, por isso, não dependem da prevalência π_1 : mudar só a proporção de doentes, mantida a distribuição de $\mathbf{X}$ dentro de cada classe, não altera S nem E . As duas últimas condicionam na decisão e dependem de π_1 . Pelo teorema de Bayes,

$$VPP = \frac{\mathbb{P}(g(\mathbf{X}) = 1 \mid Y = 1) \pi_1}{\mathbb{P}(g(\mathbf{X}) = 1)} = \frac{S \pi_1}{S \pi_1 + (1 - E)(1 - \pi_1)}.$$

Exemplo 2.1 (Um bom teste numa doença rara). Um teste com sensibilidade e especificidade de 99%, aplicado a uma população em que $\pi_1 = 1\%$, tem

$$VPP = \frac{0,99 \cdot 0,01}{0,99 \cdot 0,01 + 0,01 \cdot 0,99} = \frac{1}{2} :$$

metade dos positivos que ele aponta é falsa. Com $\pi_1 = 0,1\%$, a precisão cai para cerca de 9%. O teste é o mesmo; o que mudou foi a raridade da doença.

Quando a classe positiva é rara, interessa ao mesmo tempo encontrar os positivos e não acusar negativos demais, isto é, ter sensibilidade e precisão altas. A **estatística** F_1 combina as duas pela média harmônica:

$$F_1 = \frac{2}{1/S + 1/VPP} = \frac{2S \cdot VPP}{S + VPP}, \quad \text{estimada por} \quad \hat{F}_1 = \frac{2VP}{2VP + FP + FN}. \quad (1)$$

A forma da direita, que sai de substituir $\hat{S}$ e $\widehat{VPP}$ na da esquerda, mostra que o F_1 não usa os verdadeiros negativos, que numa classe rara são a imensa maioria e diriam pouco. A média harmônica fica perto da menor das duas quantidades, e é por isso que ela é usada aqui. Um classificador que declara todo mundo positivo tem $S = 1$ e, se a prevalência é 2%, precisão 0,02: a média aritmética das duas seria 0,51, um valor respeitável para um classificador inútil, enquanto $F_1 = 2 \cdot 0,02/1,02 \approx 0,039$.

Atenção

Todas essas estimativas devem ser calculadas numa amostra independente da usada para construir g . No treino, elas superestimam o desempenho, pelo mesmo motivo que o erro de treino subestima o risco (Aula 03).

As taxas da curva ROC. Na curva ROC (Seção 4) e no `scikit-learn`, duas dessas quantidades aparecem com outro nome: a sensibilidade é a **taxa de verdadeiros positivos**, $TPR = S$, e o complemento da especificidade é a **taxa de falsos positivos**, $FPR = 1 - E$, isto é, a

probabilidade $\mathbb{P}(g(\mathbf{X}) = 1 \mid Y = 0)$ de acusar um negativo. Na amostra, elas são estimadas por VP/P e FP/N (a função `roc_curve` devolve justamente `fpr` e `tpr`). As duas dividem por um total de coluna; por isso, dados P e N , as duas estimativas reconstroem a matriz inteira:

$$VP = \widehat{TPR} \cdot P, \quad FN = (1 - \widehat{TPR}) P, \quad FP = \widehat{FPR} \cdot N, \quad VN = (1 - \widehat{FPR}) N.$$

É esse par que a curva ROC vai acompanhar.

Observação 2.2. Quem vem de testes de hipóteses já conhece as duas. Tome $Y = 0$ como a hipótese nula e a decisão $g(\mathbf{X}) = 1$ como sua rejeição: a FPR é a probabilidade do erro do tipo I, e a TPR, o poder do teste.

O risco em termos das taxas. Pela lei da probabilidade total, condicionando na classe verdadeira,

$$R(g) = \mathbb{P}(g(\mathbf{X}) \neq Y) = \pi_1 (1 - S) + (1 - \pi_1) (1 - E).$$

O risco é, portanto, uma média ponderada das taxas de erro das duas classes, a de falsos negativos, $1 - S$, e a de falsos positivos, $1 - E$, com pesos iguais às prevalências. Na amostra de teste vale a identidade análoga, agora exata:

$$\frac{FP + FN}{m} = \frac{P}{m} \cdot \frac{FN}{P} + \frac{N}{m} \cdot \frac{FP}{N}.$$

Numa doença rara, $\pi_1 \approx 0$, e o risco praticamente ignora a sensibilidade: é por isso que o classificador trivial parece bom.

Exemplo 2.3 (A doença rara em números). Numa amostra de teste com $m = 1000$ pacientes, dos quais $P = 10$ são doentes ([AME] §7.4), compare o classificador trivial $g_1 \equiv 0$ com um classificador hipotético g_2 , que encontra 8 dos 10 doentes e dá alarme falso para 40 dos 990 saudáveis:

g_1	$Y = 0$	$Y = 1$	g_2	$Y = 0$	$Y = 1$
0	990	10	0	950	2
1	0	0	1	40	8

As taxas de erro são $10/1000 = 0,010$ para g_1 e $42/1000 = 0,042$ para g_2 : pelo risco estimado, g_1 é melhor. As taxas por classe dizem outra coisa: $\hat{S} = 0$ para g_1 e $\hat{S} = 8/10 = 0,8$ para g_2 , ao custo de uma taxa de falsos positivos de $40/990 \approx 0,040$. A identidade acima explica a discrepância, $0,01 \cdot 1 + 0,99 \cdot 0 = 0,010$ e $0,01 \cdot 0,2 + 0,99 \cdot 0,040 \approx 0,042$: a sensibilidade que g_1 perde por inteiro entra no risco com peso 0,01.

3 Perdas assimétricas e o corte ótimo

Para levar em conta custos diferentes, atribua um custo $l_0 > 0$ a cada falso negativo e um custo $l_1 > 0$ a cada falso positivo. O índice indica a decisão tomada no erro: l_0 é o custo de decidir 0 quando $Y = 1$, e l_1 , o de decidir 1 quando $Y = 0$. O critério passa a ser o custo esperado

$$R_l(g) = l_1 \mathbb{P}(g(\mathbf{X}) = 1, Y = 0) + l_0 \mathbb{P}(g(\mathbf{X}) = 0, Y = 1) \quad (2)$$

([AME] §9.1). Com $l_0 = l_1 = 1$ ele volta a ser o risco 0–1. Em termos das taxas da seção anterior, $R_l(g) = l_0 \pi_1 (1 - S) + l_1 (1 - \pi_1) (1 - E)$: os custos corrigem os pesos que as prevalências davam aos dois erros.

Proposição 3.1 (Corte ótimo sob perda assimétrica). *Seja $\eta(\mathbf{x}) = \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$. O classificador*

$$g^*(\mathbf{x}) = \mathbf{1} \left\{ \eta(\mathbf{x}) > \frac{l_1}{l_0 + l_1} \right\}$$

minimiza (2) entre todos os classificadores.

Demonstração. Dado $\mathbf{X} = \mathbf{x}$, a decisão $g(\mathbf{x})$ está fixada e só Y é aleatório; por isso

$$\begin{aligned}\mathbb{P}(g(\mathbf{X}) = 1, Y = 0 \mid \mathbf{X} = \mathbf{x}) &= \mathbf{1}\{g(\mathbf{x}) = 1\} (1 - \eta(\mathbf{x})), \\ \mathbb{P}(g(\mathbf{X}) = 0, Y = 1 \mid \mathbf{X} = \mathbf{x}) &= \mathbf{1}\{g(\mathbf{x}) = 0\} \eta(\mathbf{x}).\end{aligned}$$

Tomando a esperança em $\mathbf{X}$,

$$R_l(g) = \mathbb{E}\left[l_1 (1 - \eta(\mathbf{X})) \mathbf{1}\{g(\mathbf{X}) = 1\} + l_0 \eta(\mathbf{X}) \mathbf{1}\{g(\mathbf{X}) = 0\}\right].$$

Para cada $\mathbf{x}$, o termo dentro da esperança vale $l_1(1 - \eta(\mathbf{x}))$ se $g(\mathbf{x}) = 1$ e $l_0 \eta(\mathbf{x})$ se $g(\mathbf{x}) = 0$. O primeiro é menor exatamente quando $l_1(1 - \eta(\mathbf{x})) < l_0 \eta(\mathbf{x})$, isto é, quando $\eta(\mathbf{x}) > l_1/(l_0 + l_1)$. Logo g^* minimiza o integrando em cada $\mathbf{x}$ e, portanto, a esperança. Nos pontos em que $\eta(\mathbf{x}) = l_1/(l_0 + l_1)$ as duas decisões custam o mesmo, e qualquer escolha ali também é ótima. $\square$

Com $l_0 = l_1$, o corte é $1/2$ e g^* é o classificador de Bayes da Aula 07. Se errar um positivo custa dez vezes mais que errar um negativo, $l_0 = 10 l_1$, o corte cai para $1/11 \approx 0,09$: basta uma probabilidade de 9% para chamar alguém de positivo. Só a razão l_0/l_1 importa, e o modelo não muda: as probabilidades estimadas são as mesmas, muda apenas o número com que elas são comparadas. Na prática, como η é desconhecida, o classificador *plug-in* usa uma estimativa $\hat{\eta}$ no lugar dela.

Observação 3.2 (Custos inversamente proporcionais às prevalências). Um caso particular aparece com frequência: $l_0 = 1 - \pi_1$ e $l_1 = \pi_1$, isto é, errar numa classe custa tanto quanto a frequência da *outra*. O corte ótimo vira $l_1/(l_0 + l_1) = \pi_1$, a própria prevalência ([AME] §9.1), e o custo esperado fica

$$R_l(g) = (1 - \pi_1) \pi_1 (1 - S) + \pi_1 (1 - \pi_1) (1 - E) = \pi_1(1 - \pi_1) (2 - S - E).$$

Minimizá-lo é o mesmo que maximizar $S + E$, o critério usado com a curva ROC na Seção 4. A Seção 5 mostra que reponderar as classes pelo inverso das frequências leva ao mesmo corte.

4 Escolhendo o corte: curva ROC e AUC

Um classificador *plug-in* usa uma estimativa $\hat{\eta}(\mathbf{x})$ de $\mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$ e um corte K ,

$$g_K(\mathbf{x}) = \mathbf{1}\{\hat{\eta}(\mathbf{x}) \geq K\},$$

e o corte pode ser escolhido depois de ajustado o modelo. Cada K dá um classificador, com sua taxa de verdadeiros positivos e sua taxa de falsos positivos, $\text{TPR}(K)$ e $\text{FPR}(K)$. A **curva ROC** (*Receiver Operating Characteristic*) é o conjunto desses pontos,

$$\{(\text{FPR}(K), \text{TPR}(K)) : K \in [0, 1]\},$$

isto é, a sensibilidade contra 1–especificidade à medida que o corte percorre $[0, 1]$. Na amostra de teste só os valores distintos de $\hat{\eta}(\mathbf{X}_i)$ importam como cortes, e a curva estimada é a poligonal que liga os pontos correspondentes.

As duas taxas diminuem ou ficam iguais quando K aumenta. De fato, se $K < K'$, todo $\mathbf{x}$ com $\hat{\eta}(\mathbf{x}) \geq K'$ também tem $\hat{\eta}(\mathbf{x}) \geq K$: o conjunto dos classificados como positivos só encolhe quando o corte sobe, de modo que VP e FP diminuem ou ficam iguais, enquanto P e N não dependem do corte. Descendo o corte de 1 a 0, as duas taxas crescem juntas: encontrar mais positivos, em geral, custa acusar mais negativos, e a curva mostra quanto se paga de uma pela outra. Propriedades:

- com K acima de todas as probabilidades estimadas, ninguém é classificado como positivo: ponto $(0, 0)$; com $K = 0$, todos são: ponto $(1, 1)$;

- o canto $(0, 1)$ corresponde a um classificador sem erro nenhum;
- a diagonal corresponde a decidir sem olhar $\mathbf{x}$: sortear $g = 1$ com probabilidade q , independentemente de $\mathbf{X}$, dá $\text{TPR} = \text{FPR} = q$;
- a **AUC** (*area under the curve*) resume a curva num número entre 0 e 1: o classificador perfeito tem $\text{AUC} = 1$, e o sorteio da diagonal, $\text{AUC} = 1/2$. Se Z_1 e Z_0 são os escores $\hat{\eta}$ de um positivo e de um negativo sorteados de forma independente,

$$\text{AUC} = \mathbb{P}(Z_1 > Z_0) + \frac{1}{2} \mathbb{P}(Z_1 = Z_0);$$

sem empates, é a probabilidade de o modelo dar escore maior ao positivo.




Figura 2: Uma regressão logística ajustada a um problema com prevalência de 7,9% e avaliada em 20 000 observações novas. À esquerda, a curva ROC: cada ponto é um corte diferente aplicado ao mesmo modelo. À direita, precisão, sensibilidade e F_1 em função do corte. No corte padrão, 0,50, a sensibilidade é muito baixa, porque poucas observações chegam a essa probabilidade; o F_1 é máximo perto de 0,23. A acurácia no corte 0,50 é 0,935, contra 0,921 do classificador que declara todos negativos: o modelo inteiro rende 1,4 ponto percentual de acurácia, e a acurácia não é a medida adequada a este problema.

Ideia central

A curva ROC e a AUC dependem de $\hat{\eta}$ apenas pela ordem que ela induz nas observações: trocar $\hat{\eta}$ por qualquer função estritamente crescente dela deixa a curva igual. Elas servem, portanto, para comparar a capacidade de ordenar de dois modelos antes de fixar custos. Para escolher o corte, use o da Proposição 3.1 se os custos forem conhecidos; na falta deles, um critério comum é maximizar $S + E$, que a Observação 3.2 mostrou equivaler a custos inversamente proporcionais às prevalências.

Atenção

A curva ROC também deve ser estimada numa amostra de teste. Em dados muito desbalanceados ela pode dar uma impressão otimista, porque a taxa de falsos positivos divide pelo número de negativos, que é enorme. Mil falsos positivos entre 50 000 negativos dão $\text{FPR} = 0,02$, quase nada no eixo horizontal; mas, se houver 110 verdadeiros positivos, a precisão é $110/1110 \approx 0,10$, e só um em cada dez alarmes é verdadeiro. A *curva precisão–revocação*, que traça a precisão contra a sensibilidade, registra esse custo e informa mais quando os positivos são raros.

5 Lidando com dados desbalanceados

Há três estratégias usuais, e as três podem ser lidas como maneiras de codificar custos.

Mover o corte

Para um classificador que estima η , basta trocar o corte $1/2$ pelo da Proposição 3.1, ou pela prevalência estimada, como na Observação 3.2. O modelo não é reajustado, nenhum dado é descartado e as probabilidades estimadas continuam valendo como probabilidades.

Reponderar Dar peso w_1 a cada observação positiva e w_0 a cada negativa na função objetivo do ajuste (o argumento `class_weight` do `scikit-learn`). É a saída natural para métodos que não estimam η ; para os que estimam, o efeito é conhecido, e vem a seguir.

Reamostrar Alterar a prevalência da amostra de treino, replicando positivos (*oversampling*; o SMOTE cria positivos sintéticos por interpolação) ou descartando negativos (*undersampling*).

Para um modelo probabilístico ajustado por máxima verossimilhança, como a regressão logística, o efeito de reponderar pode ser calculado. Para cada $\mathbf{x}$, a log-verossimilhança ponderada esperada, $w_1 \eta(\mathbf{x}) \log p + w_0 (1 - \eta(\mathbf{x})) \log(1 - p)$, é máxima em

$$p_w(\mathbf{x}) = \frac{w_1 \eta(\mathbf{x})}{w_1 \eta(\mathbf{x}) + w_0 (1 - \eta(\mathbf{x}))} \iff \frac{p_w(\mathbf{x})}{1 - p_w(\mathbf{x})} = \frac{w_1}{w_0} \cdot \frac{\eta(\mathbf{x})}{1 - \eta(\mathbf{x})},$$

como se vê igualando a zero a derivada em p . Se o modelo é flexível o bastante para conter p_w , o ajuste reponderado estima p_w , e não η : suas chances ficam multiplicadas por w_1/w_0 . (Na regressão logística, se η é logística, p_w também é, com o intercepto deslocado de $\log(w_1/w_0)$.) E classificar com $p_w(\mathbf{x}) > 1/2$ é o mesmo que classificar com $\eta(\mathbf{x}) > w_0/(w_0 + w_1)$: reponderar move o corte, mas pelo caminho de distorcer as probabilidades. Com pesos inversamente proporcionais às frequências de treino, $w_c \propto 1/n_c$ (o `class_weight="balanced"`), o corte implícito é $n_1/(n_0 + n_1)$, a prevalência da amostra, exatamente como na Observação 3.2.

Reamostrar tem o mesmo efeito por outro caminho. O modelo é ajustado numa amostra em que a prevalência é π'_1 , e não π_1 ; se a distribuição de $\mathbf{X}$ dentro de cada classe não muda, o teorema de Bayes diz que as chances que ele estima ficam multiplicadas por

$$\frac{\pi'_1/(1 - \pi'_1)}{\pi_1/(1 - \pi_1)}.$$

O SMOTE, por criar pontos novos, muda também a distribuição de $\mathbf{X}$ entre os positivos, e o efeito dele não é exatamente esse.

Atenção

Reponderar e reamostrar deslocam as probabilidades estimadas por um fator conhecido. Se você precisa delas como probabilidades da população original, para calcular um custo esperado ou comunicar um risco, é preciso desfazer esse fator, multiplicando as chances estimadas pelo seu inverso; mais simples é não mexer no treino e mover o corte. E não reamostre por reflexo: se os dois erros custam o mesmo, o classificador de Bayes, com corte $1/2$, já é o correto, por mais desbalanceados que sejam os dados.

6 Classificar bem $\neq$ estimar bem probabilidades

Para tomar a decisão, um classificador *plug-in* com corte K só precisa acertar de que lado do corte está $\eta(\mathbf{x})$: em todo $\mathbf{x}$ em que $\hat{\eta}(\mathbf{x}) - K$ e $\eta(\mathbf{x}) - K$ têm o mesmo sinal, g_K concorda com o classificador ótimo ([AME] §9.2). Isso pode acontecer com $\hat{\eta}$ muito longe de η , de modo que classificar bem não garante estimar bem as probabilidades.

Às vezes, porém, o que se quer são as próprias probabilidades: para ordenar casos por risco, para calcular o custo esperado de uma decisão quando os custos mudam de caso a caso, ou para comunicar um risco a alguém. Duas noções interessam então. A primeira é a **calibração**: $\hat{\eta}$ é calibrada se, entre as observações às quais atribui probabilidade p , a fração de positivos é p , isto é, $\mathbb{P}(Y = 1 \mid \hat{\eta}(\mathbf{X}) = p) = p$. A ferramenta visual correspondente é a **curva de calibração**: agrupam-se as observações de teste pela probabilidade predita e compara-se, em cada grupo, a média predita com a frequência observada de positivos. Um modelo calibrado fica sobre a diagonal.

A segunda é medir $\hat{\eta}$ com uma **regra de pontuação própria**: uma perda $s(p, y)$ cujo valor esperado, quando $Y \sim \text{Bernoulli}(\eta)$, é mínimo em $p = \eta$. As duas mais usadas, estimadas pela média na amostra de teste, são

- o **score de Brier**, $s(p, y) = (p - y)^2$, estimado por $\frac{1}{m} \sum_i (\hat{\eta}(\mathbf{X}_i) - Y_i)^2$;
- a **entropia cruzada** (*log-loss*), a log-verossimilhança negativa da Bernoulli, que é o que a regressão logística minimiza: $s(p, y) = -[y \log p + (1 - y) \log(1 - p)]$.

Para o Brier, a verificação ocupa uma linha: se $Y \sim \text{Bernoulli}(\eta)$,

$$\mathbb{E}[(p - Y)^2] = (p - \eta)^2 + \eta(1 - \eta),$$

mínimo em $p = \eta$. Tomando a esperança também em $\mathbf{X}$, o risco de Brier de $\hat{\eta}$ é

$$\mathbb{E}[(\hat{\eta}(\mathbf{X}) - Y)^2] = \mathbb{E}[(\hat{\eta}(\mathbf{X}) - \eta(\mathbf{X}))^2] + \mathbb{E}[\eta(\mathbf{X})(1 - \eta(\mathbf{X}))] :$$

o erro quadrático de $\hat{\eta}$ como estimador de η , mais uma parcela que não depende do modelo. É a decomposição da Aula 01 para a regressão, aplicada a $Y \in \{0, 1\}$, cuja função de regressão é η .

A acurácia e a AUC não são regras próprias. A primeira só vê de que lado do corte cai cada probabilidade; a segunda só vê a ordem, que não muda quando $\hat{\eta}$ é trocada por qualquer função estritamente crescente dela. Nenhuma das duas registra a má calibração. Por isso, ao escolher hiperparâmetros por validação cruzada (Aula 03), use o Brier ou a entropia cruzada quando o que importa são as probabilidades ([AME] §9.2).

Ideia central

A Figura 3 ilustra o título desta seção. Se o objetivo é só decidir, como aprovar ou não um crédito com um corte escolhido na validação, os dois modelos servem quase igualmente, e a AUC diz isso corretamente. Se o objetivo é usar o número, para calcular um custo esperado ou informar um risco, o Bayes ingênuo não serve, e só uma medida de calibração mostra isso. A métrica deve ser escolhida pela pergunta que se quer responder.

Observação 6.1. O descalibramento do Bayes ingênuo tem a causa vista na Aula 07: com covariáveis correlacionadas, o produto $\prod_j f(x_j \mid Y = c)$ conta a mesma evidência várias vezes, e as probabilidades saem empurradas para 0 e 1. Há correções feitas depois do ajuste: a escala de Platt, que ajusta uma regressão logística sobre os escores, e a regressão isotônica, que ajusta uma função crescente; o `scikit-learn` oferece as duas em `CalibratedClassifierCV`. Elas precisam de dados próprios, separados dos usados no ajuste, pelo mesmo motivo de sempre.

Resumo

- A acurácia soma os dois erros num número só; numa classe rara, o classificador trivial já tem acurácia alta (Fig. 2).




Figura 3: Curvas de calibração de dois modelos num problema com covariáveis fortemente correlacionadas, em que a hipótese do Bayes ingênuo é falsa (prevalência de 7,9%; 20 000 observações de teste, agrupadas em dez faixas com o mesmo número de observações). Os dois modelos ordenam as observações quase igual, com AUC de 0,774 e 0,776, mas o Bayes ingênuo atribui em média 0,98 à faixa mais alta, em que só 29% são positivos. O score de Brier (0,065 para a logística, 0,152 para o Bayes ingênuo, mais que o dobro) e a entropia cruzada (0,237 contra 0,698) registram a diferença que a AUC não vê.

- A matriz de confusão (Fig. 1) estima sensibilidade e especificidade, que condicionam na classe verdadeira e não dependem da prevalência, e precisão e VPN, que condicionam na decisão e dependem dela; o F_1 (1) é a média harmônica de sensibilidade e precisão. O risco 0–1 é a média das taxas de erro das duas classes, ponderada pelas prevalências.
- Com custos l_0 e l_1 , o corte ótimo é $l_1/(l_0 + l_1)$ (Prop. 3.1); custos inversamente proporcionais às prevalências levam ao corte π_1 e a maximizar $S + E$.
- A curva ROC traça TPR contra FPR à medida que o corte varia; ela e a AUC dependem só da ordem dada pelo modelo. Com positivos raros, a curva precisão–revocação informa mais.
- Mover o corte, reponderar e reamostrar são maneiras de codificar custos; as duas últimas deslocam as probabilidades estimadas por um fator conhecido.
- Classificar bem não é estimar bem probabilidades (Fig. 3): para avaliar probabilidades, use a calibração e regras de pontuação próprias, como o Brier e a entropia cruzada.

Leitura recomendada. [AME] §7.4 (a matriz de confusão e as medidas derivadas dela), §9.1 (perdas assimétricas, cortes e dados desbalanceados, de onde vêm a nossa Prop. 3.1 e a Observação 3.2) e §9.2 (classificação *versus* estimação de probabilidades, o tema da Figura 3). [ISLP] §4.4.2: a matriz de confusão no exemplo do `Default`, com uma discussão concreta de sensibilidade numa classe rara, a curva ROC e a AUC (Figura 4.8), e as Tabelas 4.6 e 4.7, que reúnem os nomes das medidas.

Para praticar. `Lista teorica 08.pdf` (teórica, com gabarito) e `Lista prática 08.ipynb` (prática, para completar as lacunas), nesta mesma pasta.