Aula 08 — Métricas para Classificação

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §7.4 e cap. 9; ISLP §4.4–4.5

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- explicar por que a acurácia pode ser uma medida enganosa, quando uma das classes é rara ou quando os dois tipos de erro têm custos diferentes;
- construir a **matriz de confusão**, definir sensibilidade, especificidade, precisão, valor preditivo negativo e F_1 como estimativas de probabilidades, e escrever o risco em termos das taxas de erro de cada classe;
- deduzir o **corte ótimo** de um classificador *plug-in* sob uma perda assimétrica;
- definir a **curva ROC**, interpretar a **AUC** e reconhecer quando a curva precisão–revocação informa mais;
- comparar as estratégias para dados desbalanceados: mover o corte, reponderar e reamostrar;
- distinguir *classificar bem* de *estimar bem probabilidades* e avaliar a calibração com regras de pontuação próprias.

A Aula 07 terminou com um aviso: a acurácia pode enganar. Esta aula desenvolve esse aviso a partir de uma pergunta simples:

> *numa população em que* 1% *das pessoas tem certa doença, um teste que declara todo mundo saudável acerta* 99% *das vezes. Ele é um bom teste?*

Não é: ele não encontra doente nenhum. A acurácia, porém, não registra isso, porque soma num único número dois erros de natureza muito diferente. O que segue constrói medidas que separam esses erros e mostra como escolher entre elas conforme a pergunta que se quer responder.

1 Por que a acurácia não basta

Considere a classificação binária, com $Y \in \{0, 1\}$, e um classificador g. A Aula 07 avaliou g pelo risco 0–1,

$$R(g) = \mathbb{P}\big(g(\boldsymbol{X}) \neq Y\big),$$

cujo complemento, $1 - R(g)$, é a **acurácia**. Esse critério trata todo erro como igual, e há duas situações frequentes em que isso não serve.

- *Custos assimétricos.* Num exame de rastreamento, deixar de detectar um doente (um *falso negativo*) costuma ser muito mais grave que mandar um saudável para um exame confirmatório (um *falso positivo*). O risco 0–1 dá aos dois o mesmo peso.
- *Uma classe rara.* Se $\pi_1 = \mathbb{P}(Y = 1)$ é pequena, o classificador trivial $g \equiv 0$ tem risco π_1 e acurácia $1 - \pi_1$, alta, sem acertar positivo nenhum. Mais que isso: se as covariáveis informam pouco sobre Y, pode acontecer de $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) < 1/2$ para todo $\boldsymbol{x}$, e então o próprio classificador de Bayes é $g \equiv 0$ ([AME] §9.1). Os métodos que aproximam o classificador de Bayes passam a aproximar o classificador trivial.

Atenção

O desbalanceamento, sozinho, não é um defeito do problema. Se os dois erros custam o mesmo, o classificador de Bayes minimiza exatamente o que interessa, a probabilidade de erro, por mais rara que seja uma das classes. A dificuldade aparece quando os custos diferem: o classificador de Bayes pesa os dois erros igualmente e deixa de ser o classificador desejado. As técnicas das Seções 3 a 5 são maneiras de levar esses custos em conta.

2 Matriz de confusão e métricas

Para avaliar um classificador g já construído, usa-se uma *amostra de teste* $(\boldsymbol{X}_1, Y_1), \ldots, (\boldsymbol{X}_m, Y_m)$: observações i.i.d. com a distribuição de $(\boldsymbol{X}, Y)$ e independentes dos dados usados para construir g. A classe $Y = 1$ é chamada de *positiva*; em geral, é a classe de interesse, como o doente ou a fraude. Cruzar o que g prediz com o valor verdadeiro produz quatro contagens,

$$\mathrm{VP} = \#\{i : g(\boldsymbol{X}_i) = 1,\ Y_i = 1\}, \qquad \mathrm{FP} = \#\{i : g(\boldsymbol{X}_i) = 1,\ Y_i = 0\},$$

$$\mathrm{FN} = \#\{i : g(\boldsymbol{X}_i) = 0,\ Y_i = 1\}, \qquad \mathrm{VN} = \#\{i : g(\boldsymbol{X}_i) = 0,\ Y_i = 0\},$$

os verdadeiros e falsos positivos e negativos, que se organizam na **matriz de confusão** da Figura 1. Os totais das colunas, $P = \mathrm{VP} + \mathrm{FN}$ e $N = \mathrm{FP} + \mathrm{VN}$, são os números de positivos e de negativos verdadeiros da amostra, e $P + N = m$.

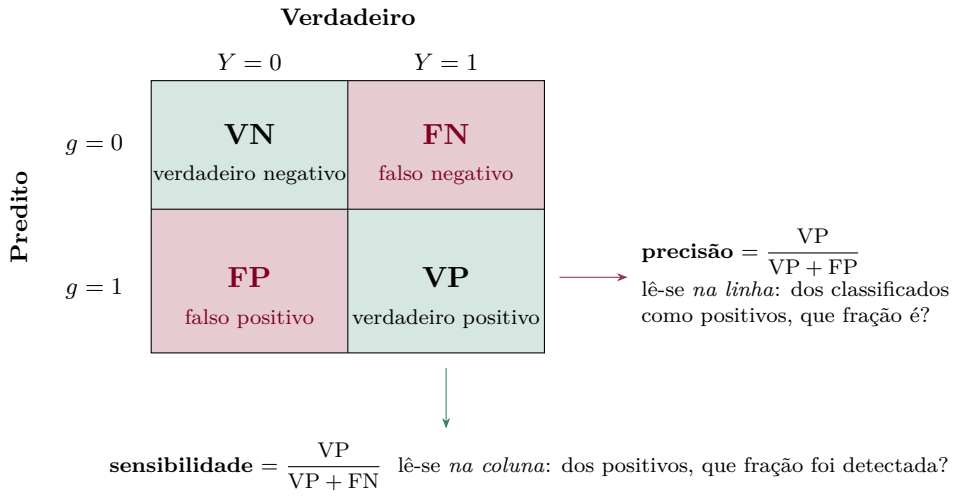


Figura 1: A matriz de confusão, com o predito nas linhas e o verdadeiro nas colunas, como no [AME] (Tabela 7.1) e no [ISLP] (Tabela 4.6). Precisão e sensibilidade têm o mesmo numerador, VP, e denominadores diferentes: a precisão divide pelo total da linha, o que o classificador previu; a sensibilidade, pelo total da coluna, o que de fato era. O `confusion_matrix` do `scikit-learn` devolve a transposta desta tabela, com o verdadeiro nas linhas.

Cada medida desta seção é a estimativa de uma probabilidade sobre uma observação nova $(\boldsymbol{X}, Y)$, independente dos dados usados para construir g. As quatro principais condicionam ou

na classe verdadeira, ou na decisão:

$$\begin{aligned}
\text{sensibilidade:} \quad & S = \mathbb{P}\big(g(\boldsymbol{X}) = 1 \mid Y = 1\big), && \widehat{S} = \frac{\mathrm{VP}}{P}, \\
\text{especificidade:} \quad & E = \mathbb{P}\big(g(\boldsymbol{X}) = 0 \mid Y = 0\big), && \widehat{E} = \frac{\mathrm{VN}}{N}, \\
\text{precisão:} \quad & \mathrm{VPP} = \mathbb{P}\big(Y = 1 \mid g(\boldsymbol{X}) = 1\big), && \widehat{\mathrm{VPP}} = \frac{\mathrm{VP}}{\mathrm{VP} + \mathrm{FP}}, \\
\text{valor preditivo negativo:} \quad & \mathrm{VPN} = \mathbb{P}\big(Y = 0 \mid g(\boldsymbol{X}) = 0\big), && \widehat{\mathrm{VPN}} = \frac{\mathrm{VN}}{\mathrm{VN} + \mathrm{FN}}.
\end{aligned}$$

Cada estimador é a proporção correspondente na amostra de teste: $\widehat{S}$, por exemplo, é a fração de acertos entre os P positivos e, pela lei dos grandes números, converge para S à medida que o número de positivos cresce. A sensibilidade também se chama *revocação* (*recall*), e a precisão, *valor preditivo positivo*, daí a sigla VPP.

As duas primeiras condicionam na classe verdadeira e, por isso, não dependem da prevalência π_1: mudar só a proporção de doentes, mantida a distribuição de $\boldsymbol{X}$ dentro de cada classe, não altera S nem E. As duas últimas condicionam na decisão e dependem de π_1. Pelo teorema de Bayes,

$$\mathrm{VPP} = \frac{\mathbb{P}\big(g(\boldsymbol{X}) = 1 \mid Y = 1\big)\,\pi_1}{\mathbb{P}\big(g(\boldsymbol{X}) = 1\big)} = \frac{S\,\pi_1}{S\,\pi_1 + (1 - E)\,(1 - \pi_1)}.$$

Exemplo 2.1 (Um bom teste numa doença rara)**.** Um teste com sensibilidade e especificidade de 99%, aplicado a uma população em que $\pi_1 = 1\%$, tem

$$\mathrm{VPP} = \frac{0{,}99 \cdot 0{,}01}{0{,}99 \cdot 0{,}01 + 0{,}01 \cdot 0{,}99} = \frac{1}{2}:$$

metade dos positivos que ele aponta é falsa. Com $\pi_1 = 0{,}1\%$, a precisão cai para cerca de 9%. O teste é o mesmo; o que mudou foi a raridade da doença.

Quando a classe positiva é rara, interessa ao mesmo tempo encontrar os positivos e não acusar negativos demais, isto é, ter sensibilidade e precisão altas. A **estatística** F_1 combina as duas pela média harmônica:

$$F_1 = \frac{2}{1/S + 1/\mathrm{VPP}} = \frac{2\,S \cdot \mathrm{VPP}}{S + \mathrm{VPP}}, \qquad \text{estimada por} \qquad \widehat{F}_1 = \frac{2\,\mathrm{VP}}{2\,\mathrm{VP} + \mathrm{FP} + \mathrm{FN}}. \tag{1}$$

A forma da direita, que sai de substituir $\widehat{S}$ e $\widehat{\mathrm{VPP}}$ na da esquerda, mostra que o F_1 não usa os verdadeiros negativos, que numa classe rara são a imensa maioria e diriam pouco. A média harmônica fica perto da menor das duas quantidades, e é por isso que ela é usada aqui. Um classificador que declara todo mundo positivo tem $S = 1$ e, se a prevalência é 2%, precisão 0,02: a média aritmética das duas seria 0,51, um valor respeitável para um classificador inútil, enquanto $F_1 = 2 \cdot 0{,}02/1{,}02 \approx 0{,}039$.

Atenção

Todas essas estimativas devem ser calculadas numa amostra independente da usada para construir g. No treino, elas superestimam o desempenho, pelo mesmo motivo que o erro de treino subestima o risco (Aula 03).

As taxas da curva ROC. Na curva ROC (Seção 4) e no `scikit-learn`, duas dessas quantidades aparecem com outro nome: a sensibilidade é a **taxa de verdadeiros positivos**, $\mathrm{TPR} = S$, e o complemento da especificidade é a **taxa de falsos positivos**, $\mathrm{FPR} = 1 - E$, isto é, a probabilidade $\mathbb{P}\big(g(\boldsymbol{X}) = 1 \mid Y = 0\big)$ de acusar um negativo. Na amostra, elas são estimadas por VP/P

e FP/N (a função `roc_curve` devolve justamente `fpr` e `tpr`). As duas dividem por um total de coluna; por isso, dados P e N, as duas estimativas reconstroem a matriz inteira:

$$\mathrm{VP} = \widehat{\mathrm{TPR}} \cdot P, \qquad \mathrm{FN} = \left(1 - \widehat{\mathrm{TPR}}\right) P, \qquad \mathrm{FP} = \widehat{\mathrm{FPR}} \cdot N, \qquad \mathrm{VN} = \left(1 - \widehat{\mathrm{FPR}}\right) N.$$

É esse par que a curva ROC vai acompanhar.

Observação 2.2. Quem vem de testes de hipóteses já conhece as duas. Tome $Y = 0$ como a hipótese nula e a decisão $g(\boldsymbol{X}) = 1$ como sua rejeição: a FPR é a probabilidade do erro do tipo I, e a TPR, o poder do teste.

O risco em termos das taxas. Pela lei da probabilidade total, condicionando na classe verdadeira,

$$R(g) = \mathbb{P}\big(g(\boldsymbol{X}) \neq Y\big) = \pi_1 \,(1 - S) + (1 - \pi_1)\,(1 - E).$$

O risco é, portanto, uma média ponderada das taxas de erro das duas classes, a de falsos negativos, $1 - S$, e a de falsos positivos, $1 - E$, com pesos iguais às prevalências. Na amostra de teste vale a identidade análoga, agora exata:

$$\frac{\mathrm{FP} + \mathrm{FN}}{m} = \frac{P}{m} \cdot \frac{\mathrm{FN}}{P} + \frac{N}{m} \cdot \frac{\mathrm{FP}}{N}.$$

Numa doença rara, $\pi_1 \approx 0$, e o risco praticamente ignora a sensibilidade: é por isso que o classificador trivial parece bom.

Exemplo 2.3 (A doença rara em números)**.** Numa amostra de teste com $m = 1000$ pacientes, dos quais $P = 10$ são doentes ([AME] §7.4), compare o classificador trivial $g_1 \equiv 0$ com um classificador hipotético g_2, que encontra 8 dos 10 doentes e dá alarme falso para 40 dos 990 saudáveis:

g_1	$Y=0$	$Y=1$
0	990	10
1	0	0

g_2	$Y=0$	$Y=1$
0	950	2
1	40	8

As taxas de erro são $10/1000 = 0{,}010$ para g_1 e $42/1000 = 0{,}042$ para g_2: pelo risco estimado, g_1 é melhor. As taxas por classe dizem outra coisa: $\widehat{S} = 0$ para g_1 e $\widehat{S} = 8/10 = 0{,}8$ para g_2, ao custo de uma taxa de falsos positivos de $40/990 \approx 0{,}040$. A identidade acima explica a discrepância, $0{,}01 \cdot 1 + 0{,}99 \cdot 0 = 0{,}010$ e $0{,}01 \cdot 0{,}2 + 0{,}99 \cdot 0{,}040 \approx 0{,}042$: a sensibilidade que g_1 perde por inteiro entra no risco com peso 0,01.

3 Perdas assimétricas e o corte ótimo

Para levar em conta custos diferentes, atribua um custo $l_0 > 0$ a cada falso negativo e um custo $l_1 > 0$ a cada falso positivo. O índice indica a decisão tomada no erro: l_0 é o custo de decidir 0 quando $Y = 1$, e l_1, o de decidir 1 quando $Y = 0$. O critério passa a ser o custo esperado

$$R_l(g) = l_1\, \mathbb{P}\big(g(\boldsymbol{X}) = 1,\, Y = 0\big) + l_0\, \mathbb{P}\big(g(\boldsymbol{X}) = 0,\, Y = 1\big) \tag{2}$$

([AME] §9.1). Com $l_0 = l_1 = 1$ ele volta a ser o risco 0–1. Em termos das taxas da seção anterior, $R_l(g) = l_0\, \pi_1\,(1 - S) + l_1\,(1 - \pi_1)\,(1 - E)$: os custos corrigem os pesos que as prevalências davam aos dois erros.

Proposição 3.1 (Corte ótimo sob perda assimétrica)**.** *Seja* $\eta(\boldsymbol{x}) = \mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$*. O classificador*

$$g^*(\boldsymbol{x}) = \mathbf{1}\Big\{\ \eta(\boldsymbol{x}) > \tfrac{l_1}{l_0 + l_1}\ \Big\}$$

minimiza (2) *entre todos os classificadores.*

Demonstração. Dado $\boldsymbol{X} = \boldsymbol{x}$, a decisão $g(\boldsymbol{x})$ está fixada e só Y é aleatório; por isso

$$\mathbb{P}(g(\boldsymbol{X}) = 1,\, Y = 0 \mid \boldsymbol{X} = \boldsymbol{x}) = \mathbf{1}\{g(\boldsymbol{x}) = 1\}\ (1 - \eta(\boldsymbol{x})),$$
$$\mathbb{P}(g(\boldsymbol{X}) = 0,\, Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) = \mathbf{1}\{g(\boldsymbol{x}) = 0\}\ \eta(\boldsymbol{x}).$$

Tomando a esperança em $\boldsymbol{X}$,

$$R_l(g) = \mathbb{E}\Big[\, l_1\,(1 - \eta(\boldsymbol{X}))\,\mathbf{1}\{g(\boldsymbol{X}) = 1\} + l_0\,\eta(\boldsymbol{X})\,\mathbf{1}\{g(\boldsymbol{X}) = 0\}\,\Big].$$

Para cada $\boldsymbol{x}$, o termo dentro da esperança vale $l_1(1 - \eta(\boldsymbol{x}))$ se $g(\boldsymbol{x}) = 1$ e $l_0\,\eta(\boldsymbol{x})$ se $g(\boldsymbol{x}) = 0$. O primeiro é menor exatamente quando $l_1(1 - \eta(\boldsymbol{x})) < l_0\,\eta(\boldsymbol{x})$, isto é, quando $\eta(\boldsymbol{x}) > l_1/(l_0 + l_1)$. Logo g^* minimiza o integrando em cada $\boldsymbol{x}$ e, portanto, a esperança. Nos pontos em que $\eta(\boldsymbol{x}) = l_1/(l_0 + l_1)$ as duas decisões custam o mesmo, e qualquer escolha ali também é ótima. □

Com $l_0 = l_1$, o corte é $1/2$ e g^* é o classificador de Bayes da Aula 07. Se errar um positivo custa dez vezes mais que errar um negativo, $l_0 = 10\,l_1$, o corte cai para $1/11 \approx 0{,}09$: basta uma probabilidade de 9% para chamar alguém de positivo. Só a razão l_0/l_1 importa, e o modelo não muda: as probabilidades estimadas são as mesmas, muda apenas o número com que elas são comparadas. Na prática, como η é desconhecida, o classificador *plug-in* usa uma estimativa $\widehat{\eta}$ no lugar dela.

Observação 3.2 (Custos inversamente proporcionais às prevalências)**.** Um caso particular aparece com frequência: $l_0 = 1 - \pi_1$ e $l_1 = \pi_1$, isto é, errar numa classe custa tanto quanto a frequência da *outra*. O corte ótimo vira $l_1/(l_0 + l_1) = \pi_1$, a própria prevalência ([AME] §9.1), e o custo esperado fica

$$R_l(g) = (1 - \pi_1)\,\pi_1\,(1 - S) + \pi_1\,(1 - \pi_1)\,(1 - E) = \pi_1(1 - \pi_1)\,(2 - S - E).$$

Minimizá-lo é o mesmo que maximizar $S + E$, o critério usado com a curva ROC na Seção 4. A Seção 5 mostra que reponderar as classes pelo inverso das frequências leva ao mesmo corte.

4 Escolhendo o corte: curva ROC e AUC

Um classificador *plug-in* usa uma estimativa $\widehat{\eta}(\boldsymbol{x})$ de $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x})$ e um corte K,

$$g_K(\boldsymbol{x}) = \mathbf{1}\{\widehat{\eta}(\boldsymbol{x}) \geq K\}\,,$$

e o corte pode ser escolhido depois de ajustado o modelo. Cada K dá um classificador, com sua taxa de verdadeiros positivos e sua taxa de falsos positivos, $\mathrm{TPR}(K)$ e $\mathrm{FPR}(K)$. A **curva ROC** (*Receiver Operating Characteristic*) é o conjunto desses pontos,

$$\{\,(\mathrm{FPR}(K),\ \mathrm{TPR}(K)) : K \in [0, 1]\,\},$$

isto é, a sensibilidade contra 1−especificidade à medida que o corte percorre $[0, 1]$. Na amostra de teste só os valores distintos de $\widehat{\eta}(\boldsymbol{X}_i)$ importam como cortes, e a curva estimada é a poligonal que liga os pontos correspondentes.

As duas taxas diminuem ou ficam iguais quando K aumenta. De fato, se $K < K'$, todo $\boldsymbol{x}$ com $\widehat{\eta}(\boldsymbol{x}) \geq K'$ também tem $\widehat{\eta}(\boldsymbol{x}) \geq K$: o conjunto dos classificados como positivos só encolhe quando o corte sobe, de modo que VP e FP diminuem ou ficam iguais, enquanto P e N não dependem do corte. Descendo o corte de 1 a 0, as duas taxas crescem juntas: encontrar mais positivos, em geral, custa acusar mais negativos, e a curva mostra quanto se paga de uma pela outra. Propriedades:

- com K acima de todas as probabilidades estimadas, ninguém é classificado como positivo: ponto $(0, 0)$; com $K = 0$, todos são: ponto $(1, 1)$;

- o canto $(0, 1)$ corresponde a um classificador sem erro nenhum;
- a diagonal corresponde a decidir sem olhar $\boldsymbol{x}$: sortear $g = 1$ com probabilidade q, independentemente de $\boldsymbol{X}$, dá $\mathrm{TPR} = \mathrm{FPR} = q$;
- a **AUC** (*area under the curve*) resume a curva num número entre 0 e 1: o classificador perfeito tem $\mathrm{AUC} = 1$, e o sorteio da diagonal, $\mathrm{AUC} = 1/2$. Se Z_1 e Z_0 são os escores $\widehat{\eta}$ de um positivo e de um negativo sorteados de forma independente,

$$\mathrm{AUC} = \mathbb{P}(Z_1 > Z_0) + \tfrac{1}{2}\,\mathbb{P}(Z_1 = Z_0);$$

sem empates, é a probabilidade de o modelo dar escore maior ao positivo.

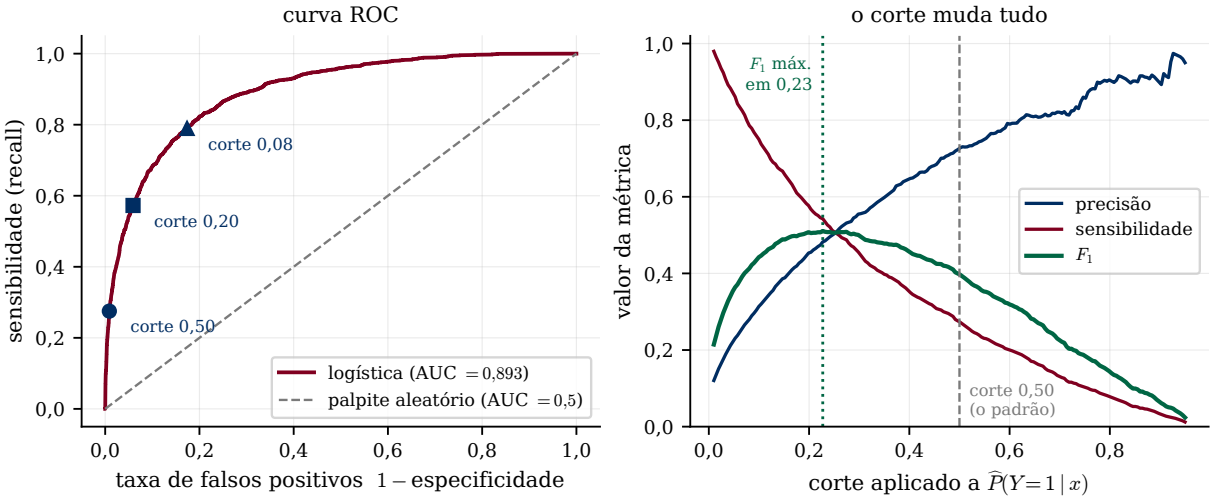


Figura 2: Uma regressão logística ajustada a um problema com prevalência de 7,9% e avaliada em 20 000 observações novas. À esquerda, a curva ROC: cada ponto é um corte diferente aplicado ao mesmo modelo. À direita, precisão, sensibilidade e F_1 em função do corte. No corte padrão, 0,50, a sensibilidade é muito baixa, porque poucas observações chegam a essa probabilidade; o F_1 é máximo perto de 0,23. A acurácia no corte 0,50 é 0,935, contra 0,921 do classificador que declara todos negativos: o modelo inteiro rende 1,4 ponto percentual de acurácia, e a acurácia não é a medida adequada a este problema.

Ideia central

A curva ROC e a AUC dependem de $\widehat{\eta}$ apenas pela ordem que ela induz nas observações: trocar $\widehat{\eta}$ por qualquer função estritamente crescente dela deixa a curva igual. Elas servem, portanto, para comparar a capacidade de ordenar de dois modelos antes de fixar custos. Para escolher o corte, use o da Proposição 3.1 se os custos forem conhecidos; na falta deles, um critério comum é maximizar $S + E$, que a Observação 3.2 mostrou equivaler a custos inversamente proporcionais às prevalências.

Atenção

A curva ROC também deve ser estimada numa amostra de teste. Em dados muito desbalanceados ela pode dar uma impressão otimista, porque a taxa de falsos positivos divide pelo número de negativos, que é enorme. Mil falsos positivos entre 50 000 negativos dão $\mathrm{FPR} = 0{,}02$, quase nada no eixo horizontal; mas, se houver 110 verdadeiros positivos, a precisão é $110/1110 \approx 0{,}10$, e só um em cada dez alarmes é verdadeiro. A *curva precisão–revocação*, que traça a precisão contra a sensibilidade, registra esse custo e informa mais quando os positivos são raros.

5 Lidando com dados desbalanceados

Há três estratégias usuais, e as três podem ser lidas como maneiras de codificar custos.

Mover o corte Para um classificador que estima η, basta trocar o corte $1/2$ pelo da Proposição 3.1, ou pela prevalência estimada, como na Observação 3.2. O modelo não é reajustado, nenhum dado é descartado e as probabilidades estimadas continuam valendo como probabilidades.

Reponderar Dar peso w_1 a cada observação positiva e w_0 a cada negativa na função objetivo do ajuste (o argumento `class_weight` do `scikit-learn`). É a saída natural para métodos que não estimam η; para os que estimam, o efeito é conhecido, e vem a seguir.

Reamostrar Alterar a prevalência da amostra de treino, replicando positivos (*oversampling*; o SMOTE cria positivos sintéticos por interpolação) ou descartando negativos (*undersampling*).

Para um modelo probabilístico ajustado por máxima verossimilhança, como a regressão logística, o efeito de reponderar pode ser calculado. Para cada $\boldsymbol{x}$, a log-verossimilhança ponderada esperada, $w_1\,\eta(\boldsymbol{x})\log p + w_0(1-\eta(\boldsymbol{x}))\log(1-p)$, é máxima em

$$p_w(\boldsymbol{x}) = \frac{w_1\,\eta(\boldsymbol{x})}{w_1\,\eta(\boldsymbol{x}) + w_0(1-\eta(\boldsymbol{x}))} \qquad \Longleftrightarrow \qquad \frac{p_w(\boldsymbol{x})}{1-p_w(\boldsymbol{x})} = \frac{w_1}{w_0}\cdot\frac{\eta(\boldsymbol{x})}{1-\eta(\boldsymbol{x})},$$

como se vê igualando a zero a derivada em p. Se o modelo é flexível o bastante para conter p_w, o ajuste reponderado estima p_w, e não η: suas chances ficam multiplicadas por w_1/w_0. (Na regressão logística, se η é logística, p_w também é, com o intercepto deslocado de $\log(w_1/w_0)$.) E classificar com $p_w(\boldsymbol{x}) > 1/2$ é o mesmo que classificar com $\eta(\boldsymbol{x}) > w_0/(w_0+w_1)$: reponderar move o corte, mas pelo caminho de distorcer as probabilidades. Com pesos inversamente proporcionais às frequências de treino, $w_c \propto 1/n_c$ (o `class_weight="balanced"`), o corte implícito é $n_1/(n_0+n_1)$, a prevalência da amostra, exatamente como na Observação 3.2.

Reamostrar tem o mesmo efeito por outro caminho. O modelo é ajustado numa amostra em que a prevalência é π_1', e não π_1; se a distribuição de $\boldsymbol{X}$ dentro de cada classe não muda, o teorema de Bayes diz que as chances que ele estima ficam multiplicadas por

$$\frac{\pi_1'/(1-\pi_1')}{\pi_1/(1-\pi_1)}.$$

O SMOTE, por criar pontos novos, muda também a distribuição de $\boldsymbol{X}$ entre os positivos, e o efeito dele não é exatamente esse.

Atenção

Reponderar e reamostrar deslocam as probabilidades estimadas por um fator conhecido. Se você precisa delas como probabilidades da população original, para calcular um custo esperado ou comunicar um risco, é preciso desfazer esse fator, multiplicando as chances estimadas pelo seu inverso; mais simples é não mexer no treino e mover o corte. E não reamostre por reflexo: se os dois erros custam o mesmo, o classificador de Bayes, com corte $1/2$, já é o correto, por mais desbalanceados que sejam os dados.

6 Classificar bem ≠ estimar bem probabilidades

Para tomar a decisão, um classificador *plug-in* com corte K só precisa acertar de que lado do corte está $\eta(\boldsymbol{x})$: em todo $\boldsymbol{x}$ em que $\widehat{\eta}(\boldsymbol{x}) - K$ e $\eta(\boldsymbol{x}) - K$ têm o mesmo sinal, g_K concorda com o classificador ótimo ([AME] §9.2). Isso pode acontecer com $\widehat{\eta}$ muito longe de η, de modo que classificar bem não garante estimar bem as probabilidades.

Às vezes, porém, o que se quer são as próprias probabilidades: para ordenar casos por risco, para calcular o custo esperado de uma decisão quando os custos mudam de caso a caso, ou para comunicar um risco a alguém. Duas noções interessam então. A primeira é a **calibração**: $\widehat{\eta}$ é calibrada se, entre as observações às quais atribui probabilidade p, a fração de positivos é p, isto é, $\mathbb{P}(Y = 1 \mid \widehat{\eta}(\boldsymbol{X}) = p) = p$. A ferramenta visual correspondente é a **curva de calibração**: agrupam-se as observações de teste pela probabilidade predita e compara-se, em cada grupo, a média predita com a frequência observada de positivos. Um modelo calibrado fica sobre a diagonal.

A segunda é medir $\widehat{\eta}$ com uma **regra de pontuação própria**: uma perda $s(p, y)$ cujo valor esperado, quando $Y \sim \text{Bernoulli}(\eta)$, é mínimo em $p = \eta$. As duas mais usadas, estimadas pela média na amostra de teste, são

- o **score de Brier**, $s(p, y) = (p - y)^2$, estimado por $\frac{1}{m}\sum_i \left(\widehat{\eta}(\boldsymbol{X}_i) - Y_i\right)^2$;
- a **entropia cruzada** (*log-loss*), a log-verossimilhança negativa da Bernoulli, que é o que a regressão logística minimiza: $s(p, y) = -\big[\, y \log p + (1 - y)\log(1 - p)\,\big]$.

Para o Brier, a verificação ocupa uma linha: se $Y \sim \text{Bernoulli}(\eta)$,

$$\mathbb{E}\big[(p - Y)^2\big] = (p - \eta)^2 + \eta\,(1 - \eta),$$

mínimo em $p = \eta$. Tomando a esperança também em $\boldsymbol{X}$, o risco de Brier de $\widehat{\eta}$ é

$$\mathbb{E}\big[(\widehat{\eta}(\boldsymbol{X}) - Y)^2\big] = \mathbb{E}\big[(\widehat{\eta}(\boldsymbol{X}) - \eta(\boldsymbol{X}))^2\big] + \mathbb{E}\big[\eta(\boldsymbol{X})(1 - \eta(\boldsymbol{X}))\big]\,:$$

o erro quadrático de $\widehat{\eta}$ como estimador de η, mais uma parcela que não depende do modelo. É a decomposição da Aula 01 para a regressão, aplicada a $Y \in \{0, 1\}$, cuja função de regressão é η.

A acurácia e a AUC não são regras próprias. A primeira só vê de que lado do corte cai cada probabilidade; a segunda só vê a ordem, que não muda quando $\widehat{\eta}$ é trocada por qualquer função estritamente crescente dela. Nenhuma das duas registra a má calibração. Por isso, ao escolher hiperparâmetros por validação cruzada (Aula 03), use o Brier ou a entropia cruzada quando o que importa são as probabilidades ([AME] §9.2).

Ideia central

A Figura 3 ilustra o título desta seção. Se o objetivo é só decidir, como aprovar ou não um crédito com um corte escolhido na validação, os dois modelos servem quase igualmente, e a AUC diz isso corretamente. Se o objetivo é usar o número, para calcular um custo esperado ou informar um risco, o Bayes ingênuo não serve, e só uma medida de calibração mostra isso. A métrica deve ser escolhida pela pergunta que se quer responder.

Observação 6.1. O descalibramento do Bayes ingênuo tem a causa vista na Aula 07: com covariáveis correlacionadas, o produto $\prod_j f(x_j \mid Y = c)$ conta a mesma evidência várias vezes, e as probabilidades saem empurradas para 0 e 1. Há correções feitas depois do ajuste: a escala de Platt, que ajusta uma regressão logística sobre os escores, e a regressão isotônica, que ajusta uma função crescente; o `scikit-learn` oferece as duas em `CalibratedClassifierCV`. Elas precisam de dados próprios, separados dos usados no ajuste, pelo mesmo motivo de sempre.

Resumo

- A acurácia soma os dois erros num número só; numa classe rara, o classificador trivial já tem acurácia alta (Fig. 2).

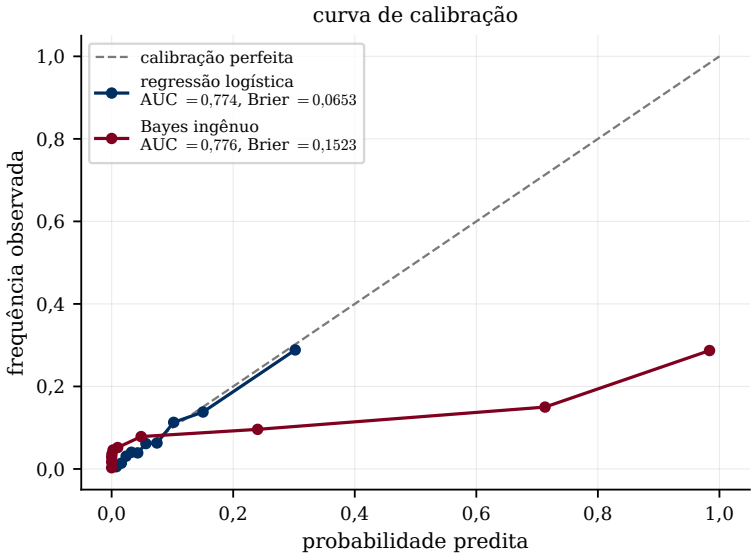


Figura 3: Curvas de calibração de dois modelos num problema com covariáveis fortemente correlacionadas, em que a hipótese do Bayes ingênuo é falsa (prevalência de 7,9%; 20 000 observações de teste, agrupadas em dez faixas com o mesmo número de observações). Os dois modelos ordenam as observações quase igual, com AUC de 0,774 e 0,776, mas o Bayes ingênuo atribui em média 0,98 à faixa mais alta, em que só 29% são positivos. O score de Brier (0,065 para a logística, 0,152 para o Bayes ingênuo, mais que o dobro) e a entropia cruzada (0,237 contra 0,698) registram a diferença que a AUC não vê.

- A matriz de confusão (Fig. 1) estima sensibilidade e especificidade, que condicionam na classe verdadeira e não dependem da prevalência, e precisão e VPN, que condicionam na decisão e dependem dela; o F_1 (1) é a média harmônica de sensibilidade e precisão. O risco 0–1 é a média das taxas de erro das duas classes, ponderada pelas prevalências.
- Com custos l_0 e l_1, o corte ótimo é $l_1/(l_0 + l_1)$ (Prop. 3.1); custos inversamente proporcionais às prevalências levam ao corte π_1 e a maximizar $S + E$.
- A curva ROC traça TPR contra FPR à medida que o corte varia; ela e a AUC dependem só da ordem dada pelo modelo. Com positivos raros, a curva precisão–revocação informa mais.
- Mover o corte, reponderar e reamostrar são maneiras de codificar custos; as duas últimas deslocam as probabilidades estimadas por um fator conhecido.
- Classificar bem não é estimar bem probabilidades (Fig. 3): para avaliar probabilidades, use a calibração e regras de pontuação próprias, como o Brier e a entropia cruzada.

Leitura recomendada. [AME] §7.4 (a matriz de confusão e as medidas derivadas dela), §9.1 (perdas assimétricas, cortes e dados desbalanceados, de onde vêm a nossa Prop. 3.1 e a Observação 3.2) e §9.2 (classificação *versus* estimação de probabilidades, o tema da Figura 3). [ISLP] §4.4.2: a matriz de confusão no exemplo do `Default`, com uma discussão concreta de sensibilidade numa classe rara, a curva ROC e a AUC (Figura 4.8), e as Tabelas 4.6 e 4.7, que reúnem os nomes das medidas.

Para praticar. `Lista teorica 08.pdf` (teórica, com gabarito) e `Lista prática 08.ipynb` (prática, para completar as lacunas), nesta mesma pasta.