Aula 08 — Métricas para Classificação

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §7.4 e §9.1; ISLP §4.4.2

Objetivos da aula

Ao final desta aula o aluno deve ser capaz de:

- explicar por que a *acurácia* é insuficiente quando uma classe é rara ou quando os erros têm custos diferentes;
- ler uma **matriz de confusão** e definir sensibilidade, especificidade, TPR e FPR como estimativas de probabilidades;
- formular **perdas assimétricas** e deduzir o *corte ótimo* de um classificador *plug-in*;
- construir e interpretar a **curva ROC** e a **AUC**.

Em sala

Continuação direta da Aula 07: lá vimos que o classificador de Bayes minimiza a probabilidade de erro, mas a probabilidade de erro nem sempre é o que importa. Pergunta de abertura: *"numa população em que* 1% *tem certa doença, um teste que declara todo mundo saudável acerta* 99% *das vezes. Ele é um bom teste?"*

1 Por que a acurácia não basta

Com $Y \in \{0, 1\}$ e o risco 0–1 da Aula 07, $R(g) = \mathbb{P}(g(\boldsymbol{X}) \neq Y)$, a **acurácia** é $1 - R(g)$. Ela trata todo erro como igual, o que falha em dois casos:

- **custos assimétricos:** num rastreamento, um falso negativo costuma ser muito pior que um falso positivo;
- **classe rara:** com $\pi_1 = \mathbb{P}(Y = 1)$ pequena, $g \equiv 0$ tem risco π_1 e acurácia $1 - \pi_1$ sem acertar positivo nenhum. Se, além disso, $\mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{x}) < 1/2$ para todo $\boldsymbol{x}$, o próprio classificador de Bayes é $g \equiv 0$ ([AME] §9.1).

Atenção

O desbalanceamento, sozinho, não é o problema: com custos iguais, o classificador de Bayes continua minimizando o que interessa. O problema são os custos diferentes, e a Seção 3 mostra como levá-los em conta.

2 Matriz de confusão e métricas

Fixado g, avaliamos numa amostra de teste $(\boldsymbol{X}_1, Y_1), \ldots, (\boldsymbol{X}_m, Y_m)$, i.i.d. e independente dos dados de treino, com $Y = 1$ a classe positiva:

		Verdadeiro	
		$Y=0$	$Y=1$
Predito	$g=0$	VN (verd. neg.)	FN (falso neg.)
	$g=1$	FP (falso pos.)	VP (verd. pos.)
	total	N	P

O `confusion_matrix` do `scikit-learn` devolve a transposta desta tabela, com o verdadeiro nas linhas. Os totais das colunas são os P positivos e os N negativos verdadeiros. Cada medida estima uma probabilidade sobre uma observação nova $(\boldsymbol{X}, Y)$:

$$\begin{aligned} \text{sensibilidade:} \quad & S = \mathbb{P}(g(\boldsymbol{X})=1 \mid Y=1), && \widehat{S} = \mathrm{VP}/P, \\ \text{especificidade:} \quad & E = \mathbb{P}(g(\boldsymbol{X})=0 \mid Y=0), && \widehat{E} = \mathrm{VN}/N. \end{aligned}$$

As duas condicionam na classe verdadeira e não dependem da prevalência $\pi_1 = \mathbb{P}(Y=1)$: com g fixado, cada uma só depende da distribuição de $\boldsymbol{X}$ dentro de uma classe.

Atenção

Todas essas estimativas se fazem no conjunto de *teste*, nunca no treino (Aula 03).

Na ROC e no `scikit-learn` (a `roc_curve` devolve `fpr` e `tpr`), S é a **taxa de verdadeiros positivos**, TPR, e $1-E$ é a **taxa de falsos positivos**, FPR, estimadas por VP/P e FP/N; o complemento $1-S$ é a taxa de falsos negativos. Dados P e N, a TPR e a FPR reconstroem a matriz. Com $Y=0$ como hipótese nula e $g=1$ como rejeição, a FPR é a probabilidade do erro do tipo I e a TPR, o poder.

Em sala

O exemplo dos slides: 1000 pacientes, 10 doentes; o trivial $g_1 \equiv 0$ contra um g_2 com VP 8, FN 2, FP 40 e VN 950. Pergunte qual dos dois o risco prefere (0,010 contra 0,042: prefere g_1) e por quê: os 10 doentes que g_1 perde são só 1% dos pacientes, e os 40 alarmes falsos de g_2, 4%. As taxas por classe separam os dois erros: TPR 0 contra 0,8, FPR 0 contra $40/990 \approx 0{,}040$.

3 Perdas assimétricas e o corte ótimo

Atribua custo $\ell_0 > 0$ a cada falso negativo (decidir 0 quando $Y=1$) e $\ell_1 > 0$ a cada falso positivo (decidir 1 quando $Y=0$):

$$R_\ell(g) = \ell_1\,\mathbb{P}(g(\boldsymbol{X})=1,\, Y=0) + \ell_0\,\mathbb{P}(g(\boldsymbol{X})=0,\, Y=1). \tag{1}$$

Proposição 3.1 (Corte ótimo sob perda assimétrica)**.** *Com $\eta(\boldsymbol{x}) = \mathbb{P}(Y=1 \mid \boldsymbol{X}=\boldsymbol{x})$, o classificador $g^*(\boldsymbol{x}) = \mathbf{1}\left\{ \eta(\boldsymbol{x}) > \frac{\ell_1}{\ell_0+\ell_1} \right\}$ minimiza (1).*

Demonstração. Condicionando em $\boldsymbol{X}$,

$$R_\ell(g) = \mathbb{E}\Big[\, \ell_1(1-\eta(\boldsymbol{X}))\mathbf{1}\{g(\boldsymbol{X})=1\} + \ell_0\,\eta(\boldsymbol{X})\mathbf{1}\{g(\boldsymbol{X})=0\} \,\Big].$$

Para cada $\boldsymbol{x}$, decidir 1 custa $\ell_1(1-\eta(\boldsymbol{x}))$ e decidir 0 custa $\ell_0\,\eta(\boldsymbol{x})$; o primeiro é menor se e só se $\eta(\boldsymbol{x}) > \ell_1/(\ell_0+\ell_1)$. Minimizar o integrando em cada $\boldsymbol{x}$ minimiza a esperança; no empate, qualquer decisão é ótima. □

Ideia central

Mudar os custos muda o corte, não o modelo: as probabilidades estimadas são as mesmas. Com $\ell_0 = \ell_1$ o corte é $1/2$ (Bayes); com $\ell_0 = 10\,\ell_1$, é $1/11 \approx 0{,}09$. Só a razão ℓ_0/ℓ_1 importa.

Em sala

Pergunte: se deixar passar um doente custa dez vezes mais que um alarme falso, a partir de que probabilidade se deve chamar alguém de positivo? ($1/11$, cerca de 9%.)

4 Escolhendo o corte: curva ROC e AUC

Um classificador *plug-in* usa uma estimativa $\widehat{\eta}$ e um corte p_0: $g_{p_0}(\boldsymbol{x}) = \mathbf{1}\{\widehat{\eta}(\boldsymbol{x}) \geq p_0\}$. Cada p_0 dá um par $(\mathrm{FPR}(p_0), \mathrm{TPR}(p_0))$, e a **curva ROC** (*Receiver Operating Characteristic*) é o conjunto $\{(\mathrm{FPR}(p_0), \mathrm{TPR}(p_0)) : p_0 \in [0,1]\}$, a sensibilidade contra 1−especificidade à medida que o corte varia. As duas taxas diminuem ou ficam iguais quando p_0 aumenta: o conjunto dos classificados como positivos só encolhe, e P e N não dependem do corte. Propriedades:

- vai de $(0,0)$ (p_0 acima de todas as probabilidades: ninguém é positivo) a $(1,1)$ ($p_0 = 0$: todos são);
- o canto superior esquerdo $(0,1)$ é o classificador sem erro;
- a diagonal é o "palpite aleatório": sortear $g = 1$ com probabilidade q, ignorando $\boldsymbol{x}$, dá $\mathrm{TPR} = \mathrm{FPR} = q$;
- a **AUC** (área sob a curva) vale 1 para o classificador perfeito, cuja curva passa por $(0,1)$, e $1/2$ para o sorteio da diagonal.

Ideia central

Fixados os custos, o corte é o da Prop. 3.1, com $\widehat{\eta}$ no lugar de η; a curva mostra o que cada um dos outros cortes daria, e a AUC resume o desempenho do modelo ao longo de todos eles.

Atenção

A curva ROC também deve ser construída no *teste*: no treino, as duas taxas saem otimistas.

Resumo

- A acurácia engana com custos assimétricos ou classe rara; olhe a **matriz de confusão**.
- Sensibilidade (TPR) e especificidade ($1 - \mathrm{FPR}$) condicionam na classe verdadeira e não dependem da prevalência.
- **Perda assimétrica** (1) $\Rightarrow$ corte ótimo $\ell_1/(\ell_0 + \ell_1)$ (Prop. 3.1).
- **ROC**: TPR contra FPR à medida que o corte varia; a **AUC** é a área sob ela.

Leitura recomendada. [AME] §7.4 (matriz de confusão e métricas) e §9.1 (perdas assimétricas, cortes e a curva ROC); [ISLP] §4.4.2 (matriz de confusão, ROC e AUC no exemplo do `Default`; Tabelas 4.6 e 4.7).