

Aula 08 — Métricas para Classificação

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §7.4 e cap. 9; ISLP §4.4–4.5

Objetivos da aula

Ao final desta aula o aluno deve ser capaz de:

- explicar por que a *acurácia* é insuficiente quando uma classe é rara ou quando os erros têm custos diferentes;
- ler uma **matriz de confusão**, definir sensibilidade, especificidade, precisão, VPN e F_1 como estimativas de probabilidades e escrever o risco em termos das taxas de erro de cada classe;
- formular **perdas assimétricas** e deduzir o *corte ótimo* de um classificador *plug-in*;
- construir e interpretar a **curva ROC** e a **AUC**;
- comparar as estratégias para **dados desbalanceados** (corte, pesos, reamostragem) e ver que todas codificam custos;
- distinguir *classificar bem* de *estimar bem probabilidades* (calibração e regras de pontuação próprias).

Em sala

Continuação direta da Aula 07: lá vimos que o classificador de Bayes minimiza a probabilidade de erro, mas a probabilidade de erro nem sempre é o que importa. Pergunta de abertura: “*numa população em que 1% tem certa doença, um teste que declara todo mundo saudável acerta 99% das vezes. Ele é um bom teste?*”

1 Por que a acurácia não basta

Com $Y \in \{0, 1\}$ e o risco 0–1 da Aula 07, $R(g) = \mathbb{P}(g(\mathbf{X}) \neq Y)$, a **acurácia** é $1 - R(g)$. Ela trata todo erro como igual, o que falha em dois casos:

- **custos assimétricos**: num rastreamento, um falso negativo costuma ser muito pior que um falso positivo;
- **classe rara**: com $\pi_1 = \mathbb{P}(Y = 1)$ pequena, $g \equiv 0$ tem risco π_1 e acurácia $1 - \pi_1$ sem acertar positivo nenhum. Se, além disso, $\mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}) < 1/2$ para todo $\mathbf{x}$, o próprio classificador de Bayes é $g \equiv 0$ ([AME] §9.1).

Atenção

O desbalanceamento, sozinho, não é o problema: com custos iguais, o classificador de Bayes continua minimizando o que interessa. O problema são os custos diferentes, e as Seções 3 a 5 são maneiras de levá-los em conta.

2 Matriz de confusão e métricas

Fixado g , avaliamos numa amostra de teste $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_m, Y_m)$, i.i.d. e independente dos dados de treino, com $Y = 1$ a classe positiva:

		Verdadeiro	
		$Y = 0$	$Y = 1$
Predito	$g = 0$	VN (verd. neg.)	FN (falso neg.)
	$g = 1$	FP (falso pos.)	VP (verd. pos.)
total		N	P

O `confusion_matrix` do `scikit-learn` devolve a transposta desta tabela, com o verdadeiro nas linhas. Os totais das colunas são os P positivos e os N negativos verdadeiros. Cada medida estima uma probabilidade sobre uma observação nova $(\mathbf{X}, Y)$:

$$\begin{aligned}
 \text{sensibilidade: } S &= \mathbb{P}(g(\mathbf{X}) = 1 \mid Y = 1), & \hat{S} &= \text{VP}/P, \\
 \text{especificidade: } E &= \mathbb{P}(g(\mathbf{X}) = 0 \mid Y = 0), & \hat{E} &= \text{VN}/N, \\
 \text{precisão: } \text{VPP} &= \mathbb{P}(Y = 1 \mid g(\mathbf{X}) = 1), & \widehat{\text{VPP}} &= \text{VP}/(\text{VP} + \text{FP}), \\
 \text{valor preditivo negativo: } \text{VPN} &= \mathbb{P}(Y = 0 \mid g(\mathbf{X}) = 0), & \widehat{\text{VPN}} &= \text{VN}/(\text{VN} + \text{FN}).
 \end{aligned}$$

Sensibilidade e especificidade condicionam na classe verdadeira e não dependem da prevalência π_1 ; precisão e VPN condicionam na decisão e dependem dela. Pelo teorema de Bayes,

$$\text{VPP} = \frac{S \pi_1}{S \pi_1 + (1 - E)(1 - \pi_1)}.$$

Em sala

Pergunte: num teste com sensibilidade e especificidade de 99%, aplicado a uma doença com prevalência de 1%, que fração dos positivos apontados é de fato doente? A fórmula dá exatamente 1/2; com prevalência de 0,1%, cerca de 9%. O teste é o mesmo; mudou a raridade da doença.

A **estatística** F_1 é a média harmônica de sensibilidade e precisão:

$$F_1 = \frac{2}{1/S + 1/\text{VPP}} = \frac{2S \cdot \text{VPP}}{S + \text{VPP}}, \quad \hat{F}_1 = \frac{2\text{VP}}{2\text{VP} + \text{FP} + \text{FN}}. \quad (1)$$

Ela não usa os VN, e a média harmônica fica perto da menor das duas: quem declara todos positivos numa prevalência de 2% tem $S = 1$, precisão 0,02 e $F_1 \approx 0,039$, contra 0,51 da média aritmética.

Atenção

Todas essas estimativas se fazem no conjunto de *teste*, nunca no treino (Aula 03).

Na ROC e no `scikit-learn` (a `roc_curve` devolve `fpr` e `tpr`), S é a **taxa de verdadeiros positivos**, TPR, e $1 - E$ é a **taxa de falsos positivos**, FPR, estimadas por VP/P e FP/N . Dados P e N , essas duas estimativas reconstroem a matriz. Com $Y = 0$ como hipótese nula e $g = 1$ como rejeição, a FPR é a probabilidade do erro do tipo I e a TPR, o poder.

Com $\pi_1 = \mathbb{P}(Y = 1)$, pela probabilidade total,

$$R(g) = \pi_1 (1 - S) + (1 - \pi_1) (1 - E) :$$

o risco é a média das duas taxas de erro, ponderada pelas prevalências. Na amostra, a mesma conta é uma identidade exata:

$$\frac{FP + FN}{m} = \frac{P}{m} \cdot \frac{FN}{P} + \frac{N}{m} \cdot \frac{FP}{N}.$$

Em sala

O exemplo dos slides: 1000 pacientes, 10 doentes; o trivial $g_1 \equiv 0$ contra um g_2 com VP 8, FN 2, FP 40 e VN 950. Pergunte qual dos dois o risco prefere (0,010 contra 0,042: prefere g_1) e deixe a turma achar o motivo na decomposição: a sensibilidade que g_1 perde por inteiro entra com peso $\pi_1 = 0,01$.

3 Perdas assimétricas e o corte ótimo

Atribua custo $l_0 > 0$ a cada falso negativo (decidir 0 quando $Y = 1$) e $l_1 > 0$ a cada falso positivo (decidir 1 quando $Y = 0$):

$$R_l(g) = l_1 \mathbb{P}(g(\mathbf{X}) = 1, Y = 0) + l_0 \mathbb{P}(g(\mathbf{X}) = 0, Y = 1) = l_0 \pi_1 (1 - S) + l_1 (1 - \pi_1) (1 - E). \quad (2)$$

Proposição 3.1 (Corte ótimo sob perda assimétrica). Com $\eta(\mathbf{x}) = \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$, o classificador $g^*(\mathbf{x}) = \mathbf{1}\left\{\eta(\mathbf{x}) > \frac{l_1}{l_0 + l_1}\right\}$ minimiza (2).

Demonstração. Condiçãoando em $\mathbf{X}$,

$$R_l(g) = \mathbb{E}\left[l_1(1 - \eta(\mathbf{X}))\mathbf{1}\{g(\mathbf{X}) = 1\} + l_0 \eta(\mathbf{X})\mathbf{1}\{g(\mathbf{X}) = 0\}\right].$$

Para cada $\mathbf{x}$, decidir 1 custa $l_1(1 - \eta(\mathbf{x}))$ e decidir 0 custa $l_0 \eta(\mathbf{x})$; o primeiro é menor se e só se $\eta(\mathbf{x}) > l_1/(l_0 + l_1)$. Minimizar o integrando em cada $\mathbf{x}$ minimiza a esperança; no empate, qualquer decisão é ótima. $\square$

Ideia central

Mudar os custos muda o corte, não o modelo: as probabilidades estimadas são as mesmas. Com $l_0 = l_1$ o corte é 1/2 (Bayes); com $l_0 = 10l_1$, é $1/11 \approx 0,09$. Com $l_0 = 1 - \pi_1$ e $l_1 = \pi_1$, custos inversamente proporcionais às prevalências, o corte é π_1 ([AME] §9.1) e $R_l(g) = \pi_1(1 - \pi_1)(2 - S - E)$: minimizar o custo é maximizar $S + E$, o critério usado com a ROC.

Em sala

Pergunte: se deixar passar um doente custa dez vezes mais que um alarme falso, a partir de que probabilidade se deve chamar alguém de positivo? (1/11, cerca de 9%.)

4 Escolhendo o corte: curva ROC e AUC

Um classificador *plug-in* usa uma estimativa $\hat{\eta}$ e um corte K : $g_K(\mathbf{x}) = \mathbf{1}\{\hat{\eta}(\mathbf{x}) \geq K\}$. Cada K dá um par $(FPR(K), TPR(K))$, e a **curva ROC** (*Receiver Operating Characteristic*) é o conjunto $\{(FPR(K), TPR(K)) : K \in [0, 1]\}$, a sensibilidade contra 1-especificidade à medida que o corte varia. As duas taxas diminuem ou ficam iguais quando K aumenta: o conjunto dos classificados como positivos só encolhe, e P e N não dependem do corte. Propriedades:

- vai de $(0, 0)$ (K acima de todas as probabilidades: ninguém é positivo) a $(1, 1)$ ($K = 0$: todos são);
- o canto superior esquerdo $(0, 1)$ é o classificador sem erro;
- a diagonal é o “palpite aleatório”: sortear $g = 1$ com probabilidade q , ignorando $\mathbf{x}$, dá $\text{TPR} = \text{FPR} = q$;
- a **AUC** (área sob a curva) vale 1 para o classificador perfeito e $1/2$ para o sorteio. Com um positivo e um negativo sorteados de forma independente, e escores Z_1 e Z_0 , $\text{AUC} = \mathbb{P}(Z_1 > Z_0) + \frac{1}{2} \mathbb{P}(Z_1 = Z_0)$.

Ideia central

A ROC e a AUC dependem de $\hat{\eta}$ só pela ordem que ela induz, e não mudam se $\hat{\eta}$ for trocada por uma função estritamente crescente dela: servem para comparar modelos antes de fixar custos. Fixado o contexto, escolhe-se K pela Prop. 3.1, se os custos são conhecidos, ou maximizando $S + E$, que é o caso l_c inversamente proporcional a π_c .

Atenção

A curva ROC também deve ser construída no *teste*. Em dados muito desbalanceados ela pode parecer otimista: mil falsos positivos entre 50 000 negativos dão $\text{FPR} = 0,02$, mas, com 110 verdadeiros positivos, só um em cada dez alarmes é verdadeiro. A curva precisão–revocação registra isso.

5 Lidando com dados desbalanceados

Três estratégias, todas codificando custos:

Mover o corte

para métodos que estimam η , usar o corte da Prop. 3.1, ou a prevalência estimada. Não mexe no modelo e preserva as probabilidades.

Reponderar dar pesos w_1 e w_0 às classes na função objetivo (`class_weight` no `scikit-learn`). Útil quando o método não estima η .

Reamostrar alterar a prevalência do treino: *oversampling* da minoria (o SMOTE cria pontos sintéticos) ou *undersampling* da maioria.

Para um modelo ajustado por máxima verossimilhança, a log-verossimilhança ponderada é maximizada em

$$p_w(\mathbf{x}) = \frac{w_1 \eta(\mathbf{x})}{w_1 \eta(\mathbf{x}) + w_0 (1 - \eta(\mathbf{x}))}, \quad \frac{p_w}{1 - p_w} = \frac{w_1}{w_0} \cdot \frac{\eta}{1 - \eta} :$$

o modelo reponderado estima p_w , com as chances multiplicadas por w_1/w_0 , e classificar com $p_w > 1/2$ é usar o corte $w_0/(w_0 + w_1)$ em η . Com $w_c \propto 1/n_c$ (`class_weight="balanced"`), o corte implícito é a prevalência da amostra. Reamostrar para a prevalência π'_1 multiplica as chances estimadas por $\frac{\pi'_1/(1-\pi'_1)}{\pi_1/(1-\pi_1)}$, desde que a distribuição de $\mathbf{X}$ em cada classe não mude.

Atenção

Reponderar e reamostrar deslocam as probabilidades por um fator conhecido; para usá-las como probabilidades da população original é preciso desfazer o fator. Se os custos são iguais, o corte $1/2$ já é o correto, por mais desbalanceados que sejam os dados: não reamostre por reflexo.

6 Classificar bem $\neq$ estimar bem probabilidades

Para decidir, basta que $\hat{\eta}(\mathbf{x}) - K$ tenha o mesmo sinal que $\eta(\mathbf{x}) - K$ ([AME] §9.2): um classificador *plug-in* pode estar perto do ótimo com $\hat{\eta}$ longe de η . Quando as probabilidades em si importam (ordenar riscos, decidir com custos que mudam caso a caso, comunicar um risco), interessam:

- a **calibração**: $\mathbb{P}(Y = 1 \mid \hat{\eta}(\mathbf{X}) = p) = p$, vista na curva de calibração (média predita contra frequência observada, por faixas de $\hat{\eta}$);
- as **regras de pontuação próprias**, perdas $s(p, y)$ cujo valor esperado sob $Y \sim \text{Bernoulli}(\eta)$ é mínimo em $p = \eta$: o **score de Brier**, $(p - y)^2$, e a **entropia cruzada**, $-[y \log p + (1 - y) \log(1 - p)]$.

Para o Brier, $\mathbb{E}[(p - Y)^2] = (p - \eta)^2 + \eta(1 - \eta)$, e, tomando a esperança em $\mathbf{X}$,

$$\mathbb{E}[(\hat{\eta}(\mathbf{X}) - Y)^2] = \mathbb{E}[(\hat{\eta}(\mathbf{X}) - \eta(\mathbf{X}))^2] + \mathbb{E}[\eta(\mathbf{X})(1 - \eta(\mathbf{X}))],$$

a decomposição da Aula 01 aplicada a $Y \in \{0, 1\}$. A acurácia e a AUC não são próprias: uma só vê o lado do corte, a outra só a ordem. Por isso, Brier e entropia cruzada são os critérios indicados para escolher *tuning parameters* (por exemplo, o λ da logística penalizada) quando o objetivo é estimar bem as probabilidades.

Ideia central

Um modelo bem calibrado é aquele em que, entre os casos a que ele atribui $\hat{\eta} = 0,7$, cerca de 70% são de fato positivos. Brier e entropia cruzada penalizam a má calibração; acurácia e AUC, não. Na figura de calibração da versão do aluno, a logística e o Bayes ingênuo têm praticamente a mesma AUC (0,774 e 0,776) e Brier de 0,065 e 0,152.

Em sala

Pergunte: dois modelos com a mesma AUC servem igualmente para calcular um custo esperado? Não: a AUC só vê a ordem, e o custo esperado usa o valor de $\hat{\eta}$.

Resumo

- A acurácia engana com custos assimétricos ou classe rara; olhe a **matriz de confusão**.
- Sensibilidade e especificidade não dependem da prevalência; precisão e VPN dependem. O F_1 (1) é a média harmônica de sensibilidade e precisão. O risco 0–1 é a média das taxas de erro ponderada pelas prevalências.
- **Perda assimétrica** (2) $\Rightarrow$ corte ótimo $l_1/(l_0 + l_1)$ (Prop. 3.1); custos inversos às prevalências dão o corte π_1 e o critério $\max(S + E)$.
- **ROC/AUC** avaliam o ordenamento, independentemente do corte; com positivos raros, a curva precisão–revocação informa mais.
- Corte, pesos e reamostragem codificam custos; os dois últimos deslocam as probabilidades por um fator conhecido.
- Classificar bem $\neq$ estimar bem: use calibração, Brier e entropia cruzada.

Leitura recomendada. [AME] §7.4 (matriz de confusão e métricas), §9.1 (perdas assimétricas, cortes, dados desbalanceados), §9.2 (classificação vs. estimação de probabilidades); [ISLP] §4.4.2 (matriz de confusão, ROC e AUC no exemplo do `Default`; Tabelas 4.6 e 4.7).