

Lista Teórica 08 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 08 — Métricas para Classificação

Exercício 1 — uma matriz de confusão, quatro taxas. Um sistema de detecção de fraude, já construído, foi aplicado a uma amostra de teste de $n = 10\,000$ transações, independente dos dados usados para construí-lo; 500 delas eram fraudes. Tome a fraude como a classe positiva, $Y = 1$. A matriz de confusão, com o previsto nas linhas e o real nas colunas, como em aula, é

		real	
		normal	fraude
previsto	normal	9 400	300
	fraude	100	200

- Calcule a taxa de erro, a sensibilidade (taxa de verdadeiros positivos), a taxa de falsos positivos e a especificidade. Que probabilidade cada uma das quatro estima?
- Calcule a taxa de erro do classificador que responde *sempre* “normal”. Compare com a do item (a).
- Um relatório afirma: “o sistema erra em apenas 4% das transações”. Reescreva essa frase de modo que ela informe o leitor em vez de enganá-lo.
- O banco decide baixar o corte do sistema para capturar mais fraudes. Quais das quatro taxas do item (a) não podem diminuir, quais não podem aumentar e quais podem mudar em qualquer sentido? Justifique.

Solução

(a) Lendo a tabela, $VN = 9\,400$, $FN = 300$, $FP = 100$ e $VP = 200$. Os totais das colunas são os $P = VP + FN = 500$ positivos e os $N = FP + VN = 9\,500$ negativos verdadeiros, e $n = P + N = 10\,000$. Escrevendo g para o sistema e $(\mathbf{X}, Y)$ para uma transação nova,

taxa	na amostra	valor	estima
taxa de erro	$(FP + FN)/n = 400/10\,000$	0,0400	$\mathbb{P}(g(\mathbf{X}) \neq Y)$
sensibilidade (TPR)	$VP/P = 200/500$	0,4000	$\mathbb{P}(g(\mathbf{X}) = 1 \mid Y = 1)$
taxa de falsos positivos (FPR)	$FP/N = 100/9\,500$	0,0105	$\mathbb{P}(g(\mathbf{X}) = 1 \mid Y = 0)$
especificidade	$VN/N = 9\,400/9\,500$	0,9895	$\mathbb{P}(g(\mathbf{X}) = 0 \mid Y = 0)$

Cada taxa é a proporção, na amostra de teste, do evento correspondente: a taxa de erro conta os erros entre todas as transações; a sensibilidade, os acertos entre as fraudes; a taxa de falsos positivos, os alarmes entre as transações normais. Como a amostra de teste não foi usada para construir g , essas proporções estimam as probabilidades da última coluna, que são as de uma transação nova. A especificidade é o complemento da taxa de falsos positivos, $0,9895 = 1 - 0,0105$, porque as duas dividem pelo mesmo total N ; do mesmo modo, $1 - \text{TPR} = FN/P = 0,6$ é a taxa de falsos negativos.

Em palavras: o sistema encontra 40% das fraudes e acusa cerca de 1% das transações normais.

Repare ainda que as duas taxas de classe são estimadas com quantidades de dados muito diferentes. Dadas as classes, cada fraude é detectada independentemente com a mesma probabilidade, de modo que VP é binomial com $P = 500$ ensaios; o erro-padrão da sensibilidade estimada é $\sqrt{0,4 \cdot 0,6/500} \approx 0,022$. O da taxa de falsos positivos, com $N = 9\,500$ ensaios, é $\sqrt{0,0105 \cdot 0,9895/9\,500} \approx 0,001$. Numa classe rara, a taxa que mais interessa é justamente a estimada com menos dados.

(b) O classificador trivial erra **0,0500** das transações, um ponto percentual a mais que o sistema. Ele acerta as 9 500 transações normais e erra as 500 fraudes, de modo que a sua taxa de erro é exatamente a proporção de fraudes, 500/10 000; a sua sensibilidade e a sua taxa de falsos positivos são ambas 0.

A comparação mostra a escala da taxa de erro neste problema. Responder sempre a classe majoritária, sem olhar a transação, já erra só 5%; um classificador útil precisa ficar abaixo disso, e o sistema fica em 4%. Um ponto percentual de taxa de erro separa, aqui, um detector que encontra 40% das fraudes de um classificador que não encontra nenhuma.

(c) A frase é verdadeira, mas engana, porque soma numa conta só dois erros de natureza muito diferente. Dos 400 erros, 300 são fraudes não detectadas, isto é, 60% das 500 fraudes, e 100 são alarmes falsos, cerca de 1% das 9 500 transações normais. Como as fraudes são só 5% das transações, a taxa de erro é quase toda determinada pela classe normal: até o classificador do item (b), que não detecta nada, erra apenas 5%. Uma versão que informa:

“o sistema detecta 40% das fraudes e acusa indevidamente cerca de 1% das transações normais, o que aqui significou 100 alarmes falsos”,

isto é, a sensibilidade e a taxa de falsos positivos, ditas por extenso.

(d) A sensibilidade e a taxa de falsos positivos não podem diminuir, a especificidade não pode aumentar, e a taxa de erro pode mudar em qualquer sentido.

Suponha que o sistema acuse uma transação quando $\hat{p}(\mathbf{x}) \geq K$, sendo $\hat{p}$ a probabilidade de fraude que ele estima, e que o corte passe de K a $K' < K$. Toda transação com $\hat{p}(\mathbf{x}) \geq K$ também tem $\hat{p}(\mathbf{x}) \geq K'$: o conjunto das transações acusadas só cresce. Logo VP e FP não diminuem, FN e VN não aumentam, e os totais $P = 500$ e $N = 9\,500$ não dependem do corte.

- A sensibilidade, VP/P , e a taxa de falsos positivos, FP/N , têm numerador que não diminui e denominador fixo; não podem diminuir. A primeira aumenta de fato assim que o novo corte acusa ao menos uma fraude a mais, e a segunda, assim que acusa ao menos uma transação normal a mais.
- A especificidade, $VN/N = 1 - FP/N$, não pode aumentar.
- A taxa de erro pode ir para os dois lados. Se o novo corte acusa a fraudes e b transações normais que antes passavam, então FN diminui de a , FP aumenta de b , e a taxa de erro muda de $(b - a)/n$. Se forem 50 fraudes e 10 normais, ela cai de 0,0400 para 0,0360; se forem 5 fraudes e 200 normais, sobe para 0,0595.

Nenhuma das quatro precisa mudar: se nenhuma transação tiver $\hat{p}(\mathbf{x})$ entre K' e K , nada se altera.

A sensibilidade e a taxa de falsos positivos andam, portanto, juntas: baixar o corte compra sensibilidade pagando com falsos positivos. Cada uma, sozinha, é trivial de manipular, porque o corte 0 dá sensibilidade 1, com taxa de falsos positivos 1, e um corte acima de todas as probabilidades dá taxa de falsos positivos 0, com sensibilidade 0. Por isso as duas só informam aos pares, e é esse par que a curva ROC acompanha.

Exercício 2 — o corte que minimiza o custo. Nem todo erro custa o mesmo. Seja $c_{FP} > 0$ o custo de um falso positivo e $c_{FN} > 0$ o de um falso negativo (os l_1 e l_0 das notas), e suponha que acertar não custe nada. Suponha também que o classificador conheça $p(\mathbf{x}) = \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$.

- (a) Num ponto $\mathbf{x}$ com $p = p(\mathbf{x})$, escreva o custo esperado de decidir $\hat{y} = 1$ e o de decidir $\hat{y} = 0$.
- (b) Conclua que a decisão ótima em $\mathbf{x}$ é $\hat{y} = 1$ quando

$$p > \frac{c_{FP}}{c_{FP} + c_{FN}},$$

e explique por que decidir assim em cada $\mathbf{x}$ minimiza também o custo esperado total.

- (c) No sistema do Exercício 1, cada alarme falso custa R\$ 10, o preço de investigar uma transação honesta, e cada fraude não detectada custa R\$ 500. Qual é o corte ótimo? Interprete o número.
- (d) O corte padrão do `scikit-learn` é 0,5. Que razão de custos ele supõe implicitamente? Por que isso é quase sempre inadequado num problema desbalanceado?

Solução

(a) Dado $\mathbf{X} = \mathbf{x}$, a decisão está fixada e só Y é aleatório, com $Y \mid \mathbf{X} = \mathbf{x} \sim \text{Bernoulli}(p)$. Decidindo $\hat{y} = 1$, paga-se c_{FP} se $Y = 0$ e nada se $Y = 1$; decidindo $\hat{y} = 0$, paga-se c_{FN} se $Y = 1$ e nada se $Y = 0$. Os custos esperados são

$$\mathbb{E}[\text{custo} \mid \mathbf{X} = \mathbf{x}, \hat{y} = 1] = c_{FP}(1 - p), \quad \mathbb{E}[\text{custo} \mid \mathbf{X} = \mathbf{x}, \hat{y} = 0] = c_{FN}p.$$

(b) Decidir $\hat{y} = 1$ é melhor exatamente quando o seu custo esperado é menor:

$$c_{FP}(1 - p) < c_{FN}p \iff c_{FP} < p(c_{FP} + c_{FN}) \iff p > \frac{c_{FP}}{c_{FP} + c_{FN}},$$

em que a última passagem divide por $c_{FP} + c_{FN} > 0$. Na igualdade as duas decisões custam o mesmo, e qualquer uma é ótima.

Para o custo total, seja g a regra acima e h um classificador qualquer. Pela lei da esperança total, o custo esperado de um classificador é $\mathbb{E}[\text{custo}] = \mathbb{E}[\mathbb{E}[\text{custo} \mid \mathbf{X}]]$, a média, sobre a distribuição de $\mathbf{X}$, do custo esperado condicional. Em cada $\mathbf{x}$, o custo condicional de g é o menor dos dois valores do item (a), e portanto não supera o de h ; tomando a média em $\mathbf{X}$, o custo esperado de g não supera o de h . Como h é arbitrário, g minimiza o custo esperado total. É a Proposição 3.1 das notas, com $l_1 = c_{FP}$ e $l_0 = c_{FN}$.

Duas consequências. O corte se escreve $1/(1 + c_{FN}/c_{FP})$ e depende só da razão entre os custos: multiplicar os dois pela mesma constante, por exemplo mudar de moeda, não altera a decisão. E, com $c_{FP} = c_{FN}$, o corte é $1/2$ e a regra é o classificador de Bayes da Aula 07.

(c) Com $c_{FP} = 10$ e $c_{FN} = 500$,

$$p^* = \frac{10}{10 + 500} = \frac{1}{51} \approx \mathbf{0,0196}.$$

Vale a pena investigar toda transação com probabilidade de fraude acima de cerca de 2%. Em $p = 1/51$ os dois custos esperados empatam, $10 \cdot \frac{50}{51} = 500 \cdot \frac{1}{51}$; acima disso, o custo esperado de deixar passar, $500p$, supera o de investigar, $10(1 - p)$. Em outras palavras, como uma fraude perdida custa 50 alarmes falsos, aceita-se investigar cerca de 50 transações honestas para encontrar uma fraude.

Um cuidado com o modelo de custos. O enunciado cobra R\$ 10 só dos alarmes falsos; se investigar uma fraude verdadeira também custar R\$ 10, os acertos deixam de ser gratuitos.

Refazendo a conta do item (a) com custos para as quatro células, o que importa são as diferenças entre decidir certo e decidir errado em cada classe, e o corte vira

$$\frac{10 - 0}{(10 - 0) + (500 - 10)} = \frac{10}{500} = 0,02,$$

muito perto do anterior. A conclusão não muda, mas o exemplo mostra que vale escrever os custos das quatro situações antes de calcular.

(d) O corte 0,5 corresponde a $c_{FP}/(c_{FP} + c_{FN}) = 1/2$, isto é, a $c_{FP} = c_{FN}$: ele supõe que os dois erros custam o mesmo. É o corte do classificador de Bayes, ótimo para o risco 0–1; o problema não está nele, e sim em usá-lo quando os custos são outros.

Num problema desbalanceado ele quase sempre é inadequado, por dois motivos que se somam. O primeiro é substantivo: a classe rara costuma ser a que importa (a fraude, a doença, a falha de um equipamento), e deixá-la passar custa muito mais que um alarme falso. O segundo é estatístico: com prevalência pequena, $p(\mathbf{x})$ raramente passa de $1/2$, e, se $p(\mathbf{x}) < 1/2$ em todo $\mathbf{x}$, a regra com corte 0,5 não acusa ninguém, por melhor que o modelo ordene as transações. A **Lista prática 08** mede isso num banco com prevalência de 10%: a regressão logística tem AUC 0,85 e, no corte 0,5, classifica como positivas só 484 das 12 000 observações de teste, quando 1 182 o são.

A conduta que decorre do exercício é separar as duas tarefas: primeiro estimar bem $p(\mathbf{x})$, depois escolher o corte pelos custos do problema.