

Lista Teórica 08 — Gabarito

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 08 — Métricas para Classificação

Exercício 1 — uma matriz de confusão, cinco métricas. Um sistema de detecção de fraude foi aplicado a 10 000 transações, das quais 500 eram fraudulentas. O resultado:

		previsto	
		fraude	normal
real	fraude	200	300
	normal	100	9 400

- Calcule acurácia, precisão, *recall* (sensibilidade), especificidade e F_1 .
- Calcule a acurácia do classificador que responde *sempre* “normal”. Compare com a do item (a).
- Um relatório afirma: “o sistema tem 96% de acurácia”. Reescreva essa frase de modo que ela informe o leitor em vez de enganá-lo.
- Se o banco decidir baixar o corte para capturar mais fraudes, quais das cinco métricas do item (a) necessariamente *sobem*, quais necessariamente *descem*, e quais podem ir para qualquer lado?

Solução

(a) Com $VP = 200$, $FN = 300$, $FP = 100$, $VN = 9\,400$:

métrica	fórmula	valor
acurácia	$(VP + VN)/n = 9\,600/10\,000$	0,9600
precisão	$VP/(VP + FP) = 200/300$	0,6667
<i>recall</i>	$VP/(VP + FN) = 200/500$	0,4000
especificidade	$VN/(VN + FP) = 9\,400/9\,500$	0,9895
F_1	$2VP/(2VP + FP + FN) = 400/800$	0,5000

(b) Ele acerta todas as 9 500 transações normais e erra todas as fraudes: acurácia = $9\,500/10\,000 = 0,9500$.

O sistema de verdade tem 0,9600. **Um ponto percentual** separa um detector que encontra 40% das fraudes de um programa que não faz nada.

(c) Uma versão honesta seria: “o sistema detecta 40% das fraudes (*recall*); dois em cada três alertas que ele emite são fraudes de verdade (*precisão*); e ele marca indevidamente 1% das transações normais”.

O que torna a frase original enganosa não é a acurácia estar errada — ela está certa — e sim ela ser **quase toda determinada pela prevalência**: dos 9 600 acertos, 9 400 são transações normais classificadas como normais, o que qualquer classificador trivial também faria. A informação está nos 600 casos restantes, e a acurácia os dilui em dez mil.

(d) Baixando o corte, mais transações são chamadas de fraude: nenhuma que era chamada deixa de ser. Então VP e FP não podem descer, e FN e VN não podem subir. Rigorosamente, nenhuma das cinco métricas *precisa* mudar — se nenhuma transação nova passar do corte, fica tudo igual —, mas duas só se movem num sentido:

- **Nunca desce:** o *recall* $VP/(VP+FN)$ — o numerador não desce e o denominador $VP+FN$ é fixo (o total de fraudes). Ele sobe de fato assim que o novo corte pega ao menos uma fraude a mais.
- **Nunca sobe:** a especificidade $VN/(VN+FP)$, pelo mesmo argumento com o total de normais. Ela cai assim que uma transação normal a mais é marcada.
- **Pode ir para qualquer lado:** a precisão (tipicamente desce, mas pode subir se os casos recém-incluídos forem majoritariamente fraudes), a acurácia (troca FN por FP , e o saldo depende de quantos de cada) e o F_1 . Se o novo corte acrescenta a fraudes e b transações normais, $F_1 = 2VP/(2VP+FP+FN)$ vira $2(VP+a)/(2VP+FP+FN+a+b)$: sobe quando os casos novos têm fraudes o bastante e desce quando são quase só alarmes falsos.

A moral: *recall* e especificidade sozinhos são triviais de manipular — corte 0 dá *recall* 1, corte 1 dá especificidade 1. Só faz sentido olhá-los **aos pares**, e é isso que a curva ROC faz.

Exercício 2 — o corte que minimiza o custo. Nem todo erro custa o mesmo. Seja c_{FP} o custo de um falso positivo e c_{FN} o de um falso negativo, e suponha que o classificador forneça $p(\mathbf{x}) = \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$.

- Escreva o custo esperado de decidir $\hat{y} = 1$ e o de decidir $\hat{y} = 0$, num ponto $\mathbf{x}$ com probabilidade p .
- Conclua que a decisão ótima é $\hat{y} = 1$ quando $p > \frac{c_{FP}}{c_{FP} + c_{FN}}$.
- No sistema do Exercício 1, investigar um alerta custa R\$ 10 e uma fraude não detectada custa R\$ 500. Qual o corte ótimo?
- O corte padrão do `scikit-learn` é 0,5. Que razão de custos ele supõe implicitamente? Por que isso é quase sempre errado num problema desbalanceado?

Solução

(a) Se decidimos $\hat{y} = 1$, erramos quando $Y = 0$, o que acontece com probabilidade $1 - p$; o custo esperado é $(1 - p)c_{FP}$. Se decidimos $\hat{y} = 0$, erramos quando $Y = 1$, com probabilidade p ; o custo esperado é $p c_{FN}$. (Acertar custa zero.)

(b) Decidimos $\hat{y} = 1$ quando o custo esperado dessa decisão é menor:

$$(1 - p)c_{FP} < p c_{FN} \iff c_{FP} < p(c_{FP} + c_{FN}) \iff p > \frac{c_{FP}}{c_{FP} + c_{FN}}.$$

Note que o corte depende **apenas da razão** entre os custos: multiplicar os dois por uma constante não muda nada, o que é tranquilizador — a decisão não depende da moeda.

(c) Com $c_{FP} = 10$ e $c_{FN} = 500$:

$$p^* = \frac{10}{10 + 500} = \frac{10}{510} \approx \mathbf{0,0196}.$$

Ou seja: vale a pena investigar qualquer transação com **2% de chance** de ser fraude. Faz sentido — investigar é 50 vezes mais barato que deixar passar.

(d) O corte 0,5 corresponde a $\frac{c_{FP}}{c_{FP}+c_{FN}} = \frac{1}{2}$, isto é **CFP = CFN**: ele supõe que os dois erros custam o mesmo.

Isso é quase sempre errado em problema desbalanceado, e por dois motivos que se somam. Primeiro, o motivo substantivo: a classe rara costuma ser justamente a que importa (fraude, doença, falha de equipamento), e deixá-la passar custa muito mais caro que um alarme falso. Segundo, o motivo estatístico: com prevalência de 5%, pouquíssimas observações têm $p(\mathbf{x}) > 0,5$ — o modelo pode ordenar muito bem as transações e ainda assim chamar de fraude só uma pequena parte das fraudes, porque quase nenhuma passa do corte. A **Lista prática 08** mede isso num banco com prevalência de 10%: a logística tem AUC 0,85 e, no corte 0,5, chama de positivas só 484 das 12 000 observações de teste, quando 1 182 o são.

É por isso que a conduta correta é separar as duas decisões: **primeiro estime $p(\mathbf{x})$ bem, depois escolha o corte**, e escolha-o pelo custo do problema, não pelo padrão da biblioteca.

Exercício 3 — AUC na mão. A AUC tem uma interpretação probabilística exata:

$$\text{AUC} = \mathbb{P}(\text{score de um positivo} > \text{score de um negativo}),$$

com sorteio independente e uniforme entre positivos e entre negativos. Considere cinco observações:

observação	A	B	C	D	E
score	0,9	0,8	0,6	0,4	0,1
y	1	0	1	1	0

- Liste todos os pares (positivo, negativo) e calcule a AUC diretamente pela definição.
- Se você somar 0,3 a todos os scores, a AUC muda? E se você elevar todos ao quadrado? Justifique.
- Qual é a AUC de um classificador que atribui scores completamente ao acaso? E de um que ordena *perfeitamente ao contrário*?
- Nesta amostra, qual é a maior acurácia atingível escolhendo bem o corte? Compare com a AUC e comente.

Solução

(a) Positivos: A (0,9), C (0,6), D (0,4). Negativos: B (0,8), E (0,1). São $3 \times 2 = 6$ pares:

par	comparação	positivo ganha?
A,B	$0,9 > 0,8$	sim
A,E	$0,9 > 0,1$	sim
C,B	$0,6 > 0,8$	não
C,E	$0,6 > 0,1$	sim
D,B	$0,4 > 0,8$	não
D,E	$0,4 > 0,1$	sim

$$\text{AUC} = \frac{4}{6} = \frac{2}{3} \approx \mathbf{0,6667}.$$

(b) **Não muda em nenhum dos dois casos.** A AUC depende só das comparações “>” entre escores, e qualquer transformação **estritamente crescente** preserva todas elas. Somar 0,3 é crescente; elevar ao quadrado também é, no intervalo $[0, 1]$ em que os escores estão.

Essa é a virtude e o defeito da AUC ao mesmo tempo: ela mede *ordenação* e é cega a *calibração*. Um modelo cujos escores estão todos entre 0,49 e 0,51 pode ter AUC 1,0 — e nenhuma das probabilidades ser utilizável. (Cuidado com o caso não estritamente crescente: elevar ao quadrado escores *negativos* inverteria comparações e mudaria a AUC.)

(c) Ao acaso: AUC = **0,5**, porque com escores independentes dos rótulos a probabilidade de o positivo ganhar é $1/2$ por simetria. Perfeitamente ao contrário: AUC = **0**.

E note que AUC 0 é ótimo disfarçado: basta inverter o sinal do escore para obter 1. Um modelo com AUC bem abaixo de 0,5 não é inútil — é um bug de sinal.

(d) Percorrendo os cortes possíveis:

corte acima de	—	0,1	0,4	0,6	0,8
prevê 1 para	todos	A,B,C,D	A,B,C	A,B	A
acertos	3	4	3	2	3
acurácia	0,6	0,8	0,6	0,4	0,6

A melhor acurácia é **0,8**, com o corte logo acima de 0,1: os três positivos são capturados e o único erro é B, um negativo chamado de positivo.

O contraste com a AUC de 0,667 é o ponto do exercício: as duas medem coisas diferentes. A acurácia avalia **uma** decisão, tomada num corte específico; a AUC resume o desempenho **sobre todos os cortes**, e por isso não depende de nenhum. Com cinco observações e classes quase equilibradas as duas ainda são comparáveis; com prevalência de 5%, como no Exercício 1, a acurácia se cola na prevalência e a AUC continua informativa.

Exercício 4 — mesma AUC, calibrações diferentes. Dois modelos produzem, para as mesmas quatro observações $y = (0, 0, 1, 1)$, os escores

$$p = (0,40, 0,45, 0,55, 0,60), \quad q = (0,05, 0,10, 0,90, 0,95).$$

- Calcule a AUC dos dois.
- Calcule o **escore de Brier**, $\frac{1}{n} \sum_i (p_i - y_i)^2$, dos dois.
- Interprete: o que cada uma das duas métricas está medindo, e qual delas você usaria para decidir se pode confiar nas probabilidades?
- As notas desta aula relatam a medição: naive Bayes e logística praticamente empatam em AUC (0,776 contra 0,774), e o Brier os separa (0,1523 contra 0,0653). Explique o que esse par de números diz sobre o naive Bayes, ligando-o à hipótese que dá nome ao método (Aula 07).

Solução

(a) Nos dois casos os dois positivos têm escores maiores que os dois negativos, então todos os $2 \times 2 = 4$ pares são vencidos pelo positivo:

$$\text{AUC}(p) = \text{AUC}(q) = \mathbf{1,0}.$$

Aliás, q é uma função estritamente crescente de p , então o item (b) do Exercício 3 já garantia a igualdade.

(b)

$$\text{Brier}(p) = \frac{1}{4} [0,40^2 + 0,45^2 + 0,45^2 + 0,40^2] = \frac{1}{4} [0,16 + 0,2025 + 0,2025 + 0,16] = \mathbf{0,18125},$$

$$\text{Brier}(q) = \frac{1}{4} [0,05^2 + 0,10^2 + 0,10^2 + 0,05^2] = \frac{1}{4} [0,0025 + 0,01 + 0,01 + 0,0025] = \mathbf{0,00625}.$$

O Brier de p é **29 vezes** o de q , com AUC idêntica.

(c) A **AUC** mede *ordenação*: com que confiabilidade o modelo coloca positivos acima de negativos. É a métrica certa quando a decisão final será tomada por um corte que você ainda vai escolher — e é insensível a qualquer reescala monótona dos escores.

O **Brier** é um erro quadrático entre a probabilidade prevista e o rótulo observado, e mede *calibração* além de ordenação: ele pune tanto ordenar mal quanto acertar a ordem com probabilidades tímidas ou exageradas. O modelo p ordena perfeitamente, mas todas as suas probabilidades ficam entre 0,40 e 0,60; se alguém tomar $p_i = 0,55$ ao pé da letra, vai agir como se houvesse 45% de chance de erro onde não há nenhuma.

Para decidir se *pode confiar nas probabilidades*, use o **Brier** (ou uma curva de calibração). A AUC não responde a essa pergunta, por construção.

E a distinção não é acadêmica: sempre que a probabilidade entra numa conta — custo esperado (Exercício 2), preço de um seguro, priorização de uma fila de espera — é calibração que importa, não ordenação.

(d) O par de números diz que **o naive Bayes ordena tão bem quanto a logística e estima probabilidades muito pior**. A AUC praticamente empatada (0,776 contra 0,774) mostra que ele coloca os positivos acima dos negativos com a mesma eficácia; o Brier 2,3 vezes maior (0,1523 contra 0,0653) mostra que os valores que ele imprime não são probabilidades confiáveis.

O mecanismo é a hipótese que dá nome ao método (Aula 07): o naive Bayes multiplica as densidades marginais como se as covariáveis fossem independentes dentro de cada classe. Quando elas são correlacionadas — e são — ele conta a *mesma* evidência várias vezes, e o produto de muitos fatores concordantes empurra a posteriori para 0 ou 1. O resultado são probabilidades sistematicamente extremas.

E por que a AUC não sofre? Na população da figura das notas dá para fazer a conta: seis covariáveis de variância 1 e correlação 0,85 duas a duas dentro de cada classe, e classes que diferem só pela média, deslocada de 1,05 em todas as coordenadas. O *log-odds* verdadeiro é o do LDA, $(\mu_1 - \mu_0)^\top \Sigma^{-1} \mathbf{x} + \text{const}$, e como $\Sigma^{-1} \mathbf{1} = \mathbf{1}/(0,15 + 0,85 \cdot 6) = \mathbf{1}/5,25$, ele vale $0,2(x_1 + \dots + x_6) + \text{const}$. O do naive Bayes, que troca Σ pela sua diagonal — aqui, a identidade —, vale $1,05(x_1 + \dots + x_6) + \text{const}$: a mesma soma, com inclinação 5,25 vezes maior. Mesma direção, mais íngreme — o escore do naive Bayes é uma função **crescente** do escore certo, e por isso ordena as observações exatamente como ele. A AUC empata; a probabilidade, que depende da inclinação, sai exagerada.

Isso é uma propriedade desta população, simétrica, e não do método. Quando as correlações não pesam igual em todas as direções, ignorá-las também *gira* a fronteira: na população de covariâncias iguais da Aula prática 07, a direção do naive Bayes forma quase 48 graus com a do classificador de Bayes, e o excesso de erro dele sobre o de Bayes dobra. Numa frase: *ordenar bem não é estimar bem* — e escolher a métrica é escolher qual das duas coisas você precisa.