

Lista Teórica 08

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 08 — Métricas para Classificação

Exercício 1 — uma matriz de confusão, quatro taxas. Um sistema de detecção de fraude, já construído, foi aplicado a uma amostra de teste de $n = 10\,000$ transações, independente dos dados usados para construí-lo; 500 delas eram fraudes. Tome a fraude como a classe positiva, $Y = 1$. A matriz de confusão, com o previsto nas linhas e o real nas colunas, como em aula, é

		real	
		normal	fraude
previsto	normal	9 400	300
	fraude	100	200

- Calcule a taxa de erro, a sensibilidade (taxa de verdadeiros positivos), a taxa de falsos positivos e a especificidade. Que probabilidade cada uma das quatro estima?
- Calcule a taxa de erro do classificador que responde *sempre* “normal”. Compare com a do item (a).
- Um relatório afirma: “o sistema erra em apenas 4% das transações”. Reescreva essa frase de modo que ela informe o leitor em vez de enganá-lo.
- O banco decide baixar o corte do sistema para capturar mais fraudes. Quais das quatro taxas do item (a) não podem diminuir, quais não podem aumentar e quais podem mudar em qualquer sentido? Justifique.

Exercício 2 — o corte que minimiza o custo. Nem todo erro custa o mesmo. Seja $c_{FP} > 0$ o custo de um falso positivo e $c_{FN} > 0$ o de um falso negativo (os l_1 e l_0 das notas), e suponha que acertar não custe nada. Suponha também que o classificador conheça $p(\mathbf{x}) = \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$.

- Num ponto $\mathbf{x}$ com $p = p(\mathbf{x})$, escreva o custo esperado de decidir $\hat{y} = 1$ e o de decidir $\hat{y} = 0$.
- Conclua que a decisão ótima em $\mathbf{x}$ é $\hat{y} = 1$ quando

$$p > \frac{c_{FP}}{c_{FP} + c_{FN}},$$

e explique por que decidir assim em cada $\mathbf{x}$ minimiza também o custo esperado total.

- No sistema do Exercício 1, cada alarme falso custa R\$ 10, o preço de investigar uma transação honesta, e cada fraude não detectada custa R\$ 500. Qual é o corte ótimo? Interprete o número.
- O corte padrão do `scikit-learn` é 0,5. Que razão de custos ele supõe implicitamente? Por que isso é quase sempre inadequado num problema desbalanceado?