

Aula 09 — Métricas para Classificação

Curso de Aprendizado de Máquina — UFRJ

Leitura recomendada: AME §7.4 e cap. 9; ISLP §4.4–4.5

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- explicar por que a *acurácia* pode ser uma péssima medida de desempenho;
- construir a **matriz de confusão** e definir sensibilidade, especificidade, precisão, VPN e F_1 ;
- derivar o **corte ótimo** sob uma perda assimétrica;
- ler uma **curva ROC**, interpretar a **AUC** e saber quando ela engana;
- escolher entre ajustar o corte, reponderar ou reamostrar em dados desbalanceados;
- distinguir *classificar bem* de *estimar bem probabilidades* e avaliar calibração.

A Aula 08 terminou com um aviso: a acurácia pode enganar. Esta aula é o desdobramento desse aviso. Comece por um caso concreto:

*um teste de câncer que diz “saúdável” para todo mundo acerta 99% das vezes.
Ele é bom?*

Obviamente não — e o desconfortável é que a *acurácia*, sozinha, não sabe disso. Precisamos de medidas que enxerguem *qual* erro foi cometido.

1 Por que a acurácia não basta

O risco 0–1 (Aula 08) trata *todo* erro como igual. Mas:

- **Custos assimétricos:** num *screening*, deixar de detectar um doente (falso negativo) é muito pior que um alarme falso (falso positivo).
- **Dados desbalanceados:** com 10 doentes em 1000, o classificador trivial $g \equiv 0$ tem acurácia 99% — e sensibilidade zero. Como métodos buscam aproximar o classificador de Bayes, eles *tendem* a esse classificador inútil quando a classe é rara.

Atenção

A raiz do problema **não é** o desbalanceamento em si, mas o fato de que os *custos* dos erros são diferentes — de modo que o classificador de Bayes (que minimiza só a probabilidade de erro) deixa de ser o classificador desejado. Tenha isso em mente: as “correções” abaixo são todas formas de codificar custos.




Figura 1: A matriz de confusão e as duas leituras que mais confundem. Precisão e sensibilidade têm o *mesmo* numerador (VP) e denominadores diferentes: uma divide pela *linha* (o que você previu), a outra pela *coluna* (o que de fato era). Saber qual é qual é metade da aula.

2 Matriz de confusão e métricas

Para classificação binária ($Y \in \{0, 1\}$, “1” = positivo), cruzamos predito $\times$ verdadeiro. A matriz de confusão separa os dois tipos de acerto e os dois tipos de erro, e é dela que sai toda métrica desta aula.

As definições formais (cada uma estima uma probabilidade condicional populacional):

$$\begin{aligned}
 \text{Sensibilidade (recall): } S &= \frac{VP}{VP + FN} && \approx \mathbb{P}(\hat{g} = 1 \mid Y = 1), \\
 \text{Especificidade: } E &= \frac{VN}{VN + FP} && \approx \mathbb{P}(\hat{g} = 0 \mid Y = 0), \\
 \text{Precisão (VPP): } P &= \frac{VP}{VP + FP} && \approx \mathbb{P}(Y = 1 \mid \hat{g} = 1), \\
 \text{Valor preditivo negativo: VPN} &= \frac{VN}{VN + FN} && \approx \mathbb{P}(Y = 0 \mid \hat{g} = 0).
 \end{aligned}$$

A **estatística** F_1 combina sensibilidade e precisão pela média harmônica:

$$F_1 = \frac{2}{1/S + 1/P} = \frac{2PS}{P + S}. \quad (1)$$

Ideia central

Por que média *harmônica* e não aritmética? Porque a harmônica pune o desequilíbrio. Um classificador com $S = 1,0$ e $P = 0,02$ — que chama todo mundo de positivo — teria média aritmética 0,51, respeitável; o F_1 dá 0,039. A média harmônica só é alta quando *as duas* são altas, que é exatamente o que se quer exigir.

Atenção

Todas essas quantidades devem ser calculadas no conjunto de *validação/teste*, nunca no treino (senão superestimam o desempenho — Aula 03). E note que sensibilidade e especificidade *não dependem da prevalência*, enquanto precisão e VPN *dependem*: o mesmo teste, aplicado a uma população com menos doentes, tem a mesma sensibilidade e uma

precisão pior. É por isso que um teste “com 99% de sensibilidade” pode, ainda assim, dar mais falsos que verdadeiros positivos numa doença rara.

3 Perdas assimétricas e o corte ótimo

Para codificar custos diferentes, redefina o risco com pesos $l_0, l_1 > 0$:

$$R(g) = l_1 \mathbb{P}(Y \neq g(\mathbf{X}), Y = 0) + l_0 \mathbb{P}(Y \neq g(\mathbf{X}), Y = 1), \quad (2)$$

onde l_0 penaliza errar um positivo (FN) e l_1 penaliza errar um negativo (FP).

Proposição 3.1 (Corte ótimo sob perda assimétrica). *O classificador que minimiza (2) é*

$$g(\mathbf{x}) = \mathbb{I}\left\{ \mathbb{P}(Y = 1 \mid \mathbf{x}) > \frac{l_1}{l_0 + l_1} \right\}.$$

Demonstração. Condicionando em $\mathbf{x}$, o custo esperado de prever 1 é $l_1 \mathbb{P}(Y = 0 \mid \mathbf{x})$ e o de prever 0 é $l_0 \mathbb{P}(Y = 1 \mid \mathbf{x})$. Prevemos 1 quando $l_1 \mathbb{P}(Y = 0 \mid \mathbf{x}) < l_0 \mathbb{P}(Y = 1 \mid \mathbf{x})$, isto é, $l_1(1 - \eta) < l_0 \eta$ com $\eta = \mathbb{P}(Y = 1 \mid \mathbf{x})$, o que dá $\eta > l_1/(l_0 + l_1)$. Como cada $\mathbf{x}$ é otimizado pontualmente, segue o resultado. $\square$

Ideia central

Eis a mensagem operacional: **mudar custos = mudar o corte**. Com $l_0 = l_1$ recuperamos o corte 1/2 (Bayes). Se errar um positivo é dez vezes mais caro ($l_0 = 10l_1$), o corte cai para $1/11 \approx 0,09$ — classificamos como positivo com muito menos evidência. Repare no que *não* é preciso fazer: reajustar o modelo. As probabilidades estimadas continuam as mesmas; muda só o número com que você as compara.

4 Escolhendo o corte: curva ROC e AUC

Um classificador *plug-in* probabilístico gera uma *família* de classificadores variando o corte K : $g_K(\mathbf{x}) = \mathbb{I}\{\hat{\mathbb{P}}(Y = 1 \mid \mathbf{x}) \geq K\}$. Cada K dá um par (sensibilidade, especificidade).

A **curva ROC** (*Receiver Operating Characteristic*) traça a sensibilidade contra 1–especificidade à medida que K varia de 1 a 0. Propriedades:

- o canto superior esquerdo $(0, 1)$ é o classificador perfeito;
- a diagonal é o “palpite aleatório”;
- a **AUC** (área sob a curva) resume o desempenho em um número: AUC = 1 é perfeito, 0,5 é aleatório. Interpretação: probabilidade de o modelo dar *score* maior a um positivo sorteado do que a um negativo sorteado.

Ideia central

A ROC/AUC avalia o *ordenamento* dado pelo modelo **independentemente do corte** — útil para comparar classificadores antes de fixar custos. Já escolhido o contexto, fixa-se K : critério comum é maximizar Sensibilidade + Especificidade (ponto mais próximo do canto $(0, 1)$), ou usar o corte da Prop. 3.1 se os custos são conhecidos.




Figura 2: Uma logística ajustada a um problema com prevalência de 7,9%, avaliada em 20 000 observações novas. **À esquerda**, a curva ROC: cada ponto é um corte diferente do *mesmo* modelo. **À direita**, o que acontece com as métricas conforme o corte anda. No corte padrão 0,50 a sensibilidade é baixíssima — o modelo quase não chama ninguém de positivo. O F_1 é maximizado em 0,23, não em 0,50. E note o número que resume tudo: a acurácia no corte 0,50 é 0,935, contra 0,921 do classificador que chuta “negativo” para todo mundo. Todo esse trabalho de modelagem comprou 1,4 ponto percentual de acurácia — e a acurácia, aqui, não é a pergunta certa.

Atenção

A curva ROC também deve ser construída na *validação/teste*. E cuidado: em dados muito desbalanceados a ROC engana, porque a taxa de falsos positivos tem no denominador a classe majoritária — que é enorme. Mil falsos positivos entre 50 000 negativos mal movem o eixo horizontal, mas podem significar que apenas um em cada dez alarmes é verdadeiro. A *curva precisão–recall* não tem esse problema e é mais informativa nesses casos.

5 Lidando com dados desbalanceados

Três famílias de estratégias (todas, no fundo, codificam custos):

Ajustar o corte

para métodos probabilísticos, basta mover K (Prop. 3.1). Em geral é a solução mais limpa: não mexe no modelo, não descarta dados, não inventa observações.

Reponderar observações

dar peso maior à classe rara no treino, de modo que sua contribuição na função objetivo aumente (`class_weight` no `scikit-learn`). Útil quando o método não estima $\mathbb{P}(Y = 1 | \mathbf{x})$.

Re-amostrar

alterar artificialmente a prevalência: *oversampling* da minoria (ex.: SMOTE) ou *undersampling* da maioria.

Atenção

Repetindo a mensagem central: o “problema” não é o desbalanceamento, são os *custos desiguais*. Se os custos forem realmente iguais, um modelo bem calibrado com corte 1/2

pode ser o correto, mesmo desbalanceado. Não aplique re-amostragem reflexivamente — e note o efeito colateral: reamostrar **destrói a calibração**, porque muda a prevalência que o modelo enxerga. Se você precisa de probabilidades interpretáveis, prefira mexer no corte.

6 Classificar bem $\neq$ estimar bem probabilidades

Um classificador *plug-in* pode estar muito perto do classificador de Bayes **sem** que $\hat{\mathbb{P}} \approx \mathbb{P}$: para a decisão, basta que $\hat{\mathbb{P}}(Y = 1 | \mathbf{x}) - K$ tenha o *mesmo sinal* que $\mathbb{P}(Y = 1 | \mathbf{x}) - K$. Ou seja, boa classificação não garante boa estimativa de probabilidade.

Quando precisamos das *probabilidades* em si (para ordenar riscos, decidir com custos variáveis, ou inferência conformal), avaliamos com **regras de pontuação próprias**, que são minimizadas pela probabilidade verdadeira:

- **Entropia cruzada / log-loss**: $-\frac{1}{n} \sum_i [Y_i \log \hat{p}_i + (1 - Y_i) \log(1 - \hat{p}_i)]$ (é a log-verossimilhança negativa da logística);
- **Score de Brier**: $\frac{1}{n} \sum_i (\hat{p}_i - Y_i)^2$ (erro quadrático das probabilidades).

A ferramenta visual correspondente é a **curva de calibração**: agrupam-se as observações por probabilidade predita e compara-se, em cada grupo, a média predita com a frequência observada. Um modelo calibrado fica sobre a diagonal — entre as observações às quais ele deu 30%, cerca de 30% devem ser positivas.




Figura 3: Duas curvas de calibração num problema com covariáveis fortemente correlacionadas — cenário em que a hipótese do Bayes ingênuo é falsa. Os dois modelos *ordenam* as observações praticamente igual (AUC 0,774 contra 0,776), mas o Bayes ingênuo chega a atribuir probabilidade 0,99 a grupos em que só 29% são positivos. O score de Brier registra a diferença que a AUC não vê: 0,065 contra 0,152, quase três vezes pior.

Ideia central

A Figura 3 é a demonstração literal do título desta seção. Se você só precisa *decidir* — aprovar ou não um crédito, marcar ou não um exame — os dois modelos são equivalentes, e a AUC lhe diz isso corretamente. Se você precisa *do número* — para calcular o valor esperado de uma decisão, ou para comunicar risco a alguém — o Bayes ingênuo é inutilizável, e só uma métrica de calibração denuncia. Escolha a métrica pela pergunta que você vai responder.

Observação 6.1. O motivo do descalibramento aqui é o da Aula 08: com covariáveis correlacionadas, o produto $f(\mathbf{x} \mid Y = c) = \prod_j f(x_j \mid Y = c)$ do Bayes ingênuo conta a mesma evidência muitas vezes, e o resultado é um modelo excessivamente confiante. Existem correções *a posteriori* — a escala de Platt (ajustar uma logística sobre os *scores*) e a regressão isotônica — disponíveis no `scikit-learn` como `CalibratedClassifierCV`. Elas exigem dados próprios, separados do treino, pelo motivo de sempre.

7 Prática em Python

```

1 from sklearn.metrics import (confusion_matrix, classification_report,
2                               roc_curve, roc_auc_score, brier_score_loss)
3
4 p = modelo.predict_proba(X_te)[: , 1] # probabilidades estimadas
5
6 # 1. métricas no corte padrão 0,5
7 print(confusion_matrix(y_te, p >= 0.5))
8 print(classification_report(y_te, p >= 0.5)) # precisao, recall, F1 por classe
9
10 # 2. desempenho independente do corte
11 print("AUC:", roc_auc_score(y_te, p))
12 fpr, tpr, cortes = roc_curve(y_te, p)
13
14 # 3. qualidade das PROBABILIDADES, não da decisão
15 print("Brier:", brier_score_loss(y_te, p))

```

Atenção

Ao escolher hiperparâmetros por validação cruzada (Aula 03), passe o `scoring` certo para a sua pergunta: `"roc_auc"` para ordenamento, `"f1"` ou `"average_precision"` para classes raras, `"neg_brier_score"` ou `"neg_log_loss"` para probabilidades calibradas. O padrão — acurácia — é justamente o que esta aula inteira desaconselha.

O notebook Aula prática 08 e o material `MatConf.pdf` exploram esses conceitos com dados reais.

Resumo

- Acurácia esconde *qual* erro foi cometido; em classe rara, o classificador trivial já acerta quase tudo (Fig. 2).
- A **matriz de confusão** (Fig. 1) gera sensibilidade e especificidade (leitura por coluna, independentes da prevalência) e precisão e VPN (leitura por linha, dependentes dela); F_1 (1) é a média harmônica de P e S .
- Custos assimétricos $\Rightarrow$ o corte ótimo é $l_1/(l_0 + l_1)$ (Prop. 3.1), não 1/2. Mudar custos é mudar o corte, não o modelo.
- **ROC/AUC** avaliam o ordenamento, livres do corte; em desbalanceamento forte, prefira precisão-recall.
- Desbalanceamento: ajustar corte (limpo), reponderar, ou reamostrar (destrói calibração).
- **Classificar bem $\neq$ estimar bem probabilidades** (Fig. 3): use *log-loss*/Brier e curvas de calibração quando o número importar.

Leitura recomendada. [AME] §7.4 (matriz de confusão e as métricas derivadas), §9.1 (perdas assimétricas, cortes e dados desbalanceados — de onde vem a nossa Prop. 3.1) e §9.2 (classificação *versus* estimação de probabilidades, o tema da nossa Figura 3). [ISLP] §4.4.2 (matriz de confusão no exemplo do `Default`, com uma discussão muito concreta de sensibilidade em classe rara) e §4.4.3 (curva ROC e AUC).

Para praticar. `recursos/listas/Lista de exercicios 08.pdf` traz questões sobre as métricas desta aula.