Aula 09 — Máquinas de Vetores de Suporte (SVM)

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §8.2 e §4.6; ISLP cap. 9

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- descrever um hiperplano de $\mathbb{R}^p$, calcular a distância de um ponto a ele e usá-lo como classificador;
- formular o classificador de margem máxima e reconhecer os seus vetores de suporte;
- formular o classificador de vetor de suporte e interpretar as folgas ε_i e o orçamento C;
- entender que a solução depende dos dados apenas por meio de produtos internos, e como isso leva aos *kernels*;
- decidir se uma função é um *kernel*, usar os *kernels* linear, polinomial e radial e entender o papel de γ;
- tratar problemas com mais de duas classes.

Na Aula 07, os classificadores foram construídos a partir de estimativas de $\mathbb{P}(Y = c \mid \boldsymbol{x})$: cada $\boldsymbol{x}$ era atribuído à classe de maior probabilidade estimada. Dois deles, a análise discriminante linear e a regressão logística, têm fronteira de decisão linear, mas chegam a ela por meio de um modelo probabilístico. Nesta aula seguimos outro caminho: procuramos diretamente um hiperplano que separe as classes, usando apenas a geometria das observações de treino, sem modelar probabilidade alguma. As primeiras ideias nessa direção são de Vapnik e Chervonenkis (1963), e a formulação usada hoje é de Cortes e Vapnik (1995). A pergunta que organiza a aula é a seguinte:

se há infinitos hiperplanos que separam as classes, qual deles escolher?

1 Hiperplanos e classificação

Definição 1.1 (Hiperplano)**.** Sejam $\beta_0 \in \mathbb{R}$ e $\boldsymbol{\beta} = (\beta_1, \ldots, \beta_p)^\top \in \mathbb{R}^p$, com $\boldsymbol{\beta} \neq \mathbf{0}$, e seja $f(\boldsymbol{x}) = \beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}$. O conjunto

$$H = \{\boldsymbol{x} \in \mathbb{R}^p : f(\boldsymbol{x}) = 0\}$$

é um *hiperplano* de $\mathbb{R}^p$. Os conjuntos $\{\boldsymbol{x} : f(\boldsymbol{x}) > 0\}$ e $\{\boldsymbol{x} : f(\boldsymbol{x}) < 0\}$ são os dois *lados* de H.

A exigência $\boldsymbol{\beta} \neq \mathbf{0}$ é essencial: com $\boldsymbol{\beta} = \mathbf{0}$, o conjunto H seria vazio ou o próprio $\mathbb{R}^p$. Com ela, H é um subespaço afim de dimensão $p - 1$. De fato, H contém o ponto $\boldsymbol{h} = -\beta_0 \boldsymbol{\beta} / \|\boldsymbol{\beta}\|^2$, e $\boldsymbol{x} \in H$ se e somente se $\boldsymbol{\beta}^\top (\boldsymbol{x} - \boldsymbol{h}) = 0$, de modo que H é o transladado, por $\boldsymbol{h}$, do complemento ortogonal de $\boldsymbol{\beta}$, que tem dimensão $p - 1$. Em $\mathbb{R}^2$, um hiperplano é uma reta; em $\mathbb{R}^3$, um plano.

Os coeficientes não são determinados pelo hiperplano: para todo $c \neq 0$, o par $(c\beta_0, c\boldsymbol{\beta})$ define o mesmo H. A normalização $\|\boldsymbol{\beta}\| = 1$ elimina essa liberdade, a menos do sinal, e o sinal escolhe qual dos lados é o positivo. Com ela, $|f(\boldsymbol{x})|$ ganha um significado geométrico preciso.

Proposição 1.2 (Distância a um hiperplano)**.** *Para todo $\boldsymbol{x} \in \mathbb{R}^p$, a distância de $\boldsymbol{x}$ ao hiperplano H é*

$$d(\boldsymbol{x}, H) = \min_{\boldsymbol{z} \in H} \|\boldsymbol{x} - \boldsymbol{z}\| = \frac{|f(\boldsymbol{x})|}{\|\boldsymbol{\beta}\|}.$$

Em particular, se $\|\boldsymbol{\beta}\| = 1$, então $d(\boldsymbol{x}, H) = |f(\boldsymbol{x})|$.

Demonstração. Seja $\boldsymbol{x}_0 = \boldsymbol{x} - \left(f(\boldsymbol{x})/\|\boldsymbol{\beta}\|^2\right)\boldsymbol{\beta}$. Como $f(\boldsymbol{x}_0) = f(\boldsymbol{x}) - \left(f(\boldsymbol{x})/\|\boldsymbol{\beta}\|^2\right)\boldsymbol{\beta}^\top\boldsymbol{\beta} = 0$, o ponto $\boldsymbol{x}_0$ está em H. Para $\boldsymbol{z} \in H$, vale $\boldsymbol{\beta}^\top(\boldsymbol{x}_0 - \boldsymbol{z}) = f(\boldsymbol{x}_0) - f(\boldsymbol{z}) = 0$; logo $\boldsymbol{x} - \boldsymbol{x}_0$, que é múltiplo de $\boldsymbol{\beta}$, é ortogonal a $\boldsymbol{x}_0 - \boldsymbol{z}$. Pelo Teorema de Pitágoras,

$$\|\boldsymbol{x} - \boldsymbol{z}\|^2 = \|\boldsymbol{x} - \boldsymbol{x}_0\|^2 + \|\boldsymbol{x}_0 - \boldsymbol{z}\|^2 \;\geq\; \|\boldsymbol{x} - \boldsymbol{x}_0\|^2 = \frac{f(\boldsymbol{x})^2}{\|\boldsymbol{\beta}\|^2},$$

com igualdade se e somente se $\boldsymbol{z} = \boldsymbol{x}_0$. □

Para classificar, codificamos as duas classes por $y \in \{-1, +1\}$ e atribuímos $\boldsymbol{x}$ à classe $+1$ se $f(\boldsymbol{x}) > 0$ e à classe -1 se $f(\boldsymbol{x}) < 0$, com uma convenção qualquer para os pontos de H. Com $\|\boldsymbol{\beta}\| = 1$, o número $|f(\boldsymbol{x})|$ é a distância de $\boldsymbol{x}$ à fronteira de decisão: quanto maior, mais longe da fronteira está o ponto, e mais segura é a sua classificação.

Sejam $(\boldsymbol{x}_1, y_1)$, …, $(\boldsymbol{x}_n, y_n)$ as observações de treino, com $\boldsymbol{x}_i \in \mathbb{R}^p$ e $y_i \in \{-1, +1\}$, e suponha que haja observações das duas classes. O hiperplano classifica corretamente a observação i exatamente quando y_i e $f(\boldsymbol{x}_i)$ têm o mesmo sinal, isto é, quando $y_i f(\boldsymbol{x}_i) > 0$. Com $\|\boldsymbol{\beta}\| = 1$, a Proposição 1.2 dá $|y_i f(\boldsymbol{x}_i)| = |f(\boldsymbol{x}_i)| = d(\boldsymbol{x}_i, H)$, e portanto

$$y_i f(\boldsymbol{x}_i) = \begin{cases} d(\boldsymbol{x}_i, H), & \text{se a observação } i \text{ está do lado certo de } H, \\ -d(\boldsymbol{x}_i, H), & \text{se está do lado errado.} \end{cases}$$

É para isso que serve a codificação ± 1: as n condições de acerto passam a ter todas a mesma forma, e o mesmo número diz se a observação está do lado certo e a que distância do hiperplano.

Definição 1.3 (Separabilidade linear)**.** As observações de treino são *linearmente separáveis* se existe $(\beta_0, \boldsymbol{\beta})$, com $\boldsymbol{\beta} \neq \mathbf{0}$, tal que

$$y_i\,(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) > 0 \qquad \text{para } i = 1, \ldots, n. \tag{1}$$

O hiperplano correspondente é dito *separador*.

2 O classificador de margem máxima

Se as observações são linearmente separáveis, há infinitos hiperplanos separadores: as desigualdades (1) são estritas e em número finito, e, por continuidade, continuam valendo depois de uma perturbação suficientemente pequena de $(\beta_0, \boldsymbol{\beta})$. É preciso um critério para escolher um deles, e o critério natural é ficar o mais longe possível das observações de treino.

Definição 2.1 (Margem)**.** Para $(\beta_0, \boldsymbol{\beta})$ com $\|\boldsymbol{\beta}\| = 1$, seja

$$m(\beta_0, \boldsymbol{\beta}) = \min_{1 \leq i \leq n} \; y_i\,(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i).$$

Se o hiperplano é separador, $m(\beta_0, \boldsymbol{\beta}) > 0$ é a menor distância de uma observação de treino a ele, e é chamado de *margem* do hiperplano.

Definição 2.2 (Classificador de margem máxima)**.** Suponha as observações linearmente separáveis. O *classificador de margem máxima* é o hiperplano dado pela solução do problema

$$\max_{\beta_0, \boldsymbol{\beta}, M} \; M \quad \text{sujeito a} \quad \sum_{j=1}^{p} \beta_j^2 = 1 \quad \text{e} \quad y_i\,(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) \geq M, \quad i = 1, \ldots, n. \tag{2}$$

Para $(\beta_0, \boldsymbol{\beta})$ fixos, as restrições dizem que M não excede nenhum dos números $y_i(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i)$, e o maior M permitido é $m(\beta_0, \boldsymbol{\beta})$. O problema (2) procura, portanto, o hiperplano de maior margem. As duas restrições têm papéis distintos.

- A restrição $\sum_j \beta_j^2 = 1$ garante que $y_i(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i)$, quando positivo, é a distância de $\boldsymbol{x}_i$ ao hiperplano, pela Proposição 1.2. Sem ela, multiplicar $(\beta_0, \boldsymbol{\beta})$ por $c > 1$ multiplicaria por c todos esses números, sem mudar o hiperplano, e M cresceria sem limite.
- As restrições $y_i(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) \geq M$ dizem que cada observação está do lado certo do hiperplano, a uma distância pelo menos M dele.

Se um ponto satisfaz as restrições com $M > 0$, todas as observações estão do lado certo, e os dados são separáveis. Reciprocamente, se $(\beta_0, \boldsymbol{\beta})$ é separador e $\|\boldsymbol{\beta}\| = 1$, as restrições valem com $M = m(\beta_0, \boldsymbol{\beta}) > 0$. Assim, o valor ótimo de (2) é positivo se e somente se as observações são linearmente separáveis. Sem separabilidade, (2) não tem solução com $M > 0$.

Definição 2.3 (Vetores de suporte)**.** As observações de treino que estão à distância M do classificador de margem máxima, isto é, com $y_i(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) = M$, são os seus *vetores de suporte*.

Nenhuma observação de treino está no interior da faixa $\{\boldsymbol{x} : |f(\boldsymbol{x})| < M\}$, e os vetores de suporte estão sobre a sua borda. Pode-se mostrar que o classificador de margem máxima depende apenas deles: retirar uma observação que não é vetor de suporte, ou deslocá-la para outro ponto do mesmo lado e fora da faixa, não altera a solução.

Atenção

Por ser determinado por poucos pontos, o classificador de margem máxima é muito sensível às observações próximas da fronteira: uma única observação nova, perto do hiperplano, pode deslocá-lo bastante. Isso indica variância alta e risco de superajuste. Além disso, ele só existe quando as classes são linearmente separáveis, o que é raro em dados reais. As duas limitações motivam a próxima seção.

3 O classificador de vetor de suporte

A ideia agora é abrir mão de classificar todas as observações de treino corretamente e com folga. Admite-se que algumas fiquem dentro da faixa da margem, ou mesmo do lado errado do hiperplano, em troca de uma solução que dependa menos de cada observação isolada e que deixe a maioria delas mais longe da fronteira. A mesma ideia resolve o caso em que as classes não são linearmente separáveis.

Definição 3.1 (Classificador de vetor de suporte)**.** Dado $C \geq 0$, o *classificador de vetor de suporte* é o hiperplano dado pela solução do problema

$$\begin{aligned} \max_{\beta_0, \boldsymbol{\beta}, \boldsymbol{\varepsilon}, M} \quad & M \\ \text{sujeito a} \quad & \textstyle\sum_{j=1}^{p} \beta_j^2 = 1, \\ & y_i\,(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) \geq M(1 - \varepsilon_i), \quad i = 1, \ldots, n, \\ & \varepsilon_i \geq 0, \quad i = 1, \ldots, n, \qquad \textstyle\sum_{i=1}^{n} \varepsilon_i \leq C. \end{aligned} \tag{3}$$

As variáveis $\varepsilon_1, \ldots, \varepsilon_n$ são as *folgas*, e C é o *orçamento* de violações.

Supomos daqui em diante que (3) tem solução com $M > 0$. A Observação 3.3, adiante, mostra que isso restringe C a uma faixa de valores.

O que as folgas medem. Fixe $(\beta_0, \boldsymbol{\beta}, M)$, com $M > 0$. A restrição da observação i vale se e somente se $\varepsilon_i \geq 1 - y_i f(\boldsymbol{x}_i)/M$, e a menor folga admissível é

$$\varepsilon_i = \max\left\{0,\ 1 - \frac{y_i f(\boldsymbol{x}_i)}{M}\right\}.$$

Numa solução de (3), podemos supor que as folgas têm esses valores mínimos, porque reduzi-las a eles preserva todas as restrições e não altera M. Com essa escolha, e lembrando que $y_i f(\boldsymbol{x}_i)$ vale $d(\boldsymbol{x}_i, H)$ do lado certo do hiperplano e $-d(\boldsymbol{x}_i, H)$ do lado errado, há quatro casos:

- $\varepsilon_i = 0$ se e somente se $y_i f(\boldsymbol{x}_i) \geq M$: a observação está do lado certo da margem, ou sobre ela;
- $0 < \varepsilon_i < 1$ se e somente se $0 < y_i f(\boldsymbol{x}_i) < M$: a observação está do lado errado da margem, mas do lado certo do hiperplano;
- $\varepsilon_i = 1$ se e somente se $f(\boldsymbol{x}_i) = 0$: a observação está sobre o hiperplano;
- $\varepsilon_i > 1$ se e somente se $y_i f(\boldsymbol{x}_i) < 0$: a observação está do lado errado do hiperplano, isto é, é classificada errado.

O papel do orçamento. Com $C = 0$, todas as folgas são nulas, e (3) coincide com (2): o classificador de margem máxima é o caso particular sem orçamento. Com $C > 0$, o orçamento limita o número de erros de classificação no treino.

Proposição 3.2. *Seja $(\beta_0, \boldsymbol{\beta}, \boldsymbol{\varepsilon}, M)$ um ponto que satisfaz as restrições de (3), com $M > 0$ e $C > 0$. Então menos de C observações de treino estão do lado errado do hiperplano.*

Demonstração. Se $y_i f(\boldsymbol{x}_i) < 0$, a restrição da observação i dá $M(1 - \varepsilon_i) \leq y_i f(\boldsymbol{x}_i) < 0$, e, como $M > 0$, segue que $\varepsilon_i > 1$. Seja E o conjunto dessas observações e ℓ o seu número de elementos. Se $\ell = 0$, não há o que provar. Se $\ell \geq 1$,

$$\ell < \sum_{i \in E} \varepsilon_i \leq \sum_{i=1}^{n} \varepsilon_i \leq C. \qquad \square$$

O orçamento também governa a margem. Se $C \leq C'$, todo ponto que satisfaz as restrições com orçamento C as satisfaz com orçamento C', e o máximo sobre um conjunto maior não pode ser menor; logo o valor ótimo de M é uma função não decrescente de C. Aumentar o orçamento é tolerar mais violações da margem em troca de uma margem maior ou igual. A Figura 1 mostra o efeito num mesmo conjunto de dados.

Vetores de suporte. Os *vetores de suporte* do classificador de vetor de suporte são as observações que estão sobre a margem ou do lado errado dela, isto é, com $y_i f(\boldsymbol{x}_i) \leq M$. Também aqui pode-se mostrar que o hiperplano depende apenas deles: uma observação do lado certo e fora da faixa da margem pode ser retirada, ou deslocada para outro ponto do lado certo e fora da faixa, sem que a solução mude. Na Figura 1, o orçamento maior alarga a faixa e traz mais pontos para dentro dela, e o número de vetores de suporte cresce.

Essa propriedade distingue o classificador de vetor de suporte de outros métodos com fronteira linear. Na análise discriminante linear (Aula 07), as médias das classes e a matriz de covariâncias comum são estimadas com todas as observações, e deslocar qualquer uma delas altera, em geral, a fronteira estimada, por mais longe dela que a observação esteja. A regressão logística fica entre os dois casos. Nas equações de máxima verossimilhança,

$$\sum_{i=1}^{n} \left(y_i - \widehat{p}(\boldsymbol{x}_i)\right) \begin{pmatrix} 1 \\ \boldsymbol{x}_i \end{pmatrix} = \mathbf{0},$$

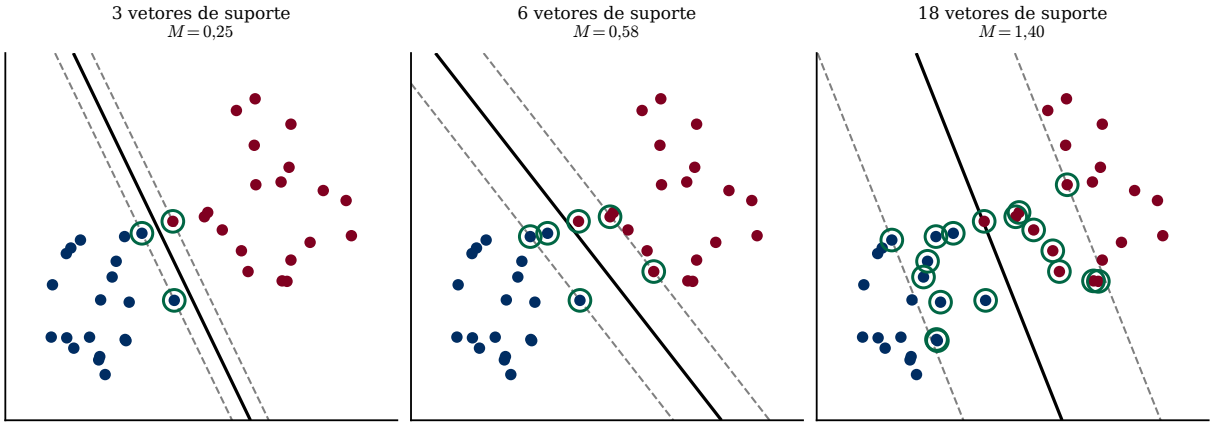


Figura 1: O mesmo conjunto de 40 pontos e três orçamentos de violação, do menor (à esquerda) ao maior (à direita). A linha cheia é o hiperplano, e as tracejadas estão à distância M dele, de modo que a faixa entre elas tem largura $2M$. Os pontos circulados em verde são os vetores de suporte. À medida que o orçamento cresce, M passa de 0,25 a 1,40, e o número de vetores de suporte, de 3 a 18.

escritas com $y_i \in \{0, 1\}$, a observação i entra com o peso $y_i - \widehat{p}(\boldsymbol{x}_i)$, que é próximo de zero quando ela está bem classificada e longe da fronteira. A logística é, portanto, pouco sensível a essas observações, mas não insensível.

Ideia central

O orçamento C é um *tuning parameter* e regula o balanço entre viés e variância. Com C pequeno, a margem é estreita e a solução depende de poucas observações, as mais próximas da fronteira: o classificador se ajusta de perto aos dados de treino, com viés baixo e variância alta. Com C grande, a margem é larga, a solução depende de muitas observações e muda pouco quando uma delas muda: viés mais alto e variância mais baixa. Como nas aulas anteriores, C é escolhido por validação cruzada (Aula 03).

Observação 3.3 (A faixa de valores de C)**.** A hipótese de que (3) tem solução com $M > 0$ falha nos dois extremos. Se os dados não são linearmente separáveis e $C = 0$, nenhum ponto com $M > 0$ satisfaz as restrições. No outro extremo, se $C > n$, tome qualquer $(\beta_0, \boldsymbol{\beta})$ com $\|\boldsymbol{\beta}\| = 1$ e folgas $\varepsilon_i = C/n > 1$: a restrição da observação i fica $y_i f(\boldsymbol{x}_i) \geq -M(C/n - 1)$, e vale para todo M suficientemente grande. O valor de M cresce, então, sem limite, e o problema não tem solução.

4 Fronteiras não lineares

A fronteira do classificador de vetor de suporte é um hiperplano, e nenhum hiperplano aproxima bem uma fronteira de Bayes muito curva. O exemplo típico é o de uma classe cercada pela outra, como nos anéis concêntricos da Figura 2: ali, o classificador linear acerta 60% das observações de treino, pouco mais que os 50% de quem atribui todas à mesma classe.

Ampliar o espaço das covariáveis. Como na regressão polinomial, podemos ajustar o classificador de vetor de suporte às $2p$ covariáveis $X_1, \ldots, X_p, X_1^2, \ldots, X_p^2$, isto é, resolver (3) com

$$f(\boldsymbol{x}) = \beta_0 + \sum_{j=1}^{p} \beta_{j1} x_j + \sum_{j=1}^{p} \beta_{j2} x_j^2$$

e a restrição $\sum_j (\beta_{j1}^2 + \beta_{j2}^2) = 1$. A fronteira $\{\boldsymbol{x} : f(\boldsymbol{x}) = 0\}$ é um hiperplano do espaço ampliado e, no espaço original, uma superfície quadrática; em $\mathbb{R}^2$, uma cônica. O preço é o número de

coeficientes. Usando todos os monômios de grau até q nas p covariáveis, que são $\binom{p+q}{q}$, já seriam 231 com $p = 20$ e $q = 2$, e 53 130 com $p = 20$ e $q = 5$.

A solução depende dos dados por meio de produtos internos. O fato que permite contornar esse custo é o seguinte, que admitiremos sem demonstração (ver [ISLP], §9.3.2).

Proposição 4.1. *Seja $(\beta_0, \boldsymbol{\beta}, \boldsymbol{\varepsilon}, M)$ uma solução de (3), e seja $\mathcal{S}$ o conjunto dos índices dos vetores de suporte. Existem $\alpha_1, \dots, \alpha_n \in \mathbb{R}$, com $\alpha_i = 0$ para $i \notin \mathcal{S}$, tais que*

$$f(\boldsymbol{x}) = \beta_0 + \sum_{i=1}^{n} \alpha_i \langle \boldsymbol{x}, \boldsymbol{x}_i \rangle = \beta_0 + \sum_{i \in \mathcal{S}} \alpha_i \langle \boldsymbol{x}, \boldsymbol{x}_i \rangle \qquad \text{para todo } \boldsymbol{x} \in \mathbb{R}^p, \tag{4}$$

em que $\langle \boldsymbol{x}, \boldsymbol{x}_i \rangle = \sum_{j=1}^{p} x_j x_{ij}$. Além disso, β_0 e $\alpha_1, \dots, \alpha_n$ podem ser calculados a partir apenas dos $n(n+1)/2$ produtos internos $\langle \boldsymbol{x}_i, \boldsymbol{x}_j \rangle$, $1 \le i \le j \le n$.

A Proposição 4.1 diz que os dados entram no ajuste e na previsão somente por meio de produtos internos. Para ajustar, bastam os produtos internos entre as observações de treino; para classificar um ponto novo $\boldsymbol{x}$, bastam os produtos internos entre $\boldsymbol{x}$ e os vetores de suporte.

5 *Kernels* e a máquina de vetores de suporte

O produto interno mede a semelhança entre dois vetores: para vetores de norma fixa, $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ é tanto maior quanto menor o ângulo entre eles. A Proposição 4.1 sugere trocá-lo por outras medidas de semelhança.

Definição 5.1 (*Kernel*)**.** Uma função $k : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$ é um *kernel* se existem um espaço de Hilbert real $\mathcal{H}$, com produto interno $\langle \cdot, \cdot \rangle_{\mathcal{H}}$, e uma função $\varphi : \mathbb{R}^p \to \mathcal{H}$ tais que

$$k(\boldsymbol{x}, \boldsymbol{x}') = \big\langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \big\rangle_{\mathcal{H}} \qquad \text{para todos } \boldsymbol{x}, \boldsymbol{x}' \in \mathbb{R}^p.$$

Um *kernel* é, portanto, um produto interno calculado depois de levar os pontos, por meio de φ, a um espaço possivelmente de dimensão infinita. Os mais usados são os seguintes.

Kernel	$k(\boldsymbol{x}, \boldsymbol{x}')$	parâmetro
linear	$\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$	nenhum
polinomial de grau q	$\big(1 + \langle \boldsymbol{x}, \boldsymbol{x}' \rangle\big)^q$	$q \in \{1, 2, \dots\}$
radial, ou gaussiano	$\exp\big(-\gamma \, \lVert \boldsymbol{x} - \boldsymbol{x}' \rVert^2\big)$	$\gamma > 0$

O linear é o próprio produto interno, com $\mathcal{H} = \mathbb{R}^p$ e φ a identidade. Para os outros dois, os exemplos a seguir exibem uma função φ.

Exemplo 5.2. Em $\mathbb{R}^2$, seja $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \boldsymbol{x}, \boldsymbol{x}' \rangle^2$. Expandindo o quadrado,

$$(x_1 x_1' + x_2 x_2')^2 = x_1^2 x_1'^2 + 2\, x_1 x_2\, x_1' x_2' + x_2^2 x_2'^2 = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle ,$$

com $\varphi(\boldsymbol{x}) = (x_1^2,\ \sqrt{2}\, x_1 x_2,\ x_2^2) \in \mathbb{R}^3$. Calcular k custa um produto interno em $\mathbb{R}^2$ e um quadrado; passar por φ dá o mesmo número com mais contas. Um plano de $\mathbb{R}^3$, $b_0 + b_1 z_1 + b_2 z_2 + b_3 z_3 = 0$, corresponde em $\mathbb{R}^2$ à cônica $b_0 + b_1 x_1^2 + \sqrt{2}\, b_2 x_1 x_2 + b_3 x_2^2 = 0$. Com $b_1 = b_3 = 1$, $b_2 = 0$ e $b_0 = -r^2$, ela é a circunferência de raio r centrada na origem, que é a fronteira de que os anéis da Figura 2 precisam.

O mesmo cálculo vale para o *kernel* polinomial em geral. Expandindo $\big(1 + \sum_j x_j x_j'\big)^q$ pela fórmula do multinômio, obtém-se uma soma de termos $c_{\boldsymbol{a}}\, \boldsymbol{x}^{\boldsymbol{a}}\, \boldsymbol{x}'^{\boldsymbol{a}}$, um para cada monômio $\boldsymbol{x}^{\boldsymbol{a}} = x_1^{a_1} \cdots x_p^{a_p}$ de grau $a_1 + \cdots + a_p \le q$, com coeficientes $c_{\boldsymbol{a}} > 0$. Basta então tomar $\varphi(\boldsymbol{x}) = \big(\sqrt{c_{\boldsymbol{a}}}\, \boldsymbol{x}^{\boldsymbol{a}}\big)_{\boldsymbol{a}}$, que tem $\binom{p+q}{q}$ coordenadas, enquanto $k(\boldsymbol{x}, \boldsymbol{x}')$ se calcula com cerca de p operações.

Exemplo 5.3. Para $p = 1$, o *kernel* radial se fatora como

$$e^{-\gamma(x-x')^2} = e^{-\gamma x^2}\, e^{-\gamma x'^2}\, e^{2\gamma x x'} = \sum_{m=0}^{\infty} \varphi_m(x)\, \varphi_m(x'), \qquad \varphi_m(x) = \sqrt{\frac{(2\gamma)^m}{m!}}\, x^m e^{-\gamma x^2},$$

pela série de Taylor de $e^{2\gamma x x'}$. Então $k(x, x') = \langle \varphi(x), \varphi(x') \rangle$, com $\varphi(x) = (\varphi_0(x), \varphi_1(x), \dots)$ no espaço ℓ^2 das sequências de quadrado somável; de fato, $\sum_m \varphi_m(x)^2 = k(x, x) = 1$. Aqui $\mathcal{H} = \ell^2$ tem dimensão infinita, e ainda assim $k(x, x')$ se calcula com uma subtração, um quadrado e uma exponencial.

Nem toda função de duas variáveis é um *kernel*, e exibir φ nem sempre é fácil. O teorema a seguir dá um critério que envolve apenas k.

Teorema 5.4. *Uma função $k : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$ é um* kernel *se e somente se*

(i) é simétrica, isto é, $k(\boldsymbol{x}, \boldsymbol{x}') = k(\boldsymbol{x}', \boldsymbol{x})$ para todos $\boldsymbol{x}, \boldsymbol{x}' \in \mathbb{R}^p$; e

(ii) é positiva semidefinida, isto é, para todo $n \geq 1$ e quaisquer $\boldsymbol{x}_1, \dots, \boldsymbol{x}_n \in \mathbb{R}^p$, a matriz $\big[k(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]_{i,j=1}^n$ é positiva semidefinida.

Demonstração de que as condições são necessárias. Se $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle_{\mathcal{H}}$, a simetria de k vem da simetria do produto interno. Dados $\boldsymbol{x}_1, \dots, \boldsymbol{x}_n$ e $\boldsymbol{a} \in \mathbb{R}^n$, a bilinearidade do produto interno dá

$$\sum_{i=1}^n \sum_{j=1}^n a_i a_j\, k(\boldsymbol{x}_i, \boldsymbol{x}_j) = \Big\langle \sum_{i=1}^n a_i \varphi(\boldsymbol{x}_i),\ \sum_{j=1}^n a_j \varphi(\boldsymbol{x}_j) \Big\rangle_{\mathcal{H}} = \Big\| \sum_{i=1}^n a_i \varphi(\boldsymbol{x}_i) \Big\|_{\mathcal{H}}^2 \ \geq\ 0. \qquad \square$$

A suficiência é mais difícil e não será demonstrada: a partir de uma função k simétrica e positiva semidefinida, constrói-se um espaço de Hilbert $\mathcal{H}$ de funções, o espaço de Hilbert com *kernel* reprodutor, em que $\varphi(\boldsymbol{x}) = k(\cdot, \boldsymbol{x})$ satisfaz a definição (Aronszajn, 1950). O [AME], §4.6, chama essas funções de *kernels* de Mercer e obtém φ pelo Teorema de Mercer. Na prática, o Teorema 5.4 serve para verificar que uma função é um *kernel* sem exibir φ, e também para mostrar que uma função não é: $k(\boldsymbol{x}, \boldsymbol{x}') = -\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$, por exemplo, não é um *kernel*, porque $k(\boldsymbol{x}_1, \boldsymbol{x}_1) = -\|\boldsymbol{x}_1\|^2 < 0$ para $\boldsymbol{x}_1 \neq \boldsymbol{0}$.

A máquina de vetores de suporte. Escolhido um *kernel* k, a *máquina de vetores de suporte* (SVM) é o classificador de vetor de suporte ajustado aos pontos $\varphi(\boldsymbol{x}_1), \dots, \varphi(\boldsymbol{x}_n)$ de $\mathcal{H}$. A Proposição 4.1 continua valendo quando $\mathbb{R}^p$ é substituído por um espaço de Hilbert, e dá a função de decisão

$$f(\boldsymbol{x}) = \beta_0 + \sum_{i \in \mathcal{S}} \alpha_i\, k(\boldsymbol{x}, \boldsymbol{x}_i), \tag{5}$$

em que β_0 e os α_i se calculam a partir dos números $k(\boldsymbol{x}_i, \boldsymbol{x}_j)$, no lugar dos produtos internos $\langle \boldsymbol{x}_i, \boldsymbol{x}_j \rangle$. Nem φ nem $\mathcal{H}$ precisam ser construídos, porque o ajuste e a previsão só usam valores de k: é o chamado *truque do kernel*. O número de parâmetros, β_0 e $\alpha_1, \dots, \alpha_n$, não depende da dimensão de $\mathcal{H}$, mesmo quando ela é infinita. A fronteira $\{\boldsymbol{x} : f(\boldsymbol{x}) = 0\}$ é a imagem inversa, por φ, de um hiperplano de $\mathcal{H}$: linear em $\mathcal{H}$, ela em geral não é linear em $\mathbb{R}^p$.

O parâmetro γ. No *kernel* radial, $k(\boldsymbol{x}, \boldsymbol{x}_i) = e^{-\gamma \|\boldsymbol{x} - \boldsymbol{x}_i\|^2}$ decai com a distância entre $\boldsymbol{x}$ e $\boldsymbol{x}_i$, e γ regula a rapidez do decaimento. Com γ grande, $k(\boldsymbol{x}, \boldsymbol{x}_i)$ é desprezível, salvo para $\boldsymbol{x}$ muito perto de $\boldsymbol{x}_i$. Em (5), $f(\boldsymbol{x})$ fica então determinado pelos poucos vetores de suporte mais próximos de $\boldsymbol{x}$, e, longe de todos eles, $f(\boldsymbol{x}) \approx \beta_0$; a fronteira pode contornar observações isoladas. É uma fronteira flexível, com risco de superajuste. Com γ pequeno, $k(\boldsymbol{x}, \boldsymbol{x}_i)$ varia devagar, muitos vetores de suporte pesam em cada ponto, e a fronteira é suave. Como C e γ interagem, eles são escolhidos juntos, por validação cruzada sobre uma grade de pares (C, γ).

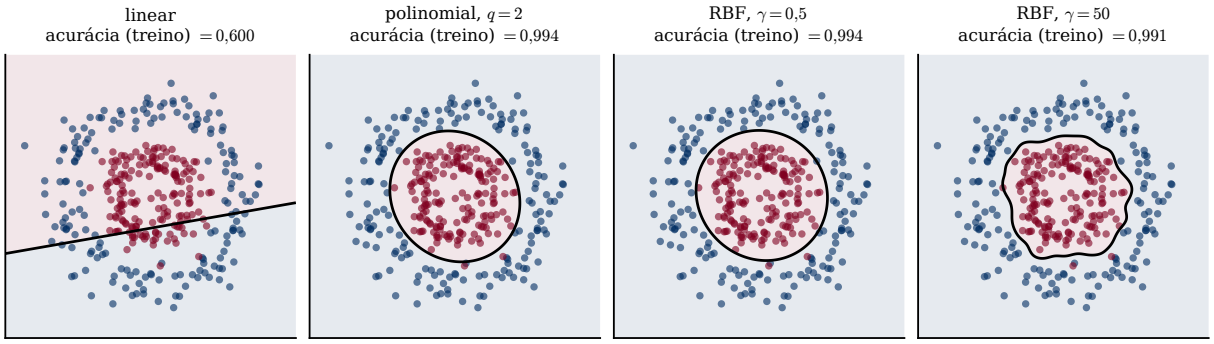


Figura 2: Duas classes de 175 pontos cada, em anéis concêntricos, e quatro máquinas de vetores de suporte ajustadas a elas. Com o *kernel* linear, a acurácia de treino é 60%. O polinomial de grau 2 usado aqui não tem o termo constante: é um múltiplo do *kernel* do Exemplo 5.2. Ele chega a 99,4% com uma fronteira próxima de uma circunferência, e o radial com $\gamma = 0{,}5$ também. O radial com $\gamma = 50$ chega a 99,1% com uma fronteira irregular, que contorna observações isoladas. A acurácia de treino quase não distingue os três últimos e não revela o superajuste do último; para escolher γ, é preciso estimar o risco, por validação cruzada, por exemplo.

6 Mais de duas classes

As formulações desta aula usam a codificação $y \in \{-1, +1\}$ de modo essencial: a condição de acerto $y_i f(\boldsymbol{x}_i) > 0$ não tem análogo direto com três ou mais classes. Com $K = |\mathcal{C}| \geq 3$ classes, combinam-se vários classificadores binários.

Um contra um

Ajusta-se uma SVM para cada par de classes, usando apenas as observações dessas duas classes; são $\binom{K}{2} = K(K-1)/2$ ajustes. Um ponto novo é atribuído à classe que vence o maior número de comparações. É o que faz o `SVC` do `scikit-learn`.

Um contra todos

Ajustam-se K SVMs, a da classe c separando-a de todas as outras juntas, com função de decisão f_c. Um ponto novo é atribuído à classe com maior $f_c(\boldsymbol{x})$. Cada um desses problemas é desbalanceado, com uma classe contra $K-1$, o que pede cuidado na avaliação (Aula 08).

Resumo

- Com $\|\boldsymbol{\beta}\| = 1$, $|f(\boldsymbol{x})|$ é a distância de $\boldsymbol{x}$ ao hiperplano (Proposição 1.2), e $y_i f(\boldsymbol{x}_i)$ vale $d(\boldsymbol{x}_i, H)$ se a observação i está do lado certo e $-d(\boldsymbol{x}_i, H)$ se está do lado errado.
- O classificador de margem máxima (2) escolhe, entre os hiperplanos separadores, o de maior margem. Só existe com dados linearmente separáveis, depende apenas dos vetores de suporte e é sensível a eles.
- O classificador de vetor de suporte (3) admite folgas ε_i com orçamento C. Menos de C observações ficam do lado errado do hiperplano (Proposição 3.2), e a margem ótima não diminui quando C cresce. O orçamento regula o balanço entre viés e variância e é escolhido por validação cruzada (Figura 1).
- A solução depende dos dados apenas por meio de produtos internos, e só os vetores de suporte entram na função de decisão (Proposição 4.1).

- Trocando o produto interno por um *kernel*, isto é, por uma função simétrica e positiva semidefinida (Teorema 5.4), obtém-se a SVM (5), com fronteira linear em $\mathcal{H}$ e, em geral, não linear em $\mathbb{R}^p$. No *kernel* radial, γ regula a flexibilidade (Figura 2).
- Com mais de duas classes, combinam-se SVMs binárias, um contra um ou um contra todos.

Leitura recomendada. [AME] §8.2 (SVM) e §4.6 (*kernels* de Mercer e o Teorema de Mercer). [ISLP] §9.1 (margem máxima), §9.2 (classificador de vetor de suporte; a Figura 9.7 de lá corresponde à nossa Figura 1), §9.3 (*kernels* e SVM; a Figura 9.9 de lá é análoga à nossa Figura 2) e §9.4 (mais de duas classes).