

# SVM

Gabriel Sanfins

Oferecido por:

INSTITUTO DE MATEMÁTICA E ESTATÍSTICA  
UNIVERSIDADE FEDERAL FLUMINENSE

# SVM – *support-vector machines*

- Ideias iniciais: 1963 – V. Vapnik e A. Chervonenkis
- ...
- Formulação atual: 1995 – C. Cortes e V. Vapnik
- Generalização esperta de ideias simples:
  - Classificador de margem máxima
  - Classificador de vetor suporte
- Relação interessante com regressão logística e outros classificadores

# Classificador de margem máxima – motivação

- Classificadores com fronteira de decisão linear:
    - LDA – modelo probabilístico em  $\mathbf{X}|Y = d$
    - Regressão logística – modelo probabilístico com  $\ln\left(\frac{p}{1-p}\right)$  linear em  $\mathbf{X}$ , sendo  $p = \mathbb{P}(Y = 1|\mathbf{X} = \mathbf{x})$
- $\implies$  Tentar aproveitar a geometria e esquecer os modelos probabilísticos!

**Definição:** Em  $\mathbb{R}^p$ , um **hiperplano** é um sub-espaco afim de dimensão  $p - 1$ . Equivalentemente, é o conjunto de pontos  $\mathbf{x} = (x_1, \dots, x_p)^T$  satisfazendo


$$\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p = 0,$$

para parâmetros  $\beta_0, \beta_1, \dots, \beta_p$  escolhidos

- Se  $\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p > 0$ , então  $\mathbf{x}$  está “de um lado” do hiperplano...
- ...e se  $\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p < 0$ , então  $\mathbf{x}$  está “do outro lado” do hiperplano

$\implies$  Tem cara que dá para ser usado como um classificador!

# Interlúdio – Hiperplanos em $\mathbb{R}^p$



**Figura 1:** (Figura 9.1 de [ISLP]) Hiperplano  $1 + 2x_1 + 3x_2 = 0$  em  $\mathbb{R}^2$  (linha sólida). A região azul são os pontos  $\mathbf{x}$  tais que  $1 + 2x_1 + 3x_2 > 0$  e região roxa são os pontos  $\mathbf{x}$  tais que  $1 + 2x_1 + 3x_2 < 0$ .

# Classificador de margem máxima – construção

- Matriz  $\mathbf{X}_{n \times p}$  de  $n$  observações em  $\mathbb{R}^p$ :

$$\mathbf{X} = \begin{bmatrix} - & \mathbf{x}_1^T & - \\ & \vdots & \\ - & \mathbf{x}_n^T & - \end{bmatrix} = \begin{bmatrix} x_{11} & \dots & x_{1p} \\ \vdots & \ddots & \vdots \\ x_{n1} & \dots & x_{np} \end{bmatrix}$$

- Observações em duas classes:  $y_1, \dots, y_n \in \{-1, 1\}$
- Nova observação  $\mathbf{x}^* = (x_1^*, \dots, x_p^*)^T$  que desejamos classificar
- Assuma que as classes sejam linearmente separáveis

$\implies$  Como escolher o “melhor” hiperplano classificador?

# Classificador de margem máxima – construção




Figura 2: (Figura 9.2 de [ISLP]) Esquerda: Duas classes e três hiperplanos separadores. Direita: Um hiperplano separador e sua respectiva regra de decisão.

# Classificador de margem máxima – construção

- Azul  $\iff y_i = 1$  e roxo  $\iff y_i = -1$
- Um hiperplano separador satisfaz

$$\beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} > 0 \text{ se } y_i = 1$$

$$\beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} < 0 \text{ se } y_i = -1$$

- Equivalentemente,

$$y_i(\beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}) > 0, \forall i = 1, \dots, n$$

- $\implies$  Podemos construir um classificador com base no **sinal** de  $f(\mathbf{x}^*) = \beta_0 + \beta_1 x_1^* + \cdots + \beta_p x_p^*$
- ...e a **magnitude** de  $f(\mathbf{x}^*)$  nos dá a “distância” ao hiperplano (confiança na classificação)



# Classificador de margem máxima – construção

- Dados linearmente separáveis  $\implies$  falta de unicidade no hiperplano separador!
- Solução: escolher aquele que esteja mais longe das observações de treinamento!
  - Distância de cada observação de treinamento a um dado hiperplano
  - Menor dessas distâncias: **margem** do hiperplano
  - Escolher o hiperplano de maior margem – aquele que tem maior distância mínima às observações de treinamento
  - Daí o nome do classificador!
- No classificador de margem máxima, as observações que atingem a margem são chamados de **vetores suporte**

# Classificador de margem máxima – construção




Figura 3: (Figura 9.2 de [ISLP]) Classificador de margem máxima (linha sólida), margens (linhas tracejadas) e os respectivos vetores suporte.

$\Rightarrow$  O classificador de margem máxima depende somente dos vetores suporte, e não das outras observações!

# Classificador de margem máxima – construção

**Definição:** O classificador de margem máxima, sob a hipótese de classes linearmente separáveis, é a solução do seguinte problema de otimização:

$$\max_{\beta_0, \beta_1, \dots, \beta_p, M} M \quad (\star)$$

$$\text{sujeito a } \sum_{j=1}^p \beta_j^2 = 1 \quad (\star\star)$$

$$\text{e } y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \geq M, \forall i = 1, \dots, n \quad (\star\star\star)$$

- $(\star\star\star)$ : Todas as observações estão do lado “certo” do hiperplano, com uma “gordurinha”  $M > 0$
- $(\star\star)$ : Unicidade na fórmula do hiperplano de margem máxima

$\implies$  Se as classes não são linearmente separáveis, o problema de otimização  $(\star, \star\star, \star\star\star)$  não tem solução com  $M > 0$ !

# Classificador de margem máxima – limitação




Figura 4: (Figura 9.5 de [ISLP]) Esquerda: Classificador de margem máxima. Direita: Classificadores de margem máxima antigo (linha pontilhada) e novo (linha sólida) após acrescentar uma nova observação no conjunto de treinamento.

⇒ Alta sensibilidade a novas observações, possível sobreajuste!


# Classificador de vetor suporte – motivação

- Pode valer a pena classificar errado algumas observações em prol de:
  - Maior robustez a observações individuais
  - Classificação mais **confiável** (i.e., mais distante do hiperplano separador) da *maioria* das observações

⇒ Em vez de exigir que **todas** as observações estejam do lado “certo” da margem, permitir que algumas estejam do lado “errado” da margem, talvez até do lado “errado” do hiperplano!

**Observação:** Além de resolver os dois problemas acima, resolve o problema das classes não serem linearmente separáveis

# Classificador de vetor suporte – motivação



**Figura 5:** (Figura 9.6 de [ISLP]) Hiperplanos de margem máxima (linha sólida) e margens (linhas tracejadas). Esquerda: Algumas observações do lado “errado” da margem, porém nenhuma do lado “errado” do hiperplano. Direita: Observações do lado “errado” da margem e do hiperplano, após acréscimo de duas novas observações, 11 e 12.

# Classificador de vetor suporte – construção

**Definição:** O classificador de vetor suporte é a solução do seguinte problema de otimização:

$$\max_{\beta_0, \beta_1, \dots, \beta_p, \varepsilon_1, \dots, \varepsilon_n, M} M \quad (*)$$

$$\text{sujeito a } \sum_{j=1}^p \beta_j^2 = 1 \quad (**)$$

$$y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \geq M(1 - \varepsilon_i), \forall i = 1, \dots, n \quad (***)$$

$$\varepsilon_i \geq 0 \text{ e } \sum_{i=1}^n \varepsilon_i \leq C \quad (****)$$

- $\varepsilon_i = 0 \iff$  observação  $i$  do lado “certo” do hiperplano
- $\varepsilon_i > 1 \iff$  observação  $i$  do lado “errado” do hiperplano
- $0 < \varepsilon_i < 1 \iff$  observação  $i$  do lado “certo” do hiperplano porém do lado “errado” da margem

# Classificador de vetor suporte – análise

- $(***)$ :  $\sum_{i=1}^n \varepsilon_i \leq C \iff C$  representa um **orçamento** para as violações do hiperplano:
  - $C = 0$  reduz ao caso do classificador de margem máxima: nenhuma violação é permitida ( $\varepsilon_1 = \dots = \varepsilon_n = 0$ )
  - $C > 0 \iff$  não mais que  $C$  observações podem estar classificadas erroneamente, no pior dos casos
- $\uparrow C \implies$  mais tolerantes com classificações errôneas  $\implies$  maior margem  $\implies \uparrow$  viés e  $\downarrow$  variância
- $\downarrow C \implies$  menos tolerantes com classificações errôneas  $\implies$  menor margem  $\implies \downarrow$  viés e  $\uparrow$  variância
- Escolher  $C$  através de validação cruzada, por exemplo



# Classificador de vetor suporte – análise




Figura 6: (Figura 9.7 de [ISLP]) Classificadores de vetor suporte ajustados com quatro valores de  $C$  distintos. Hiperplanos separadores em linha sólida e margens em linha pontilhada.

# Classificador de vetor suporte – análise

- O hiperplano depende somente das observações que estão do lado “errado” da margem e do hiperplano  $\implies$  **vetores suporte**
- De acordo com o balanço entre viés e variância:
  - $\uparrow C \implies$  margem larga  $\implies$  mais vetores suporte  $\implies \downarrow$  variância
  - $\downarrow C \implies$  margem estreita  $\implies$  menos vetores suporte  $\implies \uparrow$  variância

$\implies$  Insensibilidade a observações “longe” do hiperplano separador!

**Observação:** Distinto de outros métodos com fronteira de decisão lineares!

- LDA depende (e é sensível) a todas as observações
- Regressão logística é pouco sensível a observações “longe” da fronteira de decisão

# Classificador de vetor suporte – observação importante

**Observação:** O que é resolvido numericamente **não** são as equações  $(*, **, * * *, * * **)$ , mas sim:

$$\min_{\substack{\beta_0, \beta_1, \dots, \beta_p, \\ \varepsilon_1, \dots, \varepsilon_n}} \|(\beta_1, \dots, \beta_p)\|_2 \text{ t.q. } \begin{cases} y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \geq 1 - \varepsilon_i \\ \varepsilon_i \geq 0, \sum_{i=1}^n \varepsilon_i \leq C, \forall i = 1, \dots, n \end{cases}$$

$\implies$  Problema quadrático com restrições lineares  $\implies$  problema de otimização convexa!

Equivalente a resolver o problema (multiplicadores de Lagrange):

$$\min_{\substack{\beta_0, \beta_1, \dots, \beta_p, \\ \varepsilon_1, \dots, \varepsilon_n}} \frac{1}{2} \|(\beta_1, \dots, \beta_p)\|_2^2 + C \sum_{i=1}^n \varepsilon_i, \text{ t.q. } \varepsilon_i \geq 0$$

$$\text{e } y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \geq 1 - \varepsilon_i, \forall i = 1, \dots, n$$

## Cuidado: o $C$ do slide anterior aparece de duas formas

Repare que a **mesma letra** foi usada para dois papéis **opostos**:

- em  $(***)$ ,  $\sum_{i=1}^n \varepsilon_i \leq C$ : o  $C$  é o **orçamento** de violações. É a convenção do [ISLP] e do [AME] — a dos slides anteriores;
- na forma de Lagrange,  $\frac{1}{2} \|(\beta_1, \dots, \beta_p)\|_2^2 + C \sum_{i=1}^n \varepsilon_i$ : o  $C$  é o **peso da penalidade** sobre as violações — e é esta a convenção do `scikit-learn`

$\Rightarrow$  Tudo o que dissemos sobre “ $\uparrow C$ ” se **inverte** de uma para a outra!

No `scikit-learn`:  $\uparrow C \Rightarrow$  penaliza mais  $\Rightarrow$  tolera menos  $\Rightarrow$  margem **estreita**  $\Rightarrow$  **menos** vetores suporte.

## Cuidado: o $C$ do slide anterior aparece de duas formas

E não é sutileza de notação — dá para medir. Na Seção 8 da **Aula prática 09**, ajustando **SVC** ao **breast\_cancer** com  $\gamma$  e kernel fixos:

|                 | vetores suporte | % do treino | AUC no teste |
|-----------------|-----------------|-------------|--------------|
| SVC( $C=0.01$ ) | 92              | 23,1%       | 0,9921       |
| SVC( $C=1000$ ) | 24              | 6,0%        | 0,9911       |

O  $C$  pequeno do **scikit-learn** é que dá **mais** vetores suporte — quatro vezes mais — exatamente ao contrário do que os slides anteriores dizem do  $C$  deles.

⇒ Ao ler qualquer texto sobre SVM, confira **qual**  $C$  está em uso antes de interpretar “ $C$  grande”!

# Classificador de vetor suporte – limitação




Figura 7: (Figura 9.8 de [ISLP]) Esquerda: Observações em duas classes. Direita: Tentativa de ajustar um classificador de vetor suporte a tal conjunto de dados.

# Máquina de vetores suporte (SVM) – primeira ideia

Lembremos do classificador de vetor suporte:

$$\begin{aligned} & \max_{\beta_0, \beta_1, \dots, \beta_p, \varepsilon_1, \dots, \varepsilon_n, M} M \\ \text{sujeito a } & \sum_{j=1}^p \beta_j^2 = 1 \\ & y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \geq M(1 - \varepsilon_i), \forall i = 1, \dots, n \\ & \varepsilon_i \geq 0 \text{ e } \sum_{i=1}^n \varepsilon_i \leq C \end{aligned}$$

$\Rightarrow$  Em vez de ajustar o classificador com  $X_1, \dots, X_p$ , acrescentar também  $X_1^2, \dots, X_p^2$ !

# Máquina de vetores suporte (SVM) – primeira ideia

$$\begin{aligned} & \max_{\beta_0, \beta_{11}, \dots, \beta_{p1}, \beta_{12}, \dots, \beta_{p2}, \varepsilon_1, \dots, \varepsilon_n, M} M \\ \text{sujeito a } & \sum_{j=1}^p \sum_{k=1}^2 \beta_{jk}^2 = 1, \varepsilon_i \geq 0 \text{ e } \sum_{i=1}^n \varepsilon_i \leq C \\ & y_i \left( \beta_0 + \sum_{j=1}^p \beta_{j1} x_{ij} + \sum_{j=1}^p \beta_{j2} x_{ij}^2 \right) \geq M(1 - \varepsilon_i), \forall i = 1, \dots, n \end{aligned}$$

- No espaço aumentado  $X_1, \dots, X_p, X_1^2, \dots, X_p^2 \implies$  fronteira de decisão linear
- No espaço original  $X_1, \dots, X_p \implies$  fronteira de decisão quadrática
- Quantidade de coeficientes a estimar aumenta muito!  $\implies$  baixa eficiência computacional

Podemos tornar os dados separáveis em um espaço de dimensão infinita sem aumentar a quantidade de parâmetros a estimar!



# Máquina de vetores suporte (SVM) – construção

Podemos mostrar que:

- A fronteira de decisão do classificador de vetor suporte pode ser escrita como

$$f(\mathbf{x}) = \beta_0 + \sum_{i=1}^n \alpha_i \langle \mathbf{x}, \mathbf{x}_i \rangle,$$

onde  $\mathbf{x}_1, \dots, \mathbf{x}_n$ , são as observações de treinamento

- Para estimar  $\beta_0, \alpha_1, \dots, \alpha_n$  precisamos somente dos  $\binom{n}{2}$  produtos internos  $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$ , para  $1 \leq i < j \leq n$
- Os únicos  $\alpha_i \neq 0$  são os referentes aos vetores suporte:

$$f(\mathbf{x}) = \beta_0 + \sum_{i \in \mathcal{S}} \alpha_i \langle \mathbf{x}, \mathbf{x}_i \rangle,$$

onde  $\mathcal{S}$  é o conjunto dos índices dos vetores suporte

$\implies$  Calcular e estimar  $f$  só precisa de produtos internos!

# Digressão de Álgebra Linear

- O produto interno  $\langle \mathbf{x}, \mathbf{y} \rangle$  mede **similaridade** entre os vetores  $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$
- Como podemos medir similaridade de outras formas?
  - $k : \mathbb{R}^p \times \mathbb{R}^p \rightarrow \mathbb{R} \implies k(\mathbf{x}, \mathbf{y})$  generalização de  $\langle \cdot, \cdot \rangle : \mathbb{R}^p \times \mathbb{R}^p \rightarrow \mathbb{R}$ , dito um **kernel**
  - $k(\mathbf{x}, \mathbf{y}) = \left( 1 + \sum_{j=1}^p x_j y_j \right)^d$ , *kernel* polinomial de grau  $d$
  - $k(\mathbf{x}, \mathbf{y}) = \exp \left( -\gamma \sum_{j=1}^p (x_j - y_j)^2 \right)$ , *kernel* radial ou exponencial quadrático
  - Obviamente  $k(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle$ ! *Kernel* linear
  - ... muitos outros!

## Digressão de Álgebra Linear

Mas quais funções  $k : \mathbb{R}^p \times \mathbb{R}^p \rightarrow \mathbb{R}$  são “boas” para medir similaridade entre dois vetores?

**Resposta:** Devem existir  $\mathcal{H}$  espaço de Hilbert e  $\varphi : \mathbb{R}^p \rightarrow \mathcal{H}$  tais que

$$k(\mathbf{x}, \mathbf{y}) = \langle \varphi(\mathbf{x}), \varphi(\mathbf{y}) \rangle_{\mathcal{H}}$$

$\implies$  Intuitivamente, os dados devem ser linearmente separáveis em algum espaço, potencialmente de dimensão infinita.

**Teorema:** A função  $k : \mathbb{R}^p \times \mathbb{R}^p \rightarrow \mathbb{R}$  é um *kernel* (i.e., existem  $\mathcal{H}$  e  $\varphi$  como acima) se e somente se ela é positiva semidefinida:

$$\int_{\mathbb{R}^p} \int_{\mathbb{R}^p} g(\mathbf{x}) k(\mathbf{x}, \mathbf{y}) g(\mathbf{y}) \, d\mathbf{x} d\mathbf{y} \geq 0,$$

para toda  $g : \mathbb{R}^p \rightarrow \mathbb{R}$  tal que  $\int_{\mathbb{R}^p} \|g(\mathbf{x})\|^2 \, d\mathbf{x} < \infty$ .

# Digressão de Álgebra Linear




Figura 8: [Wikipedia]  $\varphi : \mathbb{R}^2 \rightarrow \mathbb{R}^3$  dada por  $\varphi(x_1, x_2) = (x_1, x_2, x_1^2 + x_2^2)$  e portanto  $k(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle + \|\mathbf{x}\|^2 \|\mathbf{y}\|^2$ . Dados não-separáveis linearmente em  $\mathbb{R}^2$  mas sim em  $\mathbb{R}^3$ .

# Máquina de vetores suporte (SVM) – construção

- Escolha o seu *kernel* preferido  $k$
- Encontre a fronteira de decisão da forma  $f(\mathbf{x}) = \beta_0 + \sum_{i \in \mathcal{S}} \alpha_i k(\mathbf{x}, \mathbf{x}_i)$

$\Rightarrow$  Eis o SVM!




Figura 9: (Figura 9.9 de [ISLP]) Esquerda: Ajuste com *kernel* polinomial de grau 3. Direita: Ajuste com *kernel* radial.

## Relação com regressão logística

Lembremos do classificador de vetor suporte (caso particular do SVM com *kernel* linear:

$$\begin{aligned} & \max_{\beta_0, \beta_1, \dots, \beta_p, \varepsilon_1, \dots, \varepsilon_n, M} M \\ \text{sujeito a } & \sum_{j=1}^p \beta_j^2 = 1, \varepsilon_i \geq 0 \text{ e } \sum_{i=1}^n \varepsilon_i \leq C \\ & y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \geq M(1 - \varepsilon_i), \forall i = 1, \dots, n \end{aligned}$$

Esse problema de otimização pode ser escrito como

$$\min_{\beta_0, \beta_1, \dots, \beta_p} \left\{ \sum_{i=1}^n \max[0, 1 - y_i f(\mathbf{x}_i)] + \lambda \sum_{j=1}^p \beta_j^2 \right\},$$

onde  $f(\mathbf{x}) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$

## Relação com regressão logística

$$\min_{\beta_0, \beta_1, \dots, \beta_p} \left\{ \sum_{i=1}^n \max[0, 1 - y_i f(\mathbf{x}_i)] + \lambda \sum_{j=1}^p \beta_j^2 \right\}$$


$\Downarrow$

$$\min_{\beta_0, \beta_1, \dots, \beta_p} \{L(\mathbf{X}, \mathbf{y}, \boldsymbol{\beta}) + \lambda P(\boldsymbol{\beta})\},$$

onde  $L$  é uma **função custo** e  $P$  é uma **penalidade**

- A função custo mede o ajuste do modelo aos dados
- A penalidade impõe uma restrição desejada *a priori* no modelo
- O modelo de regressão logística também pode ser escrito nessa forma

# Relação com regressão logística



**Figura 10:** (Figura 9.12 de [ISLP]) Funções perda associadas à regressão logística (verde) e classificador de vetor suporte (preto), como função de  $y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip})$ .



# Relação com regressão logística

- Na formulação de custo + penalidade, a margem do classificador de vetor suporte corresponde ao valor 1, e o seu tamanho é dado por  $\sum_{j=1}^p \beta_j^2$
- Observação do lado “certo” da margem  
 $\iff y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \geq 1 \iff$  perda do classificador de vetor suporte é zero
- A perda da regressão logística nunca é zero! Porém, é **próxima** de zero quando a perda do classificador de vetor suporte é zero!
- Além disso, ambas as perdas são próximas para observações do lado “errado” da margem

$\implies$  Ambas as técnicas dão resultados semelhantes!