Aula 09 — Máquinas de Vetores de Suporte (SVM)

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §8.2 e §4.6; ISLP cap. 9

Objetivos da aula

Ao final desta aula o aluno deve ser capaz de:

- descrever um hiperplano de $\mathbb{R}^p$, calcular a distância de um ponto a ele e usá-lo como classificador;
- formular o classificador de margem máxima e reconhecer os seus vetores de suporte;
- formular o classificador de vetor de suporte e interpretar as folgas ε_i e o orçamento C;
- entender que a solução depende dos dados apenas por meio de produtos internos, e como isso leva aos *kernels*;
- decidir se uma função é um *kernel*, usar os *kernels* linear, polinomial e radial e entender o papel de γ;
- tratar problemas com mais de duas classes.

Em sala

Na Aula 07, a análise discriminante linear e a regressão logística chegaram a fronteiras lineares por meio de modelos de probabilidade. Hoje a fronteira é procurada diretamente, pela geometria das observações. Desenhe duas nuvens de pontos separáveis e três retas que as separam, e pergunte: *qual delas você escolheria, e por quê?* A resposta esperada, a reta que fica mais longe dos pontos, é a ideia de margem. As primeiras ideias são de Vapnik e Chervonenkis (1963); a formulação atual, de Cortes e Vapnik (1995).

1 Hiperplanos e classificação

Para $\beta_0 \in \mathbb{R}$ e $\boldsymbol{\beta} = (\beta_1, \ldots, \beta_p)^\top \neq \mathbf{0}$, seja $f(\boldsymbol{x}) = \beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}$. O *hiperplano* $H = \{\boldsymbol{x} : f(\boldsymbol{x}) = 0\}$ é um subespaço afim de dimensão $p-1$ e tem dois lados, $\{f > 0\}$ e $\{f < 0\}$. Para $c \neq 0$, o par $(c\beta_0, c\boldsymbol{\beta})$ define o mesmo H; a normalização $\|\boldsymbol{\beta}\| = 1$ fixa os coeficientes a menos do sinal.

Proposição 1.1. *Para todo $\boldsymbol{x} \in \mathbb{R}^p$, $d(\boldsymbol{x}, H) = |f(\boldsymbol{x})| \,/\, \|\boldsymbol{\beta}\|$; em particular, $d(\boldsymbol{x}, H) = |f(\boldsymbol{x})|$ se $\|\boldsymbol{\beta}\| = 1$.*

Demonstração. O ponto $\boldsymbol{x}_0 = \boldsymbol{x} - \big(f(\boldsymbol{x}) / \|\boldsymbol{\beta}\|^2\big)\boldsymbol{\beta}$ está em H, e $\boldsymbol{x} - \boldsymbol{x}_0$, que é múltiplo de $\boldsymbol{\beta}$, é ortogonal a $\boldsymbol{x}_0 - \boldsymbol{z}$ para todo $\boldsymbol{z} \in H$. Por Pitágoras, $\|\boldsymbol{x} - \boldsymbol{z}\|^2 = \|\boldsymbol{x} - \boldsymbol{x}_0\|^2 + \|\boldsymbol{x}_0 - \boldsymbol{z}\|^2 \geq f(\boldsymbol{x})^2 / \|\boldsymbol{\beta}\|^2$, com igualdade em $\boldsymbol{z} = \boldsymbol{x}_0$. □

Com as classes codificadas por $y \in \{-1, +1\}$, classifica-se pelo sinal de f. Sejam $(\boldsymbol{x}_1, y_1)$, …, $(\boldsymbol{x}_n, y_n)$ as observações de treino, com as duas classes presentes. O hiperplano acerta a observação i se e somente se $y_i f(\boldsymbol{x}_i) > 0$, e, com $\|\boldsymbol{\beta}\| = 1$, $y_i f(\boldsymbol{x}_i)$ vale $d(\boldsymbol{x}_i, H)$ se a observação está do lado certo e $-d(\boldsymbol{x}_i, H)$ se está do lado errado. As observações são *linearmente separáveis* se existe $(\beta_0, \boldsymbol{\beta})$ com

$$y_i \left(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i\right) > 0, \qquad i = 1, \ldots, n. \tag{1}$$

Em sala

Pergunte por que se exige $\boldsymbol{\beta} \neq \mathbf{0}$ e o que acontece com H quando $(\beta_0, \boldsymbol{\beta})$ é multiplicado por $c \neq 0$; a segunda pergunta prepara a normalização da próxima seção. A Figura 9.1 do [ISLP] mostra os dois lados de um hiperplano de $\mathbb{R}^2$. Mostre que a codificação ± 1 junta "$f > 0$ na classe $+1$" e "$f < 0$ na classe -1" numa única condição, (1).

2 O classificador de margem máxima

Com dados separáveis, há infinitos hiperplanos separadores, porque as desigualdades (1), estritas e em número finito, resistem, por continuidade, a perturbações pequenas. Para $\|\boldsymbol{\beta}\| = 1$, seja $m(\beta_0, \boldsymbol{\beta}) = \min_i y_i(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i)$; num separador, $m > 0$ é a *margem*, a menor distância das observações a ele. O *classificador de margem máxima* resolve

$$\max_{\beta_0, \boldsymbol{\beta}, M} M \quad \text{s.a.} \quad \sum_{j=1}^{p} \beta_j^2 = 1, \qquad y_i\,(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) \geq M, \quad i = 1, \ldots, n. \tag{2}$$

Para $(\beta_0, \boldsymbol{\beta})$ fixos, o maior M viável é $m(\beta_0, \boldsymbol{\beta})$; sem a restrição $\sum_j \beta_j^2 = 1$, multiplicar os coeficientes por $c > 1$ faria M crescer sem limite. O valor ótimo é positivo se e somente se os dados são separáveis. Os *vetores de suporte* são as observações com $y_i(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) = M$, e pode-se mostrar que a solução depende apenas deles.

Em sala

Use as Figuras 9.2 e 9.3 do [ISLP]. Pergunte: *sem a restrição $\sum_j \beta_j^2 = 1$, qual seria o valor ótimo?* (Infinito.) E: *se eu deslocar um ponto que não é vetor de suporte, sem que ele entre na faixa, o que muda?* (Nada.) A Figura 9.5 do [ISLP] mostra que uma observação a mais pode mudar muito o hiperplano. Daí as duas limitações, sensibilidade alta e exigência de separabilidade, que motivam a próxima seção.

3 O classificador de vetor de suporte

Admite-se que algumas observações violem a margem, em troca de robustez e de uma margem maior para a maioria; a mesma ideia resolve o caso não separável. Dado $C \geq 0$, o *classificador de vetor de suporte* resolve

$$\max_{\beta_0, \boldsymbol{\beta}, \boldsymbol{\varepsilon}, M} M \quad \text{s.a.} \quad \|\boldsymbol{\beta}\| = 1, \quad y_i f(\boldsymbol{x}_i) \geq M(1 - \varepsilon_i), \quad \varepsilon_i \geq 0, \quad \sum_{i=1}^{n} \varepsilon_i \leq C, \tag{3}$$

e supomos que haja solução com $M > 0$. Fixados $(\beta_0, \boldsymbol{\beta}, M)$, a menor folga admissível é $\varepsilon_i = \max\{0, 1 - y_i f(\boldsymbol{x}_i)/M\}$, e com ela: $\varepsilon_i = 0$ se e somente se a observação está do lado certo da margem ou sobre ela; $0 < \varepsilon_i < 1$, do lado errado da margem e do lado certo do hiperplano; $\varepsilon_i = 1$, sobre o hiperplano; $\varepsilon_i > 1$, do lado errado do hiperplano.

Proposição 3.1. *Num ponto que satisfaz as restrições de (3) com $M > 0$ e $C > 0$, menos de C observações estão do lado errado do hiperplano.*

Demonstração. Se $y_i f(\boldsymbol{x}_i) < 0$, então $M(1 - \varepsilon_i) < 0$, e $\varepsilon_i > 1$. Se há $\ell \geq 1$ dessas observações, $\ell < \sum_i \varepsilon_i \leq C$. □

Com $C = 0$, (3) é (2). Se $C \leq C'$, o conjunto viável cresce, e o valor ótimo de M é não decrescente em C. O orçamento não pode ser grande demais: se $C > n$, as folgas $\varepsilon_i = C/n > 1$ tornam viável todo M suficientemente grande, e o problema não tem solução. Os *vetores de suporte* são as observações sobre a margem ou do lado errado dela, com $y_i f(\boldsymbol{x}_i) \leq M$, e a solução depende apenas deles. Isso distingue o método da análise discriminante linear, cujas médias e covariância usam todas as observações, e da regressão logística, em que a observação i entra nas equações de verossimilhança com o peso $y_i - \widehat{p}(\boldsymbol{x}_i)$ (com $y_i \in \{0, 1\}$), pequeno, mas não nulo, longe da fronteira.

Ideia central

C é um *tuning parameter*, escolhido por validação cruzada (Aula 03). Com C pequeno, a margem é estreita, há poucos vetores de suporte, o viés é baixo e a variância é alta. Com C grande, a margem é larga, há muitos vetores de suporte, o viés é mais alto e a variância, mais baixa.

Em sala

Desenhe uma observação em cada um dos quatro casos de ε_i e peça à turma o valor da folga. Pergunte: *com $C = 3$, quantas observações podem ficar do lado errado do hiperplano?* (No máximo duas, pela Proposição 3.1.) As Figuras 9.6 e 9.7 do [ISLP] mostram violações da margem e do hiperplano e o efeito de C sobre a margem.

4 Fronteiras não lineares

Um hiperplano não aproxima uma fronteira muito curva (Figura 9.8 do [ISLP]). Uma saída é ampliar as covariáveis, por exemplo para $X_1, \ldots, X_p, X_1^2, \ldots, X_p^2$: a fronteira é linear no espaço ampliado e quadrática no original. O custo cresce depressa, pois há $\binom{p+q}{q}$ monômios de grau até q em p variáveis. O que permite contorná-lo é o fato seguinte, admitido sem demonstração ([ISLP], §9.3.2).

Proposição 4.1. *Na solução de (3), existem $\alpha_1, \ldots, \alpha_n$, nulos fora do conjunto $\mathcal{S}$ dos índices dos vetores de suporte, tais que*

$$f(\boldsymbol{x}) = \beta_0 + \sum_{i=1}^{n} \alpha_i \langle \boldsymbol{x}, \boldsymbol{x}_i \rangle = \beta_0 + \sum_{i \in \mathcal{S}} \alpha_i \langle \boldsymbol{x}, \boldsymbol{x}_i \rangle , \tag{4}$$

e $\beta_0, \alpha_1, \ldots, \alpha_n$ podem ser calculados a partir dos $n(n+1)/2$ produtos internos $\langle \boldsymbol{x}_i, \boldsymbol{x}_j \rangle$, $1 \leq i \leq j \leq n$.

5 *Kernels* e a máquina de vetores de suporte

Uma função $k : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$ é um *kernel* se $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle_{\mathcal{H}}$ para algum espaço de Hilbert $\mathcal{H}$ e alguma $\varphi : \mathbb{R}^p \to \mathcal{H}$. Exemplos: o linear, $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$; o polinomial de grau $q \in \{1, 2, \ldots\}$, $(1 + \langle \boldsymbol{x}, \boldsymbol{x}' \rangle)^q$; o radial, $\exp(-\gamma \, \|\boldsymbol{x} - \boldsymbol{x}'\|^2)$, com $\gamma > 0$. Em $\mathbb{R}^2$, $\langle \boldsymbol{x}, \boldsymbol{x}' \rangle^2 = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle$ com $\varphi(\boldsymbol{x}) = (x_1^2, \sqrt{2}\, x_1 x_2, x_2^2)$. Para o polinomial, φ tem $\binom{p+q}{q}$ coordenadas, e para o radial, infinitas, mas calcular k custa cerca de p operações.

Teorema 5.1. *Uma função k é um* kernel *se e somente se é simétrica e, para todo n e quaisquer $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n$, a matriz $[k(\boldsymbol{x}_i, \boldsymbol{x}_j)]_{i,j=1}^n$ é positiva semidefinida.*

Demonstração da necessidade. A simetria vem da do produto interno, e $\sum_{i,j} a_i a_j k(\boldsymbol{x}_i, \boldsymbol{x}_j) = \|\sum_i a_i \varphi(\boldsymbol{x}_i)\|_{\mathcal{H}}^2 \geq 0$. A suficiência (Aronszajn, 1950; no [AME], §4.6, pelo Teorema de Mercer) não será demonstrada. □

A *máquina de vetores de suporte* (SVM) é o classificador de vetor de suporte ajustado aos pontos $\varphi(\boldsymbol{x}_i)$. Pela Proposição 4.1, que vale também em $\mathcal{H}$,

$$f(\boldsymbol{x}) = \beta_0 + \sum_{i \in \mathcal{S}} \alpha_i \, k(\boldsymbol{x}, \boldsymbol{x}_i), \tag{5}$$

com β_0 e os α_i calculados a partir dos $k(\boldsymbol{x}_i, \boldsymbol{x}_j)$. Nem φ nem $\mathcal{H}$ são construídos (é o *truque do kernel*), e o número de parâmetros não depende da dimensão de $\mathcal{H}$. No radial, γ grande torna $k(\boldsymbol{x}, \boldsymbol{x}_i)$ desprezível longe de $\boldsymbol{x}_i$ e a fronteira flexível, e γ pequeno a torna suave. C e γ são escolhidos juntos, por validação cruzada sobre uma grade de pares.

Em sala

Faça no quadro a expansão de $(x_1 x_1' + x_2 x_2')^2$ e mostre que a circunferência $x_1^2 + x_2^2 = r^2$ é a imagem inversa de um plano de $\mathbb{R}^3$. Pergunte: $k(\boldsymbol{x}, \boldsymbol{x}') = -\langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ *é um kernel?* (Não: a matriz 1×1 $[-\|\boldsymbol{x}_1\|^2]$ é negativa para $\boldsymbol{x}_1 \neq \boldsymbol{0}$.) A figura do truque do *kernel* e a Figura 9.9 do [ISLP] fecham a seção.

6 Mais de duas classes

Com $K = |\mathcal{C}| \geq 3$ classes, combinam-se SVMs binárias.

Um contra um
: Uma SVM para cada par de classes, ajustada só com as observações das duas; são $\binom{K}{2}$ ao todo, e classifica-se por votação. É o que faz o `SVC` do `scikit-learn`.

Um contra todos
: K SVMs, a da classe c contra as demais, com função de decisão f_c; classifica-se pela maior $f_c(\boldsymbol{x})$. Cada problema é desbalanceado (Aula 08).

Resumo

- Com $\|\boldsymbol{\beta}\| = 1$, $|f(\boldsymbol{x})|$ é a distância ao hiperplano, e $y_i f(\boldsymbol{x}_i) = \pm d(\boldsymbol{x}_i, H)$, com sinal positivo se e somente se a observação está do lado certo.
- Margem máxima (2): só com dados separáveis; depende apenas dos vetores de suporte e é sensível a eles.
- Vetor de suporte (3): folgas ε_i e orçamento C; menos de C erros de treino; margem ótima não decrescente em C; C escolhido por validação cruzada.
- A solução só depende de produtos internos (4); trocá-los por um *kernel*, simétrico e positivo semidefinido, dá a SVM (5).
- Mais de duas classes: um contra um ou um contra todos.

Leitura recomendada. [AME] §8.2 (SVM) e §4.6 (*kernels* de Mercer); [ISLP] §9.1 a §9.4 (§9.1 margem máxima, §9.2 classificador de vetor de suporte, §9.3 SVM com kernels, §9.4 mais de duas classes).