# Lista Teórica 09 — Gabarito

*Curso de Aprendizado de Máquina — UFF*

*Prof. Gabriel Sanfins*

Aula 09 — Máquinas de Vetores de Suporte (SVM)

---

**Exercício 1 — a margem máxima, calculada à mão.** Uma estudante quer entender o classificador de margem máxima num exemplo em que todas as contas cabem no papel. Ela toma quatro observações de $\mathbb{R}^2$:

| $i$ | 1 | 2 | 3 | 4 |
|---|---|---|---|---|
| $\boldsymbol{x}_i$ | $(3,1)$ | $(3,3)$ | $(1,1)$ | $(1,3)$ |
| $y_i$ | $+1$ | $+1$ | $-1$ | $-1$ |

Lembre que o classificador de margem máxima é dado pela solução do problema

$$\max_{\beta_0,\,\boldsymbol{\beta},\,M} \; M \quad \text{sujeito a} \quad \sum_{j=1}^{p} \beta_j^2 = 1 \quad \text{e} \quad y_i\,(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) \geq M, \quad i = 1, \ldots, n, \tag{1}$$

e que os seus vetores de suporte são as observações com $y_i(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) = M$. Escreva $f(\boldsymbol{x}) = \beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}$.

(a) Sejam $\boldsymbol{x}_i$ e $\boldsymbol{x}_j$ observações distintas de classes opostas, com $y_i = +1$ e $y_j = -1$. Mostre que todo ponto $(\beta_0, \boldsymbol{\beta}, M)$ que satisfaz as restrições de (1) tem $M \leq \|\boldsymbol{x}_i - \boldsymbol{x}_j\|/2$, e que a igualdade exige $\boldsymbol{\beta} = (\boldsymbol{x}_i - \boldsymbol{x}_j)/\|\boldsymbol{x}_i - \boldsymbol{x}_j\|$. (Some as restrições das duas observações e use a desigualdade de Cauchy–Schwarz.)

(b) Use o item (a) para determinar o classificador de margem máxima das quatro observações e o valor ótimo de $M$, e mostre que a solução é única. Quais observações são vetores de suporte?

(c) A estudante acrescenta uma quinta observação, $\boldsymbol{x}_5 = (5,2)$, com $y_5 = +1$. O classificador muda? Justifique sem resolver o problema de novo.

(d) Em vez disso, ela desloca a primeira observação de $(3,1)$ para $(2{,}5\,;\,1)$, sem mexer nas outras. Determine o novo classificador, o novo valor ótimo de $M$ e os novos vetores de suporte.

**Solução**

**(a)** Como $y_i = +1$ e $y_j = -1$, as restrições das observações $i$ e $j$ são

$$\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i \geq M \qquad \text{e} \qquad -(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_j) \geq M.$$

Somando as duas, $\beta_0$ se cancela e fica $\boldsymbol{\beta}^\top(\boldsymbol{x}_i - \boldsymbol{x}_j) \geq 2M$. Pela desigualdade de Cauchy–Schwarz e pela restrição $\|\boldsymbol{\beta}\| = 1$,

$$2M \leq \boldsymbol{\beta}^\top(\boldsymbol{x}_i - \boldsymbol{x}_j) \leq \|\boldsymbol{\beta}\|\;\|\boldsymbol{x}_i - \boldsymbol{x}_j\| = \|\boldsymbol{x}_i - \boldsymbol{x}_j\|\,,$$

que é a desigualdade pedida.
Suponha agora $M = \|\boldsymbol{x}_i - \boldsymbol{x}_j\|/2$. Então as desigualdades acima são igualdades, e, com $\boldsymbol{u} = (\boldsymbol{x}_i - \boldsymbol{x}_j)/\|\boldsymbol{x}_i - \boldsymbol{x}_j\|$, vale $\boldsymbol{\beta}^\top \boldsymbol{u} = 1$. Como $\boldsymbol{\beta}$ e $\boldsymbol{u}$ têm norma 1,

$$\|\boldsymbol{\beta} - \boldsymbol{u}\|^2 = \|\boldsymbol{\beta}\|^2 - 2\,\boldsymbol{\beta}^\top \boldsymbol{u} + \|\boldsymbol{u}\|^2 = 1 - 2 + 1 = 0,$$

e portanto $\boldsymbol{\beta} = \boldsymbol{u}$. Além disso, as duas restrições valem com igualdade, porque cada uma é pelo menos $M$ e a soma das duas é exatamente $2M$: as observações $i$ e $j$ estão ambas à distância $M$ do hiperplano.
Em palavras: nenhuma observação de treino fica no interior da faixa $\{\boldsymbol{x} : |f(\boldsymbol{x})| < M\}$, cuja largura é $2M$, e por isso a faixa não pode ser mais larga que a distância entre duas observações de classes opostas. A cota vale para todo par, e a mais forte vem do par mais próximo. Ela não é atingida em todo conjunto de dados. Com $(0,0)$ na classe $+1$ e $(-1,1)$ e $(1,1)$ na classe $-1$, a menor distância entre as classes é $\sqrt{2}$; mas a restrição de $(0,0)$, somada à média das restrições das outras duas observações, dá $-\beta_2 \geq 2M$, e portanto $M \leq 1/2 < \sqrt{2}/2$ (o valor $1/2$ é atingido pela reta $x_2 = 1/2$). Quando um ponto viável atinge a cota, porém, ele é ótimo, e é isso que o item seguinte usa.

**(b)** Os pares mais próximos de classes opostas são $\boldsymbol{x}_1, \boldsymbol{x}_3$ e $\boldsymbol{x}_2, \boldsymbol{x}_4$, à distância 2; os outros dois estão à distância $\|(2, \pm 2)\| = 2\sqrt{2}$. Pelo item (a), aplicado a $\boldsymbol{x}_1 = (3,1)$ e $\boldsymbol{x}_3 = (1,1)$, todo ponto viável tem $M \leq \|(2,0)\|/2 = 1$.
Tome $\boldsymbol{\beta} = (\boldsymbol{x}_1 - \boldsymbol{x}_3)/2 = (1,0)$, que tem norma 1, e $\beta_0 = -2$, isto é, $f(\boldsymbol{x}) = x_1 - 2$, em que $x_1$ é a primeira coordenada de $\boldsymbol{x}$. Então

$$y_1 f(\boldsymbol{x}_1) = y_2 f(\boldsymbol{x}_2) = 3 - 2 = 1 \qquad \text{e} \qquad y_3 f(\boldsymbol{x}_3) = y_4 f(\boldsymbol{x}_4) = -(1-2) = 1,$$

e o ponto com $\beta_0 = -2$, $\boldsymbol{\beta} = (1,0)$ e $M = 1$ satisfaz as restrições. Como nenhum ponto viável tem $M > 1$, ele é ótimo, e o valor ótimo é $M = 1$.
A solução é única. Se $(\beta_0, \boldsymbol{\beta}, M)$ é ótimo, então $M = 1 = \|\boldsymbol{x}_1 - \boldsymbol{x}_3\|/2$, e o caso de igualdade do item (a) dá $\boldsymbol{\beta} = (1,0)$ e $y_1 f(\boldsymbol{x}_1) = M$, isto é, $\beta_0 + 3 = 1$, ou $\beta_0 = -2$. O classificador de margem máxima é, portanto, a reta vertical $x_1 = 2$: ele classifica como $+1$ os pontos com primeira coordenada maior que 2. A faixa $\{\boldsymbol{x} : 1 < x_1 < 3\}$, de largura $2M = 2$, não contém nenhuma observação, e as quatro estão sobre as suas bordas: todas são vetores de suporte.

**(c)** Não muda. O problema com cinco observações tem as quatro restrições anteriores e mais uma. Todo ponto que o satisfaz satisfaz, portanto, as restrições do problema anterior, e a cota $M \leq 1$ do item (b), que só usou $\boldsymbol{x}_1$ e $\boldsymbol{x}_3$, continua valendo. Por outro lado, a solução anterior satisfaz a restrição nova,

$$y_5 f(\boldsymbol{x}_5) = 5 - 2 = 3 \geq 1,$$

e é, assim, um ponto viável do problema novo com $M = 1$, o maior valor possível: continua ótima. A unicidade se prova como no item (b). A observação nova não é vetor de suporte, porque está do lado certo e fora da faixa, à distância 3 do hiperplano.
O argumento só usou $y_5 f(\boldsymbol{x}_5) \geq 1$. Qualquer observação acrescentada do lado certo e fora da faixa deixa o classificador como estava, por mais longe que esteja: com $\boldsymbol{x}_5 = (50,2)$ seria igual. É nesse sentido que o classificador de margem máxima depende apenas dos vetores de suporte. Neste exemplo vale até mais: a cota e a verificação do item (b) usaram só $\boldsymbol{x}_1$ e $\boldsymbol{x}_3$, e, com apenas essas duas observações, o mesmo argumento daria o mesmo classificador. Dois dos quatro vetores de suporte já o determinam.

**(d)** Agora $\boldsymbol{x}_1 = (2{,}5\,;\,1)$, e o par $\boldsymbol{x}_1, \boldsymbol{x}_3$ está à distância $\|(1{,}5\,;\,0)\| = 1{,}5$: pelo item (a), todo ponto viável tem $M \leq 0{,}75$. O hiperplano equidistante de $\boldsymbol{x}_1$ e $\boldsymbol{x}_3$ tem $\boldsymbol{\beta} = (\boldsymbol{x}_1 - \boldsymbol{x}_3)/1{,}5 = (1,0)$ e $f(\boldsymbol{x}) = x_1 - 1{,}75$, e

$$y_1 f(\boldsymbol{x}_1) = 0{,}75, \quad y_2 f(\boldsymbol{x}_2) = 3 - 1{,}75 = 1{,}25, \quad y_3 f(\boldsymbol{x}_3) = 0{,}75, \quad y_4 f(\boldsymbol{x}_4) = 0{,}75.$$

O ponto com $\beta_0 = -1{,}75$, $\boldsymbol{\beta} = (1,0)$ e $M = 0{,}75$ é viável e atinge a cota; é, portanto, ótimo, e o caso de igualdade do item (a) mostra, como no item (b), que é a única solução.

O novo classificador é a reta $x_1 = 1{,}75$, o valor ótimo é $M = 0{,}75$, e os vetores de suporte são $\boldsymbol{x}_1$, $\boldsymbol{x}_3$ e $\boldsymbol{x}_4$. A observação $\boldsymbol{x}_2$, a 1,25 do hiperplano, deixou de ser vetor de suporte. Deslocar uma única observação de 0,5 moveu o hiperplano de 0,25, reduziu o valor ótimo de $M$ em 25%, de 1 para 0,75, e mudou o conjunto de vetores de suporte. O classificador de margem máxima depende de poucas observações, as mais próximas da fronteira, e responde a cada uma delas. Essa sensibilidade, junto com a exigência de que as classes sejam separáveis, é o que leva ao classificador de vetor de suporte do próximo exercício.

**Exercício 2 — o orçamento $C$, com uma covariável.** Uma analista tem oito observações de uma única covariável ($p = 1$). As da classe $-1$ estão em $-3$, $-2$, $-1$ e 1,5, e as da classe $+1$ em $-1{,}5$, 1, 2 e 3. Ela quer ajustar o classificador de vetor de suporte, dado pela solução de

$$\begin{aligned} \max_{\beta_0,\,\beta_1,\,\boldsymbol{\varepsilon},\,M} \quad & M \\ \text{sujeito a} \quad & \beta_1^2 = 1, \qquad y_i\,(\beta_0 + \beta_1 x_i) \geq M(1-\varepsilon_i), \quad i = 1,\ldots,8, \\ & \varepsilon_i \geq 0, \quad i = 1,\ldots,8, \qquad \textstyle\sum_{i=1}^{8} \varepsilon_i \leq C, \end{aligned} \tag{2}$$

e entender o papel do orçamento $C$. Com $p = 1$, a restrição $\beta_1^2 = 1$ deixa só $\beta_1 = \pm 1$, e o hiperplano é um ponto da reta, o corte $t = -\beta_0/\beta_1$. Lembre que, fixados $\beta_0$, $\beta_1$ e $M > 0$, a menor folga que a observação $i$ admite é $\varepsilon_i = \max\{0,\ 1 - y_i f(x_i)/M\}$, com $f(x) = \beta_0 + \beta_1 x$.

(a) Mostre que as observações não são linearmente separáveis. O que isso diz sobre (2) com $C = 0$?

(b) Tome $\beta_0 = 0$ e $\beta_1 = 1$, isto é, o corte $t = 0$, e $M = 2$. Calcule a menor folga de cada observação e diga onde ela está em relação à margem e ao hiperplano. Qual é o menor orçamento com que esse ponto satisfaz as restrições? Quais observações estão sobre a margem ou do lado errado dela, e quantas estão do lado errado do hiperplano? Compare com o que se viu em aula sobre o número de erros de treino.

(c) Para $\beta_1 = 1$ e um corte $t$ qualquer, seja $S(t, M)$ a soma das menores folgas. Agrupe as observações em quatro pares, $(-3, 3)$, $(-2, 2)$, $(-1, 1)$ e $(1{,}5\,;\,-1{,}5)$, cada um com uma observação de cada classe, e use que $\max\{0, a\} + \max\{0, b\} \geq \max\{0, a + b\}$ para mostrar que $S(t, M) \geq S(0, M)$. Calcule $S(0, M)$ como função de $M$ e esboce o seu gráfico. Mostre também que, com $\beta_1 = -1$, a soma das menores folgas é sempre maior que 8.

(d) Use o item (c) para responder: para que valores de $C$ o problema (2) tem solução com $M > 0$? Qual é a solução com $C = 4{,}5$? Qual é o valor ótimo de $M$ com $C = 5$, e quantos vetores de suporte há? O que acontece com o valor ótimo de $M$ quando $C$ cresce?

(e) A analista descobre que a observação da classe $+1$ em 3 foi registrada errado: o valor correto é 30. Mostre que, com $C = 4{,}5$, o classificador de vetor de suporte não muda. Compare com a análise discriminante linear da Aula 07. Com uma covariável e as duas classes do mesmo tamanho, ela classifica cada ponto pelo lado em que ele está do ponto médio entre as médias das duas classes; calcule esse corte antes e depois da correção.

**Solução**

**(a)** Com $p = 1$, $f(x) = \beta_1(x - t)$. Se $\beta_1 = 1$, separar as classes exigiria $x_i > t$ em toda observação da classe $+1$, em particular $-1{,}5 > t$, e $x_i < t$ em toda observação da classe $-1$, em particular $1{,}5 < t$, o que é impossível. Se $\beta_1 = -1$, exigiria $3 < t$, pela observação da classe $+1$ em 3, e $t < -3$, pela observação da classe $-1$ em $-3$, também impossível. As

observações não são, portanto, linearmente separáveis.
Com $C = 0$, as restrições $\varepsilon_i \geq 0$ e $\sum_i \varepsilon_i \leq 0$ forçam $\varepsilon_1 = \cdots = \varepsilon_8 = 0$, e as restrições restantes ficam $y_i f(x_i) \geq M$. Com $M > 0$, isso diria que o hiperplano separa as classes, o que acabamos de excluir. Com $C = 0$, o problema é o do classificador de margem máxima, e ele não tem solução com $M > 0$ para estes dados.

**(b)** Com $\beta_0 = 0$ e $\beta_1 = 1$, $f(x) = x$, e a menor folga é $\varepsilon_i = \max\{0,\, 1 - y_i x_i/2\}$:

| $x_i$ | $-3$ | $-2$ | $-1$ | 1,5 | $-1$,5 | 1 | 2 | 3 |
|---|---|---|---|---|---|---|---|---|
| $y_i$ | $-1$ | $-1$ | $-1$ | $-1$ | $+1$ | $+1$ | $+1$ | $+1$ |
| $y_i f(x_i)$ | 3 | 2 | 1 | $-1$,5 | $-1$,5 | 1 | 2 | 3 |
| $\varepsilon_i$ | 0 | 0 | 0,5 | 1,75 | 1,75 | 0,5 | 0 | 0 |

Como $|\beta_1| = 1$, o número $|y_i f(x_i)| = |x_i|$ é a distância da observação ao hiperplano, e o sinal de $y_i f(x_i)$ diz de que lado ela está. As observações em $-3$ e 3 estão do lado certo e fora da faixa $\{x : |x| < 2\}$; as em $-2$ e 2, sobre a margem; as em $-1$ e 1, dentro da faixa, mas do lado certo do hiperplano ($0 < \varepsilon_i < 1$); e as em 1,5, da classe $-1$, e $-1$,5, da classe $+1$, do lado errado do hiperplano ($\varepsilon_i > 1$). Nenhuma está sobre o hiperplano, o caso $\varepsilon_i = 1$.
As menores folgas somam $2 \cdot 1{,}75 + 2 \cdot 0{,}5 = 4{,}5$. Como toda folga admissível é pelo menos a menor, as restrições valem com algum $\boldsymbol{\varepsilon}$ se e somente se $C \geq 4{,}5$: o menor orçamento é 4,5. As observações sobre a margem ou do lado errado dela, isto é, com $y_i f(x_i) \leq M = 2$, são seis, todas exceto as em $-3$ e 3.
Duas observações estão do lado errado do hiperplano. Com $C = 4{,}5$, o resultado visto em aula garante menos de 4,5 erros de treino, isto é, no máximo 4. A cota vale com sobra, porque ela conta cada erro com uma folga apenas maior que 1, e aqui cada um consome 1,75 do orçamento.

**(c)** Com $\beta_1 = 1$ e corte $t$, $f(x) = x - t$, e a menor folga da observação $i$ é $\max\{0, a_i\}$, com $a_i = 1 - y_i(x_i - t)/M$. Nos três pares $(-d, d)$, com $d = 1, 2, 3$, a observação em $-d$ é da classe $-1$ e a em $d$, da classe $+1$, e

$$a_{-d} + a_d = \Big(1 + \frac{-d - t}{M}\Big) + \Big(1 - \frac{d - t}{M}\Big) = 2 - \frac{2d}{M};$$

no par $(1{,}5\,;\, -1{,}5)$, com a observação em 1,5 na classe $-1$ e a em $-1$,5 na classe $+1$,

$$a_{1,5} + a_{-1,5} = \Big(1 + \frac{1{,}5 - t}{M}\Big) + \Big(1 + \frac{1{,}5 + t}{M}\Big) = 2 + \frac{3}{M}.$$

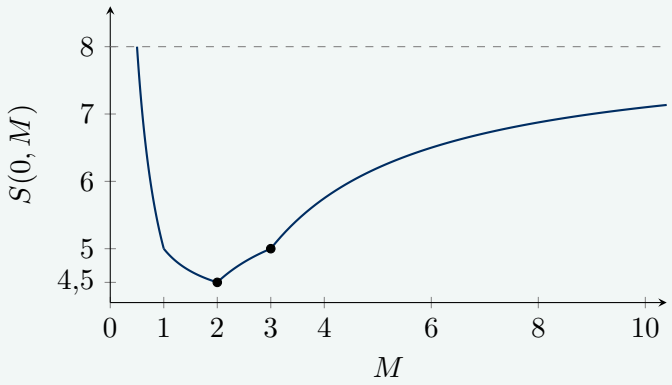
Em todos os pares, $t$ se cancela. A desigualdade $\max\{0, a\} + \max\{0, b\} \geq \max\{0, a + b\}$ vale porque o lado esquerdo é não negativo e é maior ou igual a $a + b$. Somando-a nos quatro pares,

$$S(t, M) \;\geq\; \Big(2 + \frac{3}{M}\Big) + \sum_{d=1}^{3} \max\Big\{0,\; 2 - \frac{2d}{M}\Big\}.$$

Com $t = 0$, as duas observações de cada par têm o mesmo $a_i$, e, quando $a = b$, a desigualdade é uma igualdade, porque $2\max\{0, a\} = \max\{0, 2a\}$. O lado direito é, portanto, $S(0, M)$, e $S(t, M) \geq S(0, M)$ para todo $t$. Calculando os máximos em cada faixa de valores de $M$,

$$S(0, M) = \begin{cases} 2 + 3/M, & 0 < M \leq 1, \\ 4 + 1/M, & 1 \leq M \leq 2, \\ 6 - 3/M, & 2 \leq M \leq 3, \\ 8 - 9/M, & M \geq 3. \end{cases}$$

A função decresce em $(0, 2]$, de $+\infty$ a 4,5, e cresce em $[2, \infty)$, passando por 5 em $M = 3$ e tendendo a 8 sem nunca atingir esse valor. O mínimo, 4,5, é atingido só em $M = 2$.




Com $\beta_1 = -1$, $y_i f(x_i) = -y_i(x_i - t)$, e cada menor folga é pelo menos $1 + y_i(x_i - t)/M$. Somando as oito,

$$\sum_{i=1}^{8} \varepsilon_i \;\geq\; 8 + \frac{1}{M}\sum_{i=1}^{8} y_i(x_i - t) = 8 + \frac{1}{M}\Big(\sum_{y_i=+1} x_i - \sum_{y_i=-1} x_i\Big) = 8 + \frac{4{,}5 - (-4{,}5)}{M} = 8 + \frac{9}{M} > 8,$$

em que $t$ desaparece porque há quatro observações em cada classe.

**(d)** Fixados $\beta_1$, $t$ e $M > 0$, as restrições valem com algum $\boldsymbol{\varepsilon}$ se e somente se a soma das menores folgas não passa de $C$. Pelo item (c), com $\beta_1 = -1$ isso exige $C > 8$, e com $\beta_1 = 1$ existe um corte que serve se e somente se $S(0, M) \leq C$, já que $t = 0$ minimiza a soma. Logo, o problema (2) tem solução com $M > 0$ se e somente se $4{,}5 \leq C < 8$, como se vê a seguir.

Com $C < 4{,}5$, nenhum ponto com $M > 0$ satisfaz as restrições, porque $S(0, M) \geq 4{,}5$. O orçamento tem de pagar as folgas das duas observações do lado errado do hiperplano, que somam pelo menos $2 + 3/M$ e ficam tanto maiores quanto menor é $M$, e as das observações que caem dentro da faixa, que aparecem quando $M$ cresce.

Com $C = 4{,}5$, só $M = 2$ é admissível, e, com $M = 2$, só o corte $t = 0$: no par $(-2, 2)$, $a_{-2} = -t/2$ e $a_2 = t/2$, e a desigualdade do item (c) só é uma igualdade se $t = 0$. As folgas são então as do item (b), cuja soma já é 4,5. A solução é única: o corte $t = 0$, com $M = 2$, e as seis observações listadas no item (b) são os vetores de suporte.

Com $C = 5$, os valores admissíveis de $M$ são os de $S(0, M) \leq 5$, que formam o intervalo $[1, 3]$, e o valor ótimo é $M = 3$. O mesmo argumento, aplicado ao par $(-3, 3)$, mostra que o corte é de novo $t = 0$. Agora as oito observações têm $y_i f(x_i) \leq |x_i| \leq 3 = M$: todas são vetores de suporte, e as em $-3$ e 3 estão sobre a margem.

Para $C$ entre 4,5 e 8, o valor ótimo de $M$ é a maior solução de $S(0, M) = C$:

$$M^*(C) = \frac{3}{6 - C} \;\text{ se } 4{,}5 \leq C \leq 5, \qquad M^*(C) = \frac{9}{8 - C} \;\text{ se } 5 \leq C < 8.$$

Ele cresce com $C$ e tende a infinito quando $C \to 8$. Com $C \geq 8$, todo $M \geq 3$ é admissível, pois $S(0, M) = 8 - 9/M < 8$, e $M$ cresce sem limite: não há solução. As notas mostram isso para todo orçamento maior que o número de observações; aqui o problema falha já em $C = n = 8$.

Os números ilustram o que se viu em aula. O valor ótimo de $M$ não diminui quando o orçamento cresce, e o número de vetores de suporte passa de 6, com $C = 4{,}5$, a 8, com $C = 5$: no primeiro caso, o classificador é determinado pelas seis observações mais próximas do corte; no segundo, por todas. O corte é o mesmo nos dois casos por causa

da simetria dos dados; em geral, o hiperplano também se move quando $C$ muda. Para os demais valores de $C$ entre 4,5 e 8, há dentro da faixa tantas observações de uma classe quanto da outra, e deslocar um pouco o corte não altera a soma das folgas: o corte $t = 0$ continua ótimo, mas deixa de ser o único. O valor ótimo $M^*(C)$ não depende dessa escolha.

**(e)** Com a correção, a observação da classe $+1$ em 3 passa para 30. Descartando os dois termos do par formado por ela e pela observação em $-3$, que são não negativos, e tratando os outros três pares como no item (c), a nova soma das menores folgas, com $\beta_1 = 1$, satisfaz

$$S(t, M) \;\geq\; \Big(2 + \frac{3}{M}\Big) + \max\Big\{0,\, 2 - \frac{2}{M}\Big\} + \max\Big\{0,\, 2 - \frac{4}{M}\Big\} = \begin{cases} 2 + 3/M, & 0 < M \leq 1, \\ 4 + 1/M, & 1 \leq M \leq 2, \\ 6 - 3/M, & M \geq 2, \end{cases}$$

que é pelo menos 4,5, com igualdade só em $M = 2$; e, como no item (d), com $M = 2$ a igualdade no par $(-2, 2)$ exige $t = 0$. No ponto $t = 0$, $M = 2$, as observações em $-3$ e 30 têm folga zero, e a soma vale exatamente 4,5. Com $\beta_1 = -1$, a conta do item (c) dá agora $8 + 36/M > 8$. Com $C = 4{,}5$, a única solução continua sendo o corte $t = 0$ com $M = 2$: o classificador de vetor de suporte não muda. A observação corrigida está do lado certo e fora da faixa, antes e depois da correção, e não é vetor de suporte.

Na análise discriminante linear, com as probabilidades das classes estimadas iguais (4/8 cada) e variância comum estimada $\widehat{\sigma}^2$, a diferença entre as funções discriminantes das duas classes é

$$\delta_{+1}(x) - \delta_{-1}(x) = \frac{\widehat{\mu}_{+1} - \widehat{\mu}_{-1}}{\widehat{\sigma}^2}\Big(x - \frac{\widehat{\mu}_{+1} + \widehat{\mu}_{-1}}{2}\Big),$$

e, como $\widehat{\mu}_{+1} > \widehat{\mu}_{-1}$, a LDA classifica como $+1$ os pontos à direita do ponto médio entre as médias, qualquer que seja $\widehat{\sigma}^2$. Antes da correção, $\widehat{\mu}_{-1} = -4{,}5/4 = -1{,}125$ e $\widehat{\mu}_{+1} = 4{,}5/4 = 1{,}125$, e o corte é 0, o mesmo do classificador de vetor de suporte. Depois, $\widehat{\mu}_{+1} = 31{,}5/4 = 7{,}875$, e o corte passa a $(-1{,}125 + 7{,}875)/2 = 3{,}375$. As observações da classe $+1$ em 1 e 2 ficam à esquerda dele e passam a ser classificadas errado, enquanto a da classe $-1$ em 1,5 deixa de sê-lo: os erros de treino vão de 2 para 3.

Uma única observação, do lado certo e longe da fronteira, deslocou o corte da LDA em mais de três unidades, porque a LDA estima as médias com todas as observações. O classificador de vetor de suporte não mudou, porque ela não é vetor de suporte.

**Exercício 3 — o truque do *kernel*, por extenso.** Um colega vai ajustar uma máquina de vetores de suporte com o *kernel* polinomial de grau 2, $k(\boldsymbol{x}, \boldsymbol{x}') = (1 + \langle \boldsymbol{x}, \boldsymbol{x}' \rangle)^2$, e se pergunta se não seria mais simples fazer como no início da construção da SVM: ampliar as covariáveis à mão e ajustar um classificador de vetor de suporte linear no espaço ampliado.

(a) Para $p = 2$, expanda $k(\boldsymbol{x}, \boldsymbol{x}')$ e exiba $\varphi : \mathbb{R}^2 \to \mathbb{R}^m$ tal que $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle$ para todos $\boldsymbol{x}, \boldsymbol{x}' \in \mathbb{R}^2$. Qual é $m$?

(b) A função de decisão da SVM é $f(\boldsymbol{x}) = \beta_0 + \sum_{i \in \mathcal{S}} \alpha_i \, k(\boldsymbol{x}, \boldsymbol{x}_i)$. Use o item (a) para mostrar que, com $p = 2$, $f$ é um polinômio de grau no máximo 2 em $(x_1, x_2)$. Que forma pode ter a fronteira $\{\boldsymbol{x} : f(\boldsymbol{x}) = 0\}$? Compare com a ampliação que acrescenta só os quadrados, $X_1, X_2, X_1^2, X_2^2$.

(c) Com $p$ covariáveis e grau $q$, a função $\varphi$ do *kernel* polinomial tem $\binom{p+q}{q}$ coordenadas. Calcule esse número para $q = 3$, com $p = 100$ e com $p = 1000$, e quanta memória ocupa um único $\varphi(\boldsymbol{x})$ com $p = 1000$, guardando cada coordenada em 8 bytes. Quantas operações aritméticas custa calcular $k(\boldsymbol{x}, \boldsymbol{x}')$ diretamente pela fórmula, com $p = 1000$ e $q = 3$?

(d) Suponha $n = 10\,000$ observações, $p = 1000$ e $q = 3$. Compare o que o colega teria de guardar para ajustar o classificador linear no espaço ampliado com o que a SVM precisa, e enuncie o truque do *kernel* numa frase.

**Solução**

**(a)** Com $\boldsymbol{x} = (x_1, x_2)$ e $\boldsymbol{x}' = (x_1', x_2')$, $k(\boldsymbol{x}, \boldsymbol{x}') = (1 + x_1x_1' + x_2x_2')^2$, e o quadrado de uma soma de três parcelas dá

$$k(\boldsymbol{x}, \boldsymbol{x}') = 1 + 2x_1x_1' + 2x_2x_2' + x_1^2x_1'^2 + x_2^2x_2'^2 + 2x_1x_2\,x_1'x_2'.$$

Cada termo é o produto de um fator que só depende de $\boldsymbol{x}$ por um que só depende de $\boldsymbol{x}'$, e os termos com coeficiente 2 se escrevem como $(\sqrt{2}\,u)(\sqrt{2}\,v)$. Com

$$\varphi(\boldsymbol{x}) = (1,\ \sqrt{2}\,x_1,\ \sqrt{2}\,x_2,\ x_1^2,\ x_2^2,\ \sqrt{2}\,x_1x_2) \in \mathbb{R}^6,$$

o produto interno $\langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle$ é exatamente a soma acima, e $m = 6 = \binom{2+2}{2}$: uma coordenada para cada monômio de grau até 2 em $x_1$ e $x_2$.

**(b)** Pela bilinearidade do produto interno,

$$f(\boldsymbol{x}) = \beta_0 + \sum_{i \in \mathcal{S}} \alpha_i \,\langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}_i) \rangle = \beta_0 + \langle \varphi(\boldsymbol{x}), \boldsymbol{b} \rangle\,, \qquad \boldsymbol{b} = \sum_{i \in \mathcal{S}} \alpha_i\, \varphi(\boldsymbol{x}_i) \in \mathbb{R}^6.$$

Escrevendo $\boldsymbol{b} = (b_1, \ldots, b_6)$,

$$f(\boldsymbol{x}) = (\beta_0 + b_1) + \sqrt{2}\,b_2\,x_1 + \sqrt{2}\,b_3\,x_2 + b_4\,x_1^2 + b_5\,x_2^2 + \sqrt{2}\,b_6\,x_1x_2,$$

um polinômio de grau no máximo 2 em $(x_1, x_2)$. A fronteira $\{\boldsymbol{x} : f(\boldsymbol{x}) = 0\}$ é, portanto, uma cônica (elipse, hipérbole ou parábola) ou um caso degenerado dela (uma reta, um par de retas, um ponto ou o conjunto vazio). Em $\mathbb{R}^6$, ela corresponde ao hiperplano $\{\boldsymbol{z} : \beta_0 + \langle \boldsymbol{z}, \boldsymbol{b} \rangle = 0\}$: a SVM com esse *kernel* é um classificador linear nos pontos $\varphi(\boldsymbol{x}_i)$, e a fronteira só deixa de ser linear quando é vista em $\mathbb{R}^2$.
A ampliação que acrescenta só os quadrados dá $f(\boldsymbol{x}) = \beta_0 + \beta_{11}x_1 + \beta_{21}x_2 + \beta_{12}x_1^2 + \beta_{22}x_2^2$, sem o termo $x_1x_2$, e as cônicas não degeneradas que ela produz têm eixos paralelos aos eixos coordenados. O *kernel* inclui também o produto $x_1x_2$ e produz, por exemplo, elipses inclinadas. Ele corresponde a ampliar as covariáveis com todos os monômios de grau até 2, com os pesos $\sqrt{2}$ que a expansão fixou.

**(c)** Com $q = 3$,

$$\binom{103}{3} = \frac{103 \cdot 102 \cdot 101}{6} = 176\,851, \qquad \binom{1003}{3} = \frac{1003 \cdot 1002 \cdot 1001}{6} = 167\,668\,501.$$

Com $p = 1000$, um único $\varphi(\boldsymbol{x})$ tem quase 168 milhões de coordenadas e ocupa $167\,668\,501 \times 8 \approx 1{,}34 \times 10^9$ bytes, cerca de 1,3 GB. Já $k(\boldsymbol{x}, \boldsymbol{x}') = (1 + \langle \boldsymbol{x}, \boldsymbol{x}' \rangle)^3$ se calcula com 1000 multiplicações e 999 adições para o produto interno, uma adição para somar 1 e duas multiplicações para o cubo: 2002 operações. Pelo outro caminho, só escrever as coordenadas de $\varphi(\boldsymbol{x})$ exige mais de cem milhões de operações, porque cada monômio de grau maior que zero custa pelo menos uma multiplicação, e o produto interno de dois desses vetores custa outras $2 \times 167\,668\,501 - 1 \approx 3{,}4 \times 10^8$.

**(d)** Para ajustar o classificador linear no espaço ampliado, o colega teria de guardar os $n$ vetores $\varphi(\boldsymbol{x}_i)$: $10\,000 \times 167\,668\,501 \approx 1{,}68 \times 10^{12}$ números, cerca de 13 TB. A SVM, pela representação vista em aula, só precisa dos valores $k(\boldsymbol{x}_i, \boldsymbol{x}_j)$ com $1 \le i \le j \le n$, que são $n(n+1)/2 = 50\,005\,000$ números, cerca de 400 MB, cada um calculado com 2002

operações; para classificar um ponto novo $\boldsymbol{x}$, bastam os $k(\boldsymbol{x}, \boldsymbol{x}_i)$ com $i \in \mathcal{S}$. Os parâmetros a estimar, $\beta_0$ e $\alpha_1, \ldots, \alpha_n$, são $n+1$, qualquer que seja a dimensão do espaço ampliado. O truque do *kernel*, numa frase: como o ajuste e a previsão só usam os dados por meio de produtos internos, trocar o produto interno por $k$ ajusta um classificador linear nos pontos $\varphi(\boldsymbol{x}_i)$ sem que $\varphi$ seja calculada uma única vez. O custo passa a crescer com o número de pares de observações, e não com a dimensão do espaço ampliado: com $n = 10^6$, os $n(n+1)/2$ valores de $k$ já seriam cerca de $5 \times 10^{11}$.

**Exercício 4 — quais funções são *kernels*.** Uma pesquisadora quer usar a SVM com medidas de semelhança diferentes do produto interno, e precisa decidir quais das funções que imaginou são *kernels*. Lembre que $k : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$ é um *kernel* se existem um espaço de Hilbert $\mathcal{H}$ e uma função $\varphi : \mathbb{R}^p \to \mathcal{H}$ com $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle_{\mathcal{H}}$ para todos $\boldsymbol{x}, \boldsymbol{x}'$, e que, pelo teorema visto em aula, isso acontece se e somente se $k$ é simétrica e, para todo $n \geq 1$ e quaisquer $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n \in \mathbb{R}^p$, a matriz $\big[k(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]_{i,j=1}^{n}$ é positiva semidefinida.

(a) Mostre que, se $k_1$ e $k_2$ são *kernels* e $c \geq 0$, então $c\,k_1$ e $k_1 + k_2$ também são. Conclua que $k(\boldsymbol{x}, \boldsymbol{x}') = c + \langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ é um *kernel* para todo $c \geq 0$.

(b) Mostre que todo *kernel* satisfaz $k(\boldsymbol{x}, \boldsymbol{x}) \geq 0$ e $k(\boldsymbol{x}, \boldsymbol{x}')^2 \leq k(\boldsymbol{x}, \boldsymbol{x})\, k(\boldsymbol{x}', \boldsymbol{x}')$. A pesquisadora propõe $k(\boldsymbol{x}, \boldsymbol{x}') = \|\boldsymbol{x} - \boldsymbol{x}'\|^2$, que é simétrica. É um *kernel*?

(c) No *kernel* radial, $k(\boldsymbol{x}, \boldsymbol{x}') = \exp\big(-\gamma\, \|\boldsymbol{x} - \boldsymbol{x}'\|^2\big)$, exige-se $\gamma > 0$. Para dois pontos distintos $\boldsymbol{x}_1$ e $\boldsymbol{x}_2$, calcule os autovalores da matriz $\big[k(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]_{i,j=1}^{2}$ e mostre que, com $\gamma < 0$, a função não é um *kernel*. O que acontece com $\gamma = 0$, e por que esse caso não serve para classificar?

(d) Para $n$ pontos distintos $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n$, mostre que a matriz $\big[k(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]$ do *kernel* radial converge para a identidade quando $\gamma \to \infty$ e para a matriz com todas as entradas iguais a 1 quando $\gamma \to 0$. Use isso e a forma da função de decisão, $f(\boldsymbol{x}) = \beta_0 + \sum_{i \in \mathcal{S}} \alpha_i\, k(\boldsymbol{x}, \boldsymbol{x}_i)$, para explicar por que $\gamma$ grande dá fronteiras flexíveis e $\gamma$ pequeno, fronteiras suaves. Para dois pontos à distância 1, calcule $k$ com $\gamma = 0{,}5$ e com $\gamma = 50$.

**Solução**

**(a)** Sejam $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n \in \mathbb{R}^p$, $\boldsymbol{a} \in \mathbb{R}^n$, e $K_1$ e $K_2$ as matrizes $\big[k_1(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]$ e $\big[k_2(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]$, positivas semidefinidas pelo teorema, porque $k_1$ e $k_2$ são *kernels*. As funções $c\,k_1$ e $k_1 + k_2$ são simétricas, porque $k_1$ e $k_2$ o são, e as suas matrizes nos pontos $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n$ são $cK_1$ e $K_1 + K_2$. Como

$$\boldsymbol{a}^\top (cK_1)\boldsymbol{a} = c\, \boldsymbol{a}^\top K_1 \boldsymbol{a} \geq 0 \qquad \text{e} \qquad \boldsymbol{a}^\top (K_1 + K_2)\boldsymbol{a} = \boldsymbol{a}^\top K_1 \boldsymbol{a} + \boldsymbol{a}^\top K_2 \boldsymbol{a} \geq 0,$$

as duas matrizes são positivas semidefinidas, e, pelo teorema, $c\,k_1$ e $k_1 + k_2$ são *kernels*. O mesmo se vê pela definição: se $k_\ell(\boldsymbol{x}, \boldsymbol{x}') = \langle \varphi_\ell(\boldsymbol{x}), \varphi_\ell(\boldsymbol{x}') \rangle_{\mathcal{H}_\ell}$, basta tomar $\sqrt{c}\,\varphi_1$ para $c\,k_1$ e, para $k_1 + k_2$, o par $(\varphi_1(\boldsymbol{x}), \varphi_2(\boldsymbol{x}))$, no espaço $\mathcal{H}_1 \times \mathcal{H}_2$ com o produto interno $\langle (u_1, u_2), (v_1, v_2) \rangle = \langle u_1, v_1 \rangle_{\mathcal{H}_1} + \langle u_2, v_2 \rangle_{\mathcal{H}_2}$.
A função constante igual a 1 é um *kernel*, com $\varphi(\boldsymbol{x}) = 1 \in \mathbb{R}$, e o produto interno também é, com $\varphi$ a identidade de $\mathbb{R}^p$. Pelo que acabamos de provar, $c + \langle \boldsymbol{x}, \boldsymbol{x}' \rangle = c \cdot 1 + \langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ é um *kernel* para todo $c \geq 0$; com $c = 1$, é o *kernel* polinomial de grau 1.

**(b)** Aplique o teorema a um ou dois pontos. Com $n = 1$ e o ponto $\boldsymbol{x}$, a matriz $1 \times 1$ $\big[k(\boldsymbol{x}, \boldsymbol{x})\big]$ é positiva semidefinida, isto é, $k(\boldsymbol{x}, \boldsymbol{x}) \geq 0$. Com $n = 2$ e os pontos $\boldsymbol{x}$ e $\boldsymbol{x}'$, a matriz

$$K = \begin{pmatrix} k(\boldsymbol{x}, \boldsymbol{x}) & k(\boldsymbol{x}, \boldsymbol{x}') \\ k(\boldsymbol{x}', \boldsymbol{x}) & k(\boldsymbol{x}', \boldsymbol{x}') \end{pmatrix}$$

é simétrica e positiva semidefinida. Os seus autovalores são, portanto, não negativos, e o seu determinante, que é o produto deles, também: $k(\boldsymbol{x},\boldsymbol{x})\,k(\boldsymbol{x}',\boldsymbol{x}') - k(\boldsymbol{x},\boldsymbol{x}')^2 \geq 0$. Pela definição, essa é a desigualdade de Cauchy–Schwarz em $\mathcal{H}$.
A função $k(\boldsymbol{x},\boldsymbol{x}') = \|\boldsymbol{x}-\boldsymbol{x}'\|^2$ é simétrica, mas não é um *kernel*. Para $\boldsymbol{x} \neq \boldsymbol{x}'$, ela vale $k(\boldsymbol{x},\boldsymbol{x}) = k(\boldsymbol{x}',\boldsymbol{x}') = 0$ e $k(\boldsymbol{x},\boldsymbol{x}') = \|\boldsymbol{x}-\boldsymbol{x}'\|^2 > 0$, e a desigualdade acima falharia: $0 - \|\boldsymbol{x}-\boldsymbol{x}'\|^4 < 0$. Concretamente, com $\boldsymbol{a} = (1,-1)$, $\boldsymbol{a}^\top K \boldsymbol{a} = -2\,\|\boldsymbol{x}-\boldsymbol{x}'\|^2 < 0$.
A desigualdade diz que, num *kernel*, a semelhança entre dois pontos não passa, em valor absoluto, da média geométrica das semelhanças de cada um consigo mesmo; em particular, se $k(\boldsymbol{x},\boldsymbol{x}) = 0$, então $k(\boldsymbol{x},\boldsymbol{x}') = 0$ para todo $\boldsymbol{x}'$. Uma função que vale zero entre cada ponto e ele mesmo e é positiva entre pontos distintos, como o quadrado de uma distância, mede dissimilaridade e não pode ser um *kernel*.

**(c)** Sejam $\boldsymbol{x}_1 \neq \boldsymbol{x}_2$ e $r = \|\boldsymbol{x}_1 - \boldsymbol{x}_2\| > 0$. Como $k(\boldsymbol{x},\boldsymbol{x}) = e^0 = 1$, a matriz é

$$K = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}, \qquad \rho = e^{-\gamma r^2} > 0.$$

Os vetores $(1,1)$ e $(1,-1)$ são autovetores, com autovalores $1+\rho$ e $1-\rho$, porque $K(1,1)^\top = (1+\rho)(1,1)^\top$ e $K(1,-1)^\top = (1-\rho)(1,-1)^\top$. A matriz é positiva semidefinida se e somente se $1-\rho \geq 0$, isto é, $e^{-\gamma r^2} \leq 1$, ou $\gamma r^2 \geq 0$; como $r^2 > 0$, isso equivale a $\gamma \geq 0$. Com $\gamma < 0$, o autovalor $1-\rho$ é negativo, a condição do teorema falha já com dois pontos, e a função não é um *kernel*.
Com $\gamma = 0$, $k(\boldsymbol{x},\boldsymbol{x}') = 1$ para todos $\boldsymbol{x},\boldsymbol{x}'$. É um *kernel*, com $\varphi(\boldsymbol{x}) = 1$, mas a função de decisão $f(\boldsymbol{x}) = \beta_0 + \sum_{i\in\mathcal{S}} \alpha_i$ é constante, e o sinal de $f$ é o mesmo em todo ponto: a SVM não distingue um ponto de outro. Daí a exigência $\gamma > 0$. Que, com $\gamma > 0$, a função é um *kernel* para todo $p$ é um fato que admitimos; as notas exibem $\varphi$ quando $p = 1$.

**(d)** Para $i \neq j$, $r_{ij} = \|\boldsymbol{x}_i - \boldsymbol{x}_j\| > 0$, e a entrada $e^{-\gamma r_{ij}^2}$ tende a 0 quando $\gamma \to \infty$ e a 1 quando $\gamma \to 0$; a diagonal vale sempre 1. Logo, a matriz tende à identidade quando $\gamma \to \infty$ e à matriz $\mathbf{1}\mathbf{1}^\top$, com todas as entradas iguais a 1, quando $\gamma \to 0$.
Com $\gamma$ grande, cada observação de treino é semelhante só a si mesma. Na função de decisão, o termo $\alpha_i\,k(\boldsymbol{x},\boldsymbol{x}_i)$ decai depressa com a distância a $\boldsymbol{x}_i$: fica abaixo de $e^{-1}\,|\alpha_i|$ quando $\|\boldsymbol{x}-\boldsymbol{x}_i\| \geq 1/\sqrt{\gamma}$ e abaixo de $e^{-4}\,|\alpha_i| \approx 0{,}02\,|\alpha_i|$ quando $\|\boldsymbol{x}-\boldsymbol{x}_i\| \geq 2/\sqrt{\gamma}$, de modo que o alcance de cada termo é da ordem de $1/\sqrt{\gamma}$. Longe de todos os vetores de suporte, $f(\boldsymbol{x})$ fica perto de $\beta_0$, e perto de cada um o sinal de $f$ pode ser decidido por ele. A fronteira pode, assim, contornar observações isoladas: é flexível, com viés baixo e variância alta. Com $\gamma$ pequeno, a matriz fica perto de $\mathbf{1}\mathbf{1}^\top$, que tem posto 1: o *kernel* quase não distingue as observações umas das outras, cada $k(\boldsymbol{x},\boldsymbol{x}_i)$ varia devagar na região dos dados, e a fronteira é suave, com viés mais alto e variância mais baixa.
Para dois pontos à distância 1, $e^{-0{,}5} \approx 0{,}61$ e $e^{-50} \approx 1{,}9 \times 10^{-22}$. Com $\gamma = 0{,}5$, pontos à distância 1 ainda são bem semelhantes; com $\gamma = 50$, são, para todos os efeitos, alheios um ao outro. São os dois valores da figura dos anéis concêntricos nas notas: o primeiro dá uma fronteira próxima de uma circunferência, e o segundo, uma fronteira irregular, que contorna observações isoladas. Como a acurácia de treino quase não distingue um caso do outro, $\gamma$ é escolhido junto com $C$, por validação cruzada.