Lista Teórica 09

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Aula 09 — Máquinas de Vetores de Suporte (SVM)

Exercício 1 — a margem máxima, calculada à mão. Uma estudante quer entender o classificador de margem máxima num exemplo em que todas as contas cabem no papel. Ela toma quatro observações de $\mathbb{R}^2$:

i	1	2	3	4
$\boldsymbol{x}_i$	$(3,1)$	$(3,3)$	$(1,1)$	$(1,3)$
y_i	$+1$	$+1$	-1	-1

Lembre que o classificador de margem máxima é dado pela solução do problema

$$\max_{\beta_0,\,\boldsymbol{\beta},\,M} \; M \quad \text{sujeito a} \quad \sum_{j=1}^{p} \beta_j^2 = 1 \quad \text{e} \quad y_i\,(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) \geq M, \quad i = 1, \ldots, n, \tag{1}$$

e que os seus vetores de suporte são as observações com $y_i(\beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}_i) = M$. Escreva $f(\boldsymbol{x}) = \beta_0 + \boldsymbol{\beta}^\top \boldsymbol{x}$.

(a) Sejam $\boldsymbol{x}_i$ e $\boldsymbol{x}_j$ observações distintas de classes opostas, com $y_i = +1$ e $y_j = -1$. Mostre que todo ponto $(\beta_0, \boldsymbol{\beta}, M)$ que satisfaz as restrições de (1) tem $M \leq \|\boldsymbol{x}_i - \boldsymbol{x}_j\|/2$, e que a igualdade exige $\boldsymbol{\beta} = (\boldsymbol{x}_i - \boldsymbol{x}_j)/\|\boldsymbol{x}_i - \boldsymbol{x}_j\|$. (Some as restrições das duas observações e use a desigualdade de Cauchy–Schwarz.)

(b) Use o item (a) para determinar o classificador de margem máxima das quatro observações e o valor ótimo de M, e mostre que a solução é única. Quais observações são vetores de suporte?

(c) A estudante acrescenta uma quinta observação, $\boldsymbol{x}_5 = (5,2)$, com $y_5 = +1$. O classificador muda? Justifique sem resolver o problema de novo.

(d) Em vez disso, ela desloca a primeira observação de $(3,1)$ para $(2{,}5\,;\,1)$, sem mexer nas outras. Determine o novo classificador, o novo valor ótimo de M e os novos vetores de suporte.

Exercício 2 — o orçamento C, com uma covariável. Uma analista tem oito observações de uma única covariável ($p = 1$). As da classe -1 estão em -3, -2, -1 e 1,5, e as da classe $+1$ em $-1{,}5$, 1, 2 e 3. Ela quer ajustar o classificador de vetor de suporte, dado pela solução de

$$\begin{aligned} \max_{\beta_0,\,\beta_1,\,\boldsymbol{\varepsilon},\,M} \quad & M \\ \text{sujeito a} \quad & \beta_1^2 = 1, \qquad y_i\,(\beta_0 + \beta_1 x_i) \geq M(1 - \varepsilon_i), \quad i = 1, \ldots, 8, \\ & \varepsilon_i \geq 0, \quad i = 1, \ldots, 8, \qquad \textstyle\sum_{i=1}^{8} \varepsilon_i \leq C, \end{aligned} \tag{2}$$

e entender o papel do orçamento C. Com $p = 1$, a restrição $\beta_1^2 = 1$ deixa só $\beta_1 = \pm 1$, e o hiperplano é um ponto da reta, o corte $t = -\beta_0/\beta_1$. Lembre que, fixados β_0, β_1 e $M > 0$, a menor folga que a observação i admite é $\varepsilon_i = \max\{0,\; 1 - y_i f(x_i)/M\}$, com $f(x) = \beta_0 + \beta_1 x$.

(a) Mostre que as observações não são linearmente separáveis. O que isso diz sobre (2) com $C = 0$?

(b) Tome $\beta_0 = 0$ e $\beta_1 = 1$, isto é, o corte $t = 0$, e $M = 2$. Calcule a menor folga de cada observação e diga onde ela está em relação à margem e ao hiperplano. Qual é o menor orçamento com que esse ponto satisfaz as restrições? Quais observações estão sobre a margem ou do lado errado dela, e quantas estão do lado errado do hiperplano? Compare com o que se viu em aula sobre o número de erros de treino.

(c) Para $\beta_1 = 1$ e um corte t qualquer, seja $S(t, M)$ a soma das menores folgas. Agrupe as observações em quatro pares, $(-3, 3)$, $(-2, 2)$, $(-1, 1)$ e $(1{,}5\,;\,-1{,}5)$, cada um com uma observação de cada classe, e use que $\max\{0, a\} + \max\{0, b\} \geq \max\{0, a + b\}$ para mostrar que $S(t, M) \geq S(0, M)$. Calcule $S(0, M)$ como função de M e esboce o seu gráfico. Mostre também que, com $\beta_1 = -1$, a soma das menores folgas é sempre maior que 8.

(d) Use o item (c) para responder: para que valores de C o problema (2) tem solução com $M > 0$? Qual é a solução com $C = 4{,}5$? Qual é o valor ótimo de M com $C = 5$, e quantos vetores de suporte há? O que acontece com o valor ótimo de M quando C cresce?

(e) A analista descobre que a observação da classe $+1$ em 3 foi registrada errado: o valor correto é 30. Mostre que, com $C = 4{,}5$, o classificador de vetor de suporte não muda. Compare com a análise discriminante linear da Aula 07. Com uma covariável e as duas classes do mesmo tamanho, ela classifica cada ponto pelo lado em que ele está do ponto médio entre as médias das duas classes; calcule esse corte antes e depois da correção.

Exercício 3 — o truque do *kernel*, por extenso. Um colega vai ajustar uma máquina de vetores de suporte com o *kernel* polinomial de grau 2, $k(\boldsymbol{x}, \boldsymbol{x}') = \big(1 + \langle \boldsymbol{x}, \boldsymbol{x}' \rangle\big)^2$, e se pergunta se não seria mais simples fazer como no início da construção da SVM: ampliar as covariáveis à mão e ajustar um classificador de vetor de suporte linear no espaço ampliado.

(a) Para $p = 2$, expanda $k(\boldsymbol{x}, \boldsymbol{x}')$ e exiba $\varphi : \mathbb{R}^2 \to \mathbb{R}^m$ tal que $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle$ para todos $\boldsymbol{x}, \boldsymbol{x}' \in \mathbb{R}^2$. Qual é m?

(b) A função de decisão da SVM é $f(\boldsymbol{x}) = \beta_0 + \sum_{i \in \mathcal{S}} \alpha_i \, k(\boldsymbol{x}, \boldsymbol{x}_i)$. Use o item (a) para mostrar que, com $p = 2$, f é um polinômio de grau no máximo 2 em (x_1, x_2). Que forma pode ter a fronteira $\{\boldsymbol{x} : f(\boldsymbol{x}) = 0\}$? Compare com a ampliação que acrescenta só os quadrados, X_1, X_2, X_1^2, X_2^2.

(c) Com p covariáveis e grau q, a função φ do *kernel* polinomial tem $\binom{p+q}{q}$ coordenadas. Calcule esse número para $q = 3$, com $p = 100$ e com $p = 1000$, e quanta memória ocupa um único $\varphi(\boldsymbol{x})$ com $p = 1000$, guardando cada coordenada em 8 bytes. Quantas operações aritméticas custa calcular $k(\boldsymbol{x}, \boldsymbol{x}')$ diretamente pela fórmula, com $p = 1000$ e $q = 3$?

(d) Suponha $n = 10\,000$ observações, $p = 1000$ e $q = 3$. Compare o que o colega teria de guardar para ajustar o classificador linear no espaço ampliado com o que a SVM precisa, e enuncie o truque do *kernel* numa frase.

Exercício 4 — quais funções são *kernels*. Uma pesquisadora quer usar a SVM com medidas de semelhança diferentes do produto interno, e precisa decidir quais das funções que imaginou são *kernels*. Lembre que $k : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$ é um *kernel* se existem um espaço de Hilbert $\mathcal{H}$ e uma função $\varphi : \mathbb{R}^p \to \mathcal{H}$ com $k(\boldsymbol{x}, \boldsymbol{x}') = \langle \varphi(\boldsymbol{x}), \varphi(\boldsymbol{x}') \rangle_{\mathcal{H}}$ para todos $\boldsymbol{x}, \boldsymbol{x}'$, e que, pelo teorema visto em aula, isso acontece se e somente se k é simétrica e, para todo $n \geq 1$ e quaisquer $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n \in \mathbb{R}^p$, a matriz $\big[k(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]_{i,j=1}^{n}$ é positiva semidefinida.

(a) Mostre que, se k_1 e k_2 são *kernels* e $c \geq 0$, então $c\,k_1$ e $k_1 + k_2$ também são. Conclua que $k(\boldsymbol{x}, \boldsymbol{x}') = c + \langle \boldsymbol{x}, \boldsymbol{x}' \rangle$ é um *kernel* para todo $c \geq 0$.

(b) Mostre que todo *kernel* satisfaz $k(\boldsymbol{x}, \boldsymbol{x}) \geq 0$ e $k(\boldsymbol{x}, \boldsymbol{x}')^2 \leq k(\boldsymbol{x}, \boldsymbol{x})\, k(\boldsymbol{x}', \boldsymbol{x}')$. A pesquisadora propõe $k(\boldsymbol{x}, \boldsymbol{x}') = \|\boldsymbol{x} - \boldsymbol{x}'\|^2$, que é simétrica. É um *kernel*?

(c) No *kernel* radial, $k(\boldsymbol{x}, \boldsymbol{x}') = \exp\big(-\gamma \|\boldsymbol{x} - \boldsymbol{x}'\|^2\big)$, exige-se $\gamma > 0$. Para dois pontos distintos $\boldsymbol{x}_1$ e $\boldsymbol{x}_2$, calcule os autovalores da matriz $\big[k(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]_{i,j=1}^{2}$ e mostre que, com $\gamma < 0$, a função não é um *kernel*. O que acontece com $\gamma = 0$, e por que esse caso não serve para classificar?

(d) Para n pontos distintos $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n$, mostre que a matriz $\big[k(\boldsymbol{x}_i, \boldsymbol{x}_j)\big]$ do *kernel* radial converge para a identidade quando $\gamma \to \infty$ e para a matriz com todas as entradas iguais a 1 quando $\gamma \to 0$. Use isso e a forma da função de decisão, $f(\boldsymbol{x}) = \beta_0 + \sum_{i \in \mathcal{S}} \alpha_i\, k(\boldsymbol{x}, \boldsymbol{x}_i)$, para explicar por que γ grande dá fronteiras flexíveis e γ pequeno, fronteiras suaves. Para dois pontos à distância 1, calcule k com $\gamma = 0{,}5$ e com $\gamma = 50$.