Aula 10 — KNN e Árvores de Classificação

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §8.3–8.6; ISLP §4.7.6 e cap. 8

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- adaptar o KNN da regressão para classificação e reconhecê-lo como classificador *plug-in*;
- construir uma árvore de classificação, que prediz pela moda de cada folha;
- definir o índice de Gini e a entropia como medidas de impureza e explicar por que a taxa de erro não é usada para dividir os nós;
- usar *bagging*, florestas aleatórias e *boosting* em classificação;
- comparar os classificadores do curso e escolher entre eles segundo a estrutura dos dados e o objetivo da análise.

Esta é a última aula sobre classificação. Os dois métodos que ela estuda, o KNN e as árvores, já apareceram em regressão, nas Aulas 04 e 05, e quase tudo o que se faz aqui é adaptá-los a uma resposta qualitativa: a média das respostas dá lugar à *moda*, e o erro quadrático médio dá lugar a uma medida de *impureza*.

Fixemos a notação. A resposta Y assume valores num conjunto finito $\mathcal{C}$ de classes, e as observações de treino são $(\boldsymbol{X}_1, Y_1), \dots, (\boldsymbol{X}_n, Y_n)$, com $\boldsymbol{X}_i \in \mathbb{R}^p$. Na Aula 07 vimos que, sob a perda 0–1, o classificador de menor risco é o classificador de Bayes,

$$g^*(\boldsymbol{x}) = \arg\max_{c \in \mathcal{C}} \ \mathbb{P}(Y = c \mid \boldsymbol{X} = \boldsymbol{x}),$$

e que um classificador *plug-in* substitui cada $\mathbb{P}(Y = c \mid \boldsymbol{X} = \boldsymbol{x})$ por uma estimativa $\widehat{\mathbb{P}}(Y = c \mid \boldsymbol{x})$ e atribui $\boldsymbol{x}$ à classe de maior probabilidade estimada. Os dois métodos desta aula são classificadores *plug-in*.

1 KNN para classificação

Seja d uma distância em $\mathbb{R}^p$, em geral a euclidiana. Como na Aula 04, para cada $\boldsymbol{x}$ indicamos por $d_{\boldsymbol{x}}^k$ a distância de $\boldsymbol{x}$ à k-ésima observação de treino mais próxima e por

$$\mathcal{N}_{\boldsymbol{x}}^{(k)} = \{i : d(\boldsymbol{X}_i, \boldsymbol{x}) \le d_{\boldsymbol{x}}^k\}$$

o conjunto dos índices das k observações de treino mais próximas de $\boldsymbol{x}$. Supomos que não há empates entre as distâncias, de modo que esse conjunto tem exatamente k elementos.

Definição 1.1 (KNN para classificação)**.** O classificador dos k vizinhos mais próximos atribui a $\boldsymbol{x}$ a classe mais frequente entre as respostas dos seus k vizinhos:

$$\widehat{g}(\boldsymbol{x}) = \text{moda}\{Y_i : i \in \mathcal{N}_{\boldsymbol{x}}^{(k)}\}. \tag{1}$$

Em outras palavras, cada vizinho vota na sua classe, e vence a mais votada: é o *voto da maioria*. Se duas ou mais classes empatam no número de votos, a moda não é única, e é preciso uma regra de desempate.

O KNN é um classificador *plug-in*. Para cada classe c, estime

$$\widehat{\mathbb{P}}(Y = c \mid \boldsymbol{x}) = \frac{1}{k} \sum_{i \in \mathcal{N}_{\boldsymbol{x}}^{(k)}} \mathbf{1}\{Y_i = c\}\,,$$

a proporção de vizinhos de $\boldsymbol{x}$ que pertencem à classe c. Cada estimativa está em $[0, 1]$ e, como cada vizinho pertence a exatamente uma classe, as estimativas somam 1 sobre $\mathcal{C}$: formam uma distribuição de probabilidade sobre as classes. Como $k\,\widehat{\mathbb{P}}(Y = c \mid \boldsymbol{x})$ é o número de votos da classe c, a classe de maior probabilidade estimada é a mais votada, isto é, $\arg\max_c \widehat{\mathbb{P}}(Y = c \mid \boldsymbol{x}) = \widehat{g}(\boldsymbol{x})$.

Essa estimativa mostra também em que sentido o KNN de classificação é uma adaptação direta do de regressão. Como $\mathbb{P}(Y = c \mid \boldsymbol{X} = \boldsymbol{x}) = \mathbb{E}[\mathbf{1}\{Y = c\} \mid \boldsymbol{X} = \boldsymbol{x}]$, a probabilidade condicional de cada classe é a função de regressão da variável indicadora $\mathbf{1}\{Y = c\}$, e $\widehat{\mathbb{P}}(Y = c \mid \boldsymbol{x})$ é exatamente o estimador KNN da Aula 04 aplicado às respostas $\mathbf{1}\{Y_1 = c\}, \ldots, \mathbf{1}\{Y_n = c\}$.

O número de vizinhos k controla a flexibilidade do classificador. A Figura 1 mostra as fronteiras de decisão para $k = 1$, 15 e 120. Com $k = 1$, e sem observações repetidas, cada observação de treino é a sua própria vizinha mais próxima, já que $d(\boldsymbol{X}_i, \boldsymbol{X}_i) = 0$; logo $\widehat{g}(\boldsymbol{X}_i) = Y_i$ para todo i, e a acurácia de treino é igual a 1, qualquer que seja o desempenho do classificador em observações novas.

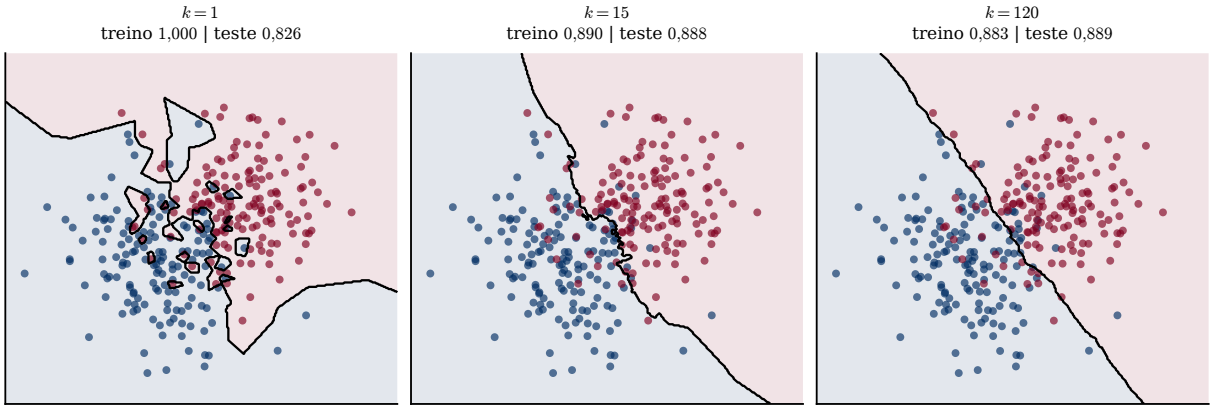


Figura 1: Fronteiras de decisão do KNN com $n = 300$ observações de treino; as acurácias de teste foram calculadas em 10 000 observações novas. Com $k = 1$, a fronteira é muito recortada e forma ilhas em torno de observações isoladas; a acurácia de treino é exatamente 1,000, e a de teste é a pior das três, 0,826. Com $k = 15$, a fronteira fica mais suave, e a acurácia de teste sobe para 0,888; com $k = 120$, a fronteira é quase uma reta, e a acurácia de teste praticamente não muda, 0,889. Como na Figura 1 da Aula 04, é o k pequeno que corresponde ao ajuste mais flexível.

Atenção

Valem os cuidados da Aula 04. Como o KNN se baseia numa distância, padronize as covariáveis: na distância euclidiana, uma covariável medida numa escala maior domina a soma dos quadrados das diferenças. E lembre da *maldição da dimensionalidade*: o KNN não seleciona covariáveis, e o seu desempenho piora quando há muitas covariáveis irrelevantes, que entram na distância com o mesmo peso das relevantes. Em problemas binários, use k ímpar para evitar empates na votação.

2 Árvores de classificação

As árvores de classificação são o análogo das árvores de regressão da Aula 05. Uma árvore particiona o espaço das covariáveis, por divisões binárias sucessivas, em regiões disjuntas $R_1, \ldots, R_J$, as folhas. Para uma região R, sejam $n_R = \#\{i : \boldsymbol{X}_i \in R\}$ o número de observações de treino em R e

$$\widehat{p}_{R,c} = \frac{1}{n_R} \sum_{i:\boldsymbol{X}_i \in R} \mathbf{1}\{Y_i = c\}\,, \qquad c \in \mathcal{C},$$

a proporção da classe c entre essas observações. A passagem da regressão para a classificação exige duas adaptações: na predição de cada folha e no critério que escolhe as divisões.

2.1 Predição: a moda

Numa folha R_k, a árvore prediz a classe majoritária, em vez da média das respostas:

$$\widehat{g}(\boldsymbol{x}) = \text{moda}\{Y_i : \boldsymbol{X}_i \in R_k\}, \qquad \boldsymbol{x} \in R_k, \tag{2}$$

e estima $\mathbb{P}(Y = c \mid \boldsymbol{X} = \boldsymbol{x})$ por $\widehat{p}_{R_k,c}$, a proporção da classe c na folha. Pelo mesmo argumento usado no KNN, a classe majoritária é a de maior $\widehat{p}_{R_k,c}$, e a árvore é também um classificador *plug-in*.

É a substituição que o classificador de Bayes indica. Em regressão, sob a perda quadrática, o alvo é a média condicional $\mathbb{E}[Y \mid \boldsymbol{X} = \boldsymbol{x}]$ (Aula 01), e a árvore o estima pela média das respostas da folha. Em classificação, sob a perda 0–1, o alvo é $g^*(\boldsymbol{x})$, a moda da distribuição condicional de Y dado $\boldsymbol{X} = \boldsymbol{x}$ (Aula 07), e a árvore o estima pela moda das respostas da folha.

2.2 Critério de divisão: impureza

A segunda adaptação responde à pergunta:

como uma árvore decide a melhor pergunta a fazer em cada nó,
quando o alvo é uma classe?

Em regressão, a Aula 05 escolhia a divisão de menor EQM, mas o EQM não faz sentido com Y qualitativo. A medida *óbvia*, a taxa de erro, é justamente a que não funciona, e veremos por quê depois de definir as duas que funcionam.

Uma divisão é boa quando produz regiões *puras*, isto é, regiões em que as observações de treino são, idealmente, todas da mesma classe. Para medir o quanto uma região R se afasta disso, usam-se as medidas de impureza

$$\text{Índice de Gini:} \quad G(R) = \sum_{c \in \mathcal{C}} \widehat{p}_{R,c}\,(1 - \widehat{p}_{R,c}), \tag{3}$$

$$\text{Entropia:} \quad D(R) = -\sum_{c \in \mathcal{C}} \widehat{p}_{R,c}\,\log_2 \widehat{p}_{R,c}, \tag{4}$$

com a convenção $0 \log_2 0 = 0$. A base do logaritmo só multiplica D por uma constante positiva e não altera nenhuma das comparações que faremos; a base 2 é a da Figura 2. A terceira medida é a taxa de erro de classificação,

$$E(R) = 1 - \max_{c \in \mathcal{C}} \widehat{p}_{R,c},$$

a proporção de observações de treino de R que a classe majoritária classifica errado.

Proposição 2.1. *As medidas $G(R)$ e $D(R)$ se anulam se e somente se R é pura, isto é, se $\widehat{p}_{R,c} = 1$ para alguma classe c. Além disso, $G(R) \leq 1 - 1/|\mathcal{C}|$ e $D(R) \leq \log_2 |\mathcal{C}|$, com igualdade, nos dois casos, se e somente se as classes estão equilibradas, isto é, se $\widehat{p}_{R,c} = 1/|\mathcal{C}|$ para toda classe c.*

Demonstração. Como $0 \le \widehat{p}_{R,c} \le 1$, cada parcela $\widehat{p}_{R,c}(1-\widehat{p}_{R,c})$ e cada parcela $-\widehat{p}_{R,c}\log_2 \widehat{p}_{R,c}$ é não negativa, e se anula se e somente se $\widehat{p}_{R,c} \in \{0,1\}$. Como as proporções somam 1, estarem todas em $\{0,1\}$ equivale a uma delas valer 1, o que prova a primeira afirmação.

Para o máximo de G, note que $G(R) = \sum_c \widehat{p}_{R,c} - \sum_c \widehat{p}^{\,2}_{R,c} = 1 - \sum_c \widehat{p}^{\,2}_{R,c}$. Pela desigualdade de Cauchy–Schwarz,

$$1 = \Big(\sum_{c\in\mathcal{C}} \widehat{p}_{R,c}\cdot 1\Big)^2 \le |\mathcal{C}| \sum_{c\in\mathcal{C}} \widehat{p}^{\,2}_{R,c},$$

com igualdade se e somente se as proporções são todas iguais; logo $G(R) \le 1 - 1/|\mathcal{C}|$, com igualdade exatamente nesse caso. Para o máximo de D, seja $\mathcal{C}_+$ o conjunto das classes com $\widehat{p}_{R,c} > 0$. Pela desigualdade de Jensen aplicada à função côncava $\log_2$, com os pesos $\widehat{p}_{R,c}$,

$$D(R) = \sum_{c\in\mathcal{C}_+} \widehat{p}_{R,c}\log_2 \frac{1}{\widehat{p}_{R,c}} \le \log_2 \sum_{c\in\mathcal{C}_+} \widehat{p}_{R,c}\,\frac{1}{\widehat{p}_{R,c}} = \log_2 |\mathcal{C}_+| \le \log_2 |\mathcal{C}|\,.$$

Como $\log_2$ é estritamente côncava, a primeira desigualdade vale com igualdade se e somente se $\widehat{p}_{R,c}$ é constante em $\mathcal{C}_+$, e a segunda, se e somente se $\mathcal{C}_+ = \mathcal{C}$; as duas juntas equivalem a $\widehat{p}_{R,c} = 1/|\mathcal{C}|$ para toda classe c. □

Seja I uma das medidas G ou D. Quando uma região R, com n_R observações de treino, é dividida em $R_1 = \{\boldsymbol{x} \in R : x_j < t\}$ e $R_2 = \{\boldsymbol{x} \in R : x_j \ge t\}$, com n_1 e n_2 observações ($n_1 + n_2 = n_R$), a impureza depois da divisão é a média das impurezas das duas regiões ponderada pelo tamanho delas, e a redução de impureza é

$$\Delta I = I(R) - \Big[\frac{n_1}{n_R}\,I(R_1) + \frac{n_2}{n_R}\,I(R_2)\Big].$$

A cada passo, escolhem-se a covariável x_j e o corte t que maximizam ΔI. Como $I(R)$ e n_R não dependem da divisão, isso equivale a minimizar $n_1 I(R_1) + n_2 I(R_2)$, o análogo da soma de quadrados minimizada na Aula 05: lá, a soma de quadrados de R_m é n_m vezes o EQM de R_m, de modo que cada região também pesa pelo seu número de observações.

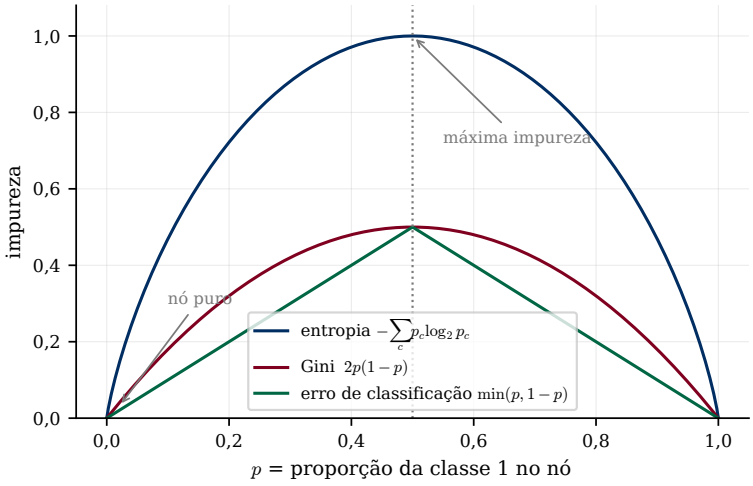


Figura 2: As três medidas num nó com duas classes, em função da proporção p da classe 1: o Gini é $2p(1-p)$, a entropia é $-p\log_2 p - (1-p)\log_2(1-p)$ e o erro de classificação é $\min(p, 1-p)$. As três se anulam nos extremos, onde o nó é puro, e são máximas em $p = 1/2$. A diferença que importa está na forma: Gini e entropia são estritamente côncavas e suaves, enquanto o erro de classificação é formado por dois segmentos de reta, com um bico em $p = 1/2$ e derivada constante de cada lado.

Ideia central: Por que não usar a taxa de erro para dividir?

No caso de duas classes, a taxa de erro de um nó com proporção p da classe 1 é $\min(p, 1-p)$, a curva verde da Figura 2, que é linear em cada uma das metades $[0, 1/2]$ e $[1/2, 1]$. Isso tem uma consequência séria. Considere um nó com 400 observações e $p = 0{,}75$, e uma divisão que produza dois filhos de 200 observações, um com $p = 0{,}50$ e outro com $p = 1{,}00$. O erro do pai é 0,25, e o erro ponderado dos filhos é $\frac{1}{2}(0{,}50) + \frac{1}{2}(0) = 0{,}25$: a redução é zero, embora um dos filhos seja puro, o que é claramente um progresso.
Não é uma coincidência do exemplo. Se um nó com n observações e proporção p é dividido em filhos com n_1 e n_2 observações e proporções p_1 e p_2, então $p = (n_1 p_1 + n_2 p_2)/n$, porque as observações da classe 1 do nó são as dos dois filhos somadas. Se a classe majoritária é a mesma nos dois filhos, p_1 e p_2 estão na mesma metade de $[0, 1]$, onde o erro é linear, e a média ponderada dos erros dos filhos é o erro do pai: a redução é zero. Gini e entropia, por serem estritamente côncavas, registram qualquer ganho de pureza: a média ponderada das impurezas dos filhos é estritamente menor que a do pai sempre que $p_1 \neq p_2$. No exemplo, o Gini cai de $2(0{,}75)(0{,}25) = 0{,}375$ para $\frac{1}{2} \cdot 2(0{,}50)(0{,}50) + \frac{1}{2} \cdot 0 = 0{,}250$. A taxa de erro continua útil na *poda*, onde o que interessa é justamente o desempenho de classificação.

Exemplo 2.2 (Escolha de divisão pelo Gini)**.** O [AME] considera dez hospitais e quer predizer se um hospital tem tomógrafo a partir de duas covariáveis binárias: ter especialidade em cardiologia e ter mais de 100 leitos. A tabela mostra, para cada uma das duas divisões possíveis da raiz, o número de hospitais em cada região, quantos deles têm tomógrafo e o Gini $2\widehat{p}(1-\widehat{p})$ da região, com $\widehat{p}$ a proporção de hospitais com tomógrafo.

divisão	região	hospitais	com tomógrafo	Gini
cardiologia	sim	4	2	$2 \cdot \frac{2}{4} \cdot \frac{2}{4} = \frac{1}{2}$
	não	6	4	$2 \cdot \frac{4}{6} \cdot \frac{2}{6} = \frac{4}{9}$
mais de 100 leitos	sim	6	5	$2 \cdot \frac{5}{6} \cdot \frac{1}{6} = \frac{5}{18}$
	não	4	1	$2 \cdot \frac{1}{4} \cdot \frac{3}{4} = \frac{3}{8}$

O Gini ponderado da divisão por cardiologia é $\frac{4}{10} \cdot \frac{1}{2} + \frac{6}{10} \cdot \frac{4}{9} = \frac{7}{15} \approx 0{,}467$, e o da divisão por leitos é $\frac{6}{10} \cdot \frac{5}{18} + \frac{4}{10} \cdot \frac{3}{8} = \frac{19}{60} \approx 0{,}317$. A divisão por leitos deixa as regiões mais puras e é a escolhida. O [AME] chega a 0,472 e 0,326 porque soma $\widehat{p}(1-\widehat{p})$ nas duas regiões sem ponderar pelo tamanho delas; a ordem entre as divisões, e portanto a escolha, é a mesma.

Observação 2.3. Gini e entropia quase sempre escolhem as mesmas divisões. As duas curvas da Figura 2 têm quase a mesma forma: a menos de um fator de escala, que não altera o $\arg\min$, elas quase coincidem, e por isso o $\arg\min$ sobre as divisões candidatas raramente muda de uma medida para a outra. Não vale a pena, portanto, incluir essa escolha numa busca por validação cruzada; é melhor gastar o orçamento no α da poda ou na profundidade da árvore.

A construção segue as duas etapas da Aula 05: *cresce-se* uma árvore grande, dividindo as regiões pelo critério acima, e depois ela é *podada* por custo–complexidade, com α escolhido por validação cruzada. Valem também as mesmas vantagens, que são a interpretabilidade, o tratamento direto de covariáveis categóricas, a seleção automática de covariáveis e a captura de interações, e a mesma desvantagem, os cortes perpendiculares aos eixos.

3 *Ensembles* para classificação

As formas de agregar árvores também valem em classificação; o que muda é que cada árvore agregada é agora uma árvore de classificação.

Bagging / Florestas
Ajustam-se B árvores, cada uma numa amostra *bootstrap* do treino, e as predições são agregadas pelo *voto da maioria*. Pode-se também tomar a média das B estimativas de $\mathbb{P}(Y = c \mid \boldsymbol{x})$ e classificar pela maior; em geral isso é melhor, porque preserva a informação sobre a confiança de cada árvore, que o voto descarta. As florestas aleatórias diminuem a correlação entre as árvores sorteando, em cada nó, m das p covariáveis como candidatas à divisão; em classificação, a regra empírica é $m \approx \sqrt{p}$, mais agressiva que o $p/3$ usado em regressão. Aumentar B não leva a superajuste, e o ajuste fornece, sem custo adicional, a estimativa do risco pelas observações deixadas fora de cada amostra *bootstrap* (OOB, do inglês *out-of-bag*) e medidas de importância das covariáveis.

Boosting As árvores são ajustadas em sequência. A variante clássica em classificação é o AdaBoost: a cada rodada, as observações são reponderadas, com mais peso para as que estão sendo classificadas errado, e o classificador final é um voto ponderado dos aprendizes fracos, as árvores pequenas ajustadas em cada rodada. Um B grande pode levar a superajuste, o que se evita com parada antecipada (*early stopping*); o XGBoost é a implementação de referência.

Observação 3.1. Codifique as classes por $y \in \{-1, +1\}$ e escreva o classificador final do AdaBoost como o sinal de $f(\boldsymbol{x}) = \sum_{b=1}^{B} \alpha_b \, g_b(\boldsymbol{x})$, em que $g_b(\boldsymbol{x}) \in \{-1, +1\}$ é a árvore ajustada na rodada b e $\alpha_b > 0$ é o seu peso no voto. Embora tenha sido proposto por outro caminho (Freund e Schapire, 1995), o AdaBoost equivale a construir f por etapas, um termo de cada vez, minimizando a *perda exponencial* $e^{-y\,f(\boldsymbol{x})}$ (Friedman, Hastie e Tibshirani, 2000). Essa perda depende da observação apenas pelo produto $y\,f(\boldsymbol{x})$, que é positivo quando a classificação está certa, e cresce exponencialmente quando ele é negativo: um ponto mal classificado por larga diferença pesa muito mais do que na perda 0–1, que vale 1 para qualquer erro. Isso explica a conhecida sensibilidade do AdaBoost a rótulos errados.

4 Comparando os classificadores do curso

A tabela resume os classificadores vistos no curso.

Método	**Fronteira**	**Interpretab.**	**Observações**
Logística	linear (no *log-odds*)	alta (coefs.)	dá probabilidades; robusta
LDA / QDA	linear / quadrática	média	ótimos sob gaussianidade
Bayes ingênuo	depende	média	forte com texto; com correlação, probabilidades extremas
KNN	muito flexível, local	baixa	sensível a escala e dimensão
Árvore	“escada” (eixos)	**altíssima**	instável sozinha
Florestas / Boosting	muito flexível	baixa	topo de desempenho em dados tabulares
SVM (kernel)	linear ou não linear	baixa	ótima com classes separadas

Ideia central

Nenhum método é melhor que os outros em todos os problemas; é o que se costuma resumir na expressão "não existe almoço grátis". A escolha depende da estrutura dos dados e do objetivo da análise, e quatro perguntas resolvem a maioria dos casos:

1. Preciso de boas estimativas de $\mathbb{P}(Y = 1 \mid \boldsymbol{x})$, por exemplo para usar o corte ótimo da Aula 08? Se sim, prefira a logística; se não, qualquer um serve.
2. Preciso explicar a decisão a alguém? Se sim, use uma árvore ou a logística.
3. Há muitas covariáveis irrelevantes? Então evite o KNN e a SVM com *kernel* radial, que somam todas as coordenadas na distância, e prefira a logística com penalização Lasso, as florestas ou o *boosting*.
4. Os dados são tabulares e o objetivo é acertar? Comece pelo *boosting* de árvores, que costuma ter o melhor desempenho, e use os outros como referência.

Em qualquer caso, compare os candidatos por validação cruzada, com a métrica adequada ao problema.

Atenção: o que a tabela não mostra: probabilidade não é escore

A primeira das quatro perguntas, sobre as probabilidades, parece uma preferência de estilo, mas é uma restrição. A §7 da `Aula prática 10` compara os sete métodos numa base em que a classe positiva é rara (10% das observações) e mede duas coisas que vale guardar.
A acurácia deixa de distinguir os métodos. Ela varia de 0,8989 a 0,9072 entre os sete, uma faixa de menos de um ponto percentual, e quatro deles empatam exatamente em 0,8989, a acurácia de quem responde "não" para todos, porque nunca preveem a classe positiva. Na mesma tabela, a AUC vai de 0,554, perto do sorteio, a 0,834. Com uma classe rara, a acurácia é dominada pela classe majoritária e não mede o que interessa.
O corte por custo pode não separar ninguém. Para um falso negativo que custa vinte falsos positivos, o corte ótimo da Aula 08 é $\ell_1/(\ell_0 + \ell_1) = 1/21 \approx 0{,}0476$. Com ele, a árvore podada e o AdaBoost mandam investigar todos os clientes, porque as probabilidades que eles produzem quase nunca ficam abaixo de 0,05. A cada mil clientes, entre os quais há 101 positivos, a logística manda investigar 410 e encontra 82, e a SVM manda 493 e encontra 89.
O corte $\ell_1/(\ell_0+\ell_1)$ é ótimo para as probabilidades verdadeiras (Proposição 3.1 da Aula 08). Aplicado às estimativas de um modelo, ele herda os erros delas, e só faz sentido com um modelo que estime bem $\mathbb{P}(Y = 1 \mid \boldsymbol{x})$.

Resumo

- KNN (1): voto da maioria entre os k vizinhos; é *plug-in*, com $\widehat{\mathbb{P}}(Y = c \mid \boldsymbol{x})$ igual à proporção de vizinhos da classe c. Com $k = 1$, a acurácia de treino é 100%, e a de teste é a pior das três da Figura 1.
- Árvore de classificação (2): prediz a moda da folha e escolhe as divisões minimizando a impureza ponderada, medida pelo Gini (3) ou pela entropia (4).
- A taxa de erro não serve para dividir, porque é linear por partes e registra redução zero em divisões que aumentam a pureza (Figura 2); serve para podar.
- Os *ensembles* valem em classificação: florestas com $m \approx \sqrt{p}$ e o AdaBoost, que equivale a *boosting* com perda exponencial.
- Nenhum método é melhor em todos os problemas: escolha pela estrutura dos dados e pelo objetivo, e compare por validação cruzada com a métrica adequada (Aula 08).

Leitura recomendada. [AME] §8.3 (árvores de classificação, com o exemplo do tomógrafo usado aqui), §8.4 e §8.5 (*bagging*, florestas e *boosting* em classificação) e §8.6 (KNN). [ISLP] §4.7.6 (KNN) e Capítulo 8, em especial o §8.1.2, que trata das árvores de classificação e dos critérios de impureza.