

Aula 10 — KNN e Árvores de Classificação

Curso de Aprendizado de Máquina — UFF

Prof. Gabriel Sanfins

Leitura recomendada: AME §8.3–8.6; ISLP §4.7.6 e cap. 8

O que você vai aprender

Ao final desta aula você deve ser capaz de:

- adaptar o KNN da regressão para classificação e reconhecê-lo como classificador *plug-in*;
- construir uma **árvore de classificação**, predizendo pela moda da folha;
- definir **Gini** e **entropia** como medidas de impureza e explicar por que não se usa a taxa de erro para dividir;
- transferir *bagging*, florestas e *boosting* para classificação;
- comparar todos os classificadores do curso e escolher segundo a estrutura dos dados e o objetivo.

Esta é a última aula do Bloco II, e ela fecha um ciclo: praticamente tudo aqui é uma tradução do Bloco I, com a média virando *moda* e o EQM virando *impureza*. Comece pela pergunta:

*como uma árvore decide a melhor pergunta a fazer em cada nó,
quando o alvo é uma classe?*

A resposta ocupa a Seção 2.2, e o mais interessante nela é que a medida *óbvia* — a taxa de erro — é justamente a que não funciona.

1 KNN para classificação

Adaptação direta da regressão KNN (Aula 04): para classificar $\mathbf{x}$, olhe seus k vizinhos mais próximos e tome a **classe mais frequente** (voto da maioria):

$$\hat{g}(\mathbf{x}) = \text{moda}\{Y_i : i \in \mathcal{N}_{\mathbf{x}}\}. \quad (1)$$

Equivalentemente, é um classificador *plug-in* (Aula 07): estima-se

$$\hat{\mathbb{P}}(Y = c \mid \mathbf{x}) = \frac{1}{k} \sum_{i \in \mathcal{N}_{\mathbf{x}}} \mathbf{1}\{Y_i = c\}$$

(a proporção de vizinhos da classe c) e toma-se o $\arg \max_c$. Essa estimativa está, por construção, em $[0, 1]$.

Ideia central

A acurácia de treino de 1,000 com $k = 1$ é o exemplo mais limpo de todo o curso do que a Aula 01 dizia: o erro de treino é um estimador *otimista* do risco, e seu otimismo cresce com a flexibilidade. Aqui ele não é só otimista — é *perfeito*, e o modelo é o pior dos três. Se alguém lhe mostrar um classificador com 100% de acerto, a primeira pergunta é “em qual conjunto?”.




Figura 1: Fronteiras de decisão do KNN com $n = 300$ pontos de treino, avaliadas em 10 000 observações novas. Com $k = 1$ a fronteira é rendilhada e cria ilhas em torno de observações isoladas: a acurácia de treino é **exatamente** 1,000 — cada ponto é seu próprio vizinho mais próximo — e a de teste é a pior das três, 0,826. Com $k = 15$ a fronteira suaviza e o teste sobe para 0,888; com $k = 120$ ela fica quase reta e o teste é praticamente igual, 0,889. Compare com a Figura 1 da Aula 04: é o mesmo botão, com a mesma leitura invertida (k pequeno = flexível).

Atenção

Valem os mesmos cuidados da Aula 04: *padronize* as covariáveis (KNN usa distância) e lembre da *maldição da dimensionalidade* — KNN não seleciona variáveis e degrada com muitas covariáveis irrelevantes. Em binário, use k *ímpar* para evitar empates.

2 Árvores de classificação

São o análogo das árvores de regressão (Aula 05): partição recursiva do espaço de covariáveis em regiões $R_1, \dots, R_J$. Duas adaptações:

2.1 Predição: a moda

Numa folha R_k , prediz-se a **classe majoritária** (em vez da média):

$$\hat{g}(\mathbf{x}) = \text{moda}\{Y_i : \mathbf{X}_i \in R_k\}, \quad \mathbf{x} \in R_k, \quad (2)$$

e $\hat{\mathbb{P}}(Y = c | \mathbf{x}) = \hat{p}_{R_k, c}$, a proporção da classe c na folha. É a substituição que o Teorema de Bayes da Aula 07 previa: em regressão o alvo era a média condicional, em classificação é a moda condicional.

2.2 Critério de divisão: impureza

O EQM não faz sentido com Y qualitativo. Em cada região R , seja $\hat{p}_{R, c}$ a proporção da classe c . Buscam-se divisões que tornem as folhas **puras** (idealmente, uma só classe por folha). Mede-se a impureza por:

$$\text{Índice de Gini: } G(R) = \sum_{c \in \mathcal{C}} \hat{p}_{R, c} (1 - \hat{p}_{R, c}), \quad (3)$$

$$\text{Entropia: } D(R) = - \sum_{c \in \mathcal{C}} \hat{p}_{R, c} \log \hat{p}_{R, c}. \quad (4)$$

Ambas são *mínimas* (zero) quando a folha é pura (algum $\hat{p}_{R, c} = 1$) e *máximas* quando as classes estão equilibradas. A cada passo escolhe-se a divisão que mais reduz a impureza (ponderada pelo tamanho das folhas).




Figura 2: As três medidas num nó binário, em função da proporção p da classe 1. Todas zeram nos extremos (nó puro) e são máximas em $p = 1/2$. A diferença que importa está no *formato*: Gini e entropia são estritamente côncavas e suaves, enquanto o erro de classificação é feito de dois segmentos de reta — tem um bico em $p = 1/2$ e derivada constante nos dois lados.

Ideia central: Por que não usar a taxa de erro para dividir?

Olhe a curva verde da Figura 2: ela é *linear* em cada metade. Isso tem uma consequência devastadora. Suponha um nó com 400 observações, $p = 0,75$, e uma divisão que produza duas folhas de 200 cada, uma com $p = 0,50$ e outra com $p = 1,00$. O erro do pai é 0,25; o erro ponderado dos filhos é $\frac{1}{2}(0,50) + \frac{1}{2}(0,00) = 0,25$. **Redução zero** — e no entanto uma das folhas ficou *pura*, o que é claramente um progresso. Por linearidade, isso acontece sempre que a classe majoritária não muda. Gini e entropia, sendo estritamente côncavas, registram qualquer ganho de pureza: no mesmo exemplo o Gini cai de 0,375 para 0,250. A taxa de erro continua útil na *poda* final, onde o que interessa é justamente o desempenho de classificação.

Exemplo 2.1 (Escolha de divisão por Gini). Para decidir entre dividir por “Cardiologia” ou por “> 100 leitos” (predição: hospital tem tomógrafo), calcula-se o Gini ponderado de cada partição e escolhe-se a de *menor* valor (maior pureza). No exemplo do [AME], $\text{Gini}(\text{Leitos}) \approx 0,326 < \text{Gini}(\text{Cardiologia}) \approx 0,472$: divide-se por leitos.

Observação 2.2. Gini e entropia quase sempre escolhem as mesmas divisões — a diferença numérica entre as duas curvas da Figura 2 é pequena, e o *argmin* sobre as divisões candidatas raramente muda. Não vale a pena colocar essa escolha numa busca por validação cruzada; gaste o orçamento no α de poda ou na profundidade.

A construção segue as duas etapas da Aula 05: *crece-se* uma árvore grande e depois *poda-se* por custo-complexidade (α por CV). As mesmas vantagens valem: interpretabilidade, categóricas nativas, seleção automática de variáveis e captura de interações — e a mesma desvantagem, os cortes perpendiculares aos eixos.

3 Ensembles para classificação

Toda a Aula 05 se transfere; as árvores individuais agora classificam:

Bagging / Florestas

treina B árvores em amostras bootstrap e agrega por **voto da maioria** (ou

média das probabilidades — em geral melhor, porque preserva alguma informação sobre a confiança). Florestas descorrelacionam sorteando m variáveis por nó; regra empírica em classificação: $m \approx \sqrt{p}$, mais agressiva que o $p/3$ da regressão. Robustas a B ; OOB e importância de variáveis “de graça”.

Boosting ajuste sequencial. A variante clássica para classificação é o **AdaBoost**: a cada rodada, reponderam-se as observações dando mais peso às mal classificadas, e o classificador final é um voto ponderado dos aprendizes fracos. Como em regressão, B grande pode superajustar (use *early stopping*); XGBoost é a implementação de referência.

Observação 3.1. Vale registrar a ponte teórica: o AdaBoost, apesar de ter sido inventado por outro caminho, equivale a fazer *boosting* com a **perda exponencial** $e^{-y g(x)}$ — mais uma perda de margem, no mesmo eixo horizontal da Figura 4 da Aula 09. Vista assim, ela é ainda mais agressiva que a *hinge* com os pontos mal classificados, o que explica a sensibilidade conhecida do AdaBoost a rótulos errados.

4 Comparando os classificadores do curso

Método	Fronteira	Interpretab.	Observações
Logística	linear (no <i>log-odds</i>)	alta (coefs.)	dá probabilidades; robusta
LDA / QDA	linear / quadrática	média	ótimos sob gaussianidade
Bayes ingênuo	depende	média	forte com texto; descalibra se há correlação
KNN	muito flexível, local	baixa	sensível a escala e dimensão
Árvore	“escada” (eixos)	altíssima	instável sozinha
Florestas / Boosting	muito flexível	baixa	topo de desempenho em dados tabulares
SVM (kernel)	linear ou não linear	baixa	ótima com classes separadas

Ideia central

Não há método universalmente melhor (“não existe almoço grátis”). A escolha depende da *estrutura* dos dados e do *objetivo*. Quatro perguntas que resolvem a maioria dos casos:

1. **Preciso de probabilidades calibradas?** Se sim, logística; se não, qualquer um (Aula 08).
2. **Preciso explicar a decisão a alguém?** Se sim, árvore ou logística.
3. **Há muitas covariáveis irrelevantes?** Então evite KNN e SVM-RBF, que somam todas as coordenadas na distância; prefira Lasso, florestas ou *boosting*.
4. **Os dados são tabulares e o objetivo é acertar?** Comece por *boosting* de árvores — é o que costuma ganhar — e use os outros como referência.

E, em qualquer caso, compare os candidatos por validação cruzada com a métrica adequada ao problema.

Atenção: o que a tabela acima não mostra: probabilidade não é escore

A primeira pergunta da lista — “*preciso de probabilidades calibradas?*” — parece uma preferência de estilo, e é uma restrição dura. A §7 da **Aula prática 11** compara os sete métodos numa base de classe rara (10% de positivos) e mede duas coisas que valem ser guardadas.

A acurácia deixa de distinguir os métodos. Ela varia de 0,8989 a 0,9072 entre os sete — menos de um ponto — e *quatro* deles empatam exatamente no 0,8989 de quem responde “não” para todo mundo, porque nunca preveem positivo. A precisão média (AP) varia de 0,119 a 0,453 na mesma tabela, por um fator de quase quatro. Com classe rara, a acurácia não erra por pouco: ela não mede.

E o corte por custo pode não cortar nada. Aplicando o corte ótimo da Aula 08 para um falso negativo que custa vinte falsos positivos — 0,0476 — a árvore podada e o AdaBoost mandam investigar **todos os mil por mil**. As probabilidades que eles produzem quase nunca descem abaixo de 0,05, então o corte não separa ninguém. A logística manda 410 e encontra 82 dos 101 positivos; o SVM manda 493 e encontra 89.

A fórmula $c_{FP}/(c_{FP} + c_{FN})$ é ótima **para probabilidade honesta**. Antes de usá-la, confira a calibração do modelo (Aula 08) — ou calibre-o, que é barato.

5 Prática em Python

```

1 from sklearn.neighbors import KNeighborsClassifier
2 from sklearn.tree import DecisionTreeClassifier, plot_tree
3 from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier
4
5 # KNN: k impar, padronizado dentro do pipeline (Aula 06)
6 knn = make_pipeline(StandardScaler(), KNeighborsClassifier(n_neighbors=11))
7
8 # Arvore: criterion "gini" (padrao) ou "entropy" -- na pratica, tanto faz
9 arv = DecisionTreeClassifier(criterion="gini", ccp_alpha=0.01).fit(X_tr, y_tr)
10 plot_tree(arv, feature_names=nomes, class_names=classes, filled=True)
11
12 # Floresta: m = sqrt(d) e o padrao em classificacao
13 rf = RandomForestClassifier(n_estimators=500, max_features="sqrt",
14                             oob_score=True, random_state=0).fit(X_tr, y_tr)

```

Repare que `max_features="sqrt"` já é o padrão do `RandomForestClassifier`, enquanto no `RandomForestRegressor` o padrão é usar todas as variáveis — isto é, *bagging*, não floresta. Se você quer uma floresta em regressão, precisa dizer.

Os notebooks **Aula prática 10, Comparação entre classificadores paramétricos e Exemplo - KNN e árvores em dados artificiais** desenham as fronteiras de decisão de todos esses métodos lado a lado, nos mesmos dados. É o melhor jeito de fixar a intuição de “flexível × rígido” que percorreu o curso inteiro — vale rodar os dois.

Resumo

- **KNN (1)**: voto da maioria entre os k vizinhos; é *plug-in* com $\hat{\mathbb{P}}$ igual à proporção local. Com $k = 1$ o treino dá 100% e o teste dá o pior resultado (Fig. 1).
- **Árvore de classificação (2)**: prediz a moda da folha; divide minimizando **Gini (3)** ou **entropia (4)**.

- A *taxa de erro* não serve para dividir porque é linear por partes e registra redução zero em divisões que aumentam a pureza (Fig. 2); serve para podar.
- *Ensembles* transferem-se inteiros: florestas com $m \approx \sqrt{p}$, AdaBoost como *boosting* com perda exponencial.
- Não há método universalmente melhor: escolha pela estrutura dos dados e pelo objetivo, e compare por validação cruzada com a métrica certa (Aula 08).

Leitura recomendada. [AME] §8.3 (árvores de classificação, com o exemplo do tomógrafo reproduzido aqui), §8.4–8.5 (*bagging*, florestas e *boosting* em classificação) e §8.6 (KNN). [ISLP] §4.7.6 (KNN) e Capítulo 8 — §8.1.2 trata especificamente das árvores de classificação e dos critérios de impureza, com a versão deles da nossa Figura 2.

Para praticar. `Lista teorica 10.pdf` (teórica, com gabarito) e `Lista prática 10.ipynb` (prática, para completar as lacunas), nesta mesma pasta.